Lucas Barboza Ribeiro Claro

Comparação de desempenho dos algoritmos KNN e Bayes Ingênuo para localização interna com *fingerprinting*

São Paulo - Brasil

2022

Lucas Barboza Ribeiro Claro

Comparação de desempenho dos algoritmos KNN e Bayes Ingênuo para localização interna com *fingerprinting*

Monografia apresentada na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro

Bacharelado em Ciência da Computação

Orientador: Fábio Henrique Abenza Freire

São Paulo - Brasil

2022

Resumo

Esse trabalho se propõe a comparar o desempenho de dois algoritmos de classificação que podem ser empregados no *fingerprinting*. Esse método de localização para ambientes fechados utiliza assianturas de redes sem fio do local para mapear o ambiente e poder determinar em qual dos locais mapeados o usuário se encontra. Os algoritmos que foram testados durante a etapa de determinação das posições são o KNN e o Bayes Ingênuo. Para isso se foi necessário criar uma ferramenta para a coleta de dados de redes sem fio de um ambiente. Obtidos os dados, foi possível analisar o desempenho dos algoritmos utlizando direrentes métricas de análise de modelos. Por fim, os dados foram comparados em função do crescimento do conjunto amostral.

Palavras-chaves: *fingerprinting*. localização. KNN. Bayes Ingênuo.

Abstract

This work proposes to compare the performance of two classification algorithms that can be used in fingerprinting. This indoor location method uses the location's wireless network signatures to map the environment and is able to to determine which of the mapped locations the user is in. The algorithms that were tested during the position determination phase are the KNN and the Naivr Bayes. To do this, it was necessary to create a tool to collect data from wireless networks in an environment. After obtaining the data, it was possible to analyze the performance of the algorithms using different metrics for model analysis. Finally, the data were compared as a function of the growth of the sample set.

Key-words: fingerprinting. localization. KNN. Nayve Bayes.

Lista de ilustrações

Figura 1 – Constelação GPS 16
Figura 2 – Método Angulação 17
Figura 3 – Método Trilateração 18
Figura 4 – Método Fingerprinting 19
Figura 5 – Algumas definições de IA 20
Figura 6 – Diferença Regressão e Classificação 23
Figura 7 – Exemplo de uma matriz de confusão binária e multiclasse 25
Figura 8 – Curva ROC e a área sob ela 28
Figura 9 – Curva ROC de com área próxima a 1 29
Figura 10 – Fluxo dos dados no projeto 32
Figura 11 – Exemplo de um registro do Firebase 33
Figura 12 – Telas do aplicativo de coleta de dados 34
Figura 13 – Mapa Acadêmico 1 - Térreo 35
Figura 14 – Mapa Acadêmico 1 - Mezanino 36
Figura 15 – Estrutura do Banco Relacional de Importação 37
Figura 16 – Comparação da acurácia dos modelos 42
Figura 17 – Distribuição das classes 53
Figura 18 – Matriz de confusão KNN com distância Euclidiana na Etapa 1 55
Figura 19 – Matriz de confusão KNN com distância Manhattan na Etapa 1 56
Figura 20 – Matriz de confusão Bayes Ingênuo na Etapa 1 56
Figura 21 – Matriz de confusão KNN com distância Euclidiana na Etapa 2 57
Figura 22 – Matriz de confusão KNN com distância Manhattan na Etapa 2 57
Figura 23 – Matriz de confusão Bayes Ingênuo na Etapa 2 58
Figura 24 – Matriz de confusão KNN com distância Euclidiana na Etapa 3 58
Figura 25 – Matriz de confusão KNN com distância Manhattan na Etapa 3 59
Figura 26 – Matriz de confusão Bayes Ingênuo na Etapa 3 59

Lista de abreviaturas e siglas

GPS	Sistema de posicionamento global
Apps	Aplicativos de celular
GNSS	Sistema de navegação por satélite
SPS	Serviço de posicionamento padrão
PPS	Serviço de posicionamento preciso
CA	*Coarse Acquisition* (Aquisição grosseira)
AOA	*Angle of Arrivel* (Ângulo de chegada)
RSS	*Received Signal Strength* (Força do sinal recebido)
TOA	*Time of Arrivel* (Tempo de chegada)
TDOA	*Time Difference of Arrivel* (Diferença do tempo de chegada)
IA	*Inteligência Artificial*
TP	Verdadeiros positivos.
TN	Verdadeiros negativos.
FP	Falsos positivos.
FN	Falsos negativos.

Sumário

1 INTRODUÇÃO . . . 13
1.1 Contexto . . . 13
1.2 Objetivos . . . 13
1.2.1 Objetivo Geral . . . 14
1.2.2 Objetivos Específicos . . . 14

2 REVISÃO BIBLIOGRÁFICA . . . 15
2.1 Sistemas de Posicionamento . . . 15
2.1.1 Localização Externa - GNSS . . . 15
2.1.2 Métodos de Localização Interna . . . 17
2.1.3 *Fingerprinting* . . . 18
2.2 Inteligência Artificial . . . 20
2.2.1 Aprendizagem de Máquina . . . 21
2.2.2 Classificação vs. Regressão . . . 22
2.2.2.1 *K-Nearest Neighbors* . . . 23
2.2.2.2 Bayes Ingênuo . . . 24
2.2.3 Métricas de avaliação . . . 24
2.2.3.1 Matriz de confusão . . . 25
2.2.3.2 Acurácia . . . 25
2.2.3.3 Precisão e Revocação . . . 26
2.2.3.4 Acurácia Balanceada . . . 26
2.2.3.5 *F1-score* . . . 27
2.2.3.6 Área ROC . . . 27
2.3 Trabalhos Relacionados . . . 28

3 DESENVOLVIMENTO . . . 31
3.1 Proposta do projeto . . . 31
3.2 Metodologia . . . 31
3.3 Coletor de Dados . . . 31
3.4 Coleta de Dados . . . 33
3.5 Testes . . . 34
3.6 Resultados . . . 36

4 CONCLUSÕES . . . 43
4.1 Trabalhos Futuros . . . 43

REFERÊNCIAS 45

APÊNDICES 49

APÊNDICE A – CONSULTA SQL PARA PIVOTAR OS DADOS NO BANCO RELACIONAL 51

APÊNDICE B – QUANTIDADE DE INSTÂNCIAS DE CADA CLASSE EM CADA ETAPA DE TESTES 53

APÊNDICE C – MATRIZES DE CONFUSÃO 55

1 Introdução

Este é um trabalho de conclusão de curso de graduação em Ciência da Computação, que aborda métodos existentes para localização em ambientes fechados, com enfoque no *fingerprinting* e os atuais usos dessa tecnologia. Para isso, foram realizados estudos que envolvem as áreas de redes, inteligência artificial e computação móvel.

O trabalho está dividido em: introdução, onde o assunto é contextualizado e os objetivos definidos; revisão bibliográfica, na qual consta a pesquisa realizada para fundamentar a análise feita dos algoritmos levantados; desenvolvimento, onde são detalhados os testes realizados com esses algoritmos; e, por fim, a conclusão do trabalho.

1.1 Contexto

Uma pesquisa da Cuponation (2021) apontou que a venda de smartphones cresceu 73% nos 6 anos anteriores a pesquisa, somando mais de 6 bilhões de aparelhos vendidos no mundo. Segundo G1 (2022), em 2021 o usuário no Brasil passou em média 5,4 horas por dia no celular e foi líder nesse ranking pelo segundo ano consecutivo. Em 2016, mais de meio trilhão das pesquisas submetidas ao Google.com foram realizadas a partir de um dispositivo móvel, entre elas quase um terço foram relacionadas à localização. E as pesquisas realizadas nos celulares sobre locais crescem 50% mais rápido que outros assuntos (AMIRIAN; BASIRI; MORLEY, 2016).

Porém, para estimar a localização do aparelho, os celulares utilizam principalmente o sinal do sistema de posicionamento global (GPS)[1], que não é suficiente para ser captado em ambientes fechados (SHALA; RODRIGUEZ, 2011). Aplicações de saúde, segurança e realidade aumentada, navegação e rastreio podem se beneficiar de um sistema de localização interna mais precisa. (GU et al., 2019)

1.2 Objetivos

Os objetivos deste trabalho estão divididos em objetivo geral, que se propoe a responder a questão de pesquisa, e objetivos específicos, que detalham os passos necessários para se atingir o objetivo geral.

[1] Sigla do inglês *Global Positioning System*

1.2.1 Objetivo Geral

Comparar diferentes algoritmos de classificação aplicados a uma técnica de localização de dispositivos móveis em ambientes fechados que utiliza o padrão dos sinais de pontos de acesso de redes sem fio para determinar uma posição.

1.2.2 Objetivos Específicos

1. Implementar um software para coleta de dados de localização no campus Santo Amaro do Centro Universitário Senac.

2. Coletar dados para uma amostra de treino e de teste destinados aos testes com os algoritmos.

3. Rodar o KNN e o Bayes Ingênuo com essas amostras para determinar o desempenho de ambos.

4. Comparar os resultados obtidos.

2 Revisão Bibliográfica

Nesse capítulo serão revisados os tópicos teóricos necessários para a realização dos objetivos propostos na Introdução. Primeiro, serão levantados métodos de posicionamento que existem atualmente. Em seguida, são apresentados conceitos de Inteligência Artificial necessários para alguns algoritmos de localização. Por fim, é apresentada a análise de trabalhos relacionados.

2.1 Sistemas de Posicionamento

Nessa seção, são levantados e discutidos métodos de posicionamento presentes no estado da arte para os espaços externo e o interno. Começando pelo método mais relevante para a localização externa, a localização via satélite. (AMIRIAN; BASIRI; MORLEY, 2016).

2.1.1 Localização Externa - GNSS

Um Sistema de navegação por satélite (GNSS)[1] é uma tecnologia que permite a localização de um dispositivo através de ondas de rádio. Entre os GNSS existentes é possível citar o Sistema de Posicionamento Global, criado pelo Departamento de Defesa dos Estados Unidos da America, que busca uma navegação precisa, em tempo real e em escala global. O projeto teve início em 1973 e chegou em funcionamento pleno em 1995 (MENDES, 2013). O uso civil dessa tecnologia foi liberado em 1980 pelo então presidente Ronald Reagan, mas até o ano 2000 um sistema chamado Disponibilidade Seletiva inseria erros pseudoaleatórios nos dados para restringir a precisão do GPS (CARVALHO; ARAÚJO, 2009).

O GPS é dividido em 3 segmentos: espacial, de controle e segmento de usuário. O espacial corresponde à constelação de 24 satélites em órbita distribuídos de forma que no mínimo 4 satélites estejam visíveis de qualquer ponto do globo, como mostra a Figura 1 (número mínimo de satélites necessários para se determinar uma posição (SILVA, 2019) apud (KAPLAN; HEGARTY, 2005)). O segmento de controle diz respeito às estações de controle em Terra que gerenciam os satélites, as órbitas e a sincronia dos relógios. A parte do usuário é o conjunto de equipamentos que captam o sinal dos satélites e realizam os cálculos que determinam uma posição (MENDES, 2013).

Segundo Mendes (2013), Carvalho e Araújo (2009) dois serviços são fornecidos pelo GPS, o *Standard Positioning Service* - SPS (Serviço de posicionamento padrão) e o

[1] Sigla do inglês *Global Navigation Satellite System*

Precision Positioning Service – PPS (Serviço de posicionamento preciso). O usuário comum só têm acesso ao SPS, onde os dados são enviados segundo o código *Coarse Acquisition* (CA). Esse código contém as informações necessárias para um receptor de GPS distinguir os diferentes satélites e as medidas de distância entre eles. A incerteza da posição obtida pelo SPS é menor que 9m no plano horizontal e 15m no plano vertical.

Figura 1 – Constelação GPS

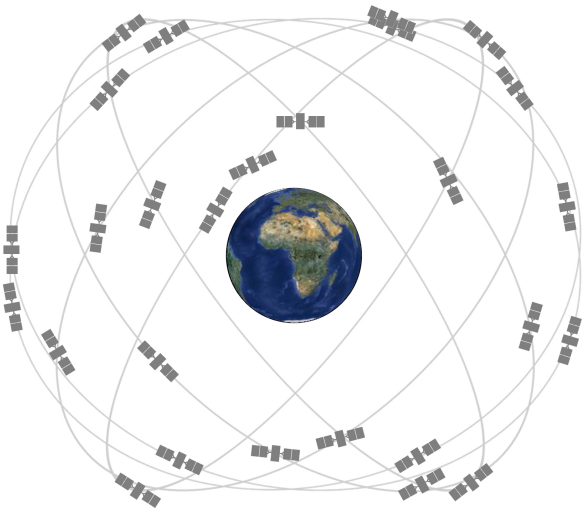

Fonte: GPS.gov (2022)

As principais causas da imprecisão do GPS estão relacionadas a erros na órbita dos satélites, diferença entre os relógios do segmento espacial e o segmento de usuário, erros provocados por efeitos atmosféricos na propagação do sinal e pela rotação da Terra (CARVALHO; ARAÚJO, 2009). Dentro de um ambiente fechado, paredes e telhados pioram ainda mais a qualidade do sinal recebido por barrarem a linha de visão (SHALA; RODRIGUEZ, 2011).

Um outro sistema que coexiste com o GPS é o *Global Navigational Satellite System* (GLONASS), projeto que foi iniciado em 1976 pela antiga União Soviética. A primeira constelação de satélites data de 1995 e segue operacional até a data de escrita desse trabalho sob controle do governo russo. Seu funcionamento é semelhante ao GPS (EMBRAPA, 2018). Além desses dois, na data corrente também estão em operação ou desenvolvimento os sistemas: o Galileu (Europa), o *BeiDou* (China) e o QZSS (Japão) (VECTORNAV, 2022).

Tendo em vista que um GNSS não possui precisão o suficiente para operar em um ambiente fechado (SHALA; RODRIGUEZ, 2011), surge a necessidade de métodos próprios para esse cenário. No capítulo seguinte estão detalhados alguns métodos desenhados para ambientes internos.

2.1.2 Métodos de Localização Interna

Pu, Pu e Lee (2011) classificam em três os métodos para se estimar a localização de um objeto utilizando dispositivos de rede: angulação, lateração e proximidade.

A angulação é baseada em cálculos trigonométricos que usam o ângulo de chegada dos sinais (AOA - *Angle of Arrival*) como variáveis. Para isso, é preciso que pelo menos dois emissores estejam fixados no mesmo eixo vertical e dois no mesmo eixo horizontal, como mostra a Figura 2.

Figura 2 – Método Angulação

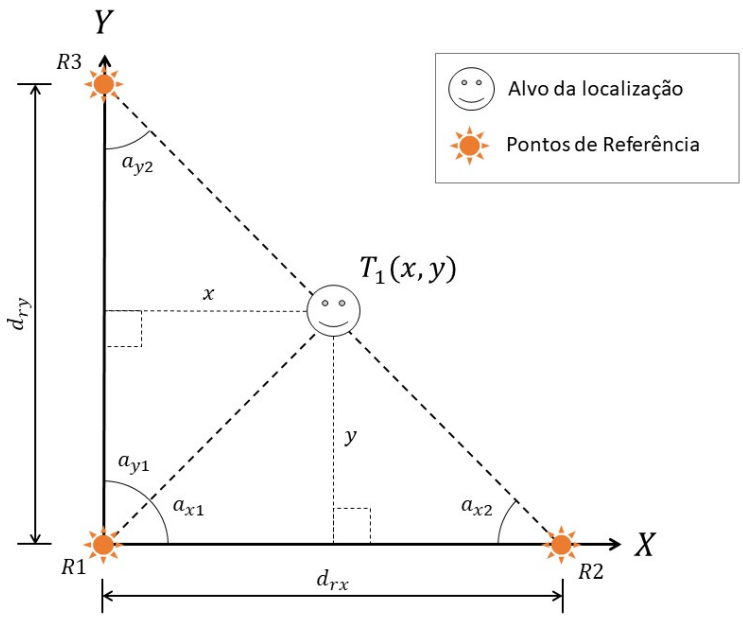

Adaptado de: Pu, Pu e Lee (2011)

A lateração calcula a posição do alvo utilizando a distância entre ele e pelo menos 3 pontos de referência como mostra a Figura 3. Para se obter essas distâncias é preciso ter a força do sinal recebido (RRS - *Received Signal Strength*) de cada Ponto de Acesso ou o tempo de viagem dos sinais como variável. O cálculo com a RSS é feito através da diferença entre a potência do sinal que é emitido e a potência do sinal recebido, já que todo sinal perde potência ao longo da distância percorrida. O cálculo com o tempo de viagem é baseado na diferença entre o momento de emissão do sinal e o momento que ele foi recebido (TOA - *Time of Arrival*), para isso é preciso que o os relógios de ambos os dispositivos estejam em sincronia ou que dois sinais com velocidades de propagação diferentes sejam enviados por cada dispositivo (TDOA - *Time Difference of Arrival*) (PU; PU; LEE, 2011).

O método por proximidade não define uma posição exata. Seu objetivo é definir uma entre determinadas posições simbólicas, tendo como dado qual o ponto de acesso

Figura 3 – Método Trilateração

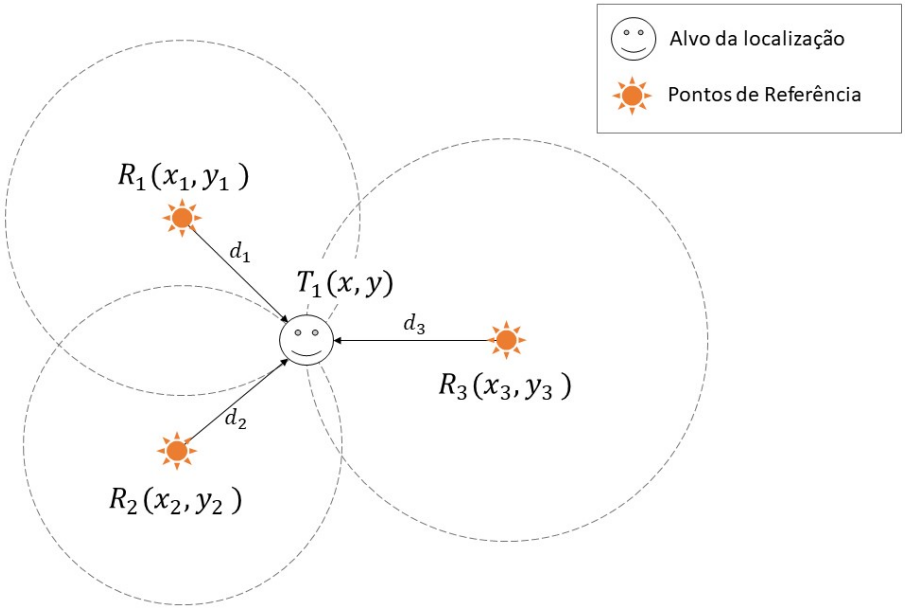

Adaptado de: Pu, Pu e Lee (2011)

mais próximo. Dessa forma, a precisão desse método depende da densidade de aparelhos emissores (FARID; NORDIN; ISMAIL, 2013).

As implementações baseadas nas medidas dos ângulos e atrasos dos sinais são mais complexas por dependerem de *hardwares* específicos para obtenção dos dados. A métrica mais fácil de ser lida é a potência do sinal, que pode ser obtida facilmente na maioria das redes sem fio, principalmente na rede 802.11 da IEEE (o WiFi) que informa em sua transmissão um indicador da potência do sinal (RSSI) (MAZUELAS et al., 2009). Entretanto o RSSI nem sempre é uma representação fiel do RSS e pode ter seu valor deslocado em relação ao valor verdadeiro como mostra Konings et al. (2017).

Bullmann et al. (2020) cita o *fingerprinting* como uma das possíveis formas de se contornar os erros causados pela variação do RSSI. Nesse método, tema da subseção seguinte, a geografia do ambiente não precisa ser levada em consideração.

2.1.3 *Fingerprinting*

O *fingerprinting* é uma técnica de localização que se ajusta ao ambiente em que é aplicada. Para isso, é necessária uma etapa anterior ao uso definitivo, onde o ambiente é mapeado. Essa etapa consiste em: armazenar dados de redes sem fio presentes no local e utilizar esses dados como assinatura dessa posição. Com essa assinatura, é possível futuramente descobrir se o usuário está próximo a essa posição (MACHAJ; BRIDA; PICHÉ, 2011).

Duas fases compõem esse método: mapeamento (ou calibração) e rastreio. Na primeira fase, é criado um mapa que associa posições à assinaturas dos sinais de rádio de cada ponto de acesso desse local. Os dados armazenados podem ser os mesmos que eram usados pelos métodos citados no capítulo anterior: RSS, AOA, TOA, TDOA (FARID; NORDIN; ISMAIL, 2013).

A segunda etapa do *fingerprinting* é a determinação de uma posição desconhecida a partir das informações obtidas no treinamento. Os dados de rede do local são coletados pelo dispositvo a ser localizado e comparados com os registros do mapa através de algum algoritmo de classificação, que vai definir qual das posições registradas no mapa o usuário se encontra. A Figura 4 exemplifica o funcionamento do *fingerprinting* usando como dado o RSS (ALTINTAS; SERIF, 2011). A parte (a) da figura mostra a coleta de dados do mapa. A parte (b) mostra um usuário sendo rastreado.

Figura 4 – Método Fingerprinting

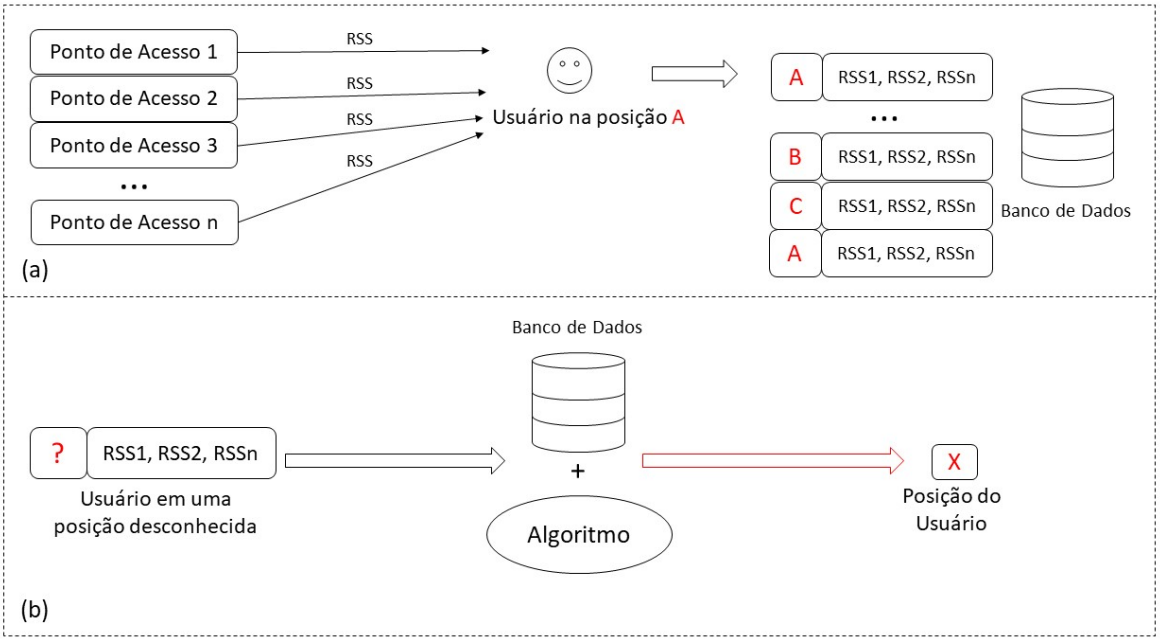

Adaptado de: Altintas e Serif (2011)

Um fator que pode afetar a operação do *fingerprinting* é o modelo do celular usado na calibração. Celulares de modelos distintos podem fazer a leitura do RSSI de formas diferentes (BULLMANN et al., 2020).

Diversas redes sem fio podem ser usadas no processo de mapeamento. O Wifi (protocolo de rede sem fio 802.11 definido pelo IEEE), por ser a mais encontrada atualmente, é a rede mais comum de ser usada em projetos de localização interna. Grande parte desses projetos utilizam o *fingerprinting* guardando o RSS, que é facilmente captado pela maioria dos dispositivos (MACHAJ; BRIDA; PICHÉ, 2011).

Na seção seguinte são descritos conceitos importantes de IA para os algoritmos de classificação que podem ser usados na segunda etapa do *fingerprinting*.

2.2 Inteligência Artificial

Norvig e Russell (2014) reúnem oito definições de Inteligência Artificial (IA) e mostram que, entre os autores do assunto, não há um consenso quanto a definição exata de uma IA. Na Figura 5, os autores separam as citações com dois eixos. O eixo horizontal divide as definições entre aquelas que se relacionam com o humano e aquelas que se relacionam com a racionalidade. O eixo vertical separa as designações entre as que se referem ao pensamento e as que se referem à ação. Esse desacordo quanto a definição de uma Inteligência Artificial se estende ao campo todo não havendo um consenso se um IA deve imitar o comportamento ou a forma de pensar do humano ou se ela deve ser construída visando uma racionalidade puramente voltada para a lógica ou para o desempenho.

Figura 5 – Algumas definições de IA

Pensando como um humano	**Pensando racionalmente**
"O novo e interessante esforço para fazer os computadores pensarem (...) *máquinas com mentes*, no sentido total e literal." (Haugeland, 1985) "[Automatização de] atividades que associamos ao pensamento humano, atividades como a tomada de decisões, a resolução de problemas, o aprendizado..." (Bellman, 1978)	"O estudo das faculdades mentais pelo uso de modelos computacionais." (Charniak e McDermott, 1985) "O estudo das computações que tornam possível perceber, raciocinar e agir." (Winston, 1992)
Agindo como seres humanos	**Agindo racionalmente**
"A arte de criar máquinas que executam funções que exigem inteligência quando executadas por pessoas." (Kurzweil, 1990) "O estudo de como os computadores podem fazer tarefas que hoje são melhor desempenhadas pelas pessoas." (Rich and Knight, 1991)	"Inteligência Computacional é o estudo do projeto de agentes inteligentes." (Poole *et al.*, 1998) "AI... está relacionada a um desempenho inteligente de artefatos." (Nilsson, 1998)

Fonte: Norvig e Russell (2014)

Uma forma de classificar uma inteligência artificial como inteligente é o teste de Turing criado por Alan Turing em 1950. O computador terá sucesso no teste se, após responder perguntas elaboradas por um interrogador humano, o humano não conseguir distinguir entre as respostas enviadas pelo computador e as respostas enviadas por outro humano. Esse teste exige da máquina as seguintes habilidades: processamento de linguagem natural, uma forma de armazenar seu conhecimento, raciocínio para usar as informações

armazenadas e responder as perguntas e uma forma de aprender, extrapolar e se adaptar a novas circunstâncias. E no caso do teste de Turing completo, onde a máquina deve interagir com o meio físico, também são exigidas as habilidades: visão computacional e robótica. Atualmente, o teste de Turing já não é mais o foco das pesquisa em Inteligência Artificial, mas essas seis disciplinas continuam presentes e são foco na maioria das pesquisas do assunto (MUELLER, 2008).

A partir dos anos 2000, o campo de Inteligência Artificial teve uma grande mudança quando o volume de dados disponíveis começou a crescer, chegando hoje a quase 100 zettabytes (DEPARTMENT, 2022). Norvig e Russell (2014) mostram a melhora de desempenho que tiveram os estudos em IA quando usavam um volume grande de dados, melhora essa muito mais significativa que a obtida por mudanças no algoritmo. Ou seja, os dados disponíveis para o treinamento de um sistema inteligente são essenciais. Na data de escrita desse trabalho, podemos encontrar IAs aplicada em diversas áreas como: direção autônoma, reconhecimento de voz, planejamento, jogos, detecção de *spam*, robótica, tradução, geração de textos e geração de imagens.

2.2.1 Aprendizagem de Máquina

Um tópico relevante no contexto das IAs é o aprendizado. Um programa aprende quando melhora seu desempenho após fazer observações do seu ambiente. Essa é uma capacidade importante por três motivos: o programador não tem como prever todos os cenários que o agente vai se encontrar, o programador não tem contole das mudanças que vão ocorrer no ambiente ao longo do tempo e alguns problemas são complexos demais para serem modelados para um programa (NORVIG; RUSSELL, 2014).

É possível classificar as formas de aprendizado em três tipos, diferenciando-os pelo tipo de retorno que o agente recebe.

- A **aprendizagem não supervisionada** é quando o modelo recebe um conjunto de entradas e cabe à ele encontrar padrões dentro desse conjunto. Nesse método a máquina opera sem nenhum tipo de *feedback*. Muito comum em problemas de agrupamento.

- Na **aprendizagem por reforço** a máquina vai receber um estímulo positivo ou negativo ao fim de uma atividade e cabe à ela deduzir quais de suas ações estão levando a esse estímulo. Durante o treinamento a inteligência vai calibrando seus parâmetros para maximizar a quantidade de reforços positivos.

- A **aprendizagem supervisionada** é quando o agente recebe pares de entrada e saída e ele desenvolve e aprimora uma função que mapeia a entrada para a saída,

podendo assim inferir uma saída para uma nova entrada. Muito comum em contextos de previsão.

Um problema comum que pode ocorrer durante o treinamento é o *overfitting*[2], quando a função gerada após o treino tem um ótimo desempenho no conjunto de testes, mas não é capaz de extrapolar para novos casos. Isso pode acontecer quando o conjunto de testes é pequeno, possui muito ruído, quando os dados estão enviesados ou são complexos demais (YING, 2019).

Determinar a posição de um usuário através da leitura de dados de RSS é um comportamento semelhante ao de algoritmos de aprendizagem supervisionada (ALTINTAS; SERIF, 2011). O *fingerprinting* em específico utiliza algoritmos de previsão de aprendizagem supervisionada. As formas mais comuns de previsão são classificação e regressão.

2.2.2 Classificação vs. Regressão

Algoritmos de aprendizagem supervisionada são amplamente usados em contextos de previsão. Essa previsão pode ser uma regressão ou uma classificação. Uma regressão busca criar uma função que retorna um valor aproximado num eixo y tendo como entrada um ou mais valores de x. Essa função é estimada com base em valores históricos (NASTESKI, 2017).

A classificação gera um resultado discreto e, ao contrário da regressão, atribui um rótulo ou classe para o valor de entrada. A classe é definida pela proximidade do novo valor com o histórico da base de dados. O número de rótulos é finito e é determinado pela quantidade de rótulos únicos no conjunto de treino (NASTESKI, 2017).

A Figura 6 exemplifica a diferença entre uma regressão e uma classificação num gráfico univariável. Na esquerda da imagem temos uma regressão linear, sendo possível supor um valor para y dado um valor x. O lado direito da imagem mostra um classificador linear com limiar rígido dividindo os pontos do gráfico em dois rótulos (NORVIG; RUSSELL, 2014).

Existem dois tipos de classificações: binária, quando existem apenas duas classes de saída e multi-classes quando existem vários possíveis rótulos (CASTELLI; VANNESCHI; LARGO, 2018). Também podemos classificar esses algoritmos pela forma que eles são treinados. Classificadores de aprendizagem preguiçosa guardam o conjunto de teste até receberem um conjunto de validação. Eles passam menos tempo treinando mas demoram mais para classificar. Classificadores de aprendizagem ansiosa tratam o conjunto de treino assim que o recebem e já ficam configurados para o conjunto de teste. Eles passam mais tempo treinando e classificam com mais rapidez (XIE et al., 2002).

[2] Ajuste excessivo em tradução livre.

Figura 6 – Diferença Regressão e Classificação

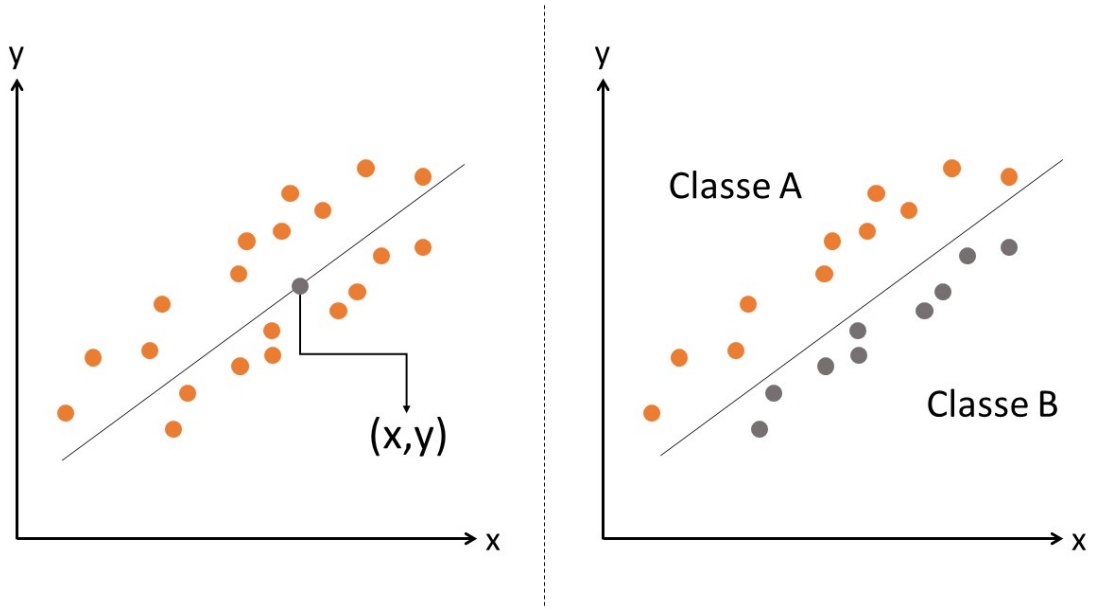

Adaptado de: Norvig e Russell (2014)

O KNN, citado na subseção 2.1.3, é um exemplo de aprendizagem preguiçosa e o Bayes ingênuo, citado mais adiante no texto, é um exemplo de aprendizagem ansiosa.

2.2.2.1 *K-Nearest Neighbors*

O KNN é um algoritmo de classicação de aprendizagem supervisionada e preguiçosa (CHENG et al., 2014). Seu funcionamento segue os seguintes passos:

1. Um número K de vizinhos é definido.
2. É medida a distância entre o novo ponto a ser classificado e os outros ponto do conjunto de dados.
3. Os K vizinhos mais próximos do novo ponto são selecionados.
4. A categoria mais comum entre os K vizinhos será a categoria definida para o novo ponto.

A escolha do tamanho de K é uma grande discussão. O valor ideal pode não ser o mesmo em conjuntos de dados diferentes, então para definir o K é importante realizar testes e conhecer o *dataset*, o valor adequado pode mitigar a ocorrência de *overfitting* nos treinos (PETERSON, 2009).

O KNN é considerado um algoritmo adequado para problemas multi-classes, independente da distribuição dos pontos. Tem como maiores desvantagens a necessidade de varrer o conjunto de dados repetidas vezes e o problema para se definir um valor de K (SINGH; THAKUR; SHARMA, 2016).

2.2.2.2 Bayes Ingênuo

Bayes Ingênuo é um algoritmo de classificação de aprendizagem supervisionada e ansiosa. Ele é baseado no Teorema de Bayes do campo da estatística. O adjetivo ingênuo de seu nome se refere ao comportamento do algoritmo de interpretar eventos de forma independentes, como se um evento não tivesse relação com outro (RISH et al., 2001).

O Teorema de Bayes é dado pela equação:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \tag{2.1}$$

Onde:

- A é uma hipótese.
- B é um evento.
- $P(A|B)$ é a probabilidade de A dado o evento B.
- $P(B|A)$ é a probabilidade das evidências supondo que A é verdadeiro.
- $P(A)$ é a probabilidade da hipótese antes de se olhar as evidências.
- $P(B)$ é a probabilidade da evidência.

O classificador vai testar cada uma das hipóteses (uma para cada rótulo) e guardar a hipótese com a maior probabilidade. Esse será a classe atribuída para a nova entrada (RISH et al., 2001).

O Bayes Ingênuo é o modelo Bayesiano mais comum em aprendizagem de máquina, performa bem com classificações multi-classes e é bem escalável. Sua maior desvantagem é não conseguir relacionar os eventos (ingenuidade) (NORVIG; RUSSELL, 2014). Ou seja, no contexto desse trabalho, ingenuidade seria a incapacidade de relacionar medidas de pontos de acesso diferentes.

2.2.3 Métricas de avaliação

Criado o classificador, é igualmente importante ter formas de avaliar e comparar os resultados apresentados por ele. Neste capítulo estão listadas algumas métricas para

analisar classificadores binários e classificadores multiclasse, selecionadas por Grandini, Bagli e Visani (2020), como: a matriz de confusão, acurácia, precisão, revocação, acurácia balanceada e F1-score. Além da área sob a curva ROC descrita por Narkhede (2018).

2.2.3.1 Matriz de confusão

Uma matriz de confusão é uma forma de representar visualmente o número de ocorrências dos valores preditos pelo modelo de classificação e dos valores reais ao mesmo tempo. Na Figura 7 temos um exemplo que mostra os resultados de uma classificação multi-classe. As classes da categorização estão listadas na mesma ordem em ambos os eixos, dessa forma os valores na diagonal principal da matriz indicam os resultados previstos corretamente.

Figura 7 – Exemplo de uma matriz de confusão binária e multiclasse

Predito

Real	Classes	Positivo	Negativo	Total
	Positivo	TP = 50	FN = 10	60
	Negativo	FP = 15	TN = 75	90
	Total	65	85	150

Predito

Real	Classes	a	b	c	Total
	a	7	5	2	14
	b	1	6	4	11
	c	4	2	8	14
	Total	12	13	14	39

Fonte: Criado pelo autor

2.2.3.2 Acurácia

Acurácia é a razão entre a quantidade de resultados classificados corretamente e o total de elementos no conjunto. Sua fórmula para classificações binária é:

$$Acurácia = \frac{TP + TN}{TP + TN + FP + FN} \tag{2.2}$$

Onde:

- TP são os elementos verdadeiros positivos.

- TN são os verdadeiros negativos.
- FP são os falsos positivos.
- FN são os falsos negativos.

Se tratando de classificações com múltiplas classes, a acurácia é obtida substituindo os valores TP e TN pela quantidade de valores classificados corretamente para cada classe (diagonal principal da matriz de confusão).

O valor obtido sempre estará entre 0 e 1 sendo 1 o valor ideal. A acurácia pode esconder erros de classificação em algumas variáveis específicas se elas tiverem poucas ocorrências na base de dados. Para encontrar esses erros é importante ter medidas que possam detalhar cada uma das classes, como: precisão e revocação.

2.2.3.3 Precisão e Revocação

Essas são métricas que ajudam a detalhar o desempenho em cada classe, além disso elas servem como base para outras métricas.

A precisão é a razão entre os valores verdadeiros positivos (TP) e o total de classificados como positivo. Dessa forma, a precisão indica a chance de uma classificado como verdadeiro ser de fato verdadeiro.

$$Precisão = \frac{TP}{TP + FP} \tag{2.3}$$

A revocação indica a capacidade do modelo de classificar como verdadeiro as instâncias que devem ser classificadas dessa forma. Ela é obtida dividindo os valores classificados como possitivos (TP) pelo total de positvos.

$$Revocação = \frac{TP}{TP + FN} \tag{2.4}$$

2.2.3.4 Acurácia Balanceada

Utilizando os dados de revocação de cada classe é possível se obter uma medida de acurácia que pondere melhor a influência de cada classe no total, impedindo que uma classe muito presente no conjunto de dados dite a acurácia do teste inteiro. Em classificações multiclasse a acurácia balanceada é obtida pela média da revocação de cada classe.

$$Acurácia\ Balanceada = \frac{\sum_{k=1}^{K} \frac{TP_k}{TP_k + FN_k}}{K} \tag{2.5}$$

2.2.3.5 *F1-score*

Outra métrica que pode ser obtida usando a precisão e a revocação. Com ela é possível pontuar o modelo analisando essa duas métricas. Encontramos esse valor através da média harmônica entre a precisão e a revocação.

$$F1\text{-}score = 2 * (\frac{Precisão * Revocação}{Precisão + Revocação}) \tag{2.6}$$

Em contextos multiclasse, chegamos no F1-*score* utilizando as médias de ambas as métricas básicas como na equação Equação 2.9. Esse método é chamado *F1-Score Macro*. Também existe o *F1-Score Micro*, cuja fórmula é a mesma da acurácia.

$$PrecisãoMédiaMacro = \frac{\sum_{k=1}^{K} \frac{TP_k}{TP_k + FP_k}}{K} \tag{2.7}$$

$$RevocaçãoMédiaMacro = \frac{\sum_{k=1}^{K} \frac{TP_k}{TP_k + FN_k}}{K} \tag{2.8}$$

$$MacroF1\text{-}Score = 2 * (\frac{PrecisãoMédiaMacro * RevocaçãoMédiaMacro}{PrecisãoMédiaMacro + RevocaçãoMédiaMacro}) \tag{2.9}$$

2.2.3.6 Área ROC

A área sob a curva ROC é outra maneira de medir a capacidade do modelo de distinguir entre classes. ROC traduzido do inglês significa características operacionais do receptor, curva ROC é uma função que descreve a relação entre Revocação (taxa de verdadeiros positivos) e a taxa de falsos positivos Figura 8. Olhando para a área sob essa função é possível entender mais sobre o comportamento do classificador.

A taxa de falsos negativos é obtida de forma análoga a revocação, dividindo os falsos negativos pelo total de valores negativos.

$$TaxaFalsosNegativos = \frac{FN}{TN + FP} \tag{2.10}$$

No eixo x do gráfico, um valor próximo ao 1 indica uma taxa maior de Falsos Positivos que Verdadeiros Negativos. No eixo y valores próximos ao 1 indicam uma taxa maior de verdadeiros Positivos que Falsos Negativos. Sendo assim, o desempenho ideal do modelo teria seus resultados no canto superior esquerdo do gráfico como na Figura 9, de forma que a área sob a curva seja próxima a 1.

O pior resultado posível é quando a área é 0,5, significando que o modelo está totalmente aleatório ou classificando todas as ocorrências da mesma forma. Além disso,

Figura 8 – Curva ROC e a área sob ela

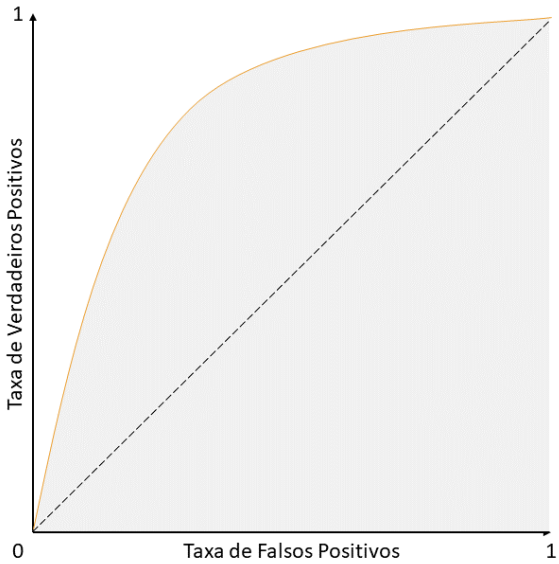

Adaptado de Narkhede (2018)

caso a área seja próxima a 0, o modelo está invertendo as classificações (podendo ser facilmente ajustado em classificações binárias).

2.3 Trabalhos Relacionados

Essa seção mostras alguns trabalhos que também abordam localização interna e criação de rotas.

O Trabalho de Altintas e Serif (2011) utiliza a infraestrutura Wi-Fi de uma escola como base para a localização por *fingerprinting*, o dado utilizado no mapeamento foi a força do sinal recebido (RSS). A área de teste media 500 m^2 e estava coberta por 5 pontos de acesso e 57 repetidores. O objetivo dos autores era melhorar o desempenho do *fingerprinting* utilizando o algoritmo K-médias como alternativa ao KNN. A conclusão do estudo foi que o K-médias pode superar o KNN quando parametrizado com precisão, porém o desvio padrão do KNN é menor. Ou seja, o KNN apresentou um desempenho mais uniforme que o k-médias, apesar do pior desempenho.

SILVA (2019), assim como Altintas e Serif (2011) utiliza a RSS de rede Wi-Fi do local que foi mapeado. Mas seu trabalho segue um rumo diferente na fase de rastreio do *fingerprinting* ao utilizar algoritmos de árvore de decisão para classificar novas entradas. Os algoritmos escolhidos foram: random forest, multi layer perceptron e Adaboost. Dentre eles o mais performático foi o Adaboost com uma taxa de aceitação de 98,61% e nível de

Figura 9 – Curva ROC de com área próxima a 1

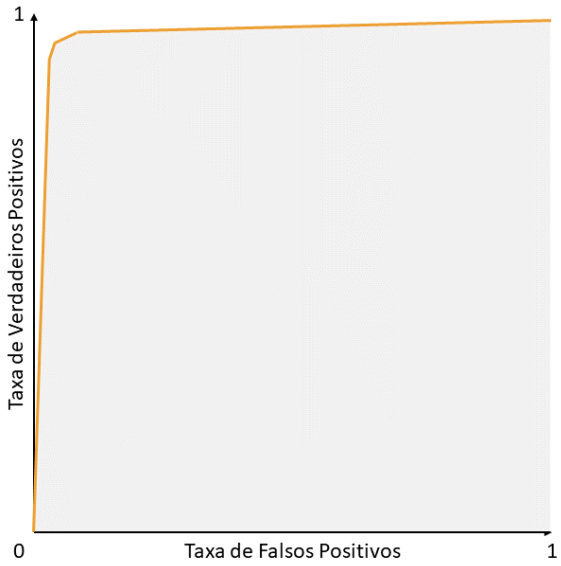

Adaptado de Narkhede (2018)

confiança 95%.

3 Desenvolvimento

Nesse capítulo são detalhados a criação da ferramenta de coleta de dados, os testes e os resultados dos algoritmos de classificação apresentados no capítulo anterior.

3.1 Proposta do projeto

Na subseção 2.2.2, é detalhado como os algoritmos de classificação utilizam dados históricos para preverem resultados a partir de novas entradas. Para gerar essa massa de dados, é preciso uma ferramenta que leia e armazene algumas informações: o local onde foi feita a leitura, a potência dos pontos de acesso que o dispositivo detecta e um identificador único para cada um desses pontos de acesso. A primeira etapa do desenvolvimento foi desenvolver essa ferramenta.

3.2 Metodologia

A coleta de dados, a análise deles e os resultados obtidos estão detalhados respectivamentes após a seção da coleta de dados. Os testes de desempenho dos algoritmos foram realizados na ferramenta Weka desenvolvida pela Universidade de Waikato. Essa ferramenta permite a criação de modelos de classificação com base em diversos algoritmos diferentes. Além disso, o Weka também retorna várias das estatísticas de desempenho que serão usadas nesse trabalho.

O fluxo dos dados está representado na Figura 10, os dados coletados na área de teste são armazenados no Firebase, transportados para um banco de dados relacional para tratamento e por fim analisados no Weka.

3.3 Coletor de Dados

O foco desse projeto são os dispositivos móveis Android, a linguagem adotada para a ferramento de coleta de dados foi o Kotlin, tecnologia padrão para a plataforma. Dentro do *framework* do Android existe um recurso responsável por gerenciar as conexões Wifi, o *WifiManager* (GOOGLE, 2022). Dentro dessa biblioteca, há o startScan, uma funcão relevante para o projeto, pois ela que realiza a leitura de todas as redes Wifi que o celular pode se conectar, se o usuário deu essa permissão para o aplicativo. Essa função está marcada como depreciada pela documentação oficial, mas ainda é possível utilizá-la. Até agora não foi apresentada uma alternativa dentro da linguagem para essa função. Da versão 10 em diante do Android o starScan opera com as seguintes limitação:

Figura 10 – Fluxo dos dados no projeto

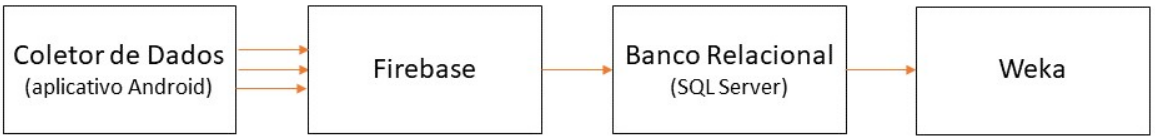

Fonte: Criado pelo autor

- Uma leitura a cada 2 minutos com o aplicativo em primeiro plano.
- Uma leitura a cada 30 minutos com o aplicativo em segundo plano.

O intervalo entre as leituras pode ser reduzido nas opções de desenvolvedor do Android, o que foi necessário para realizar com mais rapidez a coleta de dados de treino.

Segundo a Google essas limitações foram implementadas para melhorar a performance das conexões de rede e para preservar a saúde da bateria dos dispositivos (GOOGLE, 2018).

O *Firebase Realtime Database*, recurso da plataforma do Google para persistência de dados de forma não relacional, foi utilizado para armazenar os dados coletados, principalmente devido a facilidade de conexão de uma aplicação Android a esse serviço. Como o Firebase é um banco de dados não relacional, cada registro seguirá uma estrutura hierárquica contendo: a sala e a região onde foi feito o registro e um conjunto de nós que representam cada conexão à um ponto de acesso. Cada conexão contém por sua vez: um bssid (*Basic Service Set Identifier*), um ssid (*Service Set Identifier*) e um rssi (*Received signal strength indication*) como mostra a Figura 11.

Nas etapas seguintes do desenvolvimento os dados foram carregados para um banco relacional, mas a princípio eles foram armazenados no Firebase pela facilidade de acessar esse serviço sem uma estrutura de hospedagem em nuvem própriaa do projeto.

Na Figura 12 estão as telas da aplicação de coleta de dados. O primeiro componete é uma *TextView*, um elemento de exibição de texto, que indica o último resgistro feito, os elementos que exibem os textos “K21” e “K480” são *Spiners* usados para selecionar setor e sala respectivamente dentro de uma lista de opções.

Figura 11 – Exemplo de um registro do Firebase

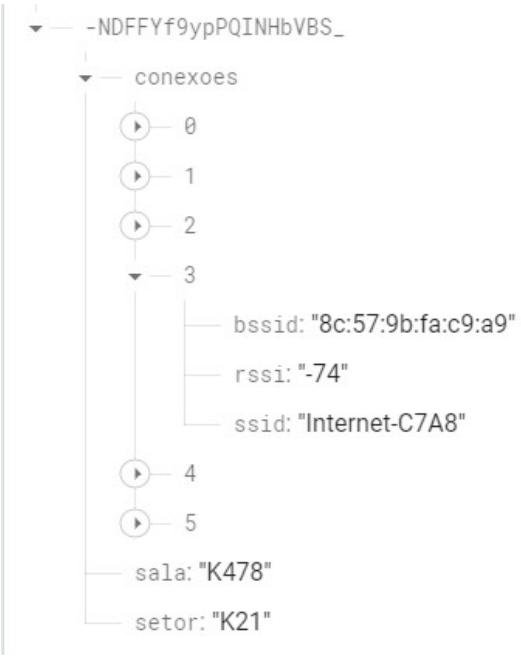

Criado pelo autor

O botão testar chama a função startScan do Android. Para ler os dados coletados pelo *scan* é preciso um *BroadcastReceiver*, uma função que ouve as transmissões recebidas pela aplicação e é disparado quando a leitura é concluída. Esse *BroadcastReceiver* exibe o diálogo que confirma a inserção no banco e realiza essa operação.

3.4 Coleta de Dados

A coleta de dados foi realizada no prédio Acadêmico 1 do Centro Universitário Senac. O edifício possiu dois andares e uma área de aproximadamene 13.680 m^2 (de acordo com o Google Maps). Nas Figura 13 e Figura 14 temos o mapa do térreo e mezanino, respectivamente.

A área de testes foi dividida em 16 setores. Cada corredor vertical (segundo a orientação da figura) forma um setor e cada corredor horizontal corresponde a 2 setores. Os setores foram nomeados utilizando a letra designada a cada corredor, o andar do corredor e cada uma de suas partes (para diferenciar os corredores que foram divididos). Dessa forma, o segundo andar do corredor C foi dividido entre setores C21 e C22, por exemplo.

A coleta de dados foi dividida em 3 etapas. Na primeira, realizada no dia 29 de Agosto, das 19h às 22h, foram coletados 267 instâncias. Na segunda etapa, realizada nos dias 26 e 29 de setembro, das 19h às 22h, foram coletados mais 240 registros somando 507 instâncias. A última etapa, feita no dia 7 de novembro, das 15h às 17h, resultou em mais 233 registros, totalizando 740 gravações.

Figura 12 – Telas do aplicativo de coleta de dados

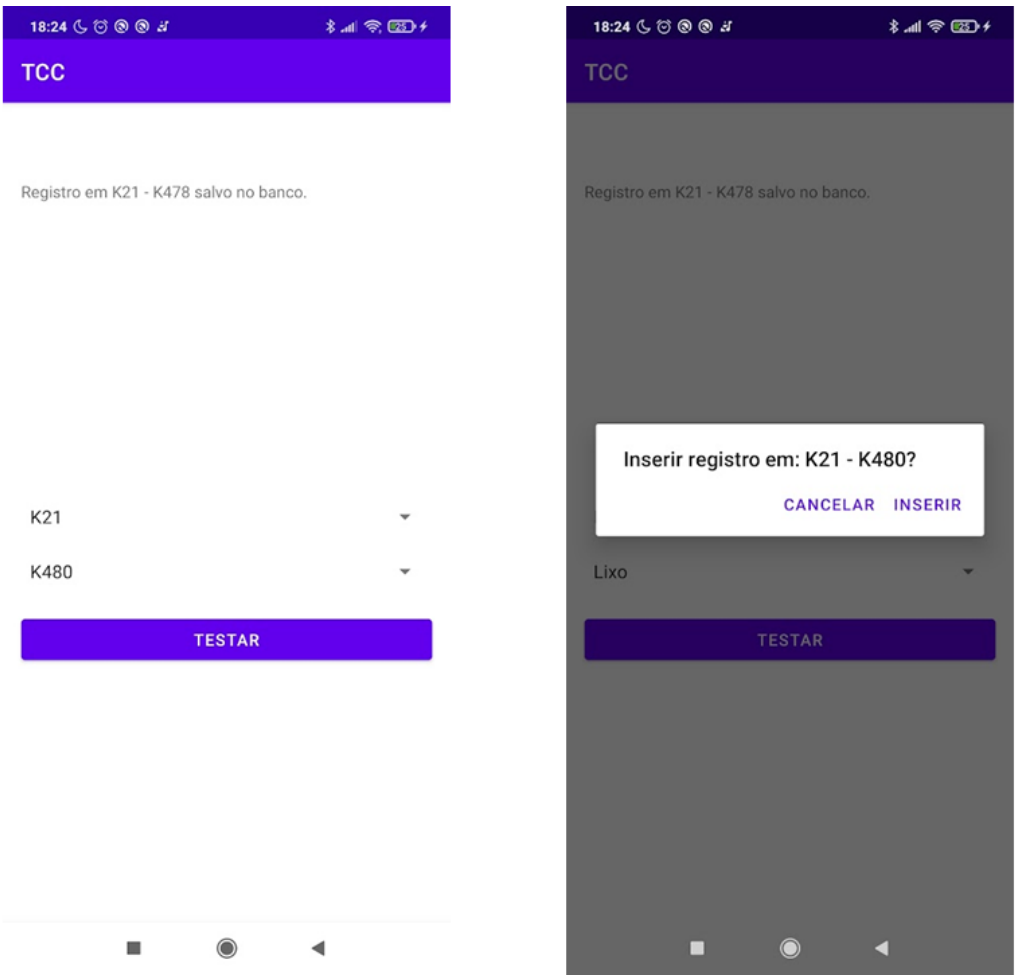

Criado pelo autor

Os dados da primeira e segunda etapa estavam mais desbalanceados, algumas classes possuíam até o dobro de registros que outras. A terceira etapa corrigiu essa defasagem balanceando a distribuição das instâncias.

A partir desses dados, foi possível testar o desempenho dos algoritmos KNN e Bayes Ingênuo. No capítulo seguinte está descrito como foram realizados esses testes.

3.5 Testes

O Weka lê conjuntos de dados através do formato *.arff*. Esse arquivo é separado em 2 partes:

- Cabeçalho: onde são descritas as colunas do conjunto de dados.
- *Data*: onde estão listados os dados.

Figura 13 – Mapa Acadêmico 1 - Térreo

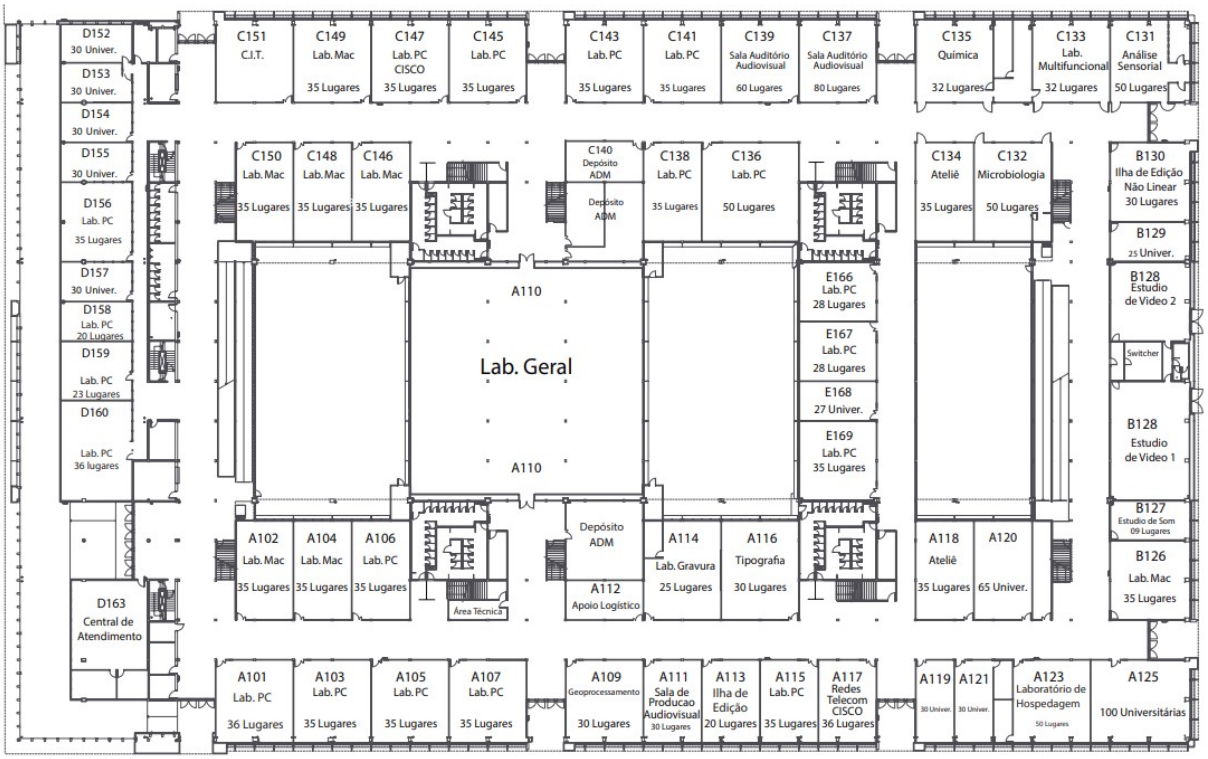

Fonte: Cedido pela Instituição

Nos dados, cada linha do arquivo corresponde a uma instância e cada item separado por vírgula é o valor da coluna descrita no cabeçalho. As colunas devem ser listadas na mesma ordem que são apresentadas no cabeçalho.

Os dados armazenados no *Real Time Database* são exportados como JSON. Então, para transforma-los em um .arff, os dados foram copiados em um banco relacional SQL Server seguindo a estrutura da Figura 15.

Com os dados em um banco relacional foi possível selecioná-los no formato desejado utilizando a consulta disponível no Apêndice A. Essa consulta retorna uma linha para cada registro realizado. As colunas são: o setor no qual foi realizada a consulta e o valor RSSI em cada um dos pontos de acesso.

O Weka possui versões do KNN e do Bayes Ingênuo. No KNN os testes foram realizados com K valendo 4 assim como fez Altintas e Serif (2011) e utilizando as distância linear Euclidiana e Manhattan. O Bayes Ingênuo foi usado com a parametrização padrão do Weka. A divisão do conjunto entre treino e teste foi 66% e 33% respectivamente (divisão sugerida do pela ferramenta).

No próximo capítulo, estão listados os resultados de cada teste e uma comparação entre eles.

Figura 14 – Mapa Acadêmico 1 - Mezanino

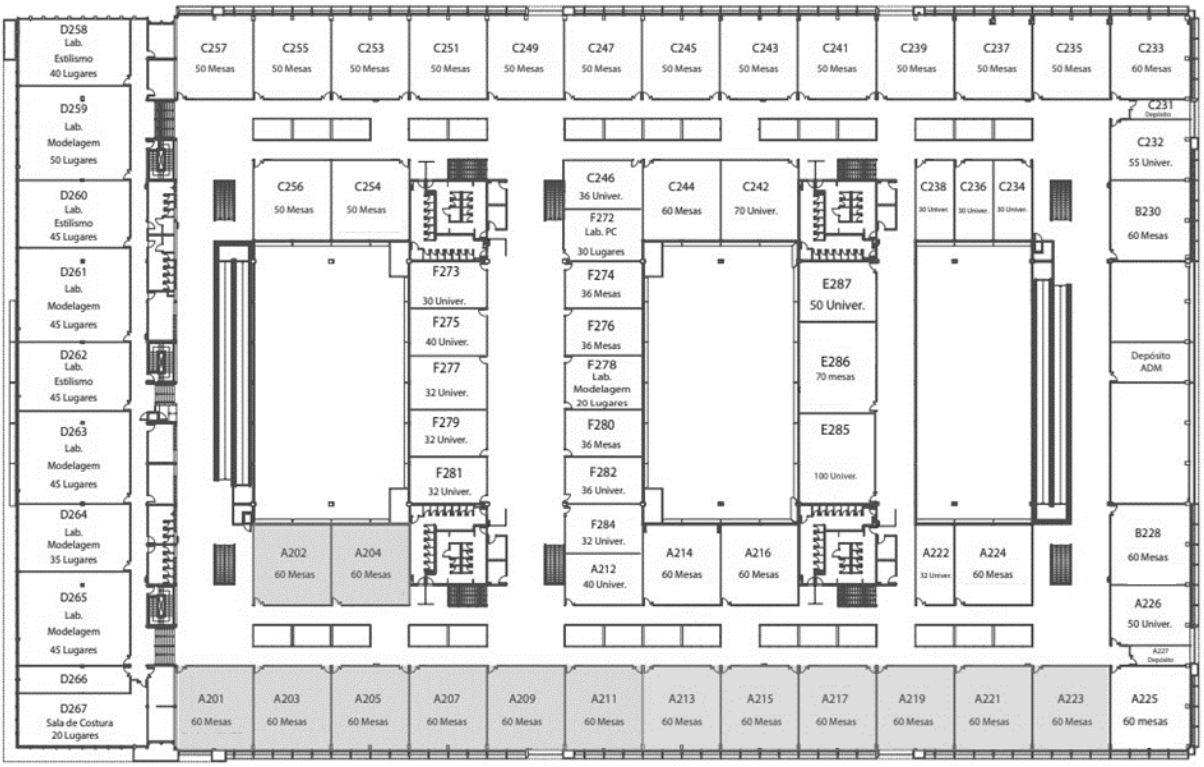

Fonte: Cedido pela Instituição

3.6 Resultados

Nas tabelas de 1 até a 9 estão listados os resultados de cada um dos testes dos 3 algoritmos nas 3 etapas de coleta de dados. Na fórmula da precisão (Equação 2.3) divide-se a taxa de verdadeiros positivos por todos os valores marcados como positivos. Caso não tenha acontecido nenhuma previsão naquela classe o resultado será uma divisão por zero. Além disso, sem um valor para a precisão não é possível calcular o *F1-Score* (Equação 2.6). Os dados que não puderam ser calculados estão marcados com ?.

A quantidade de instâncias de cada classe em cada uma das etapas se encontra no Apêndice B e as matrizes de confusão de cada um dos testes no Apêndice C.

A etapa 1 foi a que mais constou dados incalculáveis. Presume-se que a quantidade pequena de instâncias para testes possa ser a causadora disso. Essa suposição é possível pois no Bayes Ingênuo, mesmo tendo desempenhado bem, as classes NASA e B21 (classes que possuíam menos registos) não foram preditas nenhuma vez. No entanto esse provavelmente não foi o único fator para que isso tenha ocorrido, já que no KNN com distância euclidiana o mau desempenho também contribuiu, visto que nas etapas seguintes os valores incalculáveis permanecem.

Da etapa 1 para a etapa 2 nota-se uma melhora pouco considerável no Bayes

Figura 15 – Estrutura do Banco Relacional de Importação

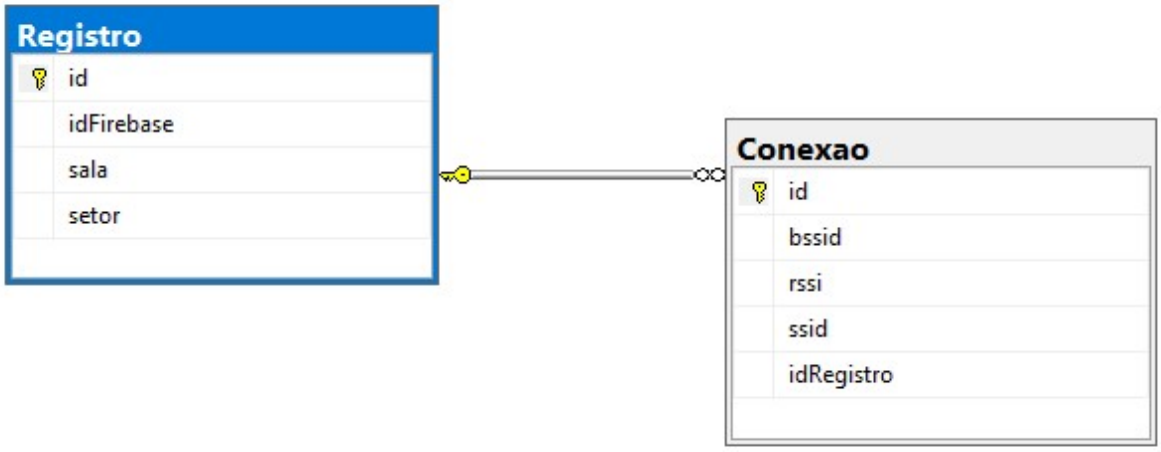

Fonte: Criado pelo autor

Tabela 1 – Resultado do KNN com distância Euclidiana na Etapa 1

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,000	0,000	0,000	0,295
A12	?	0,000	?	0,482
B11	?	0,000	?	0,500
C11	?	0,000	?	0,500
C12	0,000	0,000	0,000	0,190
D11	?	0,000	?	0,500
E11	?	0,000	?	0,500
NASA	?	0,000	?	0,500
A21	0,000	0,000	0,000	0,505
A22	0,000	0,000	0,000	0,393
B21	?	0,000	?	0,500
C21	?	0,000	?	0,482
C22	0,000	0,000	0,000	0,227
D21	?	0,000	?	0,482
E21	?	0,000	?	0,500
F21	?	0,000	?	0,500

Ingênuo e no KKN com distância Euclidiana. O mais incomum na segunda etapa é a piora no desempenho do KNN com distância Manhattan, contrariando a expectativa de que mais dados melhorariam o desempenho de todos os modelos.

Na última etapa, onde a quantidade de instâncias de cada classe estava mais balanceada, o Bayes Ingênuo teve uma melhora maior em relação a etapa anterior do que da 1 para a 2. O KNN com distância Manhattan desempenhou pior ainda. O com distância Euclidiana melhorou mais um pouco, mas continua longe do ideal.

Tabela 2 – Resultado do KNN com distância Manhattan na Etapa 1

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,667	0,750	0,706	0,902
A12	1,000	0,571	0,727	0,987
B11	?	0,000	?	0,625
C11	1,000	0,167	0,286	0,667
C12	0,241	0,778	0,368	0,895
D11	?	0,000	?	0,500
E11	?	0,000	?	0,500
NASA	?	0,000	?	0,500
A21	0,500	0,667	0,571	0,807
A22	0,313	0,714	0,435	0,847
B21	?	0,000	?	0,500
C21	1,000	0,667	0,800	0,988
C22	0,636	0,875	0,737	0,938
D21	?	0,000	?	0,769
E21	?	0,000	?	0,500
F21	1,000	0,200	0,333	0,600

Tabela 3 – Resultado do Bayes Ingênuo na Etapa 1

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	1,000	0,875	0,933	0,988
A12	0,750	0,429	0,545	0,838
B11	1,000	1,000	1,000	1,000
C11	0,600	0,500	0,545	0,804
C12	0,667	0,667	0,667	0,917
D11	1,000	1,000	1,000	1,000
E11	1,000	1,000	1,000	1,000
NASA	?	0,000	?	0,500
A21	0,769	0,833	0,800	0,928
A22	0,500	0,714	0,588	0,955
B21	?	0,000	?	0,500
C21	0,571	0,667	0,615	0,887
C22	0,600	0,750	0,667	0,967
D21	1,000	1,000	1,000	1,000
E21	1,000	1,000	1,000	1,000
F21	0,714	1,000	0,833	0,988

Tabela 4 – Resultado do KNN com distância Euclidiana na Etapa 2

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	?	0,000	?	0,439
A12	?	0,000	?	0,468
B11	?	0,000	?	0,500
C11	0,000	0,000	0,000	0,372
C12	?	0,000	?	0,500
D11	?	0,000	?	0,500
E11	?	0,000	?	0,500
NASA	?	0,000	?	0,500
A21	?	0,000	?	0,365
A22	0,038	0,385	0,068	0,249
B21	?	0,000	?	0,500
C21	0,000	0,000	0,000	0,248
C22	0,000	0,000	0,000	0,234
D21	?	0,000	?	0,479
E21	?	0,000	?	0,500
F21	?	0,000	?	0,500

Tabela 5 – Resultado do KNN com distância Manhattan na Etapa 2

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,500	0,571	0,533	0,915
A12	0,833	0,294	0,435	0,785
B11	?	0,000	?	0,500
C11	0,308	0,308	0,308	0,771
C12	1,000	0,300	0,462	0,773
D11	?	0,000	?	0,500
E11	?	0,000	?	0,500
NASA	?	0,000	?	0,500
A21	0,583	0,538	0,560	0,881
A22	0,141	0,923	0,245	0,909
B21	?	0,000	?	0,500
C21	0,588	0,769	0,667	0,951
C22	0,625	0,833	0,714	0,982
D21	?	0,000	?	0,586
E21	?	0,000	?	0,500
F21	1,000	0,071	0,133	0,607

Tabela 6 – Resultado do Bayes Ingênuo na Etapa 2

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,500	0,857	0,632	0,977
A12	0,909	0,588	0,714	0,928
B11	0,833	0,833	0,833	0,998
C11	0,583	0,538	0,560	0,857
C12	0,833	0,750	0,789	0,935
D11	0,786	1,000	0,880	0,994
E11	1,000	1,000	1,000	1,000
NASA	1,000	0,333	0,500	0,833
A21	1,000	0,615	0,762	0,948
A22	0,571	0,923	0,706	0,973
B21	1,000	0,333	0,500	1,000
C21	0,667	0,769	0,714	0,939
C22	0,696	0,889	0,780	0,970
D21	1,000	0,714	0,833	0,997
E21	1,000	0,750	0,857	0,874
F21	0,786	0,786	0,786	0,917

Tabela 7 – Resultado do KNN com distância Euclidiana na Etapa 3

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,053	0,313	0,091	0,273
A12	?	0,000	?	0,492
B11	?	0,000	?	0,500
C11	0,000	0,000	0,000	0,472
C12	?	0,000	?	0,239
D11	?	0,000	?	0,500
E11	?	0,000	?	0,500
NASA	?	0,000	?	0,500
A21	1,000	0,071	0,133	0,502
A22	0,076	0,563	0,133	0,340
B21	?	0,000	?	0,500
C21	0,000	0,000	0,000	0,402
C22	0,000	0,000	0,000	0,126
D21	?	0,000	?	0,508
E21	?	0,000	?	0,500
F21	?	0,000	?	0,500

Tabela 8 – Resultado do KNN com distância Manhattan na Etapa 3

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,226	0,750	0,348	0,923
A12	1,000	0,313	0,476	0,842
B11	?	0,000	?	0,500
C11	0,238	0,333	0,278	0,933
C12	0,889	0,500	0,640	0,870
D11	?	0,000	?	0,500
E11	1,000	0,048	0,091	0,524
NASA	?	0,000	?	0,500
A21	0,462	0,429	0,444	0,782
A22	0,165	0,813	0,274	0,870
B21	?	0,000	?	0,526
C21	0,512	0,875	0,646	0,951
C22	0,571	0,842	0,681	0,959
D21	?	0,000	?	0,676
E21	?	0,000	?	0,500
F21	1,000	0,222	0,364	0,667

Tabela 9 – Resultado do Bayes Ingênuo na Etapa 3

Classe	Precisão	Revocação	F1-Score	Área ROC
A11	0,824	0,875	0,848	0,994
A12	0,867	0,813	0,839	0,992
B11	0,875	0,583	0,700	0,947
C11	0,524	0,733	0,611	0,932
C12	0,667	0,625	0,645	0,853
D11	0,706	1,000	0,828	0,990
E11	1,000	0,762	0,865	0,975
NASA	1,000	0,875	0,933	0,999
A21	0,684	0,929	0,788	0,988
A22	0,917	0,688	0,786	0,956
B21	0,882	0,789	0,833	0,966
C21	0,750	0,750	0,750	0,949
C22	0,783	0,947	0,857	0,987
D21	1,000	0,647	0,786	0,970
E21	0,857	1,000	0,923	0,994
F21	0,889	0,889	0,889	0,940

Tabela 10 – Resultado do Teste x

Etapa	Método	Acurácia	F1-Score	Precisão Média	Revocação Média
1	KNN Euclidiana	0,000	?	?	0,000
1	KNN Manhattan	0,472	?	?	0,473
1	Bayes Ingênuo	0,747	?	?	0,747
2	KNN Euclidiana	0,029	?	?	0,029
2	KNN Manhattan	0,372	?	?	0,372
2	Bayes Ingênuo	0,750	0,770	0,793	0,750
3	KNN Euclidiana	0,059	?	?	0,060
3	KNN Manhattan	0,353	?	?	0,353
3	Bayes Ingênuo	0,801	0,825	0,802	0,813

Figura 16 – Comparação da acurácia dos modelos

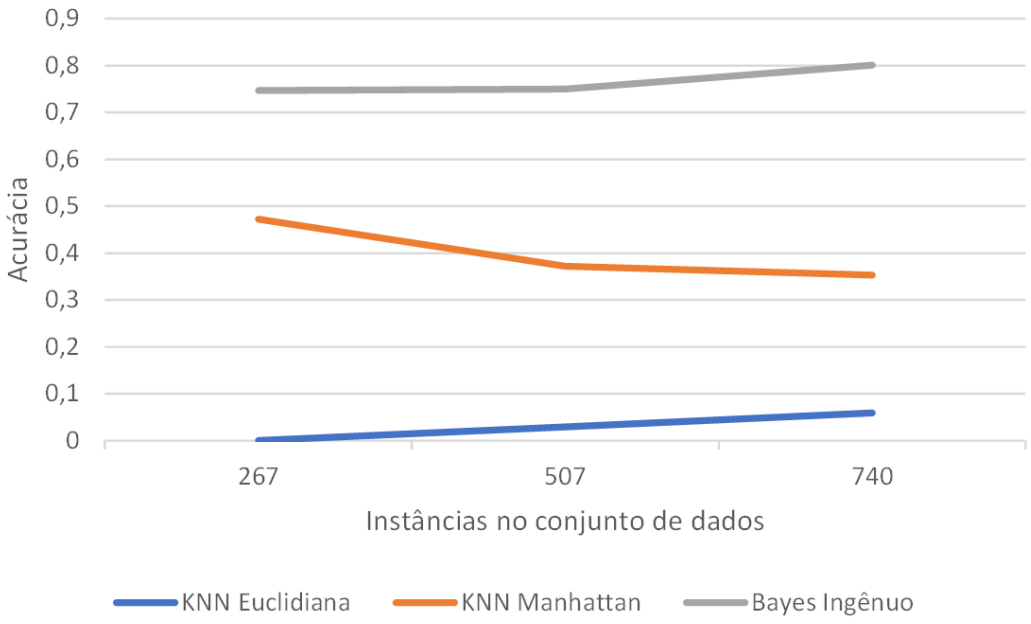

Criado pelo autor

4 Conclusões

Ao fim do trabalho foi possível reuinir com sucesso uma base de dados para localização interna utlizando um dispositivo móvel. Essa base possibilitou a realização dos testes propostos.

Após os testes realizados com os algoritmos, foi possível concluir que o Bayes Ingênuo tem uma performance muito superior ao KNN no cenário analisado, onde o número de amostrar coletadas não passa de 1000 instâncias. Vale ressaltar uma peculiaridade do Centro Universitário Senac, local usado como cenário onde há uma grande densidade de pontos de acesso, visto que ao fim da terceira etapa de coleta de dados o total era de 627 colunas no conjunto de dados.

Para se entender melhor o comportamento desses dois algoritmos, seria importante refazer esses testes em cenários e ambientes diferentes, de forma a analisar se o comportamento deles se mantém. Esperimentos como esses podem agregar informações para tomada de decisões em projetos futuros nesse campo do conhecimento.

4.1 Trabalhos Futuros

- Comparar o resultado desses algoritmos em conjuntos de dados mais volumosos.
- Realizar testes semelhantes em ambientes com uma densidade de pontos de acesso diferente
- Analisar o impacto que o modelo do dispositivo móvel usado na coleta de dados tem nos resultados.

Referências

ALTINTAS, B.; SERIF, T. Improving rss-based indoor positioning algorithm via k-means clustering. In: *17th European Wireless 2011 - Sustainable Wireless Technologies*. [s.n.], 2011. p. 1–5. Disponível em: <https://ieeexplore.ieee.org/document/5898019>. Citado 4 vezes nas páginas 19, 22, 28 e 35.

AMIRIAN, P.; BASIRI, A.; MORLEY, J. Predictive analytics for enhancing travel time estimation in navigation apps of apple, google, and microsoft. In: *Proceedings of the 9th ACM SIGSPATIAL International Workshop on Computational Transportation Science*. New York, NY, USA: Association for Computing Machinery, 2016. (IWCTS '16), p. 31–36. ISBN 9781450345774. Disponível em: <https://doi.org/10.1145/3003965.3003976>. Citado 2 vezes nas páginas 13 e 15.

BULLMANN, M. et al. Comparison of 2.4 ghz wifi ftm- and rssi-based indoor positioning methods in realistic scenarios. *Sensors*, v. 20, n. 16, 2020. ISSN 1424-8220. Disponível em: <https://www.mdpi.com/1424-8220/20/16/4515>. Citado 2 vezes nas páginas 18 e 19.

CARVALHO, E. A. de; ARAÚJO, P. C. de. *Noções básicas de sistema de posicionamento global GPS*. 2009. Disponível em: <http://www.ead.uepb.edu.br/arquivos/cursos/Geografia_PAR_UAB/Fasciculos%20-%20Material/Leituras_Cartograficas_II/Le_Ca_II_A08_MZ_GR_260809.pdf>. Citado 2 vezes nas páginas 15 e 16.

CASTELLI, M.; VANNESCHI, L.; LARGO, Á. R. Supervised learning: classification. *por Ranganathan, S., M. Grisbskov, K. Nakai y C. Schönbach*, v. 1, p. 342–349, 2018. Disponível em: <https://books.google.com.br/books?hl=pt-BR&lr=&id=rs51DwAAQBAJ&oi=fnd&pg=PA342&dq=supervised+learning+classification&ots=q_ZX8iTpSY&sig=0MVSdaUNY2gklwfhVnjV4tAjYow#v=onepage&q=supervised%20learning%20classification&f=false>. Citado na página 22.

CHENG, D. et al. knn algorithm with data-driven k value. In: LUO, X.; YU, J. X.; LI, Z. (Ed.). *Advanced Data Mining and Applications*. Cham: Springer International Publishing, 2014. p. 499–512. ISBN 978-3-319-14717-8. Disponível em: <https://link.springer.com/chapter/10.1007/978-3-319-14717-8_39>. Citado na página 23.

CUPONATION. *QUANTIDADE DE USUÁRIOS DE SMARTPHONES EM 2021*. 2021. Disponível em: <https://www.cuponation.com.br/insights/quantidadesmartphones-2021>. Acesso em: 03 abr. 2022. Citado na página 13.

DEPARTMENT, S. R. *Volume of data/information created, captured, copied, and consumed worldwide from 2010 to 2025*. 2022. Disponível em: <https://www.statista.com/statistics/871513/worldwide-data-created/#:~:text=The%20total%20amount%20of%20data,replicated%20reached%20a%20new%20high.> Acesso em: 01 maio 2022. Citado na página 21.

EMBRAPA, T. *Satélites de Monitoramento*. Campinas: [s.n.], 2018. Disponível em: <https://www.embrapa.br/satelites-de-monitoramento/missoes/glonass>. Acesso em: 19 abr. 2022. Citado na página 16.

FARID, Z.; NORDIN, R.; ISMAIL, M. Recent advances in wireless indoor localization techniques and system. *Journal of Computer Networks and Communications*, Hindawi Publishing Corporation, v. 2013, p. 185138, Sep 2013. ISSN 2090-7141. Disponível em: <https://doi.org/10.1155/2013/185138>. Citado 2 vezes nas páginas 18 e 19.

G1. *Brasileiros são os que passam mais tempo por dia no celular, diz levantamento*. 2022. Disponível em: <https://g1.globo.com/tecnologia/noticia/2022/01/12/brasileiros-sao-os-que-passam-mais-tempo-por-dia-no-celular-diz-levantamento.ghtml>. Acesso em: 29 mar. 2022. Citado na página 13.

GOOGLE. *WifiManager startScan throttled in P Beta (Developer Preview 2)*. 2018. Disponível em: <https://issuetracker.google.com/issues/79906367?pli=1>. Acesso em: 19 jan. 2023. Citado na página 32.

GOOGLE. *WifiManager*. 2022. Disponível em: <https://developer.android.com/reference/android/net/wifi/WifiManager>. Acesso em: 21 nov. 2022. Citado na página 31.

GPS.GOV. *Space Segment*. 2022. Disponível em: <https://www.gps.gov/systems/gps/space/>. Acesso em: 24 abr. 2022. Citado na página 16.

GRANDINI, M.; BAGLI, E.; VISANI, G. Metrics for multi-class classification: an overview. *arXiv preprint arXiv:2008.05756*, 2020. Disponível em: <https://arxiv.org/abs/2008.05756>. Citado na página 25.

GU, F. et al. Indoor localization improved by spatial context—a survey. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 52, n. 3, jul 2019. ISSN 0360-0300. Disponível em: <https://doi.org/10.1145/3322241>. Citado na página 13.

KONINGS, D. et al. Do rssi values reliably map to rss in a localization system? In: *2017 2nd Workshop on Recent Trends in Telecommunications Research (RTTR)*. [S.l.: s.n.], 2017. p. 1–5. Citado na página 18.

MACHAJ, J.; BRIDA, P.; PICHÉ, R. Rank based fingerprinting algorithm for indoor positioning. In: *2011 International Conference on Indoor Positioning and Indoor Navigation*. [s.n.], 2011. p. 1–6. Disponível em: <https://ieeexplore.ieee.org/abstract/document/6071929>. Citado 2 vezes nas páginas 18 e 19.

MAZUELAS, S. et al. Robust indoor positioning provided by real-time rssi values in unmodified wlan networks. *IEEE Journal of Selected Topics in Signal Processing*, v. 3, n. 5, p. 821–831, 2009. Citado na página 18.

MENDES, V. B. Sistema de posicionamento global. 2013. Disponível em: <https://fenix.ciencias.ulisboa.pt/downloadFile/281612415666769/gps_cap_I.pdf>. Citado na página 15.

MUELLER, S. T. Is the turing test still relevant? a plan for developing the cognitive decathlon to test intelligent embodied behavior. In: *19th Midwest artificial intelligence and cognitive science conference, MAICS*. [s.n.], 2008. v. 1, p. 3. Disponível em: <https://www.esd.whs.mil/Portals/54/Documents/FOID/Reading%20Room/Science_and_Technology/08-F-0799_Is_the_Turing_test_Still_Relevant.pdf>. Citado na página 21.

NARKHEDE, S. Understanding auc-roc curve. *Towards Data Science*, v. 26, n. 1, p. 220–227, 2018. Disponível em: <https://48hours.ai/files/AUC.pdf>. Citado 3 vezes nas páginas 25, 28 e 29.

NASTESKI, V. An overview of the supervised machine learning methods. *HORIZONS.B*, v. 4, p. 51–62, 12 2017. Disponível em: <https://www.researchgate.net/publication/328146111_An_overview_of_the_supervised_machine_learning_methods>. Citado na página 22.

NORVIG, P.; RUSSELL, S. *Inteligência artificial: Tradução da 3a Edição*. Elsevier Brasil, 2014. ISBN 9788535251418. Disponível em: <https://books.google.com.br/books?id=BsNeAwAAQBAJ>. Citado 5 vezes nas páginas 20, 21, 22, 23 e 24.

PETERSON, L. E. K-nearest neighbor. *Scholarpedia*, v. 4, n. 2, p. 1883, 2009. Revision #137311. Citado na página 23.

PU, C.-C.; PU, C.-H.; LEE, H.-J. Indoor location tracking using received signal strength indicator. In: FOERSTER, A.; FOERSTER, A. (Ed.). *Emerging Communications for Wireless Sensor Networks*. Rijeka: IntechOpen, 2011. cap. 11. Disponível em: <https://doi.org/10.5772/10518>. Citado 2 vezes nas páginas 17 e 18.

RISH, I. et al. An empirical study of the naive bayes classifier. In: *IJCAI 2001 workshop on empirical methods in artificial intelligence*. [s.n.], 2001. v. 3, n. 22, p. 41–46. Disponível em: <https://www.cc.gatech.edu/home/isbell/classes/reading/papers/Rish.pdf>. Citado na página 24.

SHALA, U.; RODRIGUEZ, A. Indoor positioning using sensor-fusion in android devices. 2011. Disponível em: <http://www.diva-portal.org/smash/record.jsf?pid=diva2%3A475619&dswid=-374>. Citado 2 vezes nas páginas 13 e 16.

SILVA, J. K. D. A. Sistema de gestão para localização indoor utilizando wifi fingerprints e machine learning. Jul 2019. Disponível em: <https://repository.ufrpe.br/handle/123456789/1510>. Citado 2 vezes nas páginas 15 e 28.

SINGH, A.; THAKUR, N.; SHARMA, A. A review of supervised machine learning algorithms. In: *2016 3rd International Conference on Computing for Sustainable Global Development (INDIACom)*. [s.n.], 2016. p. 1310–1315. Disponível em: <https://ieeexplore.ieee.org/abstract/document/7724478>. Citado na página 24.

VECTORNAV. *GLOBAL NAVIGATION SATELLITE SYSTEM (GNSS)*. 2022. Disponível em: <https://www.vectornav.com/resources/inertial-navigation-primer/theory-of-operation/theory-gnss?gclid=Cj0KCQjw6pOTBhCTARIsAHF23fIorrOo4ReWybt1SRGkAxnRaHJHhf03RP7jLaHRA13V7m55LfdGwcB>. Acesso em: 24 abr. 2022. Citado na página 16.

XIE, Z. et al. Snnb: A selective neighborhood based naïve bayes for lazy learning. In: CHEN, M.-S.; YU, P. S.; LIU, B. (Ed.). *Advances in Knowledge Discovery and Data Mining*. Berlin, Heidelberg: Springer Berlin Heidelberg, 2002. p. 104–114. ISBN 978-3-540-47887-4. Disponível em: <https://link.springer.com/chapter/10.1007/3-540-47887-6_10>. Citado na página 22.

YING, X. An overview of overfitting and its solutions. *Journal of Physics: Conference Series*, IOP Publishing, v. 1168, p. 022022, feb 2019. Disponível em: <https://doi.org/10.1088/1742-6596/1168/2/022022>. Citado na página 22.

Apêndices

APÊNDICE A – Consulta SQL para pivotar os dados no Banco Relacional

```
DECLARE @Columns as VARCHAR(MAX)

SELECT @Columns = COALESCE(@Columns + ', ','') + QUOTENAME([bssid])
FROM
    (SELECT DISTINCT [bssid] FROM Conexao) AS B
ORDER BY B.bssid

DECLARE @SQL as VARCHAR(MAX)
SET @SQL = 'SELECT setor, ' + @Columns + '
FROM
(
 select Registro.id, setor, bssid, rssi from Registro inner join Conexao on
     Registro.id = Conexao.idRegistro
   where setor in (''A11'', ''A12'', ''A21'', ''A22'',''B11'',''B21'',
                       ''C11'',''C12'',''C21'',''C22'',''D11'',
                       ''D21'',''E11'',''E21'',''F21'', ''NASA'')
) as PivotData
PIVOT
(
   Max(rssi)
   FOR [bssid] IN (' + @Columns + ')
) AS PivotResult'


EXEC(@SQL);
```

APÊNDICE B – Quantidade de Instâncias de cada classe em cada etapa de testes

Figura 17 – Distribuição das classes

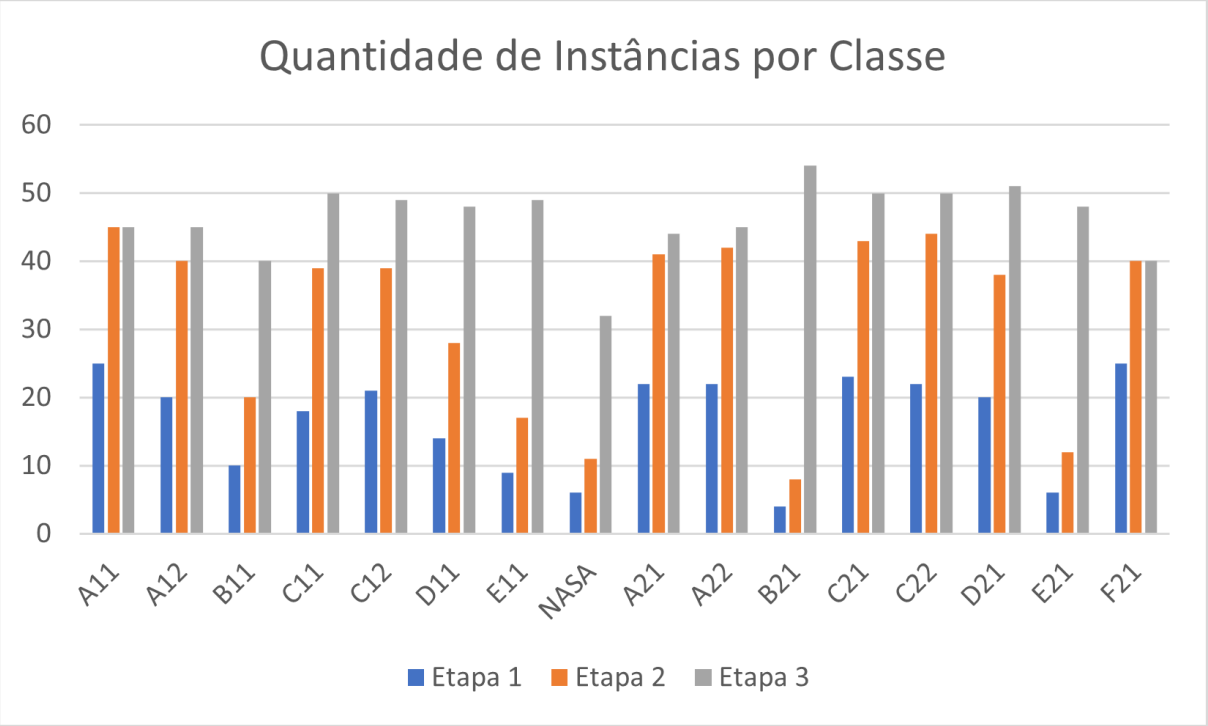

Fonte: Criado pelo autor

APÊNDICE C – Matrizes de confusão

Figura 18 – Matriz de confusão KNN com distância Euclidiana na Etapa 1

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
0	3	0	6	0	0	0	0	0	0	0	0	0	0	0	0	a = C12
11	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	b = A21
5	0	0	0	0	0	0	0	2	0	0	0	0	0	0	0	c = A22
4	0	0	0	0	0	0	0	4	0	0	0	0	0	0	0	d = A11
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	e = NASA
5	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	f = F21
2	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	g = B21
2	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	h = C21
0	0	0	8	0	0	0	0	0	0	0	0	0	0	0	0	i = C22
5	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	j = D21
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	k = E21
4	0	0	1	0	0	0	0	2	0	0	0	0	0	0	0	l = A12
3	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	m = B11
1	1	1	3	0	0	0	0	0	0	0	0	0	0	0	0	n = C11
4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	o = D11
2	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0	p = E11

Fonte: Criado pelo autor

Figura 19 – Matriz de confusão KNN com distância Manhattan na Etapa 1

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
7	0	0	0	0	0	0	0	2	0	0	0	0	0	0	0	a = C12
1	8	2	1	0	0	0	0	0	0	0	0	0	0	0	0	b = A21
1	1	5	0	0	0	0	0	0	0	0	0	0	0	0	0	c = A22
0	1	1	6	0	0	0	0	0	0	0	0	0	0	0	0	d = A11
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	e = NASA
1	1	2	0	0	1	0	0	0	0	0	0	0	0	0	0	f = F21
2	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	g = B21
1	0	0	0	0	0	0	4	1	0	0	0	0	0	0	0	h = C21
1	0	0	0	0	0	0	0	7	0	0	0	0	0	0	0	i = C22
3	0	2	1	0	0	0	0	0	0	0	0	0	0	0	0	j = D21
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	k = E21
1	0	2	0	0	0	0	0	0	0	0	4	0	0	0	0	l = A12
3	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	m = B11
4	0	0	0	0	0	0	0	1	0	0	0	0	1	0	0	n = C11
3	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	o = D11
0	4	0	0	0	0	0	0	0	0	0	0	0	0	0	0	p = E11

Fonte: Criado pelo autor

Figura 20 – Matriz de confusão Bayes Ingênuo na Etapa 1

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
6	0	0	0	0	0	0	0	2	0	0	0	0	1	0	0	a = C12
0	10	1	0	0	1	0	0	0	0	0	0	0	0	0	0	b = A21
0	1	5	0	0	0	0	0	0	0	0	1	0	0	0	0	c = A22
0	1	0	7	0	0	0	0	0	0	0	0	0	0	0	0	d = A11
0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	e = NASA
0	0	0	0	0	5	0	0	0	0	0	0	0	0	0	0	f = F21
0	0	1	0	0	0	0	1	0	0	0	0	0	1	0	0	g = B21
0	0	0	0	0	0	0	4	2	0	0	0	0	0	0	0	h = C21
2	0	0	0	0	0	0	0	6	0	0	0	0	0	0	0	i = C22
0	0	0	0	0	0	0	0	0	6	0	0	0	0	0	0	j = D21
0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	k = E21
0	1	3	0	0	0	0	0	0	0	0	3	0	0	0	0	l = A12
0	0	0	0	0	0	0	0	0	0	0	0	4	0	0	0	m = B11
1	0	0	0	0	0	0	2	0	0	0	0	0	3	0	0	n = C11
0	0	0	0	0	0	0	0	0	0	0	0	0	0	4	0	o = D11
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	4	p = E11

Fonte: Criado pelo autor

Figura 21 – Matriz de confusão KNN com distância Euclidiana na Etapa 2

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
0	0	0	0	0	0	0	0	1	6	0	0	0	0	0	0	a = A11
0	0	0	6	0	0	0	0	1	10	0	0	0	0	0	0	b = A12
0	0	0	5	0	0	1	0	1	6	0	0	0	0	0	0	c = A21
0	0	0	5	0	0	0	0	0	8	0	0	0	0	0	0	d = A22
0	0	0	4	0	0	0	0	0	2	0	0	0	0	0	0	e = B11
0	0	0	3	0	0	0	0	0	0	0	0	0	0	0	0	f = B21
0	0	0	13	0	0	0	0	0	0	0	0	0	0	0	0	g = C11
0	0	0	20	0	0	0	0	0	0	0	0	0	0	0	0	h = C12
0	0	0	13	0	0	0	0	0	0	0	0	0	0	0	0	i = C21
0	0	0	18	0	0	0	0	0	0	0	0	0	0	0	0	j = C22
0	0	0	11	0	0	0	0	0	0	0	0	0	0	0	0	k = D11
0	0	0	13	0	0	0	0	0	1	0	0	0	0	0	0	l = D21
0	0	0	1	0	0	0	0	0	2	0	0	0	0	0	0	m = E11
0	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	n = E21
0	0	0	14	0	0	0	0	0	0	0	0	0	0	0	0	o = F21
0	0	0	3	0	0	0	0	0	0	0	0	0	0	0	0	p = NASA

Fonte: Criado pelo autor

Figura 22 – Matriz de confusão KNN com distância Manhattan na Etapa 2

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
4	0	2	1	0	0	0	0	0	0	0	0	0	0	0	0	a = A11
1	5	0	11	0	0	0	0	0	0	0	0	0	0	0	0	b = A12
2	0	7	3	0	0	0	0	0	1	0	0	0	0	0	0	c = A21
0	0	1	12	0	0	0	0	0	0	0	0	0	0	0	0	d = A22
0	0	0	5	0	0	1	0	0	0	0	0	0	0	0	0	e = B11
0	0	1	2	0	0	0	0	0	0	0	0	0	0	0	0	f = B21
0	0	0	1	0	0	4	0	7	1	0	0	0	0	0	0	g = C11
0	0	0	8	0	0	4	6	0	2	0	0	0	0	0	0	h = C12
0	0	0	1	0	0	0	0	10	2	0	0	0	0	0	0	i = C21
0	0	0	3	0	0	0	0	0	15	0	0	0	0	0	0	j = C22
0	0	0	9	0	0	2	0	0	0	0	0	0	0	0	0	k = D11
1	0	0	11	0	0	1	0	0	1	0	0	0	0	0	0	l = D21
0	1	0	2	0	0	0	0	0	0	0	0	0	0	0	0	m = E11
0	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	n = E21
0	0	1	10	0	0	1	0	0	1	0	0	0	0	1	0	o = F21
0	0	0	2	0	0	0	0	0	1	0	0	0	0	0	0	p = NASA

Fonte: Criado pelo autor

Figura 23 – Matriz de confusão Bayes Ingênuo na Etapa 2

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
6	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	a = A11
2	10	0	5	0	0	0	0	0	0	0	0	0	0	0	0	b = A12
2	0	8	2	0	0	0	0	0	0	0	0	0	0	1	0	c = A21
1	0	0	12	0	0	0	0	0	0	0	0	0	0	0	0	d = A22
0	0	0	0	5	0	1	0	0	0	0	0	0	0	0	0	e = B11
0	0	0	1	1	1	0	0	0	0	0	0	0	0	0	0	f = B21
0	0	0	0	0	0	7	0	5	1	0	0	0	0	0	0	g = C11
0	0	0	0	0	0	3	15	0	2	0	0	0	0	0	0	h = C12
0	0	0	0	0	0	1	1	10	1	0	0	0	0	0	0	i = C21
0	0	0	0	0	0	0	2	0	16	0	0	0	0	0	0	j = C22
0	0	0	0	0	0	0	0	0	0	11	0	0	0	0	0	k = D11
1	0	0	0	0	0	0	0	0	0	3	10	0	0	0	0	l = D21
0	0	0	0	0	0	0	0	0	0	0	0	3	0	0	0	m = E11
0	0	0	1	0	0	0	0	0	0	0	0	0	3	0	0	n = E21
0	0	0	0	0	0	0	0	0	3	0	0	0	0	11	0	o = F21
0	0	0	0	0	0	0	0	0	0	0	0	0	0	2	1	p = NASA

Fonte: Criado pelo autor

Figura 24 – Matriz de confusão KNN com distância Euclidiana na Etapa 3

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
5	0	0	2	0	0	6	0	3	0	0	0	0	0	0	0	a = A11
3	0	0	8	0	0	5	0	0	0	0	0	0	0	0	0	b = A12
3	0	1	3	0	0	4	0	3	0	0	0	0	0	0	0	c = A21
1	0	0	9	0	0	4	0	1	1	0	0	0	0	0	0	d = A22
9	0	0	2	0	0	0	0	0	1	0	0	0	0	0	0	e = B11
15	0	0	2	0	0	0	0	0	2	0	0	0	0	0	0	f = B21
3	0	0	12	0	0	0	0	0	0	0	0	0	0	0	0	g = C11
2	0	0	14	0	0	0	0	0	0	0	0	0	0	0	0	h = C12
8	0	0	16	0	0	0	0	0	0	0	0	0	0	0	0	i = C21
0	0	0	19	0	0	0	0	0	0	0	0	0	0	0	0	j = C22
2	0	0	10	0	0	0	0	0	0	0	0	0	0	0	0	k = D11
5	0	0	12	0	0	0	0	0	0	0	0	0	0	0	0	l = D21
13	0	0	0	0	0	0	0	0	8	0	0	0	0	0	0	m = E11
17	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	n = E21
4	0	0	5	0	0	0	0	0	0	0	0	0	0	0	0	o = F21
4	0	0	4	0	0	0	0	0	0	0	0	0	0	0	0	p = NASA

Fonte: Criado pelo autor

Figura 25 – Matriz de confusão KNN com distância Manhattan na Etapa 3

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
12	0	2	2	0	0	0	0	0	0	0	0	0	0	0	0	a = A11
1	5	1	9	0	0	0	0	0	0	0	0	0	0	0	0	b = A12
5	0	6	3	0	0	0	0	0	0	0	0	0	0	0	0	c = A21
2	0	1	13	0	0	0	0	0	0	0	0	0	0	0	0	d = A22
6	0	0	4	0	0	1	0	1	0	0	0	0	0	0	0	e = B11
4	0	0	10	0	0	0	0	3	2	0	0	0	0	0	0	f = B21
0	0	0	4	0	0	5	0	6	0	0	0	0	0	0	0	g = C11
0	0	0	3	0	0	2	8	3	0	0	0	0	0	0	0	h = C12
0	0	0	1	0	0	1	0	21	1	0	0	0	0	0	0	i = C21
0	0	0	2	0	0	1	0	0	16	0	0	0	0	0	0	j = C22
0	0	0	7	0	0	4	0	1	0	0	0	0	0	0	0	k = D11
1	0	0	8	0	0	6	1	0	1	0	0	0	0	0	0	l = D21
6	0	3	3	0	0	0	0	2	6	0	0	1	0	0	0	m = E11
10	0	0	4	0	0	0	0	3	1	0	0	0	0	0	0	n = E21
1	0	0	5	0	0	0	0	0	1	0	0	0	0	2	0	o = F21
5	0	0	1	0	0	1	0	1	0	0	0	0	0	0	0	p = NASA

Fonte: Criado pelo autor

Figura 26 – Matriz de confusão Bayes Ingênuo na Etapa 3

a	b	c	d	e	f	g	h	i	j	k	l	m	n	o	p	<-- classificado como
14	1	1	0	0	0	0	0	0	0	0	0	0	0	0	0	a = A11
1	13	1	1	0	0	0	0	0	0	0	0	0	0	0	0	b = A12
1	0	13	0	0	0	0	0	0	0	0	0	0	0	0	0	c = A21
1	1	3	11	0	0	0	0	0	0	0	0	0	0	0	0	d = A22
0	0	0	0	7	2	3	0	0	0	0	0	0	0	0	0	e = B11
0	0	0	0	0	15	0	0	4	0	0	0	0	0	0	0	f = B21
0	0	0	0	0	0	11	2	2	0	0	0	0	0	0	0	g = C11
0	0	0	0	0	0	3	10	0	3	0	0	0	0	0	0	h = C12
0	0	0	0	0	0	3	1	18	2	0	0	0	0	0	0	i = C21
0	0	0	0	0	0	0	1	0	18	0	0	0	0	0	0	j = C22
0	0	0	0	0	0	0	0	0	0	12	0	0	0	0	0	k = D11
0	0	0	0	0	0	0	1	0	0	5	11	0	0	0	0	l = D21
0	0	0	0	1	0	1	0	0	0	0	0	16	3	0	0	m = E11
0	0	0	0	0	0	0	0	0	0	0	0	0	18	0	0	n = E21
0	0	1	0	0	0	0	0	0	0	0	0	0	0	8	0	o = F21
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	7	p = NASA

Fonte: Criado pelo autor