Caio Braga Silva

Técnicas de análise de rede aplicadas para discussões polarizadas em redes sociais

Brasil

2022

Caio Braga Silva

Técnicas de análise de rede aplicadas para discussões polarizadas em redes sociais

Monografia apresentada na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro

Bacharelado em Ciência da Computação

Orientador: Celso Vital Crivelaro

Coorientador: Cristiane Yayoko Ikenaga Fernandes

Brasil

2022

Agradecimentos

Deixo agradecimentos especiais aos professores Celso, Takuno, Thiago, e Cris, que me acompanharam e aconselharam ao longo de todo esse processo. Agradeço também a meus pais e Elisa, que tiveram nos últimos meses muito mais paciência do que mereço. Por fim, um abraço especial para o gatinho Akin, que fez tudo o que pôde para otimizar o cálculo de posições de vértices em grafos.

Resumo

As plataformas de redes sociais *online* se tornaram em poucos anos parte fundamental da forma como pessoas interagem entre si. Seu crescimento não foi impactante somente numa esfera comunicativa, mas também na forma como indivíduos consomem informação e se comportam em diversas esferas sociais, de forma que entender o comportamento de indivíduos *online* é de extrema importância para setores da academia, mercado, e governo.

Apesar do amplo acesso a redes sociais, ferramentas de análise do conteúdo das discussões ainda é fortemente dependente de técnicos com conhecimentos específicos de área. Neste trabalho, são revisadas algumas das principais técnicas de análise de redes sociais, aplicadas na proposta de uma arquitetura de sistema de informação de uso geral para discussões na rede social *Twitter*. Por fim, são sugeridos trabalhos futuros que podem agregar nos tópicos discutidos.

Palavras-chave: grafos. análise de redes sociais. visualização de dados.

Abstract

Online social network platforms have quickly grown to be a fundamental method of interaction between individuals. Their growth has been impactful not only on a communicative sense, but also as a means of individuals to consume information and behave socially, making it even more relevant for scholars, businesses and government agencies to understand their behavior.

Though social media access is now common, the tools for analysing discussions on them is still heavily reliant on field-specific technical knowledge. In this paper, some of the main techniques of social network analysis are reviewed, being then applied to a information system architecture proposal for a general use analytical tool for the Twitter social network. Finally, future research relevant to the discussed topic is proposed.

Keywords: graphs. social network analysis. data visualization.

Sumário

1 INTRODUÇÃO . . . 11
1.1 Contexto . . . 11
1.2 Justificativa . . . 11
1.3 Objetivos . . . 11

2 REVISÃO BIBLIOGRÁFICA . . . 13
2.1 Análise de redes sociais como tema científico . . . 13
2.1.1 Primeiros desenvolvimentos . . . 13
2.1.2 Fundamentos modernos e aplicações . . . 13
2.1.3 Redes sociais *online* . . . 14
2.2 Técnicas de análise de rede . . . 14
2.2.1 Grafos como ferramenta para análises sociais . . . 14
2.2.2 Mensurando a relevância de indivíduos em uma rede . . . 15
2.2.2.1 Métricas comuns de centralidade . . . 15
2.2.2.2 Centralidade em sistemas de influência . . . 16
2.2.2.3 O algoritmo PageRank . . . 16
2.2.3 Determinação de comunidades em uma rede . . . 17
2.2.3.1 Algoritmos de detecção de comunidades . . . 17
2.3 Representação visual de redes sociais . . . 19
2.3.1 Algoritmos de visualização de grafos . . . 20
2.3.2 Interações na visualização de redes . . . 21
2.3.3 Pontos adicionais . . . 22
2.4 Trabalhos relacionados . . . 22
2.4.1 TURank: Twitter User Ranking Based on User-Tweet Graph Analysis . . . 22
2.4.2 Identifying the New Influencers in the Internet Era: Social Media and Social Network Analysis . . . 22
2.4.3 Beyond Fact-Checking: Network Analysis Tools for Monitoring Disinformation 23

3 DESENVOLVIMENTO . . . 25
3.1 Sobre o Twitter . . . 25
3.2 Arquitetura do sistema de análise de tópicos . . . 25
3.2.1 Infraestrutura da aplicação . . . 26
3.2.2 Ferramentas de desenvolvimento . . . 26
3.2.3 Base de dados . . . 27
3.2.3.1 Esquema dos dados . . . 27
3.2.3.2 SGBDs orientados a grafos . . . 27

3.3 Extração de dados **28**
3.3.1 APIs 28
3.3.1.1 Funcionalidades da API Twitter 29
3.3.2 Implementação do sistema 29
3.4 Análise do grafo **30**
3.4.1 Filtrando dados iniciais 30
3.4.2 Determinando usuários influentes em uma rede 30
3.4.3 Demarcando comunidades 32
3.4.3.1 Limitações da detecção de comunidades na ferramenta 32
3.4.3.2 Características de relacionamentos no Twitter 33
3.4.3.3 Otimizando a busca de comunidades 33
3.5 Exibição de dados **35**
3.5.1 Requisitos 35
3.5.2 Renderização 36
3.5.3 Funcionalidades e representação 37
3.6 Resultados **38**
3.6.1 Construção da base de dados 38
3.6.2 Análise da rede 39
3.6.3 Exibição dos dados 40

4 CONCLUSÃO **41**

5 TRABALHOS FUTUROS **43**
5.1 Análise de redes sociais **43**
5.2 Análise de tópicos de discussão **43**
5.3 Visualização de grafos **43**

REFERÊNCIAS **45**

APÊNDICES **49**

APÊNDICE A – ACESSANDO O REPOSITÓRIO DO PROJETO . **51**

APÊNDICE B – O ALGORITMO PAGERANK **53**

1 Introdução

1.1 Contexto

Plataformas de redes sociais são parte vital da forma como pessoas se relacionam no mundo moderno, com bilhões de usuários ativos interagindo entre si todos os dias. Estimativas para o ano de 2022 colocam este número em 4,62 bilhões, um crescimento anual de 10,1% (Kepios, 2022).

1.2 Justificativa

O novo paradigma de interações sociais trouxe consigo mudanças relevantes para diversas áreas da sociedade. Desenvolvimentos recentes da literatura apontam para novos padrões de comportamento em engajamento político (LEVY, 2021), saúde (TSAO et al., 2021), e consumo (FRICK et al., 2021), por exemplo.

Esferas de negócios, governo e pesquisa se adaptaram para analisar estas mudanças: A análise de redes sociais é um ramo científico de crescente relevância entre a computação e as ciências sociais (CAMBRIA, 2020), e como uma vertente da ciência de dados, emprega técnicas não muito acessíveis para um público não especializado em manipulação computacional de dados, como jornalistas e pesquisadores de áreas que não a computação.

1.3 Objetivos

Neste trabalho é proposto um sistema de informação para a análise de termos na rede social *Twitter*, utilizando de técnicas de análise de grafos para mensurar de forma visualmente acessível as principais métricas de interação entre humanos na plataforma.

Como metodologia, é desenvolvida uma ferramenta que implementa os conceitos bibliográficos apresentados, acessível publicamente e validada por uma base de dados própria. O sistema proposto é genérico, gerando análises para quaisquer termos desejados por um usuário, exibindo os principais atores e comunidades engajadas na discussão. Também é considerada a exibição de dados em massa e as otimizações de performance demandadas para tanto.

2 Revisão bibliográfica

Neste capítulo são revisados os temas de maior importância na literatura para este trabalho. Uma breve introdução sobre a ciência de análise de redes sociais é apresentada, passando por conceitos matemáticos de teoria dos grafos e algoritmos de análise de rede. Por fim, são abordados conceitos de interfaces de usuário para o problema tratado.

2.1 Análise de redes sociais como tema científico

O termo "rede social" tem forte associação contemporânea às plataformas *Web* de relacionamentos. De fato, a relevância destas ferramentas com bilhões de usuários ativos (Kepios, 2022) justifica a ressignificação do termo, que surgiu inicialmente da antropologia (CAMBRIA, 2020).

Pela sua definição tradicional, redes sociais consistem de um conjunto ou conjuntos de atores e seus relacionamentos mútuos (WASSERMAN; FAUST, 1994). Diversas aplicações tem sido encontradas para a modelagem de problemas através da análise de redes sociais (SNA), como modelos epidemiológicos na área da saúde, propaganda *boca a boca* na publicidade, detecção de notícias falsas e tendências no debate político (CAMBRIA, 2020).

2.1.1 Primeiros desenvolvimentos

As primeiras décadas do estudo de redes sociais vêm justamente das ciências humanas. Cambria (2020) encontra na análise de citações um pico de publicações dos anos 60, 70, e 80 na área das ciências sociais, tratando de princípios básicos da análise de redes sociais como influenciadores e a difusão de informação por seu intermédio.

Sánchez-Cabezudo (2016) fazem um breve sumário de alguns destes conceitos primários, abordando a ideia de "líderes de opinião" desde sua caracterização inicial centrada na mídia, na forma de um modelo unidirecional. Críticas posteriores ressaltaram a importância de aspectos informais e da comunicação interpessoal, o que os autores destacam exponencialmente mais importante em uma era de redes sociais *online*.

2.1.2 Fundamentos modernos e aplicações

Dos anos 2000 em diante, Cambria (2020) nota o movimento para o desenvolvimento de métodos e técnicas baseadas em conceitos prévios. As principais publicações passam para as áreas de física, matemática, e ciência da computação, com grande presença da

análise estrutural de redes sociais, isto é, a busca por padrões em modelos de interação social.

Wasserman e Faust (1994) citam alguns conceitos fundamentais da análise de redes sociais, sendo eles:

- Atores e suas ações são considerados interdependentes entre si, e não indivíduos autônomos
- Ligações entre atores são canais de fluxo de recursos, materiais ou não
- As características de uma estrutura de rede conceptualizam uma estrutura - seja social, política, econômica, ou outra - como padrões duradouros entre atores

Assim, o tipo de análise aqui tratado é intrinsecamente sobre o efeito de ações em cadeia e sua propagação por um meio.

2.1.3 Redes sociais *online*

O surgimento de redes sociais *online* ocorre no fim dos anos 90, com a criação de plataformas como o *SixDegrees.com*. Para Sánchez-Cabezudo (2016), as plataformas de redes sociais introduziram a oportunidade de que todo indivíduo se torne uma fonte de *micro mídia*, sendo ao mesmo tempo consumidor e influenciador. A quantidade massiva de dados gerados se tornou alvo de grande interesse de pesquisadores da área, dado seu caráter focado em conexões e interações entre membros, de representação natural em uma abstração de grafos.

Entre as plataformas de redes sociais *online* modernas, o *Twitter* tem sido objeto de diversas em variados campos do conhecimento. Além de fornecer ferramentas acessíveis para a obtenção de dados da plataforma por meio da sua API (Twitter Developer, 2022), o enfoque mais unilateral da ferramenta (i.e. *seguidores* ao invés de *amigos*, mais discutido na seção 3.1) e suas formas de interação são frequentes alvos de estudo de relações de poder e influência, bem como seus mecanismos de republicação (*retweets*) tem sido frequentemente adotados como formas de endosso na literatura (KITAGAWA, 2010).

2.2 Técnicas de análise de rede

2.2.1 Grafos como ferramenta para análises sociais

Como abordado na seção 2.1.2, problemas modelados por análise de redes sociais têm, entre seus focos primários, a análise entre os relacionamentos de seus subconjuntos constituintes. Grafos são uma abstração tipicamente empregada aqui, tanto em sua forma

algébrica como sociométrica, já que redes sociais podem ser facilmente representadas por vértices como seus atores, e por arestas em seus relacionamentos. Assim, define-se um grafo G qualquer como $G = (V, A)$, com V sendo o conjunto de seus vértices, e A de suas arestas.

Uma característica útil de grafos é serem ou não *dirigidos*. Considerando vértices ligados n_1 e n_2, uma aresta dirigida cria uma relação *de* n_1 *para* n_2, por exemplo, como uma viagem da cidade n_1 para a cidade n_2. Uma representação não dirigida, por sua vez, define uma relação sem referenciais do tipo, como "n_1 é amigo de n_2". (WASSERMAN; FAUST, 1994)

2.2.2 Mensurando a relevância de indivíduos em uma rede

Ao observar redes sociais, é possível assumir que em grande parte dos casos há atores mais relevantes no contexto representado. Num modelo epidêmico, por exemplo, um pesquisador poderia considerar como mais importantes os indivíduos que tiveram contato social mais elevado com outros membros daquele universo. A métrica utilizada para identificar vértices proeminentes em um grafo é denominada *centralidade*.

2.2.2.1 Métricas comuns de centralidade

Em seu livro, Luke (2015) cita três das mais comuns técnicas de definição de centralidade:

- A **centralidade de grau** considera como mais relevante um vértice que possua mais arestas conectadas a si, ou o seu *grau*. Assim, ela é definida exatamente como o grau do vértice, onde, para um vértice v: $Cg(v_i) = G(v_i)$. A figura 1.a mostra um grafo com centralidade de grau aplicada.

- A **centralidade de proximidade** observa o quão *próximo* um vértice é dos demais em sua rede, com maiores valores indicando menor *distância* - o número da menor quantidade de arestas ligando dois vértices (caminho) - média entre eles. Matematicamente, ela é calculada pela inversa da soma de todas as distâncias entre um vértice i e os demais da rede: $Cp(V_i) = [\sum_{j=1}^{g} d(v_i, v_j)]^{-1}$. A figura 1.b exibe um grafo com centralidade de proximidade aplicada.

- **Intermediação** é a métrica que mede o quão intermediário um vértice é aos demais da rede, de forma que o menor caminho entre estes passe pelo vértice mensurado. Ela é definida portanto pela distância entre dois vértices j e k, tal que $Ci(v_i) = \sum_{j<k} d_{jk}(v_i)/g_{jk}$, onde g é o número de distâncias entre j e k contendo o vértice i. A figura 1.c mostra um grafo com intermediação aplicada.

Os algoritmos acima servem como um bom guia das diferentes formas como se pode interpretar a relevância de um ator em uma rede, e possuem diversas aplicações na análise de redes sociais. Uma de suas características, porém, é considerar todos os vértices com o mesmo peso durante o cálculo, o que pode ser indesejável para modelos de propagação.

2.2.2.2 Centralidade em sistemas de influência

Uma hipótese comum na modelagem de grafos de influência é que o endosso de alguns atores é mais importante que o de outros, de menor prestígio na rede. A **centralidade de autovetor** se difere por considerar que nem todas as conexões são iguais, dando maior peso para vértices com mais vizinhos, especialmente os mais influentes. Newman (2008) descreve matematicamente o algoritmo: Seja a centralidade de um vértice i denominada c_i, tornamos ela proporcional à média das centralidades de seus vizinhos da rede.

$$c_i = \frac{1}{\lambda} \sum_{j=1}^{n} A_{ij} c_j \tag{2.1}$$

Onde, para a centralidade c de um vértice i, A é a matriz de adjacência do grafo, e λ é um valor constante correspondente ao maior autovalor da matriz de adjacência para o autovetor correspondente.

Com esta métrica, um vértice de muitos vizinhos pode ter uma centralidade menor do que a de um com menor quantidade, porém de centralidade média mais elevada. A figura 1.d exibe um grafo com centralidade de autovetor aplicada.

2.2.2.3 O algoritmo PageRank

Baseados na centralidade de autovetor, Page et al. (1998) propõem uma métrica otimizada para um contexto de ranqueamento de páginas *web*, base do que viria a ser a ferramenta *Google*. A *web* aqui é abstraída como um grafo de páginas (vértices) ligadas por hiperlinks (arestas).

Ordenar conteúdos tão distintos por relevância pede mais do que somente uma métrica de centralidade simples. Os autores usam o mesmo princípio de pesos diferentes para vizinhos com influências diferentes, mas com uma principal discrepância: o algoritmo leva o direcionamento das arestas em consideração, calculando centralidade com base no *grau de entrada* e no respectivo peso de seus vértices iniciais.

O algoritmo demonstrou sucesso no produto para o qual foi desenvolvido, mas também teve aplicações encontradas em diversas outras áreas, como a análise de redes sociais *online* (KITAGAWA, 2010). Uma explicação mais aprofundada sobre seu funcionamento está disponível no apêndice B.

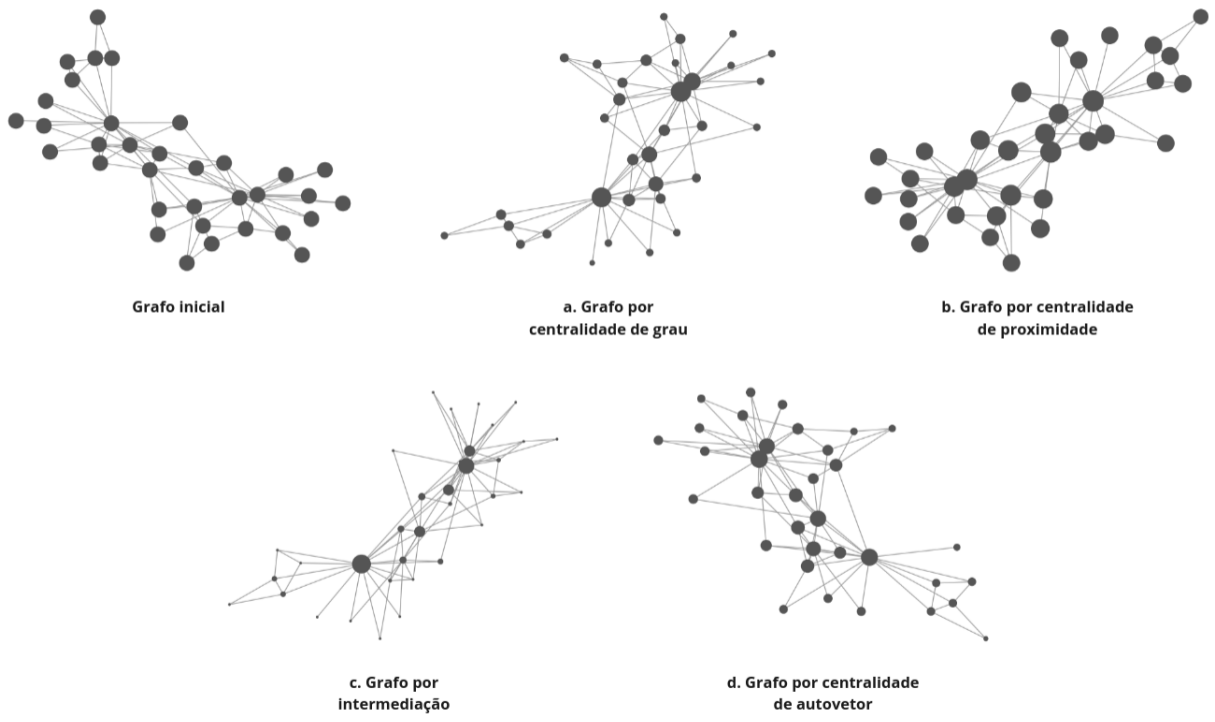

Figura 1 – Diferentes aplicações de centralidades no mesmo grafo. Elaboração própria.

2.2.3 Determinação de comunidades em uma rede

O cálculo de centralidades é uma das dimensões da análise de rede, determinando a relevância individual de um ator naquele conjunto. De forma complementar, as comunidades oferecem uma visão coletiva do relacionamento entre as entidades como um todo, sendo também um importante ponto focal.

A detecção de comunidades, técnica também definida como *agrupamento*, é um problema que envolve a partição de uma rede em comunidades de vértices densamente conectados, segregando-as de outras comunidades com as quais possuem uma quantia menos densa de arestas. Não há, porém, uma definição amplamente aceita do que é uma comunidade, o que, por um lado, permite a implementação de técnicas distintas para a resolução do problema, mas, por outro, impede diretrizes claras de comparação entre algoritmos (FORTUNATO; HRIC, 2016).

2.2.3.1 Algoritmos de detecção de comunidades

Khan e Niazi (2017) fornecem uma visão geral dos principais algoritmos de detecção de comunidades existentes. Sua categorização pode ser feita entre técnicas *aglomerativas* e *divisivas*: na primeira, cada vértice é iniciado como uma comunidade independente, unindo-se iterativamente aos seus pares mais similares para formar comunidades maiores; na segunda, a rede inteira é considerada inicialmente como uma única comunidade, sendo iterativamente dividida entre vértices de baixa similaridade.

De forma geral, os algoritmos descritos buscam otimizar funções objetivo, como a *modularidade*, métrica de coesão entre vértices de um subgrafo. É importante notar que o cálculo exato de modularidade é um problema do tipo NP-completo, e os algoritmos utilizados são heurísticas para aproximação do resultado em tempo computável que podem resultar em soluções subótimas (BRANDES et al., 2006). Uma definição aproximada de modularidade é dada pela seguinte fórmula:

$$Q = \sum_{i=1}^{m} [\frac{l_i}{L} - (\frac{g_i}{2L})^2] \tag{2.2}$$

Onde, para o cálculo de modularidade Q, m é o número de módulos, L é a quantidade de arestas, l_i corresponde à aresta i, e g é o grau dos vértices para o módulo i.

Um dos exemplos mais populares é o algoritmo divisivo *Girvan-Newman* (GIRVAN; NEWMAN, 2002), que remove arestas iterativamente com base em um coeficiente de intermediação, e então calcula a modularidade do sistema até sua estabilização. Sua complexidade em pior caso é de $O(m^2n)$, o que o torna computacionalmente custoso para grandes redes.

Uma alternativa mais rápida é o algoritmo de *Louvain* (BLONDEL et al., 2008), de abordagem aglomerativa. Trata-se de um algoritmo *guloso* - que busca otimizar o valor máximo local para a presente iteração - que une um vértice à comunidade vizinha se houver uma mudança positiva de modularidade, permanecendo na atual caso isso não seja verdadeiro, até uma estabilização da rede. Após o cálculo de modularidade, os vértices são então unidos em um *super vértice*, eliminando a necessidade de iterar por todos os membros que ali estavam. Graças a isso, o algoritmo tem complexidade $O(n\ log(n))$. Uma representação em pseudocódigo para o algoritmo é descrita no algoritmo 1.

Algoritmo 1: Representação em pseudocódigo do algoritmo de *Louvain*

```
Entrada: G_0 - grafo inicial
Saída: P_0 - lista de partições de G
para cada v ∈ V faça
    particao ← v
    modularidade_v = modularidade(particao)
fim
para cada v ∈ V faça
    para cada u ∈ vizinhos(v) faça
        modularidade_uv = modularidade(u, v)
        se modularidade_uv > modularidade_v então
            particao ← (u, v)
        fim
        v ← particao
    fim
fim
```

2.3 Representação visual de redes sociais

Tão importante quanto os dados extraídos de um grafo são a forma de sua exibição. A quantidade massiva de informação geralmente contida em uma análise de redes sociais *online* torna inviável a simples observação de dados tabulares, de forma que uma boa apresentação visual deve apresentar forma concisa as principais respostas para o problema em questão.

Cambria (2020) destaca sociogramas (figura 2) e diagramas de matriz (figura 3) como as mais comuns formas de representação presentes na literatura. Na primeira, os atores da rede são representados por vértices, e as interações que realizam entre si são arestas, direcionadas ou não.

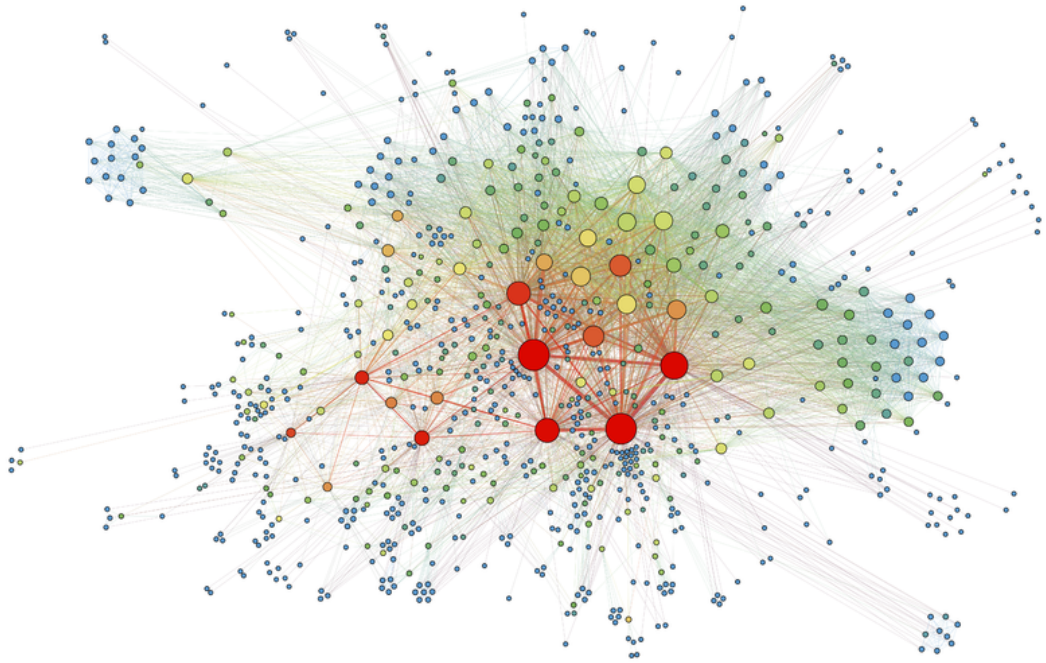

Figura 2 – Visualização de sociograma (Contribuidores Wikipedia, 2022)

Diagramas de matriz, por sua vez, são de utilização mais comum em redes com atores não muito distantes um dos outros, o que pode tornar confusa a visualização por outros métodos. Aqui, os membros são mapeados em colunas e linhas de uma matriz, onde células presentes são preenchidas, com elementos ligados diretamente adjacentes a elas.

Focaremos aqui na visualização de sociograma, que apresenta uma representação familiar de exibição de grafos, tendo também uma maior facilidade de *seriação*, isto é, de identificação dos caminhos internos da rede.

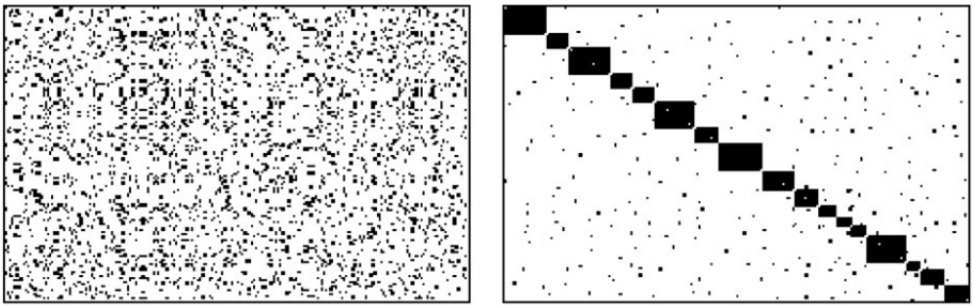

Figura 3 – Visualizações randomizada (esquerda) e agrupada (direita) em diagrama de matriz (SCHAEFFER, 2007)

2.3.1 Algoritmos de visualização de grafos

A organização de milhares de vértices em espaço cartesiano não é computacionalmente trivial. Luke (2015) elenca cinco principais objetivos para uma visualização de rede legível:

- Minimização de cruzamentos entre arestas.
- Maximização de simetria no leiaute dos vértices.
- Minimização da variação entre o comprimindo de arestas.
- Maximização do ângulo entre arestas quando elas cruzam ou se ligam a vértices.
- Minimização do espaço total usado para a exibição da rede.

Com o objetivo de colocar vértices próximos aos quais se conectam por arestas, minimizando a sobreposição de conexões entre vértices distantes, uma das principais técnicas empregadas é a de modelos direcionados por força, como proposto por Fruchterman e Reingold (1991), citado por Cambria (2020) como um dos principais algoritmos utilizados no presente.

Em seu artigo, os autores descrevem uma organização baseada em uma simulação física, com vértices atuando como "elétrons de carga positiva", e suas conexões como molas. Isso significa que há repelência mútua entre vértices, e as "molas" impedem que haja distanciamento muito elevado. O algoritmo *Fruchterman-Reingold*, que leva o nome de seus autores, tem uma execução iterativa, de forma que a simulação continue até uma quantidade determinada de iterações, ou até que o sistema se estabilize. Um exemplo de execução do algoritmo pode ser visto na figura 4.

O algoritmo, bem como seus pares direcionados por força, é não determinístico, de forma que múltiplas execuções não devem resultar em redes iguais. Ainda assim, a forma final tende a seguir os padrões estéticos propostos na lista acima (LUKE, 2015).

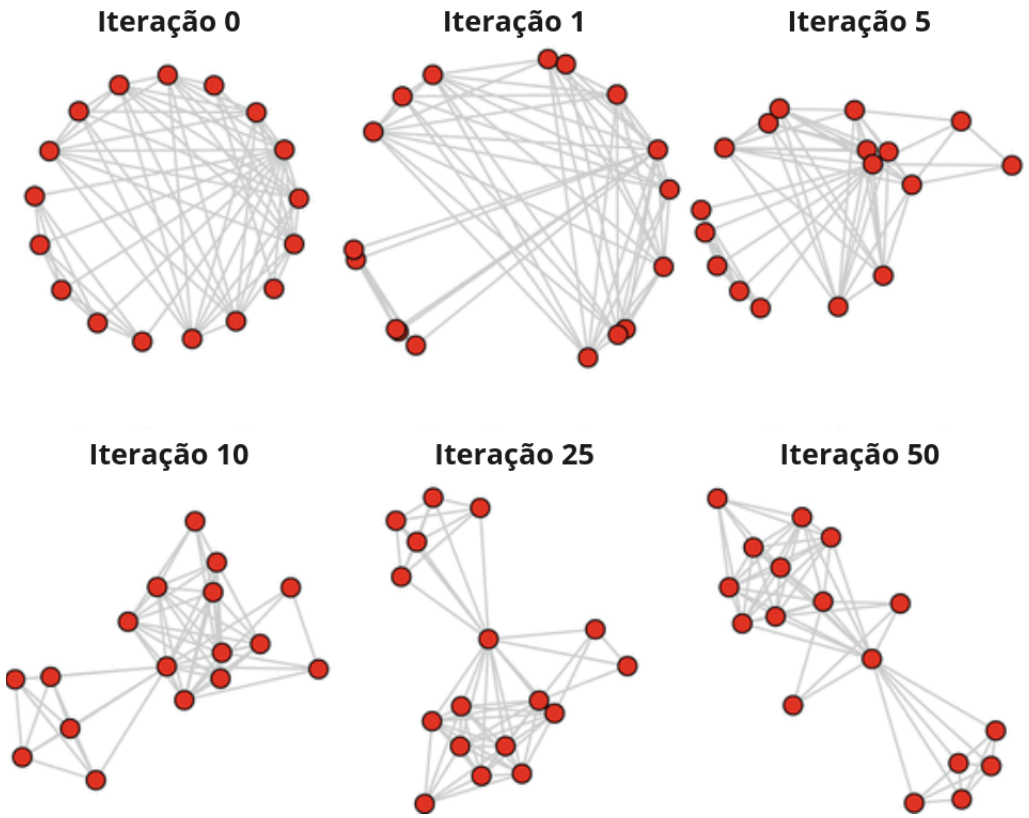

Figura 4 – Evolução iterativa do algoritmo *Fruchterman-Reingold*. Fonte: (LUKE, 2015). Adaptado pelo autor.

2.3.2 Interações na visualização de redes

Uma visualização de rede adequada não se resume somente à exibição estática da informação. Cambria (2020) coloca a interatividade, ou a capacidade de uma ferramenta de adaptar seus resultados gráficos às necessidades de um usuário, como um dos principais pontos na visualização de redes.

O artigo cita como uma das principais publicações com diretivas de usabilidade o artigo de Shneiderman (1996), que define um "mantra de visualização": Visão geral primeiro, zoom e filtros, e então detalhes sob demanda. As diretivas são postas pelo aumento da dificuldade de se explorar informação conforme seu volume cresce. Expandindo sobre os pontos relevantes para este trabalho:

- Visão geral: O ponto inicial de uma visualização deve ser um sumário de todos os seus itens.
- Zoom: Itens de interesse devem permitir uma visão aproximada, dando ao usuário o controle de aproximação do que deseja focar.
- Filtros: Usuários devem poder filtrar itens que não os interessam, deixando apenas conteúdo relevante.

- Detalhes sobre demanda: Itens desejáveis devem possuir ações de detalhamento, omitidos inicialmente para não poluir a visualização, mas facilmente acessáveis quando desejado.

- Relacionar: Os relacionamentos entre os componentes de uma visualização devem ser facilmente acessíveis pelos seus utilizadores, expandido informações sobre o que for considerado relevante.

2.3.3 Pontos adicionais

Cambria (2020) também cita "volume" como um dos principais elementos de uma visualização bem sucedida. Considerando o caráter massivo dos dados de interações entre usuários em plataformas de redes sociais, uma ferramenta de visualização deve permitir o processamento e exibição de um elevado número de dados, tendo também em mente a acessibilidade de recursos computacionais para usuários regulares.

2.4 Trabalhos relacionados

2.4.1 TURank: Twitter User Ranking Based on User-Tweet Graph Analysis

Kitagawa (2010) utiliza uma implementação do algoritmo PageRank para determinar usuários "autoridade" entre participantes de discussões da plataforma *Twitter*. Diferentes algoritmos são testados em comparação ao proposto, denominado *ObjectRank*, encontrando boa efetividade na determinação de autoridades. Os autores também destacam a importância de *retweets* na análise dos tópicos, em contraponto a propostas anteriores que faziam uso de *seguidores*, somente.

2.4.2 Identifying the New Influencers in the Internet Era: Social Media and Social Network Analysis

Sánchez-Cabezudo (2016) propõem uma combinação de métricas de centralidade de grau e intermediação para identificar os atores centrais em um grafo de discussão da plataforma *Twitter*. Uma classificação relevante é a caracterização destes influenciadores, que são divididos em três categorias: disseminadores, que maximizam sua eficiência comunicativa; engajadores, que maximizam relacionamentos com terceiros; e líderes, que ocupam postos de evidência em ambas as posições.

2.4.3 Beyond Fact-Checking: Network Analysis Tools for Monitoring Disinformation

Guarino et al. (2019) propõem uma arquitetura de sistema empregando diversas técnicas estatísticas, aprendizado de máquina, e análise de redes para checagem de fatos automatizada, alguns temas fora do escopo deste trabalho. O desenho do sistema, porém, é de grande utilidade para o tema aqui tratado, com funcionalidades modularizadas que englobam coleta de dados, análise, e visualização, categorias que serão abordadas no próximo capítulo.

3 Desenvolvimento

Neste capítulo são relatados a arquitetura e o processo de desenvolvimento de um sistema Web para análise de discussões polarizadas em redes sociais. São tratadas as ferramentas, algoritmos, e a execução do projeto, conforme fundamentado no capítulo 2. Ao final, são simulados cenários de exemplo com diferentes termos, mensurando a funcionalidade da ferramenta. O código desenvolvido pode ser acessado no apêndice A.

3.1 Sobre o Twitter

Fundado em 2006, o Twitter é uma das mais populares redes sociais atualmente utilizadas (Kepios, 2022). Usuários interagem por mensagens públicas limitadas a 280 caracteres, chamadas *tweets*. *Tweets* de um dado usuário podem ser vistos agrupados em sua página de perfil.

A exibição de conteúdo da plataforma se dá primariamente por contas das quais um usuário é *seguidor*, manifestando interesse em visualizar as interações da mesma. Uma característica da plataforma é que ao contrário de mecânicas de "amizade", em que dois usuários só subscrevem aos seus conteúdos respectivos mutuamente, a ação "seguir" é unilateral, dando espaço a perfis com alto grau de engajamento em suas publicações (aqui chamados "influenciadores").

Também relevante a este trabalho é a forma como os membros da plataforma interagem entre si. No Twitter, um usuário pode realizar *retweets* sobre qualquer *tweet*, republicando o conteúdo para seus seguidores. Uma alternativa a estes são as *mentions*, em que um usuário republica uma mensagem com a adição de novo conteúdo. Adicionalmente, a plataforma também disponibiliza "respostas", de forma que um *tweet* seja diretamente exibido na discussão da publicação original.

3.2 Arquitetura do sistema de análise de tópicos

Conforme definido na seção 2.2, um sistema de visualização de dados tem entre suas principais competências a extração dos dados, a análise, e a exibição destes. Desta forma, a ferramenta desenvolvida neste trabalho foi organizada em uma arquitetura monolítica abrangendo cada uma destas etapas. Um fluxograma geral pode ser visto na figura 5.

A aplicação é aqui definida pelo todo das funcionalidades em funcionamento conjunto, divida a seguir entre *back-end* e *front-end*. Considerando o modelo cliente-servidor empregado na *web*, o primeiro se refere à manipulação, armazenamento, e processamento

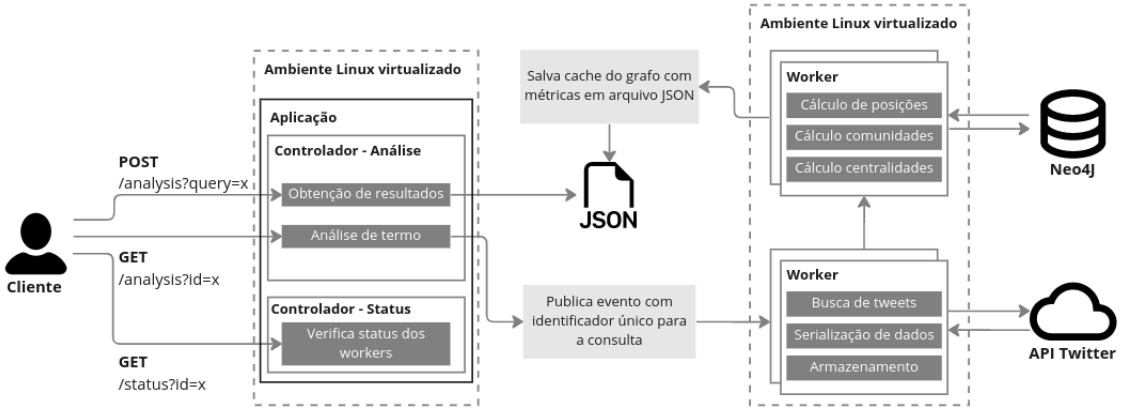

Figura 5 – Arquitetura geral do sistema. Imagem do autor.

dos dados em questão pelo servidor, enquanto o segundo se refere à exibição destes pelo cliente.

3.2.1 Infraestrutura da aplicação

Conforme mencionado, o *back-end* da aplicação segue uma arquitetura monolítica, isto é, tendo uma base de código comum para todas as suas funcionalidades. No contexto deste trabalho, isso abrange implementações de rede, banco de dados, comunicação com serviços externos, e processamento de dados.

A arquitetura monolítica não significa, porém, que todos os componentes do sistema compartilhem os mesmos recursos computacionais. O *back-end* se divide entre a aplicação, que recebe requisições por meio de um servidor HTTP, os processa e orquestra as outras ações, *workers* para processamento assíncrono que demanda mais tempo (descritos com maior detalhe na seção 2.2), e a instância do banco de dados da aplicação.

3.2.2 Ferramentas de desenvolvimento

Para garantir a replicabilidade e escalabilidade da aplicação, os diferentes componentes são executados em *containers* da ferramenta *Docker*. Um *container* é uma unidade de software que encapsula todo o código e dependências necessárias para sua execução, sendo executado de forma isolada do sistema operacional, e sendo rodado em uma versão miniaturizada própria de sistema - chamada imagem, aqui uma virtualização de sistema *Linux*. É possível executar múltiplos *containers* paralelamente, de forma a aumentar o desempenho de uma funcionalidade (Docker, 2022).

Para o desenvolvimento da aplicação foi escolhida a linguagem de programação *Python* (Python, 2022), decisão motivada principalmente pela grande disponibilidade de bibliotecas e suporte de ferramentas externas, o que será discutido nas próximas seções.

Uma ferramenta relevante é a biblioteca *Celery*, utilizada para a gestão de filas de tarefa distribuídas (Celery, 2022). O conceito de "tarefa" é fundamental para a implementação deste trabalho: Dada a complexidade de muitos dos algoritmos utilizados, bem como a dependência em serviços externos, é inviável usar uma arquitetura de sistema web baseado em requisições com respostas síncronas. Ao invés disso, o sistema valida o conteúdo das requisições à API, e então sinaliza o início do processamento ao cliente, que é dado pela adição de uma nova tarefa à fila. O conteúdo da fila é consumido por um *worker*, máquina dedicada a processamento que trabalha sob demanda com o conteúdo enfileirado.

3.2.3 Base de dados

Os dados analisados estão no centro das funcionalidades da aplicação. Eles são extraídos conforme consulta realizada pelo cliente (detalhado na seção 3.3), e então armazenados para processamento. Dessa forma, uma das principais decisões na arquitetura do sistema é o banco de dados utilizado, sendo altamente dependente do modelo de dados escolhido.

3.2.3.1 Esquema dos dados

Considerando o objetivo de mapear relações entre usuários e detectar grupos de opinião em análises de redes sociais, o modelo escolhido para armazenamento no banco de dados consiste em um grafo direcionado tendo usuários como vértices, e usando interações entre *tweets* para definir suas arestas.

Como definido na seção 2.1.3, *retweets* são definidos na literatura como uma das mais confiáveis formas de endosso entre perfis da rede social. Assim, para a análise da ferramenta, temos um grafo de usuários conectados por *retweets*, onde, seja um grafo com um conjunto de usuários U ligados por *retweets* R dado por $G = (U, R)$, a conexão entre dois usuários u_1 e u_2 se dá por uma aresta u, tal que $retweet(u_1, u_2)$ seja verdadeiro.

O modelo de grafo definido acima é fundamental não somente para documentar como os dados serão acessados e escritos, mas também na escolha do banco de dados do sistema, como mostra a próxima seção.

3.2.3.2 SGBDs orientados a grafos

Sistemas de informação modernos são em boa parte possibilitados pela capacidade de armazenamento de longo prazo para os dados relevantes aos seus modelos de negócio. Diversos paradigmas de banco de dados foram desenvolvidos ao longo das últimas décadas, com diversas aplicações para diferentes necessidades. A interface pela qual um operador

gerencia um banco de dados é chamada "Sistema de Gerenciamento de Banco de Dados", ou SGBD.

O modelo relacional, proposto inicialmente no começo dos anos 70 (CODD, 1970) e desde então o paradigma dominante nas bases de dados de uso geral utilizadas em sistemas computacionais (DB-Engines, 2021), é uma escolha natural para persistência de dados. Para problemas de análise de redes sociais, porém, é importante considerar as características fortemente baseadas em relacionamentos entre objetos. Vicknair et al. (2010) comparam consultas envolvendo travessia de grafos entre bancos de dados relacionais e orientados a grafo, obtendo resultados mais performáticos nos últimos. Isso se justifica pela estrutura dos dados armazenados, observando os requisitos de performance citados pelos autores:

- Ter muitos relacionamentos *muitos-para-muitos*.
- Ter características de árvore.

Os itens apresentados se encaixam no modelo definido na seção 3.2.3.1, afinal, o relacionamento *usuário-retweet-usuário* é exatamente o tipo de relacionamento *muitos-para-muitos* com o qual o paradigma de grafos possui uma vantagem performática, e o que fundamentou sua escolha.

3.3 Extração de dados

3.3.1 APIs

APIs - *Application programming interfaces*, ou interfaces de programação de aplicação - são definidas por Boateng, Ofoeda e Effah (2019) como "pacotes de coleção de código, providos de interfaces que auxiliam outros desenvolvedores a utilizá-los", o que, numa visão prática, facilita a comunicação entre *softwares*. Os autores também pontuam que, apesar de terem sua existência datada desde a introdução de computadores pessoais, a popularização do termo ocorreu principalmente em torno de APIs web, que são os objetos de integração deste trabalho.

De forma sucinta, uma API web fornece um contrato para o processamento de dados estruturados entre sistemas de informação. Especificamente, se tratando da API do Twitter utilizada neste trabalho, trata-se de uma forma facilmente integrável para recuperar dados de *tweets* e seus autores, junto com metadados como datas de criação, informações secundárias de usuário, e afins, de forma oficialmente suportada pela plataforma. Para a integração, foi escolhida a biblioteca Python *Tweepy* (Tweepy, 2022).

3.3.1.1 Funcionalidades da API Twitter

O Twitter oferece uma API REST disponibilizando as principais funcionalidades da plataforma, como a criação de *tweets*, *retweets*, e o acesso a conteúdo da plataforma, no qual a implementação será focada. Utilizando o *endpoint* de busca de *tweets*, é possível obter até 100 publicações para uma única chamada, através de uma consulta determinada pelo cliente. É possível solicitar também parâmetros adicionais, como dados do autor e do conteúdo mencionado na publicação, se houver (Twitter Developer, 2022).

3.3.2 Implementação do sistema

O desenvolvimento inicial do sistema vem baseado na definição de modelo e fonte de dados. O primeiro passo é uma interface de busca e processamento para termos que um usuário deseja acompanhar, construindo o grafo inicial da rede social desejada.

O *endpoint* de criação de análise é o meio pelo qual um cliente requisita a busca por *tweets* de um novo termo. O controlador valida os parâmetros necessários da requisição, como se a consulta e a data inicial das postagens foram fornecidas. Se sim, retorna uma resposta HTTP aceitando a requisição, e inicia uma tarefa assíncrona para a construção dos dados.

Considerando que a API do Twitter limita a 100 o número máximo de *tweets* que podem ser buscados por transição, parte do trabalho aqui é realizar múltiplas requisições de forma a criar um lote de mensagens. Uma das funcionalidades da API é a busca a partir de um ID de *cursor*, isso é, retornando registros a partir da criação de um primeiro ID. Assim, múltiplas requisições são feitas buscando publicações mais recentes, serializando os dados e associando *tweet*, autor, e *tweet* e autor mencionados, se houver. O lote de dados é então escrito na instância Neo4j, associando autores a autores mencionados.

Ao fim da execução, uma nova tarefa de análise do grafo é adicionada à fila de execução.

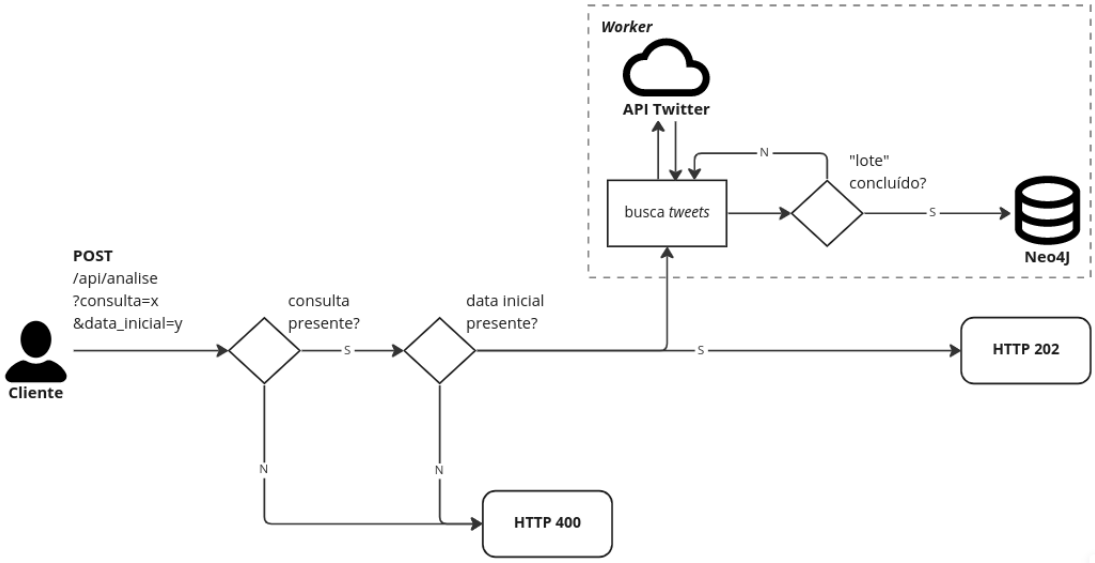

Figura 6 – Fluxo de busca de *tweets*. Realização própria.

3.4 Análise do grafo

A segunda tarefa tem por objetivo calcular as métricas relevantes do grafo, conforme abordado na seção 2.2. A biblioteca *NetworkX*, um pacote de código Python implementando diversas estruturas de dados e algoritmos de grafos, permite a execução otimizada de técnicas de análise de redes em uma interface comum, sendo escolhida para os casos de uso deste tópico (NetworkX, 2022).

3.4.1 Filtrando dados iniciais

O primeiro passo é o filtro dos dados relevantes, removendo ruídos que podem prejudicar a legibilidade e análise posterior do gráfico. Assim, é selecionado o maior subgrafo da rede, removendo vértices isolados e sem participação relevante no tópico. Também são removidos *laços*, ou arestas ligando um vértice a si mesmo, que aqui representariam *retweets* de um usuário sobre suas próprias publicações. A figura 13 mostra um dado não filtrado (figura a) e seu resultado após filtro (figura b).

3.4.2 Determinando usuários influentes em uma rede

O grafo resultante da remoção de vértices qualificados como ruído para a análise é uma grande rede conexa de influenciados e influenciáveis, que serão determinados por meio das técnicas abordadas na seção 2.2.2.

Sendo uma rede direcionada de influência, o algoritmo *PageRank* é utilizado no ranqueamento de atores. O resultado desejado é um em que *retweets* somem na influência do vértice destino de uma conexão, que será determinada pela influência do vértice *origem*.

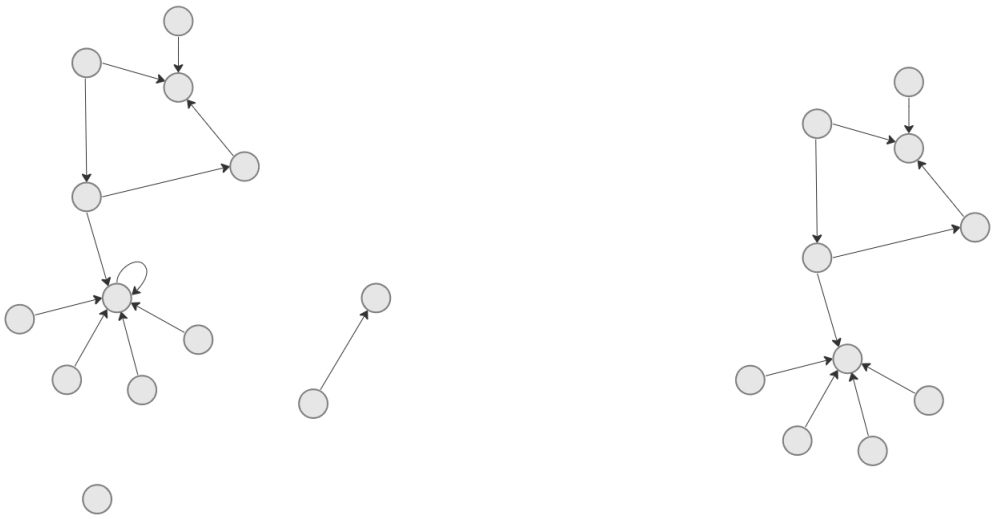

Figura 7 – Filtro de dados da rede. Realização própria.

A figura 8 mostra o após da aplicação do algoritmo, com vértices maiores sendo os de mais alta centralidade.

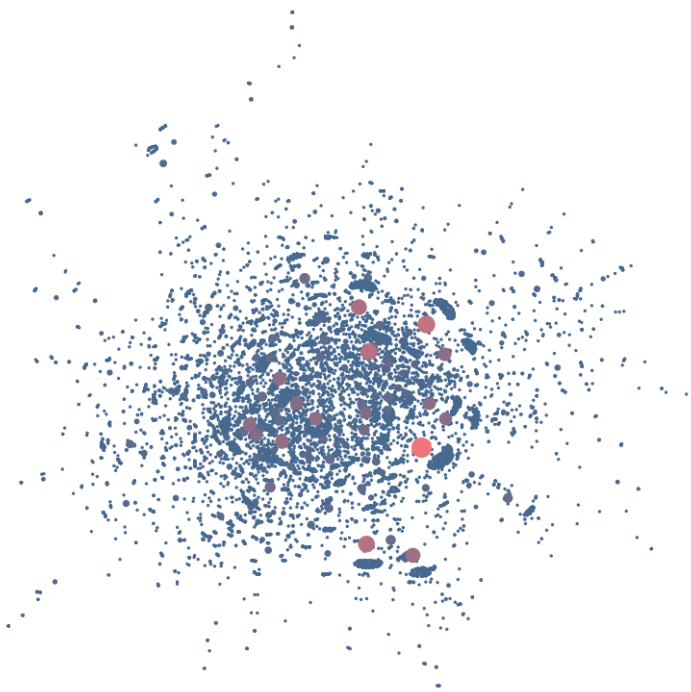

Figura 8 – Grafo com influenciadores demarcados com o algoritmo *PageRank*. Elaboração própria.

3.4.3 Demarcando comunidades

A terceira dimensão de análise, tratada na seção 2.2.3, é a determinação de comunidades presentes no grafo. Os dados exibidos até aqui foram exemplos citados de outros trabalhos e/ou pequenas redes elaboradas para testes. Nesta seção, porém, será utilizada uma base de dados própria da ferramenta construída - descrita na seção 3.6.1 - com pouco mais de 26,000 vértices coletados de *tweets* sobre as eleições presidenciais brasileiras de 2022. Os dados extraídos diretamente da plataforma ajudarão a entender as especificidades do que foi implementado.

3.4.3.1 Limitações da detecção de comunidades na ferramenta

O algoritmo de *Louvain*, discutido na revisão bibliográfica, se mostra como uma opção rápida e eficiente, mas sua simples aplicação se mostra ineficaz. A imagem 9 mostra o resultado de sua aplicação imediata, com cores distintas representando diferentes grupos.

Figura 9 – Exibição de comunidades com aplicação direta do algoritmo de *Louvain*, com 71 comunidades. Elaboração própria.

O resultado da figura é pouco expressivo, com grupos extremamente fraturados que não informam nada sobre o agrupamento de usuários na rede. Para compreender o problema, é importante reforçar a forma como os relacionamentos da rede formam a sua estrutura.

3.4.3.2 Características de relacionamentos no Twitter

A seção 3.2.3.1 determina o esquema de dados de usuários conectados através de *retweets*. Uma análise desta interação mostra que quase 95% dos usuários da base de dados tem grau igual a um, ou seja, realizaram uma única republicação, sem qualquer tipo de engajamento entre outros usuários.

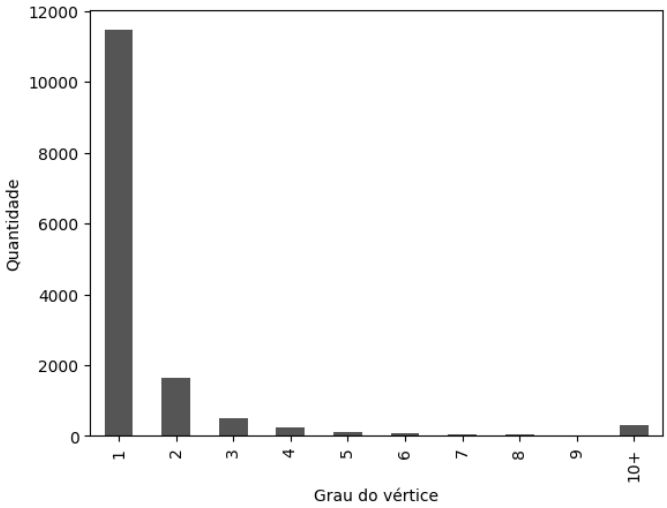

Figura 10 – Distribuição de grau entre vértices da rede. Elaboração própria.

A implicação do número apresentado é de que a grande maioria dos vértices são *folhas*, isto é, componentes terminais do grafo, não fazendo parte de nenhum caminho que não para eles mesmos. Também é notável a grande presença de vértices de grau igual a dois, que no máximo constituem pontes simples entre dois outros. O principal ponto aqui é que não há, na maior parte dos casos, o tipo de formação triangular que aumenta a densidade de um subgrafo, o que prejudica a otimização local de modularidade.

3.4.3.3 Otimizando a busca de comunidades

Como visto na seção 2.2.3, o cálculo de modularidade busca sempre otimizar o máximo local para os vizinhos de um vértice em uma iteração. Dadas as particularidades do tipo de rede modelada aqui, não é possível simplesmente aplicar o algoritmo proposto.

Como ficou claro nas figuras 8 e 10, há uma enorme quantidade de *replicadores* que somente compartilham conteúdo de uma pequena quantidade de *influenciadores*. A forma com que influenciadores se conectam, portanto, é feita através dos usuários que podem ser denominados *ponte*: replicadores que conectam ligam dois usuários de maior influência ao compartilhar conteúdo de ambos.

Com os dados mostrados acima, fica claro que há uma distribuição bastante desigual na influência de usuários. O primeiro passo na construção de um subgrafo de influenciadores, então, é a seleção dos *outliers* da distribuição. A ideia adotada, logo, é a criação de um

subgrafo constituído somente por *influenciadores*, selecionando vértices a mais de três desvios da tendência geral observada - número pouco maior do que uma centena de vértices. A figura 11 mostra os vértices selecionados em cor destacada.

Figura 11 – Subgrafo de influenciadores. Elaboração própria.

A seleção de somente influenciadores tem um problema: são usuários que engajam primariamente por conteúdo próprio, dificilmente compartilhando conteúdo de terceiros. O resultado é que o subgrafo resultante não possui ligações suficientes para qualquer tipo de análise, com vértices ilhados.

Voltando à definição de usuários ponte, sabe-se que os vértices ali presentes são indiretamente conectados entre si, restando saber de quais são mais próximos. Como o algoritmo de *Louvain* permite o cálculo de arestas ponderadas, ligamos todos os vértices do subgrafo aos seus pares para os quais possuem um caminho, de forma que uma aresta A entre dois vértices i e j tenha um peso inversamente proporcional à distância entre eles.

$$A_{ij} = \frac{1}{d(v_i, v_j)} \tag{3.1}$$

Por fim, basta restaurar os vértices de menor centralidade anteriormente removidos, atribuindo sua comunidade à do influenciador menos distante. A figura 12 exibe o grafo resultante, com duas comunidades bem definidas.

Figura 12 – Execução refinada da detecção de comunidades. Elaboração própria.

3.5 Exibição de dados

Tendo os dados adequadamente analisados, a visualização da rede no navegador aparece como último passo do fluxo de uso da ferramenta.

3.5.1 Requisitos

A seção 2.3.2 define requisitos de interatividade para a visualização, incapazes de serem atendidos pela geração de uma simples imagem. Assim, associada à opção por uma aplicação *front-end* vem a necessidade de integrar funcionalidades como *zoom*, seleção, e detalhamento dos dados exibidos. A biblioteca *vis.js* (vis.js, 2022) foi escolhida por sua fácil integração e expansibilidade, permitindo customização de estilos e o fornecimento prévio de dados dos vértices do grafo em questão. Ela é utilizada em conjunto com o *framework React*, biblioteca de código livre para criação de interfaces que facilita o gerenciamento de componentes HTML no navegador.

Um segundo requerimento a ser considerado é o de volume de dados, que possui grande relevância para o tipo de análise massiva que é objeto deste trabalho. A próxima seção trata desta otimização.

3.5.2 Renderização

Enquanto uma imagem tem requisitos computacionais indiferentes para sua renderização, independentemente de tamanho do grafo nela contido, a computação de componentes HTML interativos pode se tornar rapidamente problemática para a performance do sistema. A solução proposta aqui envolve um meio do caminho entre a estaticidade de uma imagem e o dinamismo de grafos animados vistos em algumas ferramentas.

A biblioteca *vis.js* oferece entre suas funcionalidades o cálculo de posição de vértices baseado em simulação física, que aqui será desabilitado. Trata-se de uma implementação de modelo direcionado por força calculada em tempo real, de execução inviável para um grafo com milhares de vértices.

Ao invés disso, o cálculo de posicionamento será feito no *back-end*, tendo um *cache* gravado em arquivo JSON para maior performance do cliente. Aqui, ainda no fluxo de análise do grafo no *back-end*, é executado o algoritmo *Fruchterman-Reingold* para determinação do posicionamento dos vértices, conforme visto na seção 2.3.1. O arquivo JSON contendo os resultados já é escrito conforme as especificações da biblioteca *vis.js* (vis.js, 2022). Assim, resta à aplicação *front-end* somente a responsabilidade de renderizar vértices já posicionados. A figura 13 ilustra o fluxo descrito.

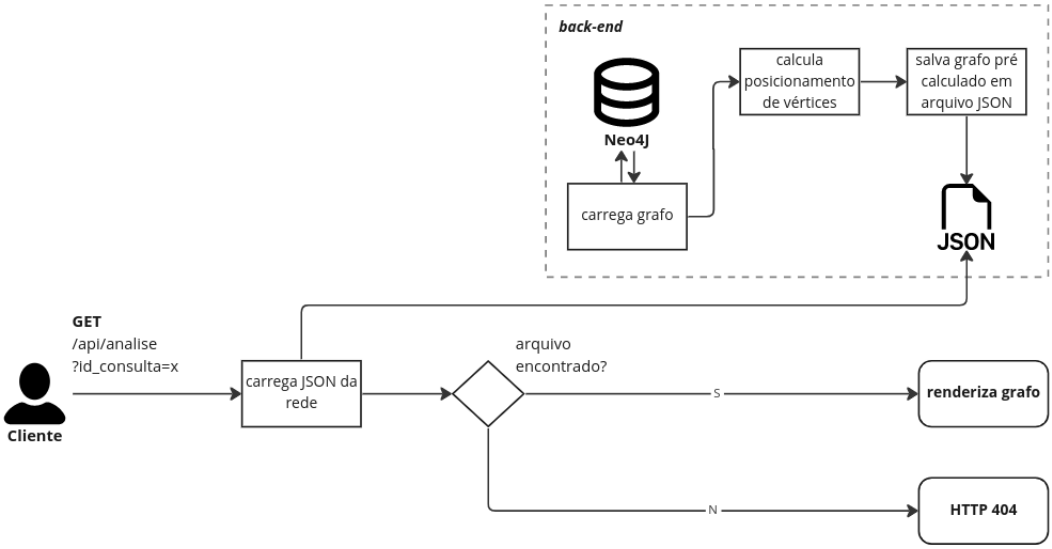

Figura 13 – Renderização do grafo no *front-end*. Realização própria.

Sem a necessidade de cálculos complexos de física, um sociograma de milhares de componentes pode ser renderizado em um navegador *web* por um computador comum, ainda se aproveitando de todas as principais funcionalidades, descritas a seguir.

3.5.3 Funcionalidades e representação

Com os dados já pré-definidos em cache do servidor, a atribuição da aplicação cliente é traduzir valores numéricos em visualizações de fácil entendimento. Já foi definido que a visualização exibida é um sociograma, com vértices como usuários e arestas como suas relações. A ferramenta *vis.js* já suporta nativamente a funcionalidade de zoom, permitindo a visualização aproximada de trechos de interesse da rede. Deve-se considerar agora os dados da análise do grafo.

Na seção 3.4.2 foram destacados os atores mais influentes da rede, que possuem centralidade de grau elevada, tal que vértices mais conectados possuam um coeficiente mais alto. Os valores significam pouco da visualização, mas podem ser simbolizados pelo tamanho individual de cada vértice - proporcionais aos seus coeficientes de centralidade - de forma que vértices maiores sejam os atores mais relevantes. Aplicam-se também restrições de tamanho máximo e mínimo, de forma que nenhum dos atores seja invisível ou visualmente poluente na rede. A figura 14 detalha a visualização de centralidade no grafo.

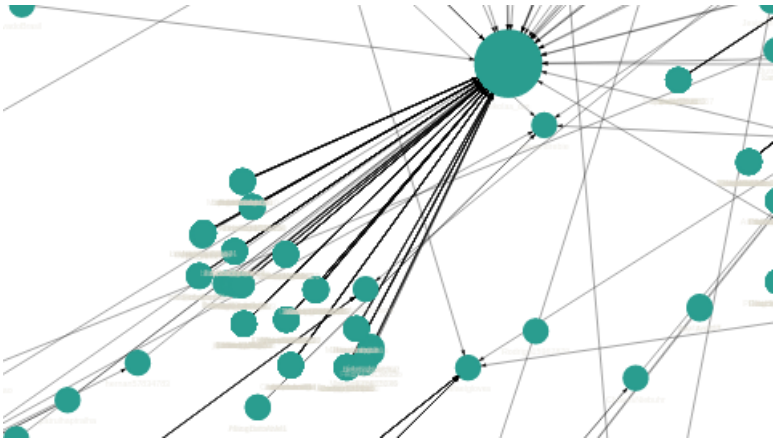

Figura 14 – Visualização de centralidade no grafo. Elaboração própria.

Outro atributo de rede calculado nos passos de análise foi o particionamento em comunidades. O algoritmo de comunidades de Louvain, por exemplo, gera uma lista de subconjuntos para cada comunidade criada. Aqui, são agregados vértices de uma mesma partição por sua cor, gerada de uma paleta pré-definida, variável com a quantidade de comunidades existentes. A figura 15 mostra a rede e suas diferentes comunidades.

Figura 15 – Visualização de comunidades no grafo. Elaboração própria.

3.6 Resultados

Nesta seção são exibidos os resultados obtidos com a ferramenta desenvolvida em todas as suas etapas: construção da base de dados, análise da rede, e sua exibição. Eles são então comparados com os critérios estabelecidos previamente, bem como com outras referências encontradas na literatura.

3.6.1 Construção da base de dados

Foi coletada uma base de dados de *Tweets* realizados durante a semana do segundo turno das eleições presidenciais brasileiras. A rede fornece um exemplo de tópico de discussão polarizado com grupos bem definidos, cenário ideal para o tipo de análise desejado.

Vale pontuar que a única interação manual executada foi o pedido inicial de análise, realizado por meio de uma requisição HTTP de tipo *POST* para o servidor, informando os termos desejados. Todos os passos descritos a seguir são realizados de forma assíncrona pela ferramenta, a começar pela consulta de dados e sua escrita no SGBD.

A escrita em lotes na base de dados dá maior agilidade ao processo, que minimiza a abertura de conexões com o banco de dados em troca de escritas maiores. A tabela 1 exibe os elementos totais da rede.

Os dados estão em linha com outros exemplos da literatura, sendo numericamente superior aos de alguns trabalhos. Sánchez-Cabezudo (2016), por exemplo, usa uma rede de pouco mais de 6.000 vértices e 5.500 arestas, enquanto Kitagawa (2010) tem cerca de

Vértices	Arestas
26.120	22.927

Tabela 1 – Total de elementos na rede

112,000 vértices representando usuários.

3.6.2 Análise da rede

A aplicação de análise da rede funciona como descrito em sua implementação, na seção 3.4.3. O grafo é particionado em duas comunidades bem divididas, destacando influenciadores.

Uma dificuldade notada foi o tempo de execução do algoritmo de posicionamento *Fruchterman-Reingold*. O valor padrão de 50 iterações se mostrou insuficiente para calcular posições contrastantes entre grupos para uma base de dados de grande volume, gerando um grafo excessivamente aglomerado ao invés disso. Desta maneira, um valor final de 200 iterações foi empregado no cálculo de posições final, elevando o tempo de execução do algoritmo para cerca de 40 minutos, tempo ainda razoável para processamento assíncrono. A figura 16 mostra os resultados de execução do algoritmo com 50, 200, e 1000 iterações, respectivamente. Não há melhoria significativa após as 200 iterações, o que valida a escolha.

Figura 16 – Execução do algoritmo *Fruchterman-Reingold* com diferentes níveis de iterações. Elaboração própria.

Por fim, é notável sistema apresentado é uma ferramenta de *análise estrutural* de redes sociais, aplicando conceitos específicos de teoria dos grafos para a área. Este tipo de análise responde a perguntas como *"qual a distribuição de grupos em um tópico de discussão?"* ou *"quem são os usuários influentes em uma comunidade?"*, mas não informa *o que* se discute nem o teor das publicações. Estes pontos não se encaixam no escopo deste trabalho, mas trata-se de um ponto importante a se ressaltar.

3.6.3 Exibição dos dados

Após o término da análise, o grafo pré-processado se torna acessível para carregamento da aplicação cliente. Sua renderização é instantânea, fornecendo uma visão geral da rede, como a da figura 15. Como os vértices são carregados já com seus metadados de posicionamento, não há custo extra de processamento para cálculos de física em tempo real, o que minimiza o uso de recursos computacionais.

A adoção da biblioteca *vis.js* dá suporte nativo à movimentação pela tela, permitindo livre deslocamento pelos dois eixos cartesianos, além de aproximações de *zoom*, um dos requisitos determinados na seção 2.3.

Adicionalmente, são implementadas ações de detalhamento do conteúdo sob controle do usuário, como o destaque de vértices sob seleção e a exibição de dados adicionais após clique em vértice, também de acordo com os requisitos de interface propostos. A figura 17 exibe estas aplicações renderizadas na ferramenta.

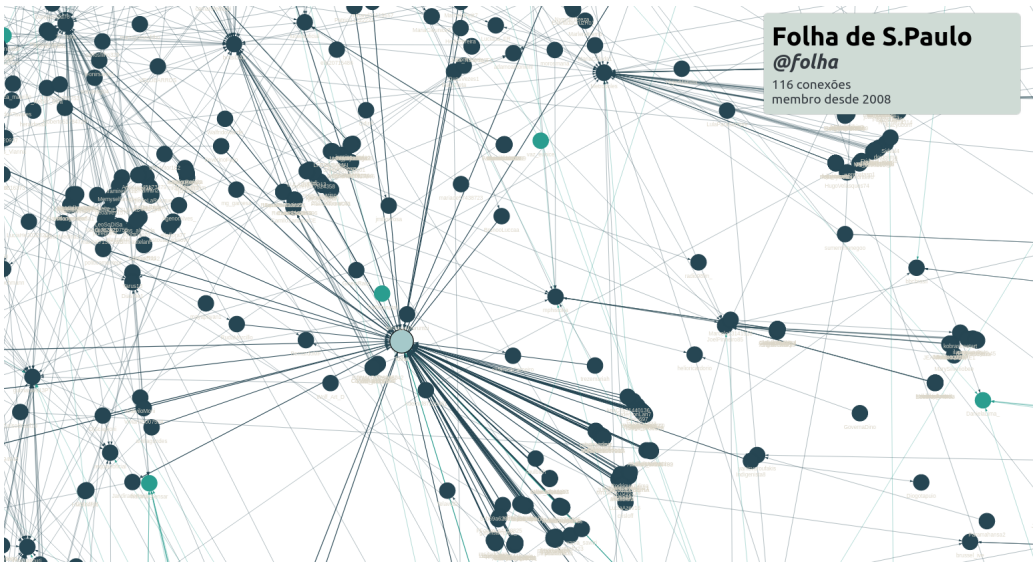

Figura 17 – Funcionalidades de interação da interface. Elaboração própria.

Um último destaque é dado à capacidade de renderização de dezenas de milhares de vértices com performance aceitável. Trata-se de desempenho superior ao do console *Neo4j*, de alguns milhares de vértices no mesmo computador. É um número insuficiente para grafos massivos de centenas de milhares ou milhões de vértices, mas um avanço substancial para ferramentas *web*.

4 Conclusão

A construção da ferramenta proposta neste trabalho mostra que instrumentos de análise de redes sociais acessíveis ao público geral são possíveis, e que visualizações de médio porte são perfeitamente adequadas para computadores de uso geral.

Como discutido na subseção 3.4.3.3, algoritmos de detecção de comunidades não são técnicas imediatamente aplicáveis a qualquer tipo de rede, sendo por vezes necessário filtrar ruídos característicos do meio de que foram extraídos.

Também não é possível dizer que o *software* desenvolvido fundamente todos os pontos relevantes de uma análise. Como elaborado na subseção 3.6.2, o que se tem são instrumentos para auxílio na interpretação dos dados.

Por fim, a acessibilidade de um sistema *web* disponível em navegador facilita o acesso à ferramenta em uma época onde computadores pessoais dividem espaço com *tablets* e *smartphones*, especialmente com as otimizações de desempenho propostas. Ainda assim, o processamento realizado em navegadores impõe um teto de performance muito inferior ao de programas nativos, que podem ser mais desejáveis especialmente para usos mais especializados.

Assim, não se propõe aqui uma solução universal para a análise de conteúdo de redes sociais. O sistema desenvolvido é otimizado para uso na plataforma escolhida, o *Twitter*, e deve ser sujeitado a análises e melhorias, como trata o próximo capítulo.

5 Trabalhos futuros

Este trabalho foi feito baseado em diversos conceitos sintetizados em outros pontos da literatura, e seu código fonte está disponível em repositório público do *Github* com licença GPL2. Nesta seção final, são sugeridos próximos possíveis pontos focais nas áreas de interesse abordadas.

5.1 Análise de redes sociais

Como tratado ao longo da seção 3.4, há diversas abordagens distintas propostas para o tema. Aqui foi implementada uma análise estática do grafo, realizada após a construção da base de dados.

Uma outra ramificação encontrada na literatura se refere à análise temporal de redes, adicionando uma dimensão extra ao grafo que acompanha a evolução dos dados por um determinado período de horas, dias, ou anos, o que pode trazer novas perspectivas para investigações do gênero.

5.2 Análise de tópicos de discussão

Sobre as questões de escopo levantadas na seção 3.6.2, é importante mencionar os trabalhos na área de análise semântica computacional. Técnicas de aprendizado computacional como análises de sentimento podem ser de grande serventia para expandir o tema.

5.3 Visualização de grafos

Um importante tema discutido foi a otimização de performance para a exibição massiva de dados numa interface de usuário. Apesar dos sucessos obtidos, a ferramenta ainda estava limitada ao processamento *single-threaded* de um navegador. A construção de ferramentas nativas que se aproveitem de múltiplos núcleos de processamento pode trazer ganhos de desempenho ainda mais notáveis.

Referências

BLONDEL, V. D. et al. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, v. 2008, n. 10, p. P10008, oct 2008. Disponível em: <https://dx.doi.org/10.1088/1742-5468/2008/10/P10008>. Citado na página 18.

BOATENG, R.; OFOEDA, J.; EFFAH, J. Application programming interface (api) research: A review of the past to inform the future. *Int. J. Enterp. Inf. Syst.*, IGI Global, USA, v. 15, n. 3, p. 76–95, jul 2019. ISSN 1548-1115. Disponível em: <https://doi.org/10.4018/IJEIS.2019070105>. Citado na página 28.

BRANDES, U. et al. *Maximizing Modularity is hard*. arXiv, 2006. Disponível em: <https://arxiv.org/abs/physics/0608255>. Citado na página 18.

CAMBRIA, D. C. Ángel P. L. G. B.-O. A. G.-P. E. The four dimensions of social network analysis: An overview of research, methods, applications, and software tools. *Information Fusion*, 2020. Disponível em: <https://doi.org/10.1016/j.inffus.2020.05.009>. Citado 6 vezes nas páginas 11, 13, 19, 20, 21 e 22.

Celery. *Documentation*. 2022. [Online; acesso em 20 de novembro de 2022]. Disponível em: <https://docs.celeryq.dev/en/stable/>. Citado na página 27.

CODD, E. F. A relational model of data for large shared data banks. *Communications of the ACM*, 1970. Disponível em: <https://dl.acm.org/doi/10.1145/362384.362685>. Citado na página 28.

Contribuidores Wikipedia. *Force-directed graph drawing — Wikipedia, The Free Encyclopedia*. 2022. [Online; acesso em 20 de novembro de 2022]. Disponível em: <https://en.wikipedia.org/w/index.php?title=Force-directed_graph_drawing&oldid=1121713234>. Citado na página 19.

DB-Engines. *DB-Engines Ranking*. 2021. Disponível em: <https://db-engines.com/en/ranking>. Citado na página 28.

Docker. *What is a container*. 2022. [Online; acesso em 20 de novembro de 2022]. Disponível em: <https://www.docker.com/resources/what-container/>. Citado na página 26.

FORTUNATO, S.; HRIC, D. Community detection in networks: A user guide. *Physics Reports*, Elsevier BV, v. 659, p. 1–44, nov 2016. Disponível em: <https://doi.org/10.1016%2Fj.physrep.2016.09.002>. Citado na página 17.

FRICK, V. et al. Do online environments promote sufficiency or overconsumption? online advertisement and social media effects on clothing, digital devices, and air travel consumption. *Journal of Consumer Behaviour*, v. 20, n. 2, p. 288–308, 2021. Disponível em: <https://onlinelibrary.wiley.com/doi/abs/10.1002/cb.1855>. Citado na página 11.

FRUCHTERMAN, T. M.; REINGOLD, E. M. Graph drawing by force-directed placement. *Software: Practice and experience*, Wiley Online Library, v. 21, n. 11, p. 1129–1164, 1991. Citado na página 20.

GIRVAN, M.; NEWMAN, M. E. Community structure in social and biological networks. *Proceedings of the national academy of sciences*, National Acad Sciences, v. 99, n. 12, p. 7821–7826, 2002. Citado na página 18.

GUARINO, S. et al. Beyond fact-checking: Network analysis tools for monitoring disinformation in social media. *International Conference on Complex Networks and Their Applications*, 2019. Disponível em: <https://www.disinfobservatory.org/wp-content/uploads/2020/04/paper-Beyond-Fact-checking-.pdf>. Citado na página 23.

Kepios. *Global Digital Reports*. 2022. [Online; acesso em 18 de novembro de 2022]. Disponível em: <https://kepios.com/reports>. Citado 3 vezes nas páginas 11, 13 e 25.

KHAN, B. S.; NIAZI, M. A. Network community detection: A review and visual survey. *CoRR*, abs/1708.00977, 2017. Disponível em: <http://arxiv.org/abs/1708.00977>. Citado na página 17.

KITAGAWA, Y. Y. T. T. T. A. H. Turank: Twitter user ranking based on user-tweet graph analysis. *Web Information Systems Engineering (WISE)*, 2010. Citado 4 vezes nas páginas 14, 16, 22 e 38.

LEVY, R. Social media, news consumption, and polarization: Evidence from a field experiment. *American Economic Review*, v. 111, n. 3, p. 831–70, March 2021. Disponível em: <https://www.aeaweb.org/articles?id=10.1257/aer.20191777>. Citado na página 11.

LUKE, D. A. Basic network plotting and layout. In: _____. *A User's Guide to Network Analysis in R*. Cham: Springer International Publishing, 2015. p. 45–53. ISBN 978-3-319-23883-8. Disponível em: <https://doi.org/10.1007/978-3-319-23883-8_4>. Citado 3 vezes nas páginas 15, 20 e 21.

NetworkX. *NetworkX - Documentation*. 2022. [Online; acesso em 20 de novembro de 2022]. Disponível em: <https://networkx.org/documentation/stable/>. Citado na página 30.

NEWMAN, M. E. The mathematics of networks. *The new palgrave encyclopedia of economics*, Citeseer, v. 2, n. 2008, p. 1–12, 2008. Citado na página 16.

PAGE, L. et al. The pagerank citation ranking: Bringing order to the web. In: *Proceedings of the 7th International World Wide Web Conference*. Brisbane, Australia: [s.n.], 1998. p. 161–172. Disponível em: <citeseer.nj.nec.com/page98pagerank.html>. Citado 2 vezes nas páginas 16 e 53.

Python. *Documentation*. 2022. [Online; acesso em 20 de novembro de 2022]. Disponível em: <https://docs.python.org/3/>. Citado na página 26.

SCHAEFFER, S. E. Graph clustering. *Computer Science Review*, 2007. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1574013707000020>. Citado na página 20.

SHNEIDERMAN, B. The eyes have it: a task by data type taxonomy for information visualizations. In: *Proceedings 1996 IEEE Symposium on Visual Languages*. [S.l.: s.n.], 1996. p. 336–343. Citado na página 21.

SáNCHEZ-CABEZUDO, M. del F. G. A. J. D. S. S. Identifying the new influencers in the internet era: Social media and social network analysis. *Revista Española de Investigaciones Sociológicas*, 2016. Citado 4 vezes nas páginas 13, 14, 22 e 38.

TSAO, S.-F. et al. What social media told us in the time of covid-19: a scoping review. *The Lancet Digital Health*, v. 3, n. 3, p. e175–e194, 2021. ISSN 2589-7500. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2589750020303150>. Citado na página 11.

Tweepy. *Getting Started - Tweepy*. 2022. [Online; acesso em 15 de novembro de 2022]. Disponível em: <https://docs.tweepy.org/en/stable/getting_started.html>. Citado na página 28.

Twitter Developer. *Get Tweets API Reference*. 2022. [Online; acesso em 19 de outubro de 2022]. Disponível em: <https://docs.tweepy.org/en/stable/getting_started.html>. Citado 2 vezes nas páginas 14 e 29.

VICKNAIR, C. et al. A comparison of a graph database and a relational database: A data provenance perspective. In: . [S.l.: s.n.], 2010. v. 10, p. 42. Citado na página 28.

vis.js. *DataSet - vis.js*. 2022. [Online; acesso em 13 de novembro de 2022]. Disponível em: <https://visjs.github.io/vis-data/data/dataset.html>. Citado 2 vezes nas páginas 35 e 36.

WASSERMAN, S.; FAUST, K. *Social Network Analysis: Methods and Applications*. [S.l.]: Cambridge University Press, 1994. (Structural Analysis in the Social Sciences). Citado 3 vezes nas páginas 13, 14 e 15.

Apêndices

APÊNDICE A – Acessando o repositório do projeto

O projeto desenvolvido neste trabalho está disponível em repositório público da plataforma *GitHub*, sob licença GPL2. Ele pode ser acessado através da *URL* <https://github.com/caiobsilva/twitter-analyzer>.

Todo o versionamento do projeto foi feito com a ferramenta *Git*, sendo necessário possuí-la no dispositivo utilizado. Adicionalmente, é necessário também ter instalado as ferramentas *Docker Compose* e *Make*. Instruções de uso da aplicação estão no repositório citado acima.

APÊNDICE B – O algoritmo PageRank

O algoritmo proposto por Page et al. (1998) é uma implementação iterativa para o cálculo de centralidade de vértices em um grafo. Eis uma descrição simples do seu funcionamento, como descrito no artigo publicado:

- Para um grafo G, todos os membros do conjunto de vértices V são iniciados com frações igualmente repartidas de peso na rede, onde $Pv = \frac{1}{V}$, isto é, o peso P de um vértice v é igual a *1* dividido pela quantidade de vértices no grafo.
- Como em uma cadeia de Markov, os pesos de cada vértice são distribuídos entre suas conexões de forma igualitária, de forma que vértices que recebem mais conexões (maior *grau de entrada*) somem maior peso agregado.
- O algoritmo se repete iterativamente, de forma que vértices de maior peso propaguem uma maior pontuação para suas conexões.

Um conceito importante aplicado no algoritmo é o de *caminhante aleatório*, que essencialmente descreve um algoritmo que transita de forma randômica por vértices conectados. Aqui, um vértice destino de mais arestas tem maior chance de receber o caminhante em seu período de trânsito, probabilidade que fundamenta a métrica de centralidade do algoritmo.