Christopher Ferreira Silva

Desenvolvimento de um Modelo de *Machine Learning* com Otimização de Hiperparâmetros para previsão de inadimplência

São Paulo - Brasil

2025

Christopher Ferreira Silva

Desenvolvimento de um Modelo de *Machine Learning* com Otimização de Hiperparâmetros para previsão de inadimplência

Monografia apresentada na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Thyago Quintas

São Paulo - Brasil
2025

Dedico a minha família e companheiros que fiz pelo caminho

Agradecimentos

Agradeço a todo suporte de família, amigos e professores.

"Não tenha medo de tentar,
tenha medo de não tentar e ver que a vida passou
e você não se arriscou como deveria.
(Chorão)

Resumo

A previsão da inadimplência é um fator-chave para o sucesso na carteira de qualquer Instituição Financeira que busque se estabelecer no mercado com segurança. Entretanto, a qualidade das etapas envolvidas na captação de bons clientes e na mitigação de maus pagadores permanece como um processo que pode ser continuamente aprimorado. Dessa forma, o presente trabalho buscou demonstrar que algoritmos de otimização de hiperparâmetros, quando aplicados a um modelo de *Machine Learning*, podem gerar resultados expressivos quanto à previsão de inadimplentes. Recorreram-se às técnicas de Otimização Bayesiana e Otimização por Algoritmo Genético, juntamente com o modelo *Random Forest*. Foram geradas três versões de modelos, sendo uma delas sem otimização, utilizando dados de duas bases públicas — alemã e australiana — referentes a sucessos e insucessos na concessão de crédito. Os modelos derivados do *dataset* alemão foram avaliados pela métrica *f1-score*, enquanto os referentes à base australiana utilizaram o *recall*. Dessa forma, buscou-se reduzir cenários de concessões que aparentam não ser problemáticos, mas que, na prática, podem resultar em inadimplência. Os modelos apresentaram resultados promissores ao final do projeto, com destaque para a Otimização por Algoritmo Genético, que alcançou os melhores valores nas métricas priorizadas e maior consistência entre as classes. Assim, conclui-se que as técnicas de Otimização de Hiperparâmetros podem, de fato, ser utilizadas para essa finalidade.

Palavras-chaves: *Machine Learning*, inadimplência, Otimização de Hiperparâmetros, Algoritmo Genético, Otimização Bayesiana, Risco de Crédito, Aprendizagem de Máquina.

Abstract

The prediction of default is a key factor for the success of the loan portfolio of any Financial Institution seeking to establish itself in the market with confidence. However, the quality of the steps involved in acquiring good clients and mitigating bad payers remains a process that can be continuously improved. In this regard, the present study sought to demonstrate that hyperparameter optimization algorithms, when applied to a Machine Learning model, can generate expressive results in predicting defaulters. Bayesian Optimization and Genetic Algorithm Optimization techniques were employed, together with the Random Forest model. Three versions of the model were generated, one of them without optimization, using data from two public datasets—the German and the Australian—referring to successes and failures in credit outcomes. The models derived from the German dataset were evaluated using the F1-score metric, while those from the Australian dataset were evaluated using recall. This approach aimed to reduce scenarios of credit granting that may initially appear non-problematic but could, in practice, result in default. The models showed promising results by the end of the project, with particular emphasis on the Genetic Algorithm optimization, which achieved the best values for the prioritized metrics and greater consistency between classes. Thus, it is concluded that Hyperparameter Optimization techniques can, in fact, be effectively used for this purpose.

Key-words: Machine Learning, Default Prediction, Hyperparameter Optimization, Genetic Algorithm, Bayesian Optimization, Credit Risk, Predictive Modeling.

Lista de ilustrações

Figura 1 – Sistema geral para classificação por *Credit Scoring* 18
Figura 2 – Tendências da taxa de aprendizado para aprendizado online 25
Figura 3 – Algoritmo K-Nearest-Neighbours 27
Figura 4 – Árvore de Decisão Classificação Íris 28
Figura 5 – *Ensemble Learning* para classificação 30
Figura 6 – Classificação *ensemble boosting* 30
Figura 7 – Modelo Linear para detecção de *outliers* 34
Figura 8 – Fluxograma da Otimização Bayesiana 37
Figura 9 – Comportamento OB 37
Figura 10 – Tipos de Cruzamento 39
Figura 11 – Mutação genética dos indivíduos 39
Figura 12 – Divisão *K-fold* na validação cruzada 40
Figura 13 – Partição *Hold-out* na validação cruzada 41
Figura 14 – Matriz de Confusão 42
Figura 15 – Curva ROC 43
Figura 16 – Limiar *Precision/Recall* 44
Figura 17 – Arquitetura do funcionamento 47
Figura 18 – Validação cruzada aninhada 52
Figura 19 – Matrizes de confusão - Base australiana 57
Figura 20 – Matrizes de confusão - Base alemã 58

Lista de tabelas

Tabela 1 – Atributos base alemã 49
Tabela 2 – Atributos base australiana 50
Tabela 3 – Hiperparâmetros arbitrários 51
Tabela 4 – Atributos da classe pygad.GA 54
Tabela 5 – Atributos da classe *BayesSearchCV* 55
Tabela 6 – Melhores valores encontrados por cada otimização - Base australiana . 56
Tabela 7 – Melhores valores encontrados por cada otimização - Base alemã 56
Tabela 8 – Métricas obtidas - Base australiana 56
Tabela 9 – Métricas obtidas - Base alemã 57

Lista de abreviaturas e siglas

AG	Algoritmo Genético
SMAC	Sequential Model-based Algorithm Configuration
RF	*Random Forest*

Sumário

1 INTRODUÇÃO . . . 12
1.1 Objetivos . . . 14
1.1.1 Objetivo Geral . . . 14
1.1.2 Objetivos Específicos . . . 14

2 REVISÃO BIBLIOGRÁFICA . . . 15
2.1 Crédito e Risco de Crédito . . . 15
2.1.1 Análise de Crédito . . . 17
2.1.2 Inadimplência . . . 20
2.2 Inteligência Artificial . . . 21
2.3 *Machine Learning* . . . 22
2.3.1 Tipos de Sistemas de *Machine Learning* . . . 22
2.3.2 Aprendizado Supervisionado/Não Supervisionado/Semissupervisionado/Por Reforço . . . 22
2.3.2.1 Aprendizado Supervisionado . . . 23
2.3.2.2 Aprendizado Não Supervisionado . . . 23
2.3.2.3 Aprendizado Semi-supervisionado . . . 23
2.3.2.4 Aprendizado por Reforço . . . 23
2.3.3 Aprendizado *Online* e em Lote . . . 25
2.3.4 Aprendizado Baseado em Instâncias, em Modelos e Paradigma Simbólico . . . 26
2.3.4.1 Aprendizado Baseado em Instâncias . . . 26
2.3.4.2 Aprendizado Baseado em Modelos . . . 27
2.3.4.3 Paradigma Simbólico . . . 27
2.3.5 Árvore de Decisão . . . 28
2.3.5.1 *Ensemble Learning* . . . 29
2.3.5.2 *Boosting* . . . 30
2.3.5.3 *Bagging* . . . 30
2.3.6 *Random Forest* . . . 31
2.3.7 Tratamento dos Dados . . . 32
2.3.7.1 *Missing Values* . . . 32
2.3.7.2 *Outliers* . . . 33
2.3.8 Balanceamento dos Dados . . . 34
2.3.9 Otimização de Hiperparâmetros . . . 35
2.3.9.1 Otimização Bayesiana . . . 36
2.3.9.2 Algoritmo Genético . . . 38
2.3.9.3 Cruzamento . . . 38
2.3.9.4 Mutação . . . 39
2.3.10 Validação do Modelo . . . 40
2.3.10.1 *Cross-Validation* . . . 40
2.3.10.2 *K-fold Cross Validation* . . . 40
2.3.10.3 *Hold-out* . . . 41
2.3.10.4 *Leave-one out* . . . 41
2.3.11 Matriz de Confusão . . . 41

2.3.11.1 Acurácia . . . 42
2.3.11.2 Precisão . . . 42
2.3.11.3 Revocação . . . 42
2.3.11.4 *F1-Score* . . . 42
2.3.11.5 Curva ROC . . . 43
2.3.11.6 *Precision Recall* . . . 44
2.4 Trabalhos Relacionados . . . 45
2.4.1 Gerenciamento Integrado de Riscos: Modelos de Predição de Risco de Crédito em Machine Learning para a Identificação de Ativos Problemáticos em uma Instituição Financeira – Segmento Habitacional PF . . . 45
2.4.2 *On Hyperparameter Optimization of Machine Learning Algorithms: Theory and Practice* . . . 45
2.4.3 Otimização de Hiperparâmetros de Algoritmos de Machine Learning Aplicado no Contexto de Análise de Risco de Crédito . . . 46
2.4.4 Comparação de Algoritmos de Aprendizado de Máquina para Predição de Pontuação de Crédito . . . 46

3 DESENVOLVIMENTO . . . 47
3.1 Proposta de solução . . . 47
3.1.1 Arquitetura proposta . . . 47
3.1.2 Ferramentas tecnológicas utilizadas . . . 48
3.2 Base de Dados . . . 48
3.2.1 Bases australiana e alemã . . . 48
3.2.2 Tratamento das bases . . . 50
3.3 Implementação do algoritmo de aprendizado de máquina . . . 51
3.3.1 Validação cruzada aninhada . . . 52
3.3.2 pyGAD . . . 53
3.3.2.1 Função de Aptidão e *Clustering* . . . 53
3.3.3 BayesSearchCV . . . 54
3.3.4 Treinamento e avaliação do modelo final . . . 55

4 RESULTADOS . . . 56

5 CONCLUSÃO . . . 60
5.1 Trabalhos Futuros . . . 61

REFERÊNCIAS . . . 62

APÊNDICES 68

APÊNDICE A – REPOSITÓRIO PÚBLICO NO GITHUB . . . 69

1 Introdução

Operações que envolvem crédito podem ser analisadas sob diferentes óticas. Tratando-se especificamente de Instituições Financeiras (IF), operações de crédito se referem à disponibilização de seus recursos monetários, sendo que esta é quem dispõe dos capitais e possui a capacidade de arcar com esse investimento para um determinado tomador — ou seja, aquele que utiliza recursos que não tem em sua posse — com a expectativa de obter esse valor acrescido de juros no futuro, em, por exemplo, duas de suas modalidades mais conhecidas: empréstimo e financiamento.

A própria origem da palavra crédito significa "confiar". Desse modo, segundo Securato e Famá (1997), o crédito tem a confiança em seu cerne, a expectativa de que, no futuro, o devedor pague pelo que lhe é fornecido no presente. Assim, é apontado que deferir crédito é troca de produtos com valor econômico, espera e risco.

Porém, durante a vigência deste pacto, existem alguns riscos que podem levar a IF a incorrer em perdas, sendo um dos mais relevantes — e que dá alicerce a esta monografia — o risco de inadimplência. De acordo com a Pesquisa Trimestral de Condições de Crédito (BANCO CENTRAL DO BRASIL (2025)), isso se mostra ainda mais significativo, dada a constatação da expectativa de aumento de inadimplentes para o primeiro trimestre de 2025.

O risco de inadimplência, ou risco de *default*, carrega consigo efeitos colaterais tanto para as instituições quanto para os devedores envolvidos, que passam a possuir um histórico financeiro duvidoso frente às dívidas não quitadas, prejudicando futuras negociações.

Selau e Ribeiro (2009) destacam que, ao conceder crédito, existe a possibilidade da perda, anteriormente adquirida com outras captações de sucesso. Sendo assim, antecipar e reduzir a inadimplência possuí sua devida importância, pois as dívidas malsucedidas têm impacto direto no aumento dos juros que serão refletidos em novas concessões.

Além disso, com o objetivo de minimizar esse e outros possíveis riscos, o Conselho Monetário Nacional por meio da Resolução Nº 4.557/2017 (CONSELHO MONETÁRIO NACIONAL (2017)) determina que, as IF disponham de uma estrutura de gerenciamento de riscos e de capital para fazer frente aos riscos a que estão expostas. Pires (2008) traz à tona a relevância sobre a liquidez de crédito, ressaltando como uma das atividades mais importantes a ser desempenhada.

Historicamente, diversas técnicas e mecanismos foram propostos para resolver tais problemáticas. Atualmente, um dos métodos tradicionais comumente utilizados para essa tarefa é o sistema chamado *Credit Scoring* que, conforme Pires (2008), refere-se a uma técnica que avalia a possibilidade de deferir crédito, a qual fundamenta-se em fórmulas estatísticas geradas com base em diversas informações do tomador, como por exemplo, dados cadastrais, dados financeiros, idoneidade do cliente, entre outros.

Deste modo, com a necessidade constante de acelerar as concessões de crédito visando negócios lucrativos de forma abrangente e segura, mesmo com a experiência dos analistas, decisões erradas são inerentes. Logo, agregar insumos às ferramentas utilizadas gera valor e maior assertividade nas decisões a serem tomadas.

Dado esse contexto, a fim de mitigar riscos e preservar a qualidade de suas operações, as IF constantemente buscam aperfeiçoar suas metodologias internas no que tange à análise de perfis que demonstram certo grau de confiabilidade para dispor de seus recursos. De acordo com Selau e Ribeiro (2009), empresas que se relacionam com crédito possuem em seu radar, buscar tendências e melhores métodos para análise de crédito, pois investir nessa atividade resulta em garantias positivas oferecendo segurança em suas transações além de diminuir o índice de inadimplência.

Assim, aliar os benefícios da tecnologia à construção de modelos que antecipem essas possibilidades têm demonstrado relevância para as partes interessadas nos segmentos bancários. Com o aumento da produção diária de dados, assim como a evolução de algoritmos de *Machine Learning*, a potencialidade de classificação oferecida por esses modelos pode tornar-se um forte aliado, especialmente por sua velocidade, quando bem parametrizados.

1.1 Objetivos

Este trabalho tem como objetivo desenvolver um modelo de classificação com a finalidade de prever clientes adimplentes ou inadimplentes no que seria uma etapa de concessão de crédito por parte de uma IF. O modelo será treinado com dados rotulados, ou seja, um modelo supervisionado que dispõe de *datasets* (bases de dados) com informações variadas acerca das características do contratante e o resultado que indica se o contrato firmado entre as partes obteve êxito (adimplência) ou não (inadimplência), definido como variável *target* ou variável dependente. Após coleta das métricas para os modelos, comparar seus resultados com os obtidos nos trabalhos relacionados.

1.1.1 Objetivo Geral

Se a utilização de Modelos de *Machine Learning* com otimização de hiperparâmetros, possibilita aumento significativo na precisão de suas previsões para inadimplência em base de dados de crédito abertas, evidenciando, inclusive, a comparação das métricas desses modelos com os dos trabalhos relacionados.

1.1.2 Objetivos Específicos

1. Comparar acurácia, *f1-score*, precisão e *recall* com o estado da arte;

2. Avaliar as diferentes capacidades de predição, treinando o modelo sem otimização e com otimização de hiperparâmetros utilizando dois algoritmos, sendo eles: Otimização Bayesiana (SMAC) e Otimização por Algoritmo Genético;

2 Revisão Bibliográfica

2.1 Crédito e Risco de Crédito

Crédito, que significa do latim "coisa confiável", em termos gerais, entende-se como a confiabilidade associada a determinada atividade. Segundo Jeronimo e Prazeres (2015), podemos dizer que o crédito está ligado diretamente à confiança depositada em alguém ou em alguma coisa.

Conforme Camargo (2010), crédito é a prática de oferecer recursos a terceiros. Tal prática possui cobrança que recai sobre quem adquire esse valor, acrescida de juros, visando a um retorno lucrativo para a entidade provedora. Esse deferimento pode ser realizado por diversos segmentos, sendo o segmento bancário o de maior destaque, que age como captador e direcionador dos montantes recebidos para serem reinvestidos na economia.

Sfeir (2014) afirma que, quem demanda recursos tem como objetivo realizações futuras, seja para evoluir seu negócio ou para adquirir algum bem de consumo. O mercado de crédito permite que esse indivíduo consiga alcançar seus objetivos através das entidades, as quais o autor define como agentes econômicos superavitários, ou seja, instituições com sobra desses recursos.

No contexto do mercado financeiro, quando há a necessidade de consumo de capital — seja por qualquer linha de crédito disponibilizada pela instituição — não é somente a confiança que garante estrutura para as partes envolvidas (credor e devedor). Conforme Jeronimo e Prazeres (2015) faz-se necessário o cumprimento processual de etapas, como: garantias reais e avais, cédulas de crédito e outros documentos que mencionam os valores contratados, as taxas de juros, os contratos, os prazos e as formas de pagamento.

Entende-se então, que a concessão de crédito carrega consigo a expectativa do recebimento posterior do montante de capital fornecido. Todavia, é prudente supor que, existe o risco desse capital não ser pago em sua totalidade dentro do prazo acordado. Esse risco é chamado de Risco de Crédito. Brito e Neto (2008) definem o Risco de Crédito como sendo a possibilidade de o credor vir a se envolver em perdas, quando as obrigações que o tomador aceita em sua posse não são quitadas nas condições determinadas.

De acordo com Silva (1997, p. 347 *apud* Silva (2004, p. 24)), a decisão de conceder ou negar crédito influencia diretamente tanto nos lucros da IF quanto no vínculo com o cliente. O risco, nesse contexto, é definido com base na análise das características do cliente, comparando-as com perfis considerados positivos ou negativos, a fim de estimar a chance de uma ocorrência de perda.

Silva (2004) define que o risco de crédito é expresso na chance de prejuízos devido à incerteza acerca do retorno sobre um valor contratado por um tomador de empréstimo. O autor, ainda cita três situações que tem por consequência o risco de crédito:

- Risco de inadimplência, possibilidade de perdas pela incapacidade de quitar com as dívidas, previamente estabelecidas entre ambas as partes, tomador e credor;
- Risco soberano, o país-sede no qual o tomador reside, impõe alguma restrição

específica;

- Risco de concentração de carteira, dada pela não diversificação da carteira de empréstimos da IF.

Por mais que o resultado desejado seja classificar, de forma assertiva, se qualquer captação representará ou não inadimplência, Tavares (2004) afirma que o risco está presente em todas as operações do mercado financeiro, pois normalmente haverá alguma probabilidade, mesmo que pequena, de determinada etapa processual, falha humana ou algum outro agravante, converter-se em um impacto negativo.

Dependendo das especificações negociais que envolvam uma concessão de crédito, Securato e Famá (1997) afirmam que, é possível admitir um risco que eles consideram regular, quando a margem para dúvidas não é expressiva. Para aqueles clientes que não são conhecidos, ou que representam certa brecha que não atenda aos padrões mínimos de segurança necessários — a critério de cada instituição — são definidos como risco não regular ou marginal.

Ainda, Brito e Neto (2008) citam 3 tipos de risco de crédito, sendo eles:

- Risco de *default*: Chance de ocorrer um evento de *default* com o tomador, dado principalmente às características relacionadas;
- Risco de exposição: Quando ocorre o *default*, é necessário todo um aparato avaliativo para dizer o quanto foi perdido nesse acordo, expondo valores que podem crescer exponencialmente, a considerar, somas de juros não pagos, quando há garantias, a flutuação do preço desses bens, etc;
- Risco de recuperação: Imprecisão pós fato do *default*, em relação à quantia que conseguirá recuperar.

É também contextualizado pelo autor, que as IF realizam um cálculo chamado de mensuração de risco de crédito, no qual se quantifica a possibilidade de a instituição ter prejuízos caso os fluxos de caixa não alcancem as expectativas, devido aos insucessos.

Dado o exposto, o risco de *default* – objeto de estudo deste trabalho – constitui a principal variável desse processo, caracterizado como a incerteza do retorno monetário sobre os recursos assumidos.

2.1.1 Análise de Crédito

Operações de disponibilização de crédito, de fato, são ferramentas que, a longo prazo, possuem grande potencial lucrativo para as IF envolvidas neste mercado. Porém, analisar grandes fluxos de dados diariamente de forma generalizada, que visam bons negócios, é uma tarefa desafiadora, que exige metodologias com uma abordagem, um preparo e um investimento em processos classificatórios. Segundo Machado, Oliveira e Leite (2021), é essencial que as IF direcionem esforços para aprimorar os processos relacionados à gestão e ao desenvolvimento de modelos de mensuração de riscos, com o objetivo de promover uma maior sustentabilidade tanto econômica quanto estratégica.

De acordo com Tavares (2004, p. 3), a competição inerente do mercado (neste caso, financeiro) para oferecer melhores propostas negociais que consigam alcançar diferentes realidades, tracionam evoluções que buscam ser cada vez mais eficientes para concessão desse crédito, considerando também a exposição aos riscos.

Desta forma, segundo Paiva (1997, p. 20), as IF assemelham-se em suas metodologias para determinar o que é um grupo de clientes de menor risco e de alto risco, e quais características os discriminam entre si, por meio da ferramenta estatística nomeada como análise discriminante.

Para Saunders (2000, *apud* Silva (2004, p. 23)), a abordagem do risco de crédito se processa por meio de três classes de modelos: a) sistemas especialistas; b) sistemas de classificação; c) sistemas de pontuação de crédito.

- Sistemas especialistas - Saunders (2000, *apud* Silva (2004, p. 24)) define que, no sistema especialista, a decisão para a liberação do crédito tem influência total da pessoalidade do analista de crédito. Além de valer da experiência profissional, o analista tende a mensurar cinco fatores-chave subjetivamente, sendo eles: caráter, capital, capacidade, garantia real e ciclo ou condições econômicas. Entretanto, segundo Caouette, Altman e Narayanan (2000, *apud* Silva (2004, p. 24)), sistemas especialistas possuem problemas, principalmente relacionados à pessoalidade referente às decisões, e ainda complementam ressaltando que, um sistema especialista é tão bom quanto os profissionais que o compõem.

- Sistemas de classificação - Segundo Brito, Neto e Corrar (2009), os sistemas de classificação de risco têm como objetivo atribuir uma medida que reflita a expectativa de inadimplência associada a um determinado tomador. Essa medida, conhecida como *rating*, é representada por letras e/ou números, conforme uma escala previamente definida. Mesmo que essa escala varie conforme os critérios adotados por cada instituição, ela deve sempre estar fundamentada em indicadores econômicos de solidez. Para apoiar a avaliação do risco de crédito, tanto IF quanto agências especializadas utilizam metodologias estruturadas que circundam sistemas de classificação, garantindo fundamento para tomada de decisões. Segundo a STANDARD & POOR'S (s.d), uma das mais influentes agências de classificação de risco no cenário global, o *rating* de crédito demonstra esperanças futuras quanto à confiabilidade acerca de crédito para determinado tomador, funcionando como uma ferramenta para estimar a probabilidade de que suas obrigações financeiras sejam cumpridas pontualmente e em sua totalidade.

- Sistema de pontuação de crédito (*Credit Scoring*) - Conforme Saunders (2000, *apud*

Silva (2004, p. 26)), a ideia do *Credit Scoring* é a pré-identificação de fatores-chave que pressupõem a chance de inadimplência, produzindo assim uma pontuação quantitativa. Esta pontuação tem como finalidade tanto definir diretamente o risco de insolvência quanto classificar o tomador.

Brito e Neto (2008) definem os modelos de classificação como ferramentas utilizadas em seus processos de concessão de crédito. Normalmente, as esperanças são medidas e podem ser expressas em forma de classificação de risco (*rating*) ou pontuação (escore).

Conforme Paiva (1997, p. 20), os Bancos seguem uma estrutura para lidar com o fluxo relacionado ao deferimento de crédito.

Figura 1 – Sistema geral para classificação por *Credit Scoring*

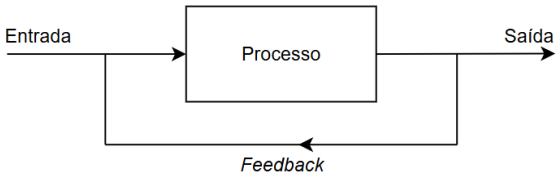

Fonte: Paiva (1997)

- Entrada: Normalmente é caracterizada por um ou mais dos 4 Cs do crédito (Caráter, Capacidade, Condições e Capital);
- Processo: É a metodologia, os pesos, os indicadores utilizados para discriminar os clientes;
- Saída: A classificação dos clientes em agrupamentos de risco ou de acordo com a probabilidade de perda;
- Feedback: É a margem de erro do Processo.

Segundo Santos (2010), para realizar a análise de crédito com o intuito de deferi-lo, as instituições podem recorrer à utilização de duas técnicas, sendo elas: a técnica subjetiva, baseada em julgamento humano, e a técnica objetiva, baseada em procedimentos estatísticos.

- A técnica subjetiva, ou caso a caso, baseia-se na experiência adquirida, disponibilidade de informações, internas ou externas, conhecimento técnico e no bom-senso. Desta forma, o analista tem capacidade de definir se o cliente possui aptidão para liquidez das dívidas adquiridas. Os Cs do crédito oferecem suporte para uma investigação de melhor qualidade, sendo eles:
  - Caráter, relacionado à idoneidade do cliente. Quando disponíveis informações históricas, auxilia esclarecendo a intencionalidade e pontualidade na amortização de dívidas;

  - Capacidade, entende-se como o julgamento subjetivo quanto à habilidade dos clientes em gerenciar e produzir lucro sobressalente, como forma de faturamento. Usualmente, à pessoa física é atribuída sua renda e à pessoa jurídica, sua receita;
  - Capital, que é medido através da situação financeira do cliente, levando em consideração a composição dos recursos, onde são aplicados e como são financiados. As fontes para análise, em sua maioria, para pessoa física são a Declaração do Imposto de Renda e, para pessoa jurídica, os Demonstrativos Contábeis;
  - Colateral, refere-se ao patrimônio do cliente que pode ser utilizado como garantias em cenários de situações adversas. Pode ser definido também como "garantia acessória"; um exemplo característico associado a este C são as hipotecas;
  - Condições, este C finalmente, está ligado a situações externas ou sistemáticas que podem sensibilizar a capacidade de pagamento dos clientes, tendo como exemplo: inflação, taxa de juros e paridade cambial (ou seja, a desvalorização do valor da moeda corrente).

- A técnica objetiva consiste em um instrumento para que os analistas de crédito consigam prever se determinado cliente pode vir a se tornar inadimplente no futuro. Trata-se de um modelo de avaliação baseado em uma fórmula estatística que tem como base dados cadastrais, financeiros, patrimoniais e de idoneidade do cliente. Esta fórmula é customizada, definindo pesos a cada índice de acordo com a prévia importância definida, podendo variar de linha de crédito para linha de crédito.

Complementando ao contexto apresentado por Santos, Silva (2008, p. 348) elucida a implementação da metodologia estatística *Credit Scoring* como sendo uma abordagem frente às necessidades massificadas, que não demandam uma minuciosidade acurada. Em resumo, a fórmula segue a estrutura:

$$Theta = C + X1p1 + X2p2 + X3p3 + X4p4 + X5p5 \tag{1}$$

Santos (2010) acerca da Fórmula 1 descreve como a soma do produto das variáveis por seus respectivos pesos e uma constante. As variáveis representam as características intrínsecas do tomador, como por exemplo: idade, dependentes, estado civil, etc. Os pesos são determinações arbitrárias por cada instituição, que refletem a importância relativa a cada variável, podendo variar ainda de acordo com a linha de crédito que será utilizada. Esses pesos são obtidos através de processos estatísticos, como análise discriminante ou regressão logística, e devem ser fixos na fórmula.

Após obter o valor é necessário ancorá-lo através do que o autor descreve como sendo a discriminação logística, a fim de definir o *score* (pontuação) que posteriormente será utilizado no sistema de classificação. Segue a fórmula:

$$Score = \frac{e^{Theta}}{(1 + e^{Theta})} \tag{2}$$

A vantagem de seguir pela técnica da Fórmula 3, está em padronizar o *score* em um número que varie numa escala entre 0 (zero) e 1 (um).

2.1.2 Inadimplência

Após o deferimento do crédito para a finalidade estipulada, existem dois possíveis cenários resultantes no tocante à liquidez deste empréstimo. O cenário em que o tomador honre a quitação das parcelas nas datas acordadas, sem que exista nenhum ônus econômico sobre sua renda ou receita que impacte os pagamentos. Desta forma é garantido, até o final do prazo, a solvência deste acordo. Em contrapartida, no panorama da não liquidez desta dívida, apresenta-se o quadro de inadimplência, ou seja, é adquirida uma dívida pelo tomador frente aos valores obrigatórios que deveriam ser gradualmente recuperados pela IF.

Segundo Santos e Famá (2006), após conceder um empréstimo, é desejado que os valores sejam pontualmente quitados, enquanto se garante que as economias do tomador estejam superiores ao valor das prestações. Contrariamente, atribui-se uma maior probabilidade de inadimplência quando o valor da renda for insuficiente.

De acordo com Teixeira (2001 *apud* Rebouças, Rocha e Costa (s. d)), a inadimplência pode ser definida como a falta de pagamento e, no sentido jurídico, nomeada como inadimplemento. O termo é utilizado para declarar a falta do cumprimento de determinada cláusula contratual.

Conforme Sehn e Junior (2007), inadimplência é a falta de pagamento ou o não cumprimento de um contrato ou cláusula. De forma mais específica, caracteriza-se como não cumprimento do pagamento por fatores influentes ou não cumprimento quando já vencido o prazo nas determinações acordadas (a título de exemplo contratual).

Maia (2007) esclarece que, qualquer que seja a prestação prometida, há por obrigação o cumprimento por parte do devedor, assim, tendo o credor o direito ao recebimento dos valores, respeitando o tratado aplicado. Assim, quando há o inadimplemento da obrigação, pode-se defini-lo como sendo absoluto ou relativo:

- Em termos jurídicos, inadimplemento absoluto, conforme o autor supracitado, acaba por ocorrer quando a obrigação não foi cumprida nem poderá sê-lo de forma útil ao credor. De forma mais simplificada, no inadimplemento absoluto, o atraso nos pagamentos ou o descumprimento das cláusulas previamente determinadas, torna inútil a recuperação/reabertura do objeto de motivação anteriormente motor para o acordo entre credor e tomador.

- Inadimplemento relativo, ainda conforme Maia (2007), concretiza-se quando ocorre o cumprimento não totalitário da obrigação, como, por exemplo, o pagamento fora da data estipulada.

2.2 Inteligência Artificial

A constante evolução tecnológica, refletiu em prol de diversos processos que antes tinham necessidade de operação manual, aperfeiçoando-os para que pudessem diminuir a interação humana, automatizando tarefas e ocasionando assim, numa maior eficiência em seus resultados.

Conforme Sichman (2021) destaca, o campo da Inteligência Artificial (IA) é constituído por diversos modelos, técnicas e tecnologias — incluindo busca, raciocínio, representação do conhecimento, mecanismos de decisão, percepção, planejamento, processamento de linguagem natural, tratamento de incertezas e aprendizado de máquina — que, aplicados individualmente ou em conjunto, são capazes de oferecer soluções para problemas típicos.

Nesse âmbito, o mercado financeiro também se beneficia, aproveitando das capacidades oferecidas pela IA, no intuito de constantemente tornar seus processos melhores e consequentemente, aumentar seus ganhos em receitas e sua influência. Como exemplo, o Banco digital NuBank, que implementou para alguns usuários no início do ano, um modelo de recomendação acerca de linhas de crédito, identificando as necessidades de cada cliente e indicando as melhores opções de acordo com o perfil e elegibilidade de cada um (NUBANK (2025)).

Segundo Barbosa e Portes (2019), a IA é uma prática desenvolvida para dispositivos eletrônicos de mimetizar o comportamento humano. Isto é, estruturar resoluções para problemas de forma análoga há como nós fazemos. A IA se propõe a lidar com problemas cotidianos como raciocinar, perceber e tomar decisões, analisando, aprendendo e interpretando informações para que assim, consiga operar com suas conclusões.

Sichman (2021), ainda define que existem 4 principais paradigmas distintos que podem ser utilizados como abordagem no sentido de resolução de problemas utilizando IA. Sendo eles:

- Paradigma simbólico - Primariamente é preciso reconhecer o problema que se está lidando, para então representá-lo partindo de uma linguagem formal e seguidamente, desenvolver um procedimento para inferir, gerando conhecimento. De forma mais simplificada, a IA "gera" sua inteligência partindo de regras lógicas bem definidas, semelhantes as utilizadas em linguagens de programação, como "se..." ou "então...";

- Paradigma conexionista - No paradigma conexionista, a linguagem assemelha-se ao comportamento e organização dos neurônios humanos, capacitando assim, o aprendizado e generalização com base em exemplos. São comumente utilizadas em problemas de Redes Neurais;

- Paradigma evolutivo – De forma geral, inspira-se na teoria de seleção natural dos indivíduos mais aptos, ou nesse caso, as soluções mais aptas a resolverem determinado problema. Hereditariedade, mutação, seleção natural e recombinação (*crossing over*), são ferramentas utilizadas pelo paradigma para selecionar as melhores gerações ou melhores indivíduos;

- Paradigma probabilístico - O modelo baseia-se não somente em verdades absolutas, mas que a disposição e probabilidade de determinadas variáveis ou fatos virem a ocorrer, podem variar de acordo com mudanças fornecidas previamente ou que são

interpretadas ao longo do processo. Para alcançar tais objetivos, o modelo possui técnicas estatísticas e probabilísticas a disposição.

2.3 *Machine Learning*

Machine Learning (ML) ou em português, Aprendizado de Máquina, pode ser entendido como um subconjunto que compõe a IA. Conforme Géron (2019, p. 4), ML é a ciência que busca gerar conhecimento a partir dos dados.

Pellicer (2020) descreve que um projeto de ML é dividido em secções que são interpretadas de forma contínua. É necessário o pré-processamento dos dados, a fim de organizar informações relevantes para treinamento, além da possibilidade de ocorrer junção de variáveis correlatas ou seleção das mais expressivas. Seguindo, o modelo é confrontado com a distribuição de dados, buscando extrair conhecimento significativo. Finalmente, como resultado obtém-se o modelo.

Ainda, a aplicabilidade de modelos de ML pode ser vastamente explorada nos mais diversos setores e áreas. Yang e Shami (2020) destacam alguns domínios de aplicação pertinentes, como por exemplo, publicidade, sistemas de recomendação, visão computacional, processamento de linguagem natural e análise de comportamento do usuário. Tais aplicabilidades são possíveis, dado que os modelos possuem a habilidade de generalizar em alta performance com a mineração dos dados.

2.3.1 Tipos de Sistemas de *Machine Learning*

De acordo com Géron (2019), existem diferentes procedimentos para modelos de ML, cada um com uma abordagem de como lidar com os dados, podendo ainda complementar-se no "caso a caso" demandado. Tais grupos podem ser descritos da seguinte forma:

- Supervisionado, não supervisionado, semissupervisionado e aprendizado por reforço;
- Se podem ou não aprender rapidamente, de forma incremental (aprendizado *online* versus aprendizado por lotes);
- Comparar novas instâncias que chegam com informações antes memorizadas, ou gerar um modelo a partir da detecção de padrões nos dados (aprendizado baseado em instâncias versus aprendizado baseado em modelos).

2.3.2 Aprendizado Supervisionado/Não Supervisionado/Semissupervisionado/Por Reforço

Conforme esclarece Géron (2019), os sistemas de ML vão variar conforme a supervisão humana empregada sobre a etapa de treinamento do modelo.

Silva (2018) ainda destaca que, este escopo na ordem de aprendizado, é característico pelo raciocínio partindo do específico para o total. Atingir generalizações com base nos dados, é alcançado através do que é definido por inferência lógica. Valendo ressaltar que, como se trata de uma inferência, pode ou não preservar a verdade.

2.3.2.1 Aprendizado Supervisionado

Acerca do aprendizado supervisionado, o autor suprarreferido define que as soluções desejadas estão contidas nas informações fornecidas, ou seja, os dados de treinamento, previamente englobam consigo a(s) variável(eis) - ou rótulos – que concluem dada subamostra. Para exemplificação, trazendo ao cenário da monografia, uma das variáveis, indica se houve ou não solvência para determinada dispersão de informações, adimplente ou inadimplente.

Em cenários supervisionados, a tarefa de classificação é típica, assim como a previsão de valores numéricos. Para prever um valor/categoria, é tido como base um conjunto de características (idade, nome, nível de escolaridade, etc.) que de acordo com Géron (2019), são classificados como previsores.

2.3.2.2 Aprendizado Não Supervisionado

Em contrapartida ao aprendizado supervisionado, o não supervisionado, não possui seus dados de treinamento rotulados. Desta forma, entende-se de acordo com Géron (2019) que, os modelos possuem a capacidade para detectar grupos semelhantes, eles são capazes de encontrar conexões sem ajuda.

Para que isso seja possível, os modelos dispõem de processos que visam descomplicar a interpretação dos dados. O primeiro exemplo citado, é a redução de dimensionalidade, uma tarefa à qual tem por objetivo, simplificar os dados sem perder muita informação, podendo mesclar características correlacionadas em uma. A título de exemplo, Géron (2019) cita que a quilometragem de um carro pode estar muito relacionada com seu tempo de uso, assim, o algoritmo pode mesclar ambas as informações, resultando na característica, desgaste do carro.

Outro comportamento importante apontado por Géron (2019) é a capacidade de detecção de anomalias. Nesse sentido, o sistema será treinado com instâncias padrão, que representem determinada característica habitual; porém, quando exposto a uma nova instância incomum, ele deve ser capaz de predizer se é uma provável anomalia.

2.3.2.3 Aprendizado Semi-supervisionado

No cenário em que o aprendizado é semi-supervisionado, Géron (2019) destaca que existem dois cenários possíveis, o primeiro seria com uma base de dados de treinamento parcialmente rotulada, e o segundo tendo uma base de dados em sua maioria com dados não rotulados, e uma pequena parcela classificada. Normalmente, algoritmos semi-supervisionados tem como estrutura, algoritmos supervisionados juntamente dos não supervisionados.

2.3.2.4 Aprendizado por Reforço

Chamado de agente, o sistema de aprendizado por reforço, de acordo com Géron (2019), assemelha-se a um adestramento. Imagine que você deseja que aquele que será adestrado execute alguma função, nesse processo você ensina a como realizar a tarefa e, a depender da resposta executada pelo adestrado, haverá uma recompensa, indicando que está se seguindo o caminho certo até o objetivo, ou, uma punição, que nesse contexto é entendido como uma recompensa negativa. Obviamente, existem muito mais diferenças do que semelhanças entre o Aprendizado por Reforço e um adestramento, porém, a base geral deste aprendizado apoia-se justamente na condição de recompensas.

Neste método de aprendizado, ainda é possível "acumular" gratificações para serem oferecidas posteriormente, no intuito de adiantar o processamento, evitar a todo novo passo dado avaliar se a recompensa é negativa ou positiva. Portanto, a depender do caso, agregar punições ou retrocessos pode ser uma escolha viável (AMAZON WEB SERVICE (2024)).

2.3.3 Aprendizado *Online* e em Lote

Aprendizado *Online* e por Lote, devem ser entendidos como opções disponíveis para escolha quando for desenvolver um modelo de Aprendizagem de Máquina. Conforme Géron (2019), no modelo de aprendizagem em lote, o modelo não possuí a capacidade de aprender de forma acumulativa, ele precisa que todos os dados necessários estejam dispostos para uso.

Dado que, a depender de cada cenário, e a possibilidade de a base de dados ser vasta, é recomendado que o treinamento seja feito *offline*, principalmente pelo fato de demandar alto custo computacional.

Além disso, Géron (2019) ressalta a importância de saber que, a cada nova adição de informações que não antes foram consideradas no treino, se faz necessário uma nova capacitação do modelo, tanto com os dados recentes quanto com os dados antigos. Desta forma, fica evidente que no sistema de aprendizado em lote, existe a limitação do treinamento incremental e dinâmico.

Géron (2019) destaca que no procedimento *online*, em contrapartida, o aprendizado é feito de forma crescente, sustentando consecutivamente as instâncias de forma individual ou em grupos, nomeados pelo autor como minilotes. Em sistemas com grande afluência de dados, o Aprendizado *online* se destaca, principalmente pelo fato contrário comparado ao aprendizado por lote, de adaptar-se rapidamente e por iniciativa própria.

Vale também evidenciar uma variável importante no processo de aprendizado *online* chamada de taxa de aprendizado. Nela é possível determinar o quão rápido se deseja que o modelo aprenda com os novos dados que surgirem, porém, quanto mais rápido, maior a tendência de esquecimento de informações previamente analisadas, e quanto mais devagar, maior a inércia sobre o aprendizado, porém, menos sensível para novos dados ou dados sem representatividade significativa (Géron (2019)).

Figura 2 – Tendências da taxa de aprendizado para aprendizado online

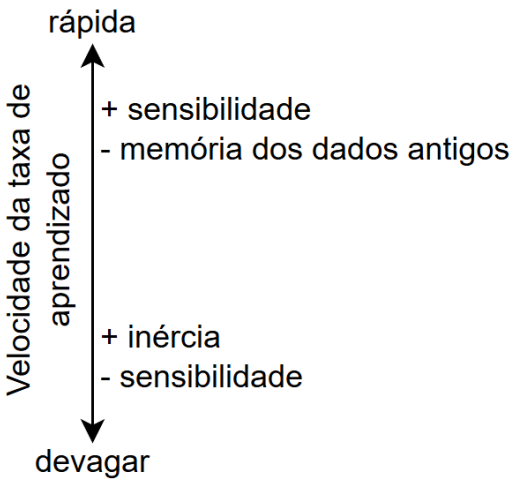

Fonte: Gerado pelo autor

2.3.4 Aprendizado Baseado em Instâncias, em Modelos e Paradigma Simbólico

Finalmente, Géron (2019) destaca que, realizar previsões é uma tarefa comumente atribuída ao ML. Ou seja, dada uma série de exemplos de treinamento que será exposto, o sistema precisa ser capaz de generalizar em casos não conhecidos.

Segundo Ferreira (2018), classificar dados segue como base uma metodologia que propicia gerar conhecimento, conhecimento esse, criado através de separar e classificar características. Para viabilizar classificações, em geral, os sistemas procuram por similaridades, as quais são desenvolvidas a partir do ponto de experiência alcançado por interpretar diferenças e relações entre objetos conhecidos com desconhecidos.

Géron (2019) então define que, existem duas abordagens principais para a generalização, sendo elas: Aprendizado Baseado em Instâncias e Aprendizado Baseado em Modelos.

2.3.4.1 Aprendizado Baseado em Instâncias

Como afirma Géron (2019), a forma mais usual de aprendizado é decorar. Em um modelo baseado em instâncias, decorar é uma das atividades mais importantes desempenhadas. Neste cenário, é preciso dispor de uma gama de dados já rotulados. Vamos supor um dado que está classificado como A e outro como B, dentre as possibilidades possíveis A e B. Quando uma nova instância X aparecer, o modelo busca determinar em qual categoria esta instância se encaixa, alcançando este objetivo, comparando os dados categorizados que já dispõe, em contraponto à nova informação. Esta comparação é feita através do que Géron (2019) define como medida de similaridade, que em linhas gerais, diz o quanto X é similar à classe A ou B partindo da comparação entre suas informações.

Complementando, Santos e Nicoletti (2018) definem os três pilares que caracterizam os algoritmos da família IBL (*Instance-Based Learning*), sendo eles:

- Função de Similaridade - encarregada de avaliar o grau de similaridade entre uma instância de treinamento i e as instâncias que compõem a definição do conceito.
- Função de Classificação - encarregada de atribuir uma categoria à instância i. Para determinar a classificação de i, são levados em conta tanto o resultado da função de similaridade quanto os dados de desempenho de classificações passadas que demonstram o conceito.
- Atualizador da Descrição do Conceito – encarregado de atualizar os registros de desempenho de classificação e decidir quais instâncias serão consideradas a serem inclusas do conceito. Como parâmetros são, a instância i, os resultados de classificação e a definição do conceito. Responsabiliza-se pela modificação do conceito.

Figura 3 – Algoritmo K-Nearest-Neighbours

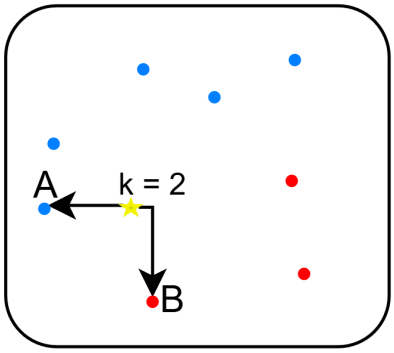

Fonte: Gerado pelo autor

2.3.4.2 Aprendizado Baseado em Modelos

Contrariamente ao modelo de prever a categoria de determinada instância partindo de outras que já estejam rotuladas na proximidade, no aprendizado baseado em modelo, a intenção é, de acordo com Géron (2019), construir um modelo a partir dos exemplos disponíveis, com o objetivo de ser utilizado para fazer previsões.

Podendo também ser definido como paradigma estatístico, Ferreira (2018) esclarece que tal paradigma tem por objetivo em sua tarefa de aprendizagem, determinar um modelo que consiga classificar os dados corretamente. Para essa finalidade, portanto, admite-se que os dados, primeiro, sejam independentes uns dos outros, ou seja, não haja interferência de determinada informação a outra, e segundo, que os dados possuam uma distribuição relacionada, melhor dizendo, que as instâncias possuam uma equivalência em sua organização, evitando que dados destoantes ou distantes de um todo possam interferir.

Para aperfeiçoar a previsibilidade do modelo/função matemático(a) quando gerado, Géron (2019) elucida que é necessário especificar um modelo de desempenho. A função *fitness* ou função de utilidade, mede o quão bom o modelo é, enquanto a função de custo mede o quão ruim ele é.

2.3.4.3 Paradigma Simbólico

Conforme Ferreira (2018), o paradigma de aprendizado simbólico tem como base criar representações simbólicas, ou seja, representações compreensíveis que elucidam o comportamento de classificação por meio de regras explícitas aplicadas em exemplos e contraexemplos de determinada base de dados. Resultando assim em rótulos concebíveis para o problema. De acordo com Gomes (2002, *apud* Silva (2018)), representações simbólicas estão tipicamente expressas na forma de árvore de decisão, regras de produção ou rede semântica.

Tomando como exemplo, árvores aleatórias com objetivo de classificação, Silva (2018) esclarece que todos os níveis da árvore são decisões que se relacionam com a estrutura do nível seguinte, até atingir os nós terminais. Isto demonstra que a cada nível da árvore, um problema mais complexo de previsão/classificação é diminuído em problemas mais simples, convergindo na produção de nós descendentes, onde a exclusividade da variável resposta é destacada.

2.3.5 Árvore de Decisão

Conforme DELGADO et al. (2012), Árvores de Decisão são algoritmos que fazem parte do escopo de mineração de dados, auxiliam na tomada de decisões. Elas utilizam mecanismos de categorização usando divisão hierárquica dos dados, ou seja, um rótulo novo é gerado para uma instância desconhecida através do seguimento de decisões lógicas.

Detalhadamente, conforme diz Lemos, Steiner e Nievola (2005), a capacidade de discriminação de uma Árvore de Decisão é possível graças à divisão em espaços menores para classificação/regressão dos atributos possíveis no escopo de um problema, e simultaneamente, é direcionado uma classe para cada espaço novo. Em sua estrutura temos os seguintes itens que a compõem:

1. nós, responsáveis por representar os atributos ou regras. Os nós podem ainda desempenhar dois papéis dentro da árvore, sendo esses: nó raiz, o atributo mais importante é demonstrado, a categoria à qual inicia a árvore (Lemos, Steiner e Nievola (2005)); nó-folha, não possui nenhum nó filho, representa a classificação final para dada amostra analisada;

2. ramos, proveniente dos nós e que recebem os valores possíveis para cada atributo (GARCIA, 2000 apud Lemos, Steiner e Nievola (2005)).

Com o intuito de poder verificar uma árvore de decisão, tomaremos o exemplo posto por Géron (2019). A título de contexto, fora gerado a visualização da distribuição de uma árvore que busca classificar espécies de flores da família íris.

Figura 4 – Árvore de Decisão Classificação Íris

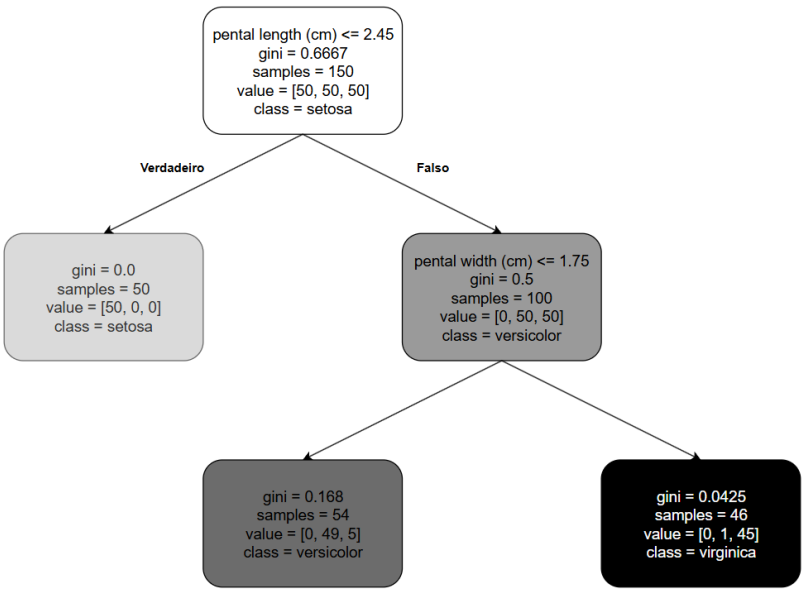

Fonte: Géron (2019)

Seguindo como base o autor, vamos à explicação de cada indicador apresentado na Figura 4:

- *samples* – conta a quantidade de instâncias pertencentes aquele nó. Por exemplo, é sabido que 150 instâncias possuem pétalas com comprimento menor ou igual à 2.45;
- *values* – diz a quantas instâncias de treinamento de cada classe este nó se aplica. Por exemplo, o nó inferior à direita se aplica a 0 Íris-Setosa, 1 Versicolor e 45 Virginica;
- gini – mede a impureza de um nó. Um nó só será puro (gini = 0) se todas as instâncias de treinamento pertencem à mesma classe a qual se aplica. Por exemplo, o nó a esquerda de profundidade 1 aplica-se somente a classe Íris-Setosa, portanto gini = 0;
- limiar – uma regra que divide as amostras. Por exemplo, no nó-raiz o limiar é a regra: *pental length* (cm) <= 2.45.

A equação de gini, calcula a pontuação do i-ésimo nó. Por exemplo, o nó direito de profundidade 2 tem uma pontuação de gini igual a: $1 - (\frac{0}{46})^2 - (\frac{1}{46})^2 - (\frac{45}{46})^2 = 0.0425$

$$G_i = 1 - \sum_{k=1}^{n} P_i, k^2 \tag{3}$$

Além de conseguir chegar até o valor do coeficiente, é possível estimar as probabilidades de cada instância aplicadas a certa classe k. Seguindo com o exemplo apresentado acima, os resultados de estimativa devem ser: 0% para Íris-Setosa, 2,17% ($\frac{1}{36}$) para Versicolor e 97,8% ($\frac{45}{46}$) para Virginica. Ou seja, dadas as probabilidades neste exemplo, grandes são as chances de a instância pertencer à classe virginica.

2.3.5.1 *Ensemble Learning*

Em linhas gerais, *Ensemble Learning* ou Aprendizado por agrupamento, entende-se como a junção de variados modelos preditores, que utilizam da mesma base de treinamento para atender determinada tarefa (classificação/regressão), no intuito de reunir os resultados individuais em busca de um "consenso". Esta técnica possui grande vantagem, pois com ela, o processamento para alcançar tal propósito ganha robustez. É esclarecido por Géron (2019) que, um conjunto de previsores é chamado de *ensemble*; assim, a técnica de agrupá-los é chamada *ensemble learning*, e um algoritmo de *ensemble learning* é chamado de *ensemble method*.

Segundo Mienye e Sun (2022), *ensemble learning* é uma técnica utilizada para combinar dois ou mais algoritmo de Aprendizado de Máquina para obter uma performance superior se comparado à quando os algoritmos são utilizados individualmente. Ao invés de basear-se em um único modelo, as predições a partir de aprendizes individuais, são combinadas utilizando uma regra para alcançar uma única previsão.

Como mostra a Figura 5, na disposição dos modelos para prever uma instância, conforme Géron (2019) esclarece, aprendizes fracos, é a unidade do modelo, aquele que executa seu próprio treinamento, enquanto que o forte aprendiz, é a junção do previsto por cada aprendiz fraco, potencializando o poder dedutivo.

Figura 5 – *Ensemble Learning* para classificação

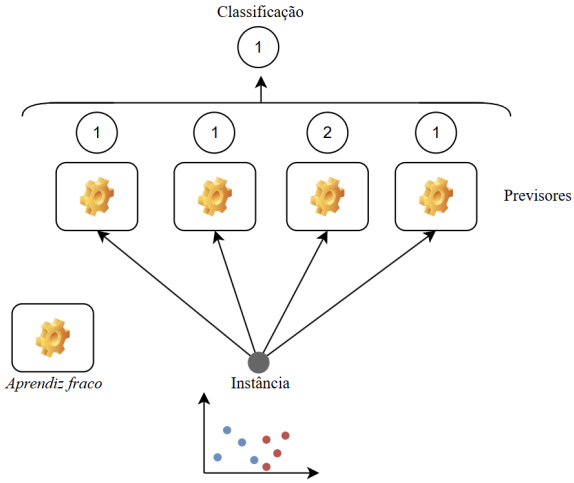

Fonte: Géron (2019)

2.3.5.2 *Boosting*

Outra das abordagens possíveis que podem ser aplicadas no contexto do *ensemble*, é o *Boosting*. Segundo Mienye e Sun (2022), o *Boosting* é aplicado de forma iterativa. Cada aprendiz fraco processa os dados de entrada, distinguindo-os frente as classificações possíveis. Uma vez finalizado esse processo, será computado os resultados, aplicando um peso maior as informações erroneamente categorizadas. Essas informações são de extremo valor para os modelos subsequentes, pois, erros de classificação serão tratados com maior destaque nas próximas rodadas a fim de serem corrigidos, dado que, por conta de seu peso, os aprendizes fracos tendem a focá-los.

Figura 6 – Classificação *ensemble boosting*

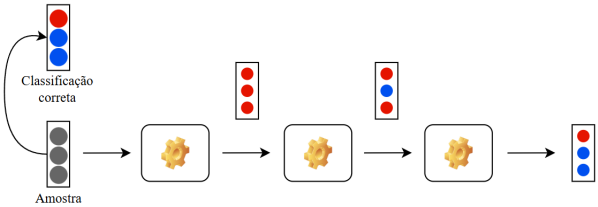

Fonte: Gerado pelo autor

2.3.5.3 *Bagging*

Breiman (1994) define *Bagging* como sendo a previsão por meio de agregação de preditores que são replicados em múltiplas versões, ocasionando em um preditor agregado. Em uma regressão, é feito uma média das previsões agregadas para chegar a um valor numérico, enquanto em tarefas de classificação, o voto majoritário ou voto por pluralidade, será critério para definir o pertencimento de determinada instância, vide como exemplo a Figura 5.

Outra característica importante citada por Géron (2019), refere-se ao comportamento do Bagging quanto ao relacionamento com os dados. É dito que nesse sistema, é

permitido a possibilidade de variância de subamostras retiradas da base de treinamento, e que então são treinadas individualmente por cada previsor. Ocorrendo ainda a possibilidade de uma instância ser avaliada mais de uma vez por um previsor, garantindo assim, maior cobertura de cenários com possível ocorrência.

2.3.6 *Random Forest*

Random Forest (RF) ou Florestas Aleatórias, é um *ensemble* de Árvores de Decisão que em sua maioria de aplicações, utiliza do método *bagging* para treinamento.

A priori, é importante entender o funcionamento deste algoritmo quanto ao seu envolvimento com os dados. Ho (1995) define a ideia principal como sendo a de selecionar subamostras randômicas da base geral de treinamento, para que sejam usadas como entrada na construção de diferentes árvores. Desta forma, é possível atingir um grau satisfatório de generalização dos casos, dado que, cada árvore contribui de forma independente com um escopo individual de dados para si.

Breiman (2001) destaca em seu estudo que, ao selecionar os conjuntos de dados aleatórios que serão implementados como entrada, essa escolha deve potencializar ao máximo a diminuição da correlação entre as árvores, ou seja, quanto mais amostras aleatórias separadas em mais indivíduos, melhor. A diminuição desta correlação entre elas é determinante, pois evita que aconteça *overfitting* (cenário possível se todas as árvores utilizassem da mesma amostra), como também melhora a acurácia e diminui a variância.

Desta forma, Santana (2020) exemplifica como é o funcionamento da separação destas informações, no qual, dois terços das amostras serão separadas para treinamento, enquanto a outra parte fica a disposição para ser utilizada como validação posterior (chamadas também de *out of bags – OOB samples*). Determinadas as partições, o RF aleatoriamente escolhe quais e quantas variáveis compor em cada nó de sua árvore. Por padrão, a métrica utilizada para o termo conhecido como *mtry* é $\sqrt{(n)}$, sendo n o número de variáveis.

O comportamento de avaliação das árvores então, será análogo ao feito pela Árvore de Decisão, herdando também os mesmos hiperparâmetros. Géron (2019) enfatiza que o sistema tem a habilidade de determinar quais variáveis são mais importantes para o conjunto de treinamento, levando em consideração seu impacto direto na pureza de cada nó.

2.3.7 Tratamento dos Dados

Para alcançar bons resultados de predições em um modelo de ML, uma etapa muito importante, é tratar as informações que serão fornecidas como entrada. Cada base de dados possui características únicas que podem variar, e a depender de como se mostra estes elementos, o impacto no resultado do algoritmo é expressivo, dado que, é possível deparar-se com dados ruidosos, incompletos ou inconsistentes.

Conforme Júnior et al. (2020) no processo de desenvolvimento de um modelo de ML, sua performance depende fortemente da qualidade dos dados que serão consumidos. Normalmente, cenários adversos ocorrem por conta, seja de que os dados foram esquecidos ou perdidos, bem como, quem gerou as informações não se atentou a falta delas, ou ainda, os valores (numérico, decimal, etc.) que foram utilizados para descrever tal particularidade, não serviam para o propósito.

Portanto, segundo Soares (2015), se faz necessário o pré-processamento de tudo que esteja desacertado ou faltante, habitualmente conhecidos como *missing values* e *outliers*.

2.3.7.1 *Missing Values*

Na maioria dos algoritmos implementados para ML, não é interessante que existam *missing values* ou dados faltantes. Segundo Cordeiro (2020), a investigação e intervenção para normalizá-los, é fator ímpar quanto aos resultados que serão colhidos. Existem três potenciais categorias para *missing values*, sendo elas (Schaper; Graham, 2002, *apud* Cordeiro (2020)):

- MCAR – Dados ausentes completamente aleatórios: Não existe nenhum vínculo entre os dados aleatoriamente faltosos com os dados presentes.
- MAR – Dados ausentes aleatórios: Existe alguma relação entre os dados ausentes e determinada informação da instância.
- MNAR – Dados ausentes não aleatórios: Existem relações entre dados inexistentes e os dados que serão analisados presentes.

Diante disso, Júnior et al. (2020) contextualiza que existem duas formas populares que podem ser aplicadas a fim de contornar essa situação. Ignorar e descartar a informação (ou neste caso, a falta dela), tendo a redução do espaço de amostras como consequência.

Detalhadamente, Soares (2015) esclarece que na abordagem de ignorar e descartar, tanto variáveis quanto amostras podem ser suscetíveis a tal procedimento. É importante alertar que, no cenário o qual existe uma porcentagem significativa de dados faltantes que interfiram nos dados totais, aplicar essa metodologia, pode não ser interessante, e é daí que surge a imputação. Na imputação, o objetivo é de substituir a falta por algum valor concebido em alguma técnica. O procedimento principal utilizado é a média dos valores de um atributo x, aplicado à informação faltante. Ainda, existe a técnica de última observação transportada (LOCF), a qual busca substituir a informação faltante pelo dado medido anterior. Por fim, temos a imputação por regressão, na qual utiliza-se de um modelo preditivo de regressão, no intuito de prever o valor a ser preenchido com base na disposição geral da base de dados.

2.3.7.2 *Outliers*

Segundo Aggarwal (2017), *outliers* são informações que fogem de um "padrão" a ser seguido, desviam-se da disposição geral dos dados, causando anomalias. Geralmente o aparecimento de discrepâncias, estão ligados a comportamentos inesperados tanto do sistema que gerou a informação, quanto da entidade, que no procedimento de coleta dos dados ou na digitalização deles, aconteceu alguma irregularidade.

Soares (2015) identifica que, *outliers* são amostras inconsistentes em relação à base de dados em geral. Sua detecção e tratamento são cruciais para a performance de um modelo, sendo que, as técnicas necessárias para cumprir essas etapas podem ser descritas como abordagens, univariadas (manejo individual de cada variável) ou multivariadas (manejo feito quando há forte relação entre variáveis, procurando evitar impactos de variabilidade entre elas).

De acordo com Aggarwal (2017), normalmente os algoritmos de detecção de discrepâncias atribuem pesos a dados que podem ser desviantes. Um modelo é treinado para identificar qual é a convergência padrão das informações, (o "padrão" que deve ser seguido), desta forma, quanto maior a diferença de um ponto de dado for da centralização observada, maior será seu peso atribuído. Portanto, o autor referido destaca alguns modelos comuns utilizados para atender esta tarefa:

- Análise de Valores Extremos – Neste modelo estatístico, a ideia principal é identificar e categorizar, o que deve ser considerado *outlier* nas caudas de uma assumida distribuição normal dos dados. Naturalmente são desenvolvidos para abordagens de dado univariados ou unidimensionais (dados de única dimensão, cada dado observado segue uma única medida. Ex: idade em anos, altura em cm, temperatura em graus celsius);

- Modelos Probabilísticos e Estatísticos - Os modelos utilizam metodologias estatísticas e probabilísticas baseadas nos dados para identificar a qual agrupamento um determinado ponto pertence, assumindo que ele foi gerado por um desses grupos. A cada ponto é atribuída uma probabilidade de pertencimento a cada *cluster*. Quando essa probabilidade é baixa, o ponto é considerado um *outlier*, por apresentar pouca evidência de que pertence a algum dos grupos encontrados;

- *Proximity-Based Models* – A abordagem aqui é de forma que os *outliers* são identificados como pontos isolados do restante dos dados, podendo ser utilizado como métricas, funções de similaridade ou de distância. Esta técnica pode ser descrita de três formas diferentes, sendo elas: a) métodos de clusterização, no qual regiões densas de dados são identificadas e consequentemente, agrupadas, assim sendo utilizadas em futuras avaliações. Pontos que estejam longe ou não contidos em tais regiões, são identificados como *outliers*; b) métodos de densidade são parecidos com os de clusterização, salvo, que eles não determinam agrupamentos. São identificadas regiões que de fato são densas, o que indica uma propensão de informações que convergem em um "padrão", desta forma, pontos que estejam em áreas mais esparsas, serão tratados como *outliers*; c) métodos de vizinho mais próximo, finalmente, determina para cada dado uma pontuação de *outlier*, indicado por sua distância em relação ao k-ésimo vizinho mais próximo. Determinando $k > 1$ (quantos vizinhos por conjunto aceitos), pequenos agrupamentos de vizinhos, identificam dados que estejam distantes deles, assim encontrando *outliers*;

- *Linear Models* – Nesses modelos, primariamente os dados são distribuídos em espaços dimensionais através do uso de correlação linear. Feito isso, são determinadas linhas por regressão linear, que dirão qual é a tendência "padrão" a ser seguida dentro do que é definido como hiperplano, conforme Figura 7. Desta forma, quanto mais distante o ponto for deste hiperplano, maiores são suas chances de apresentar um *outlier*.

Figura 7 – Modelo Linear para detecção de *outliers*

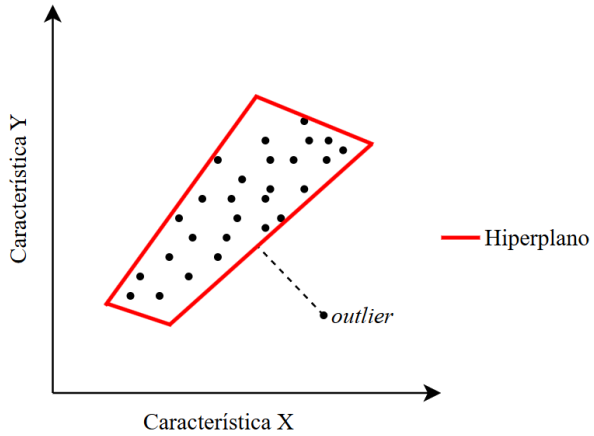

Fonte: Gerado pelo autor

2.3.8 Balanceamento dos Dados

Dados desbalanceados são outra discussão que deve ser examinada, e caso preciso, resolvida. Entende-se como o desbalanceamento quando a quantidade de uma classe específica excede em relação às outras. Segundo ALGARNI, ALGARNI e ALOUANE (2025), o desbalanceamento ocorre pela desigualdade na distribuição das classes, ocasionando assim, que determinada esteja em maior número (classe majoritária) e outra em menor número (classe minoritária). Como resultado desta desproporcionalidade, o modelo tende a tornar-se enviesado sobre a classe excedente, não raramente ignorando a classe minoritária. Assim, erros de categorização são passíveis de ocorrer.

Dada a motivação desta problemática, a literatura acerca do tema destaca que existem três forma principais para lidar com dados desbalanceados. De acordo com Troullinou et al. (2024), as técnicas utilizadas são separadas em:

- Abordagem no nível dos dados, no qual são realizadas técnicas de subamostragem em classes majoritárias ou superamostragem em classes minoritárias.

    1. Subamostragem (*undersampling*) - realizada para diminuir o número de instâncias da classe majoritária através de remoção aleatória, tendo como alvo em algoritmos modernos, informações que sejam consideradas redundantes ou menos significantes para a classificação. É válido destacar que tais algoritmos devem ser utilizados com cautela, pois uma aplicação errônea pode comprometer o comportamento do modelo, dado que, num cenário onde informações vitais da majoritária são deletadas ou uma redução imprecisa aconteça, ocasionem

problemas de *underfitting*, ou seja, incapacidade de classificação (ALGARNI, ALGARNI e ALOUANE (2025)). ENN (*Edited Nearest Neighbors*) é um algoritmo comum deste espectro, o qual compara os k vizinhos de um ponto de dado e se a maioria dos vizinhos for de uma classe contrária à sua, ele será removido.

2. Superramostragem (*oversampling*) - técnica que aumenta o número de instâncias da classe minoritária. Para entender o conceito, Xiaolong, Wen e Yanfei (2019) discorrem sobre o algoritmo mais conhecido para este fim, chamado de SMOTE (*Synthetic Minority Over-sampling Technique*). Seu funcionamento baseia-se em criar amostras sintéticas por interpolação do vizinho mais próximo sobre o ponto de dado da classe minoritária escolhido. De forma simplificada, do ponto x é escolhido o k vizinho mais próximo, e o novo ponto é gerado na reta da distância $k - x$. Porém, existe o problema da super generalização, pois o algoritmo pode criar instâncias imprudentemente, acarretando em problemas de *overfitting*. Dado isto, diversas variações do SMOTE foram desenvolvidas na literatura, com destaque para o *Borderline*-SMOTE, o qual categoriza as amostras observadas em grupos, isto é, quando mais da metade dos k vizinhos são da classe majoritária, esta amostra minoritária pertence ao grupo *danger samples*; quando mais da metade dos k vizinhos são minoritários, então é *safe sample*; quando todos os k vizinhos são majoritários, indica um *noise sample*. Separados todos os agrupamentos, o *Borderline*-SMOTE apenas gera novos pontos no grupo *danger samples*.

- Abordagem no nível do modelo, busca realizar alterações pontuais no comportamento algorítmico do modelo que será utilizado, tendo como uma das técnicas mais conhecidas, a aprendizagem sensitiva ao custo, que em linhas gerais, são priorizados má classificações de amostras positivas ou minoritárias na função de custo, sem intervenção direta na base de dados (HE et al. (2021));

- Abordagem híbrida busca diminuir as deficiências e aproveitar das forças de ambas as abordagens, juntando-as.

2.3.9 Otimização de Hiperparâmetros

Hiperparâmetros são parâmetros que podem ou não ser customizados, os quais conduzem o comportamento do algoritmo, visando melhorar a performance de previsibilidade do modelo de ML.

Segundo Yang e Shami (2020), hiperparâmetros são parâmetros configuráveis utilizados para as finalidades tanto de ajustar previamente ao treinamento o modelo de ML, quanto de orientar o algoritmo para minimizar a função de perda (avalia qual das funções escolhidas pelo modelo possui a menor média de distância entre os pontos dispostos em um plano cartesiano bidimensional, por exemplo). Vale destacar que existem dois tipos de parâmetros acerca dos modelos de ML, temos: parâmetro do modelo, o qual tem sensibilidade ao processo de aprendizagem, implicando que seus valores podem ser inicializados e atualizados durante tal processo; hiperparâmetros, aqueles os quais não podem alterar-se em tempo de execução do aprendizado, precisam ser definidos anteriormente a este ponto.

Dado o contexto, existem abordagens algorítmicas que buscam aperfeiçoar o desempenho do modelo que será utilizado, através da manipulação de seus hiperparâmetros. Conforme Silva (2022), a otimização de hiperparâmetros busca melhorar a performance de algoritmos e modelos de ML através da ponderação de todas ou a maioria dos intervalos de valores possíveis de cada hiperparâmetro do modelo, obtendo como ganho, mitigação do sobre ajuste, do desempenho, ganho de performance, etc.

Desta forma, a literatura apresenta diversas técnicas diferentes que procuram atender aos problemas propostos da otimização hiperparamétrica. Nesta monografia serão abordados os algoritmos, Otimização Bayesiana (*Bayesian Optimization*) e Otimização por Algoritmo Genético, dado que ambas as técnicas são amplamente utilizadas e nos trabalhos analisados, obtiveram ótimos resultados sobre os modelos aos quais foram submetidas.

2.3.9.1 Otimização Bayesiana

De acordo com Guindani et al. (2024), a Otimização Bayesiana (OB) tem como base, encontrar os pontos ótimos de uma função objetivo caixa-preta buscando o mínimo de esforço nas inferências possível, de forma iterativa. Função caixa-preta é uma função $f(x)$ em que não se sabe a estrutura de sua equação. Porém, através de uma métrica seja de maximização ou minimização (por exemplo, na previsão de inadimplência dado um conjunto de informações, minimizar o erro de classificação), será passado um vetor de pontos aleatórios x sobre $f(x)$, sendo este o vetor de combinação de hiperparâmetros, então a métrica adotada é quem guiará o algoritmo de OB. Como descreve Yang e Shami (2020), o algoritmo de OB possui dois componentes principais para seu funcionamento, o primeiro é o modelo *surrgate*, ou modelo substituto, o qual é responsável por estimar novos valores prováveis, com o histórico de pontos já analisados fortemente influenciável em suas decisões. Este modelo, deve respeitar a métrica pré-estabelecida. Desta forma, após fornecer as distribuições dos seguintes pontos, a função de aquisição, é acionada. No segundo componente, a ideia principal é de compensação entre duas decisões, baseando-se em históricos de outros pontos já analisados, sendo assim, a exploração, visa encontrar possíveis novos pontos desconhecidos dentro da distribuição fornecida pelo modelo *surrgate*, já a explotação, nesta mesma distribuição, visa apostar em regiões próximas aos de pontos que apresentaram pequena taxa de erro. É importante ressaltar que o conhecimento gerado com os resultados, serve de insumo para atualizar as noções do modelo.

Figura 8 – Fluxograma da Otimização Bayesiana

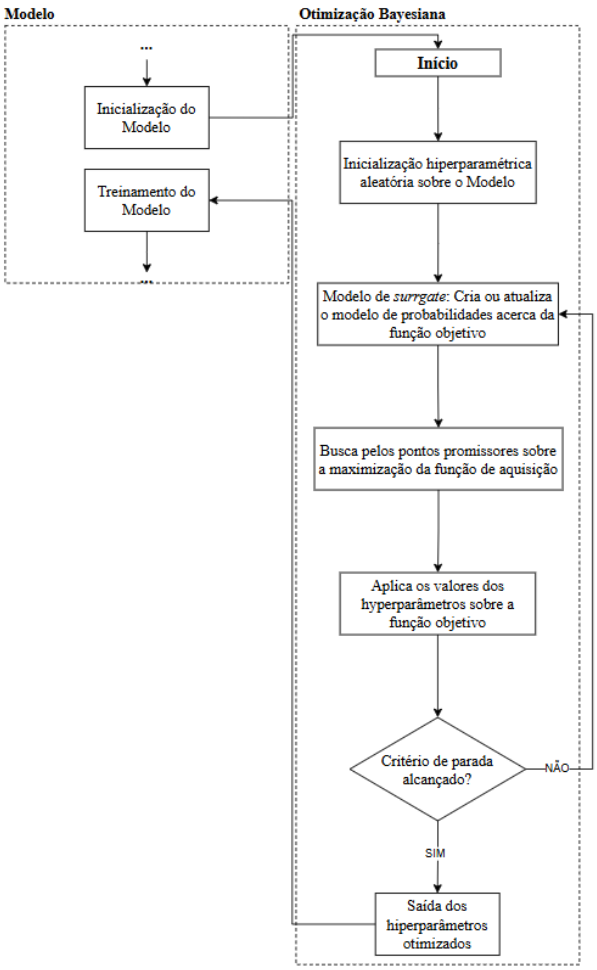

Fonte: AGHAABBASI et al. (2024)

A Figura 9 demonstra como é o funcionamento na prática do algoritmo, dado um hiperparâmetro aleatório x sobre $f(x)$.

Figura 9 – Comportamento OB

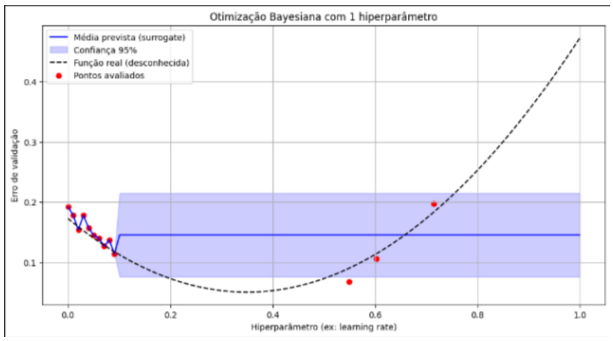

Fonte: AGHAABBASI et al. (2024)

O modelo *surrgate* padrão utilizado para a OB, é o Processo Gauciano (*Gaussian Process*), entretanto, outros foram propostos para lidar com o campo de distribuições. Conforme Yang e Shami (2020), o modelo SMAC o qual será utilizado, é definido como,

Sequencial Model-based Optimization – SMAC: Utiliza como modelo *surrgate* um *ensemble* de Árvores de Decisão de forma regressiva. Sua qualidade se dá por aceitar diferentes tipos de variáveis, como contínuas, discretas ou condicionais.

2.3.9.2 Algoritmo Genético

A otimização de hiperparâmetros por Algoritmo Genético (GA) possui forte influência acerca da teoria da evolução, onde os indivíduos com maior poder de adaptação prevalecem perante o processo evolutivo, garantindo que seus descendentes herdem as melhores características, enquanto indivíduos que demonstram pouco ou nenhum desenvolvimento evolutivo relevante, logo são extintos.

No processo de seleção natural, o algoritmo age sobre os indivíduos através de operações genéticas. Conforme Silva (2022), as etapas executadas são as seguintes:

1. Aleatoriamente é produzida a primeira geração. O intuito aqui é espalhar o maior número de combinações diversificadas, para que regiões promissoras possam ser encontradas com maior probabilidade;
2. Através de uma *fitness function* o desempenho de cada indivíduo (cada combinação de hiperparâmetros) é medido;
3. Executar operadores genéticos em busca do refino para próximas gerações;
4. Repete as etapas 2 e 3 até que um critério de parada seja atendido.

No passo 1, a inicialização da geração é dada por meio da criação populações de indivíduos ou cromossomos, indivíduos estes que são formados por genes. De acordo com Yang e Shami (2020), gene é a estrutura mais básica encontrada neste tipo de algoritmo, sendo este quem carrega um dado aleatório dentro do intervalo de possibilidades para cada hiperparâmetro. Desta forma, a composição de um indivíduo, é a combinação de hiperparâmetro aleatoriamente gerados sobre determinado modelo.

É intuitivo pensar que a primeira geração que fora produzida aleatoriamente, não conterá os melhores indivíduos para atender o que é esperado, assim, os tópicos 2 e 3 são necessários em busca das melhores combinações, ou ótimos globais. Segundo Kaleybar et al. (2023), a *fitness function* irá avaliar o quão adaptado determinado indivíduo está em comparação com o objetivo buscado, analogamente a OB, podendo ser uma maximização ou minimização. É através dela que as próximas gerações são construídas, pois indivíduos que apresentam melhores resultados, no momento de escolha por roleta, serão aqueles com maiores probabilidades de reprodução. Vale lembrar que o sistema de roleta esclarecido por Kaleybar et al. (2023), pode ainda permitir soluções consideradas pobres para serem genitoras, o que possibilita maior variabilidade.

2.3.9.3 Cruzamento

Após selecionado os indivíduos pais, a operação genética do cruzamento é quem permite que indivíduos filhos sejam gerados. Como diz Yang e Shami (2020), o cruzamento cria gerações através da troca de porções de genes entre indivíduos pais. Kaleybar et al. (2023) ainda esclarece que, dois tipos de cruzamento podem ser feitos, sendo o por ponto-único (Figura 10, exemplo a), no qual é escolhido um gene pertencente ao pai, e

todas as combinações genéticas seguintes a ele são trocadas pelo mesmo posicionamento no indivíduo mãe. No ponto-duplo de cruzamento (Figura 10, exemplo b), a diferença se dá que todos os genes seguintes aos do ponto de partida, limitam-se ao ponto final determinado.

Figura 10 – Tipos de Cruzamento

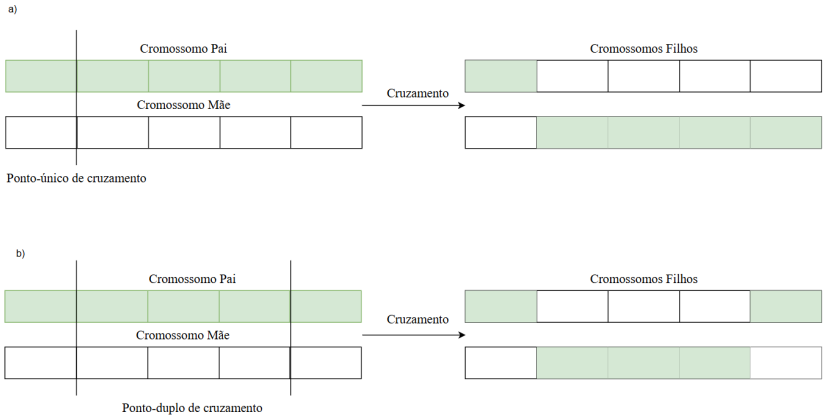

Fonte: Kaleybar et al. (2023)

2.3.9.4 Mutação

O sentido da mutação se dá pelo fato de que em determinado momento, as gerações e indivíduos podem tornar-se muito similares, portanto, diminuindo o poder de generalização. Nesse sentido, Yang e Shami (2020) descrevem que a mutação opera pequenas alterações aleatórias em um ou mais genes por cada indivíduo, evitando que a semelhança entre eles possa ser impactante no futuro e aumentando a probabilidade de encontrar ótimos globais.

Figura 11 – Mutação genética dos indivíduos

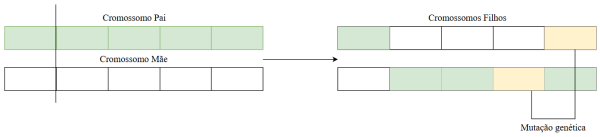

Fonte: Kaleybar et al. (2023)

2.3.10 Validação do Modelo

Avaliar o desempenho de um modelo preditivo é um processo com significante relevância no desenvolvimento de ML. A partir dos resultados que são produzidos, é possível compreender melhor o comportamento e tendências, logo demonstrando o quão bem o modelo atende seu objetivo. Diferentes técnicas foram propostas na literatura buscando as melhores metodologias para avaliação.

2.3.10.1 *Cross-Validation*

Segundo Blockeel e Struyf (2001) o *Cross-Validation* (CV), ou Validação Cruzada, é uma técnica que busca particionar um conjunto de dados G em G_j por n subconjuntos, por n vezes e executar um algoritmo (no caso um modelo de ML), sobre um subconjunto aleatório sem repetição do mesmo pós sua execução.

O objetivo principal de sua aplicação em ML conforme Nti, Nyarko-Boateng e Aningz (2021), é compreender melhor como o modelo treinado consegue lidar de forma satisfatória com exemplos do mundo real, ou dados nunca antes vistos.

2.3.10.2 *K-fold Cross Validation*

De acordo com Géron (2019), a validação cruzada por *k-fold* consiste em particionar o conjunto de dados em k subconjuntos a fim de utilizar $k - 1$ como subconjunto para teste e os remanescentes para treinamento. Assim, é possível que todo o conjunto de teste seja utilizado tanto para validação quanto para treinamento.

Conforme Nti, Nyarko-Boateng e Aningz (2021) a abordagem de particionamento em k subconjuntos é comumente utilizada para classificação, muito por conta de seu potencial em validar com considerável sucesso estes modelos. Sendo que um dos únicos contrapontos expressivos, é encontrar o valor k que melhor adapte-se ao modelo e aos dados. Desta forma a Figura 12 demonstra como é o comportamento da divisão na prática deste algoritmo.

Figura 12 – Divisão *K-fold* na validação cruzada

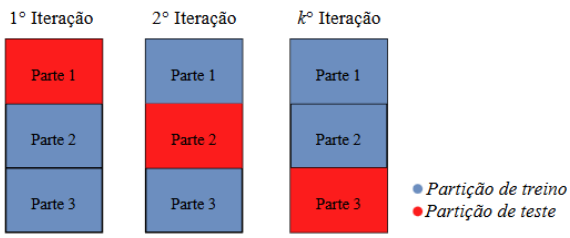

Fonte: Gerado pelo autor

Assim, conforme demonstrado, o conjunto de dados que será utilizado é dividido em k partes, separando conjuntos para os propósitos de teste e treinamento, e assim executa k vezes o algoritmo selecionado sobre cada partição.

2.3.10.3 *Hold-out*

Na abordagem de partição dos dados por *hold-out* conforme Cunha (2019), a ideia principal é separar o conjunto de dados em duas partições, sendo que uma delas seja utilizada para treinamento enquanto a remanescente para validação. Lembrando que não é obrigatório a divisão ser apenas entre duas partes, podendo como exemplo, separar em três domínios, no qual $\frac{2}{3}$ sejam utilizados para treinamento e a partição faltante para validação.

Figura 13 – Partição *Hold-out* na validação cruzada

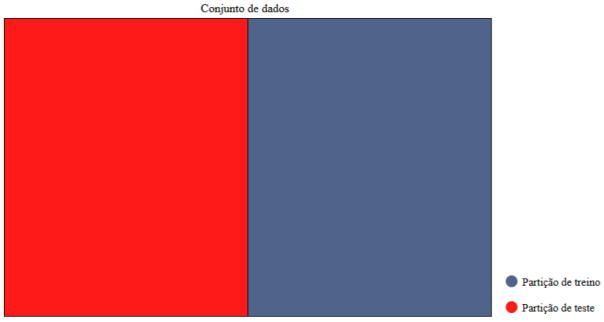

Fonte: Gerado pelo autor

2.3.10.4 *Leave-one out*

A abordagem do *leave-one out* tem como característica principal dois pontos, sendo o primeiro sua rigorosidade em relação as validações, porém, devido a este rigor, o segundo ponto, o custo, destaca-se como na verade, um contraponto. Em linhas gerais, dentro de um conjunto de dados imagine que existam n amostras, dentro de um espaço, apenas 1 ponto de dado será selecionado para compor o conjunto de validação, enquanto todos os outros $n - 1$ serão utilizados para treinamento. Devido à está característica, sua rigorosidade é um ponto que se sobressai, porém, a cada nova rodada de avaliação em que um novo ponto único é separado, o custo é expressivo.

2.3.11 Matriz de Confusão

Visualizar de forma quantificada qual foi o desempenho geral do modelo após uma bateria de processos, é um recurso significativo para compreender de forma mais aprofundada, a sensibilidade do sistema acerca das informações disponíveis. Para este propósito, a Matriz de Confusão é utilizada. Segundo Géron (2019), o intuito principal é contar quantas classes A de fato foram classificadas como A, e quantas classes foram classificadas erroneamente como B.

Segundo Rodrigues (2023), a Matriz de Confusão em problemas de classificação binária tem uma configuração de duas linhas e duas colunas, sendo que as linhas representam os valores verdadeiros do conjunto de dados, e as colunas representam os valores previstos pelo modelo. Dentro desta configuração, de acordo com Silva (2022), existem as seguintes classificações: Verdadeiros Positivos (VP), Verdadeiros Negativos (VN), Falsos Positivos (FP) e Falsos Negativos (FN).

Figura 14 – Matriz de Confusão

	Valor Previsto	
Valor Real	VP	FP
	FN	VN

Fonte: Gerado pelo autor

2.3.11.1 Acurácia

A acurácia identifica o quanto o modelo corretamente classificou tanto os dados da classe positiva quanto negativa, em comparação com todo o conjunto. É a métrica mais generalista para medir desempenho de modelos conforme Silva (2022).

$$\frac{VP + VN}{VP + FP + FN + VN} \tag{4}$$

2.3.11.2 Precisão

Para esta métrica, suponha que o modelo tenha previsto x dados como da classe positiva. Dentro deste espaço pressuposto, a precisão determina quantos dados de fato pertencem a classe. Ou seja, busca esclarecer quantos que o modelo diz ser positivo que de fato são.

$$\frac{VP}{VP + FP} \tag{5}$$

2.3.11.3 Revocação

A Revocação, ou *Recall*, define dentro do espaço de todos os possíveis dados que pertencem a classe positiva, quantos o modelo conseguiu prever com exatidão. De acordo com Géron (2019), pode ser definida também como a sensibilidade ou taxa de verdadeiros positivos (TPR), utilizados principalmente para medições como da Curva ROC.

$$\frac{VP}{VP + FN} \tag{6}$$

2.3.11.4 *F1-Score*

A métrica do *F1-Score* é uma média harmônica que une as métricas de Precisão e Revocação. Seu intuito conforme Géron (2019), normalmente é de comparação entre diferentes modelos, sendo que, a média harmônica busca evidenciar valores mais baixos. Diferentemente de uma média aritmética tradicional, ela destaca quando determinada métrica está defasada, e se o objetivo seja de manter um bom limiar entre as duas, é interessante ajustar o modelo.

$$2 \times \frac{VP}{VP + FN} \tag{7}$$

2.3.11.5 Curva ROC

A Curva ROC ou *Receiver Operating Characteristics* é uma métrica que busca demonstrar de acordo com Cordeiro (2020), a capacidade do modelo de sucesso nas previsões da classe positiva (eixo y) contra erros acerca da classe negativa (eixo x) de acordo com a variação do limiar de decisão entre 0 e 1. De acordo com Géron (2019), a sensitividade (eixo y) é análoga ao *recall*, ou seja, a proporção de acertos da classe positiva dentro do espaço de possibilidades da mesma, conforme Equação 6. A especificidade, evidencia a taxa de classes negativas corretamente classificadas, assim, a taxa de falsos positivos (eixo x) é dada por 1 – especificidade. Isto implica que, esta taxa mostra dentre todos os negativos reais, quantos o modelo erroneamente classificou como positivo.

Figura 15 – Curva ROC

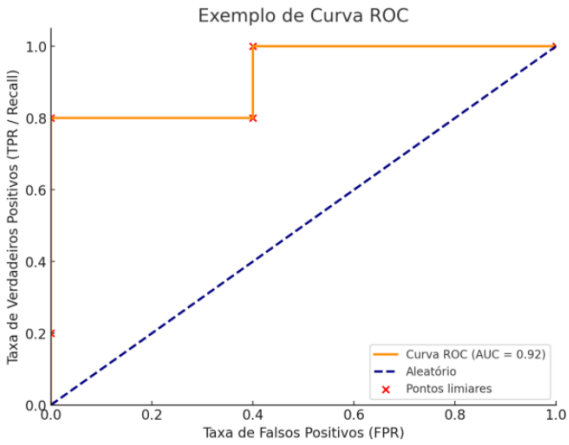

Fonte: Gerado pelo autor

A partir do exemplo na Figura 15, pode-se observar que o modelo ideal, com uma taxa de *Recall* alta e de FPR pequena, seria aquele que está mais próximo do canto superior esquerdo.

2.3.11.6 *Precision Recall*

Conforme Géron (2019), imagine que exista uma reta a qual tudo que se encontra a esquerda é considerado negativo, contrariamente, tudo a direita é positivo. Nessa reta estão dispostas classes adimplente (A) e inadimplente (I), e é preciso definir um limiar que se responsabiliza por ser balizador da classificação. Toda porcentagem provável que o modelo inferir para uma instância, caso seja maior ou igual ao limiar, será positivo, todos abaixo serão negativos.

Figura 16 – Limiar *Precision/Recall*

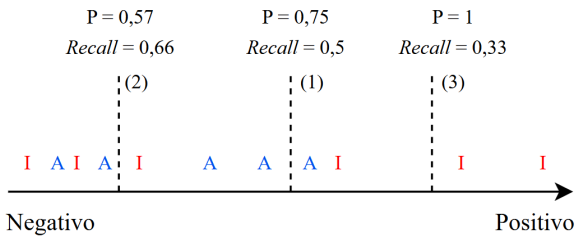

Fonte: Géron (2019)

A partir da Figura 16, será analisado o limiar (1). Nele são identificadas três instâncias dadas como inadimplentes (a classe positiva), ou três Verdadeiros Positivos, enquanto um Falso Positivo. Desta forma, a Precisão (P) encontrada para este limiar é de ($\frac{3}{4}$) 75% enquanto seu *Recall* ($\frac{3}{6}$) é de 50%. Agora, se considerado o limiar (2), o poder de generalização do modelo aumenta, com *Recall* ($\frac{4}{6}$) em 66%, porém a Precisão é impactada diretamente, passando a assumir um valor de ($\frac{4}{7}$) 57%. Finalmente, no último limiar, é focado em garantir uma precisão mais alta sobre o modelo, passando assim a assumir um valor de ($\frac{2}{2}$) 100%, – neste exemplo – enquanto o *Recall*, sofre agora uma diminuição significativa, ficando com ($\frac{2}{6}$) 33%. Dado este contexto, a métrica *Precision/Recall* busca justamente contrapor ambas as medidas no processo de avaliar o modelo e a depender do objetivo procurado, variar o limiar para ter uma Precisão rigorosa, porém perder exemplos Verdadeiros Positivos no processo, ou um limiar mais permissivo, porém com aumento em Falso Positivos.

2.4 Trabalhos Relacionados

2.4.1 Gerenciamento Integrado de Riscos: Modelos de Predição de Risco de Crédito em Machine Learning para a Identificação de Ativos Problemáticos em uma Instituição Financeira – Segmento Habitacional PF

Neste trabalho, Silva (2022) busca antever com técnicas de ML a possibilidade de inadimplência acerca de uma IF do segmento S1, ou seja, entidades com alta influência econômica que compõe a elite do sistema financeiro. Não é revelado a base de dados utilizada, por questões de segurança e privacidade da instituição e de seus clientes, porém é descrito que esta avaliação será feita mais especificamente na carteira de crédito habitacional, numa análise dentro de um espaço temporal, que indica mês a mês a situação de solvência do montante adquirido. Em cenários nos quais a liquidez não é atendida com sucesso, a autora define com o termo Ativo Problemático (AP).

Como proposta para enfrentar o problema, foram utilizados três modelos de ML, sendo eles, *Gradient Boosting*, *Random Forest* e Regressão Logística, os quais são submetidos a treinamento e análise. Assim, é demonstrado dentre os modelos aquele que se sobressai. No fluxo até o resultado, técnicas de refino, como tratamento de *Outliers* ou *Missing Values* são aplicados para diminuir o ruído, assim como o balanceamento por subamostragem na classe negativa. Ainda, é utilizado técnicas de validação como *K-fold Cross Validation* no sentido de buscar melhores parâmetros para otimização na inferência do modelo.

Como conclusão, foi observado relevante aptidão por parte do modelo de *Gradient Boosting* em comparação aos outros. Após seleção do referido, é realizada a otimização de hiperparâmetros que resulta em um salto no índice *F1-Score* de iniciais 68% para aproximadamente 98%.

2.4.2 *On Hyperparameter Optimization of Machine Learning Algorithms: Theory and Practice*

Neste artigo, Yang e Shami (2020) tem por objetivo realizar empiricamente a comparação do desempenho de diferentes modelos de ML sobre diferentes técnicas de Otimização de Hiperparâmetros. Inicialmente, é apresentada toda a base teórica tanto no espectro matemático quando aplicado de fato na prática, o que embasa e sustenta as futuras escolhas aplicadas aos modelos.

Os três modelos que atendem a diferentes escopos de hiperparâmetros mais comuns são selecionados, sendo eles, KNN (*K-Nearest Neighbours*), que possuí um hiperparâmetro significativo para suas inferências, o SVM (*Support Vector Machine*), que detém de alguns hiperparâmetros relevantes, a título de exemplo, o kernel e o parâmetro de penalidade C, e por fim, o *Random Forest*, o qual possuí uma variedade de hiperparâmetros relevantes que influenciam completamente seu poder de previsibilidade (Yang e Shami (2020)). Desta forma, para complementar ambos os cenários tanto de classificação quanto de regressão, são utilizadas as bases de dados MNIST que são compostas de diversos número escritos a mão, no intuito de classificação, e *Boston housing* com informações fornecidas para prever o preço de casas em Boston, categorizando um problema de Regressão.

Portanto, com os modelos selecionados, os algoritmos escolhidos para otimização de hiperparâmetros são apresentados, sendo divididos em grupos por Otimização Bayesiana, com variação de seus modelos *surrgate*, incluindo o modelo SMAC (Yang e Shami (2020)); Otimizações por Multi-Fidelidade e Otimizações por Meta-Heurística, fortemente influenciados por teorias evolutivas humanas, no qual é descrito o Algoritmo Genético. Portanto, é esclarecido os prós e contras acerca de cada otimização juntamente a cada algoritmo, inclusive com tabelas demonstrando índice de acurácias para classificação e Erros Quadráticos Médios (MSE) para regressão, com os hiperparâmetros por padrão e pós otimização. Vale ressaltar que a motivação da escolha do SMAC e AG devem-se principalmente aos argumentos apresentados neste artigo, que demonstram boa capacidade de lidar com grandes espaços de configuração e adaptabilidade no sentido de lidar com diferentes tipos de variáveis, como contínuas, discretas ou categóricas.

2.4.3 Otimização de Hiperparâmetros de Algoritmos de Machine Learning Aplicado no Contexto de Análise de Risco de Crédito

Silva (2022) irá destacar no contexto de Análise de Crédito, sobre vários modelos de ML, qual possui melhor desempenho na tarefa de prever possível inadimplência, aplicando conceitos de Otimização de Hiperparâmetros. Como bases de dados utilizada, o autor apresenta o *Australian Credit Approval*, *German Credit (UPDATE) Data Set*, *Default or Credit Card Clients Data Set* e *Predictive model for credit approval*, os quais são analisados e posteriormente refinados no intuito das comparações.

As técnicas utilizadas para otimização, são apresentadas, sendo elas: *BayeSearch* com modelo *surrgate* padrão, Algoritmo Genético e *RandomSearch*, que no caso desta última técnica, de forma geral, busca aleatoriamente modificar os valores dos hiperparâmetros e continuamente avaliar através de uma métrica se tal modificação mostrou-se positiva ou negativa. Por fim, vale destacar que no trabalho o algoritmo que obteve melhor desempenho dentre os demais foi o modelo de RF juntamente com a otimização por Algoritmo Genético, principalmente em bases com relevante número de registros.

2.4.4 Comparação de Algoritmos de Aprendizado de Máquina para Predição de Pontuação de Crédito

O último trabalho destacado são dos autores Lopes, Colombi e Mutz (2023). Neste artigo, os autores buscam determinar dentro de uma gama de modelos de ML, qual melhor atende ao objetivo da previsão de pontuação de crédito. As bases utilizadas para realizar o trabalho foram: *Australian Credit Approval*, *German Credit (UPDATE) Data Set* e *Default or Credit Card Clients Data Set*.

Os algoritmos escolhidos para comparação foram o KNN, Árvore de Decisão, Floresta Aleatória, AdaBoost, XGBoost, Regressão Logística, SVM e Perceptron com Múltiplas Camadas, além de um com todos os modelos empilhados.

Como metodologia aplicada, os autores buscaram comparar os modelos antes e depois de técnicas de validação cruzada justamente para avaliar possíveis problemas de *underfitting* ou *overfitting*. De modo geral, os modelos de acordo com os autores que se destacaram na pesquisa foram, o *stack ensemble* e XGBoost, ambos alcançando significativa acurácia, com uma média geral dentre todas as bases de 81,41% e 80,87% respectivamente, sem otimização de hiperparâmetros.

3 Desenvolvimento

Este capítulo apresenta uma descrição do processo de desenvolvimento do modelo de *Machine Learning* com o objetivo de prever possíveis clientes inadimplentes. Também serão descritas as ferramentas utilizadas, características das bases de dados, execução do projeto e seus resultados, tendo como base, os estudos mostrados no capítulo 2.

3.1 Proposta de solução

A proposta apresentada busca prever o máximo de ocorrências de inadimplências no ato de concessão de crédito com base em dados públicos, diluída em dois pontos principais: verificar se hávera algum ganho significativo relacionado a otimização dos hiperparâmetros do modelo e foco maior sobre a métrica de *Recall*, dado que, quanto maior sua taxa, menor a quantidade de FN, acarretando em menor prejuízo para as IFs dado a diminuição de acordos que erroneamente poderiam ser considerados adimplentes quando na verdade não são.

3.1.1 Arquitetura proposta

Os itens abaixo contemplam a arquitetura que será utilizada:

- Extração dos dados sobre as bases, as quais possuem variadas informações referentes às concessões feitas pela instituição incluindo a variável alvo que indica se determinada concessão resultou em adimplência ou inadimplência;
- Tratamento dos dados, como valores nulos, escalonamento, padronização e divisão de proporções para treinamento e teste, com o intuito de potencializar a etapa de processamento e inferência do modelo;
- Configuração dos algoritmos de otimização de hiperparâmetros para serem aplicados sobre o modelo em relação a porção de treinamento, resultando no encontro da solução ótima para dar seguimento ao processo.
- Exposição do modelo sobre toda a parcela de treinamento e coleta dos resultados sobre a parcela de teste.

Figura 17 – Arquitetura do funcionamento

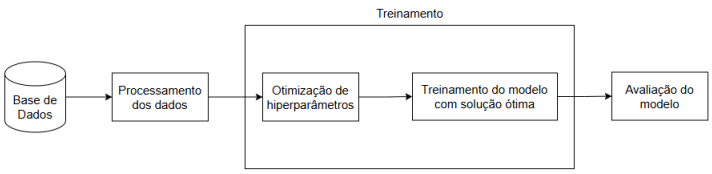

Fonte: Elaborado pelo Autor

3.1.2 Ferramentas tecnológicas utilizadas

Para o desenvolvimento do modelo foi escolhido a linguagem de programação Python na versão 3.12.12, dada a sua vasta possibilidade de integração com diversas bibliotecas disponíveis para as tarefas propostas nesta monografia, como também possuir forte influência em áreas relacionadas a *Machine Learning*. Além do Python, foi utilizado o *Google Colab*, uma plataforma *online* para manipulação de *Jupiter Notebooks* que resumidamente é um ambiente de programação interativo que permite a combinação de código python com outras funcionalidades.

Importante ressaltar o papel das bibliotecas *Numpy* para computação científica (Harris et al. (2020)), *Pandas* (PANDAS (2020)) para a manipulação de *Dataframes* em geral, *Matplotlib* (Hunter (2007)) para representação de dados em gráficos. Outra biblioteca que tem influência fundamental no desenvolvimento do modelo, sendo sólida e comumente utilizada em problemas de IA, é o *Scikit-learn* (Pedregosa et al. (2011)). Com ela é possível criar diferentes modelos, tratar valores nulos ou vazios, escalonamento de variávies, otimizar hiperparâmetros, validação cruzada além de outras funcionalidades.

Finalmente, a biblioteca *PyGAD* (Gad (2021)) possui relação com o algoritmo genético. É uma biblioteca *open-source* que abstrai a complexidade algorítmica por detrás dessa otimização através da classe pygad.GA, que será explicada com maiores detalhes mais a frente. Lembrando que a versão utilizada foi a 3.5.0. Em conjunto também foi utilizado a biblioteca *Scikit-learn Optimize* (scikit-optimize developers (2024)) na versão 0.10.2 para a finalidade de explorar e utilizar os recursos voltados a otimização Bayesiana

3.2 Base de Dados

Conforme já citado, neste projeto serão utilizadas duas bases de dados como fontes de insumo para o modelo, ambas públicas e que tratam sobre empréstimos.

3.2.1 Bases australiana e alemã

A base australiana possui informações acerca de concessões realizadas sobre cartões de crédito, na qual dispõe de 690 registros separados por 14 colunas, sendo dessas, 6 numéricas, 8 categóricas e 1 coluna alvo binária, caracterizando-se como um problema de classificação. A distribuição das classes alvos é dada por 307 (44,5%) casos inadimplentes e 383 (55,5%) de casos adimplentes. Vale lembrar, que os rótulos desta base foram anonimizados para preservar informações pessoais, tornando-se colunas com os nomes de A1 até A15.

A segunda base de dados refere-se a diversas informações referentes a concessões de crédito, que também foram classificados como créditos bons ou ruins. Os dados datam de 1973 até 1975 e são distribuídos em 20 atributos juntamente com o atributo alvo. Sua distribuição de classes é mais desbalanceada comparada a da primeira base, contendo 300 (30%) casos inadimplentes e 700 (70%) adimplentes sobre um total de 1000 instâncias.

Tabela 1 – Atributos base alemã

Atríbuto	**Tipo do atributo**	**Descrição**
status	Categórico	Situação da conta corrente do devedor junto ao banco
duration	Numérico	Duração do crédito em meses
credit_history	Categórico	Histórico de cumprimento de contratos de crédito anteriores ou atuais
purpose	Categórico	Propósito do crédito
amount	Numérico	Quantidade do empréstimo
savings	Categórico	Poupanças do devedor
employment_duration	Numérico	Duração do vínculo empregatício do devedor com o empregador atual
installment_rate	Numérico	Parcelas do crédito como percentagem da renda disponível do devedor
personal_status_sex	Categórico	Informações combinadas sobre sexo e estado civil
other_debtors	Categórico	Existe outro devedor ou fiador para o crédito?
present_residence	Categórico	Tempo (em anos) que o devedor reside na residência atual.
property	Categórico	O bem mais valioso do devedor
age	Numérico	Idade do devedor
other_installment_plans	Categórico	Planos de parcelamento de fornecedores que não sejam o banco que concede o crédito
housing	Categórico	Tipo de moradia em que o devedor reside
number_credits	Categórico	Número de créditos, incluindo o atual, que o devedor tem (ou tinha) neste banco
job	Categórico	Qualidade do trabalho do devedor
people_liable	Numérico	Número de pessoas que dependem financeiramente do devedor
telephone	Categórico	Existe alguma linha telefônica fixa registrada em nome do devedor?
foreign_worker	Categórico	O devedor é um trabalhador estrangeiro?
credit_risk	Numérico	O contrato de crédito foi cumprido (bom) ou não (ruim)?

Tabela 2 – Atributos base australiana

Coluna	**Tipo do atributo**
A1	Categórico
A2	Numérico
A3	Numérico
A4	Categórico
A5	Categórico
A6	Categórico
A7	Numérico
A8	Categórico
A9	Categórico
A10	Numérico
A11	Categórico
A12	Categórico
A13	Numérico
A14	Numérico
A15	Numérico

3.2.2 Tratamento das bases

Um passo importante a ser realizado antes de expor, de fato, os dados ao modelo, é trata-los. Por se tratar de uma grande quantidade de informações coletadas, há possibilidades que podem interferir de forma significativa no poder de previsão. Uma das questões mais comuns são valores nulos ou vazios. Para evitar problemas causados nesse cenário, foi efetuado a substituição pela média em atributos numéricos e pela moda em atributos categóricos graças ao módulo *SimpleImputer* do *scikit-learn*.

Além do tratamento de nulos ou vazios, outra medida tomada foi o dimensionamento das variáveis. Dado que, sobre análise exploratória foi verificada a presença de dados discrepantes em determinados atributos, permanecer com esses valores pode enviesar o modelo de forma que se julgue que maiores grandezas possuem maior importância. Assim, a técnica de padronização *z-score* é uma das abordagens possíveis e a que foi utilizada. Nela, a média do atributo passa a ser 0 e o desvio padrão (σ) assume o valor de 1 conforme Equação 8, garantindo redução da dimensinalidade do recurso.

$$x' = \frac{x - u}{\sigma} \tag{8}$$

Após os tratamentos realizados, foi aplicada então uma divisão para delimitar os particionamentos para o treinamento e avaliação do modelo, sendo 70% e 30% respectivamente.

3.3 Implementação do algoritmo de aprendizado de máquina

O algoritmo utilizado para executar a tarefa de classificação, conforme descrito no capítulo 2.3.6, foi o *Random Forest*. Devido a característica de forte adaptabilidade a diferentes tipos de atributos e por convergir em bons resultados nos trabalhos pesquisados, o *Random Forest* mostrou-se uma opção sólida.

Dado que o objetivo é otimizar hiperparâmetros, foram selecionados 5 relacionados ao comportamento do modelo. Abaixo segue uma lista com o nome e descrição de cada um:

- ***n_estimators***: define o número de estimadores utilizados, o número de Árvores de Decisão para processar os dados;
- ***max_depth***: profundidade de nós máxima que cada árvore pode atingir;
- ***min_samples_split***: o número mínimo de amostras para dividir um nó interno, garantindo que o nó com menos amostras que o definido não sejam divididos, assim diminuindo a complexidade da árvore;
- ***min_samples_leaf***: define o número mínimo de amostras que deve existir em cada nó folha, lembrando que caso a divisão de um nó não satisfaça esse valor, o nó que seria "pai", torna-se o nó folha;
- ***criterion***: uma medida que calcula o grau de qualidade de uma divisão, suportando duas métricas, *gini*, para calcular a impureza do nó e *entropy* para ganho de informação.

Daqui em diante serão apresentadas três variações do *Random Forest* utilizando a classe *RandomForestClassifier* do *scikit-learn*, cada uma por um processo diferente. O primeiro é um modelo que não foi submetido a nenhum tipo de otimização, e a Tabela 3 descreve os valores de seus hiperparâmetros, que foram escolhidos de forma arbitrária e aleatória.

Tabela 3 – Hiperparâmetros arbitrários

Hiperparâmetro	**Valor**
n_estimators	10
max_depth	10
min_samples_split	5
min_samples_leaf	4
criterion	gini

Após instânciar a classe com os hiperparâmetros apresentados, foi executada uma validação cruzada com 10 *folds* e, subsequentemente, o modelo foi exposto aos dados da porção de treinamento e coletadas suas métricas acerca de suas previsões.

3.3.1 Validação cruzada aninhada

Antes de tratar das otimizações, é necessário esclarecer um ponto importante que serve como base para o processo de busca dos hiperparâmetros ótimos, juntamente com a validação das métricas sobre esses hiperparâmetros: a validação cruzada aninhada. O ponto aqui é que, em uma validação cruzada comum, os mesmos dados que seriam utilizados para encontrar os melhores hiperparâmetros também seriam usados para avaliar as métricas computadas. O problema nessa abordagem está no fato de que, de forma indireta, o modelo já conhece essas informações, o que poderia levar a problemas de *overfitting*. O termo que classifica essa situação é chamado de *data leakage* ou vazamento de dados.

A validação cruzada soluciona esse problema ao isolar os dados utilizados para cada uma das tarefas em *loops*. A camada mais externa, ou *outer loop*, é responsável por executar a divisão das informações em treino e teste, que então são utilizadas pelo *inner loop* (camada interna), o qual conduz o processo de otimização sobre os dados que antes eram *folds* de treino da camada externa e se tornam novas partições para teste e validação. Após encontrar as melhores soluções internas, estas são confrontadas com os *folds* de treino e teste da camada externa, sendo assim possível mensurar as métricas do modelo.

Figura 18 – Validação cruzada aninhada

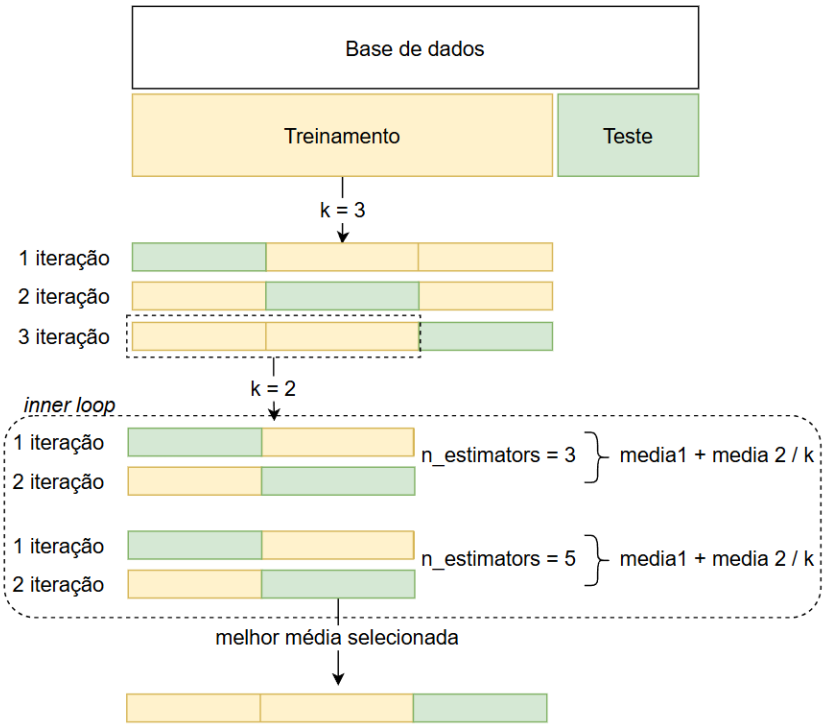

Fonte: Adaptado pelo autor de Blancas (2022)

Nesse tipo de validação cruzada, dois pontos merecem destaque. Como demonstrado na Figura 18, o retorno do *loop* interno para o externo, com a melhor combinação, é acompanhado do retreinamento, considerando um número maior de *folds*, e o *fold* separado para teste nas camadas externas, de fato, nunca é previamente visto.

Dado o contexto, para a etapa de treinamento desse projeto, foi utilizado 10 *folds* para a camada externa e 2 *folds* para a interna, ambas divisões estratificadas.

3.3.2 pyGAD

A biblioteca PyGAD é uma ferramenta desenvolvida para otimizar hiperparâmetros por meio de Algoritmos Genéticos. O primeiro passo a ser executado consiste em instanciar a classe pygad.GA, que contém os atributos necessários para seu funcionamento. Ressalta-se que a escolha dos valores atribuídos foi feita de forma arbitrária.

Como foram selecionados cinco hiperparâmetros para serem otimizados, o atributo *num_genes* deve respeitar esse número de entradas, definindo quantos valores podem ser gerados na busca ou solução. Após determinar quantos genes existem por indivíduo, foi estipulado o intervalo de valores em que cada um desses pode atuar, por meio do atributo *gene_space*.

Em relação ao processo evolutivo, alguns pontos merecem destaque. O primeiro deles refere-se às manipulações algorítmicas que podem ser executadas. A etapa de seleção dos pais, definida pelo atributo *parent_selection_type*, foi configurada com o valor 'sss' (*Steady-State Selection*), que é uma abordagem voltada a garantir maior diversidade entre as gerações, preservando boas soluções e evitando a substituição abrupta de toda a população. Quanto ao tipo de cruzamento, optou-se por *single_point*, que, conforme explicado no Capítulo 2.3.9.3, define um ponto (aleatório na biblioteca) que delimita a troca de genes entre os pais. Por fim, o tipo de mutação adotado foi o *random*, no qual genes são escolhidos e mutados aleatoriamente, respeitando o intervalo de soluções possíveis.

3.3.2.1 Função de Aptidão e *Clustering*

A função de aptidão ou *fitness function* é um dos argumentos obrigatórios para instanciar a classe. Seu papel é avaliar o quão bem cada solução experimentada se saiu. O algoritmo que estima essa qualidade deve ser implementado pelo usuário, e como o foco aqui é diminuir a taxa de FN, a métrica de *recall* foi adotada como principal vetor de qualidade recebendo o argumento *pos_label* igual a 0 para a base alemã, para que se mantesse condinzente com a classe positiva (inadimplente) apresentada na documentação do *dataset*.

Na assinatura do método, devem ser respeitados três argumentos obrigatórios. O argumento *solution* pode ser considerado o mais importante da função, sendo uma lista (indivíduo) em que cada item representa um valor aleatório atribuído a um gene. Cada índice é ordenado, respeitando os parâmetros *num_genes* e *genes_space*. Assim, da posição 0 até a posição 4, cada valor foi utilizado para instanciar o Random Forest (RF) de acordo com seus hiperparâmetros escolhidos para serem otimizados.

Por fim, é exigido que a função retorne um valor numérico, que será utilizado para definir a aptidão (*fitness*) dessa solução. Dessa forma, após o treinamento e teste do modelo, o valor de *recall* é retornado, servindo como base para determinar a aptidão de cada solução.

Após o desenvolvimento da função, esta precisa ser passada como argumento para a classe, no entanto, surge uma complicação ao unir ambos. Como mencionado anteriormente, a assinatura da função deve ser cumprida e, simultaneamente, ela precisa ter acesso aos *folds* com os dados para treinamento e validação. Dessa forma, é inviável criar outros dois parâmetros, X e Y, para atender a essa segunda demanda.

Para resolver esse problema, foi utilizado o *closure*, que se refere a funções aninhadas.

Nesse contexto, a função encapsulada consegue capturar os valores dos objetos do escopo da função que a envolve e fazer uso de seus recursos em seu escopo. Assim, foi implementada uma função externa que recebe os *folds* de treino e teste e, dentro de seu escopo, contém a função de aptidão com sua estrutura garantida e acesso aos dados necessários para avaliar os hiperparâmetros.

Abaixo segue uma tabela com todos os atributos que foram utilizados para instânciar a classe pygad.GA:

Tabela 4 – Atributos da classe pygad.GA

Atributo	**Valor**
num_generations	50
num_parents_mating	4
fitness_func	fitness_fn
sol_per_pop	10
num_genes	5
gene_space	[range(50, 201), range(10, 21), range(5, 51), range(5, 51), [1, 2]]
parent_selection_type	*'sss'*
crossover_type	*'uniform'*
mutation_type	*'random'*

3.3.3 BayesSearchCV

Para a implementação da otimização Bayesiana (2.3.9.1), recorreu-se à biblioteca *scikit-optimize* (ou *skopt*), na versão 0.10.2. Por meio dela, é possível utilizar a classe *BayesSearchCV*. Essa classe também possui diversos atributos que conduzem seu funcionamento; contudo, serão aqui destacados apenas aqueles considerados relevantes para essa otimização.

O intervalo de valores possíveis para cada hiperparâmetro, definido pela biblioteca como espaço de busca, foi o mesmo utilizado na otimização por AG, com a única ressalva de precisar estar contido em um dicionário em Python. Além disso, a validação cruzada aninhada também foi empregada nessa otimização, sendo passada, como valor, a divisão interna dos dados (em dois *folds*), pelo atributo *cv*.

Em relação ao modelo *surrogate* SMAC, é necessário defini-lo por meio do atributo *optimizer_kwargs*. Um *Optimizer*, em linhas gerais, refere-se ao processo de *loop* e às suas definições, que são executadas passo a passo pela otimização. Dentre essas definições, é possível determinar o estimador padrão a ser utilizado durante o processo, ou seja, o modelo *surrogate*. Assim, foi definido o *base_estimator* igual a RF, lembrando que o *skopt* fornece alguns estimadores padrão possíveis, sendo RF um deles. Portanto, a busca pelos melhores valores passa a ser conduzida por várias Árvores de Decisão.

Na otimização Bayesiana, é possível definir uma métrica a ser utilizada como balizadora de qualidade, semelhante à função de aquisição do AG. O atributo *scoring* é o responsável por definir esse vetor e, entre os valores possíveis, o valor *recall* pode ser atribuído, dado que o *skopt* possui integração interna com as ferramentas do *scikit-learn*, o que facilita o processo de avaliação das soluções.

Tabela 5 – Atributos da classe *BayesSearchCV*

Atributo	**Valor**
estimator	rf_model
search_spaces	params
n_iter	50
optimizer_kwargs	{'base_estimator': 'RF'}
random_state	SEED
verbose	2
scoring	'*recall*'
cv	kf_inner

3.3.4 Treinamento e avaliação do modelo final

Realizado todo o processo de busca pelos melhores hiperparâmetros, a última etapa consistiu em criar o modelo para cada solução encontrada, expondo-o à parcela completa de treinamento (70%) e, por fim, avaliando suas métricas sobre a parcela de teste (30%), previamente definida.

Vale ressaltar que todas as etapas possíveis foram executadas com a definição de uma *SEED*, a qual busca garantir a reprodutibilidade por meio da definição de um número aleatório que pode ser passado como argumento em determinados processos, por meio do atributo *random_state*. Isso foi aplicado, por exemplo, ao processo de divisão dos dados por *k-folds*, à criação das classes *pygad.GA* e *BayesSearchCV*, bem como a todas as instâncias da classe *RandomForestClassifier* utilizadas para a construção dos modelos.

4 Resultados

A implementação da otimização de hiperparâmetros resultou em uma melhoria no poder preditivo dos modelos com algumas ressalvas. Considerando a métrica de *recall* especificada com relação à média das classes na base australiana, o Algoritmo Genético se sobressaiu, alcançando 86%, enquanto a Otimização Bayesiana (SMAC) e o modelo sem otimização obtiveram 85% em suas métricas.

No dataset alemão, o modelo que se destacou foi o sem otimização, com 70% de *recall*, enquanto a otimização por Algoritmo Genético chegou a 65%, além de 62% da Otimização Bayesiana.

Também foram coletados os melhores hiperparâmetros encontrados por cada método de otimização. A Tabela 6 e a Tabela 7 apresentam esses valores para as bases australiana e alemã, respectivamente.

Tabela 6 – Melhores valores encontrados por cada otimização - Base australiana

Hiperparâmetros	**Bayesiana**	**AG**
n_estimators	52	104
max_depth	12	16
min_samples_split	40	46
min_samples_leaf	45	46
criterion	*gini*	*entropy*

Tabela 7 – Melhores valores encontrados por cada otimização - Base alemã

Hiperparâmetros	**bayesiana**	**AG**
n_estimators	104	196
max_depth	11	19
min_samples_split	21	23
min_samples_leaf	46	50
criterion	*entropy*	*gini*

Foram registrados também os valores das métricas individuais de cada classe para melhor segmentação dos números e interpretação dos resultados:

Tabela 8 – Métricas obtidas - Base australiana

Modelo	Precisão			Revocação			F1-score		
	0	**1**	**Média**	**0**	**1**	**Média**	**0**	**1**	**Média**
Sem otimização	88%	81%	85%	88%	81%	85%	88%	81%	85%
Bayesiana	86%	84%	85%	87%	83%	85%	87%	83%	85%
AG	87%	86%	86%	90%	83%	86%	88%	84%	86%

Tabela 9 – Métricas obtidas - Base alemã

Modelo	Precisão			Revocação			F1-score		
	0	**1**	**Média**	**0**	**1**	**Média**	**0**	**1**	**Média**
Sem otimização	74%	80%	77%	47%	93%	70%	57%	86%	72%
Bayesiana	74%	76%	75%	29%	96%	62%	42%	85%	76%
AG	74%	77%	76%	36%	95%	65%	48%	85%	67%

Afim de possibilitar uma melhor visualização numérica dos acertos e erros obtidos por cada otimização, foram geradas as matrizes de confusão referentes a cada um dos 3 modelos desenvolvidos

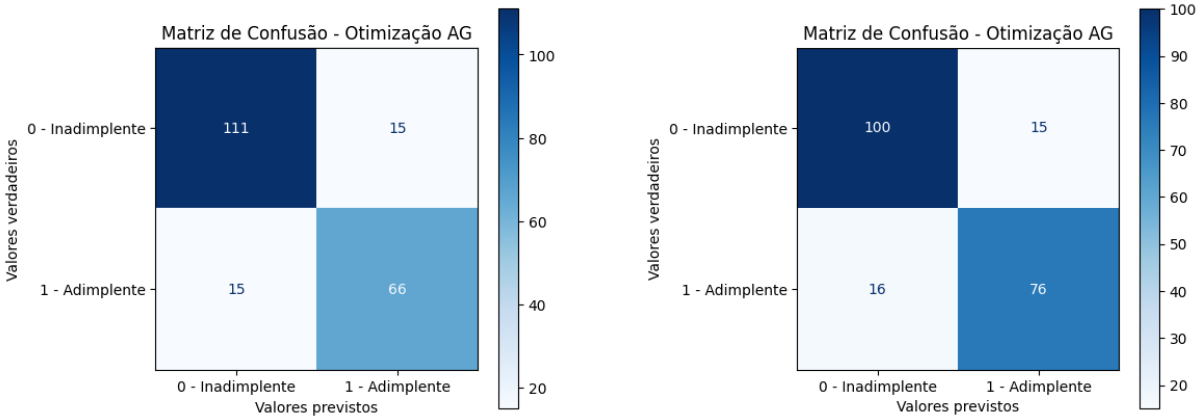

(a) Sem otimização

(b) Bayesiana

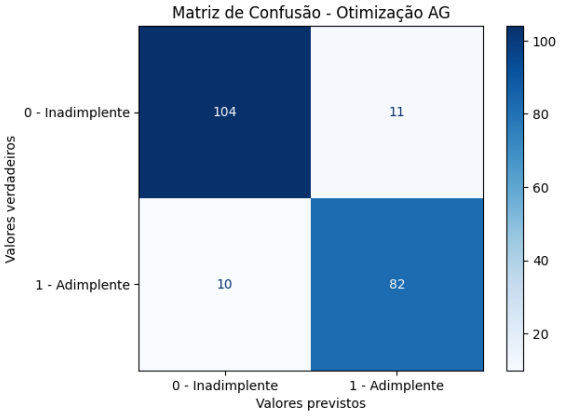

(c) Algotimo Genético

Figura 19 – Matrizes de confusão - Base australiana

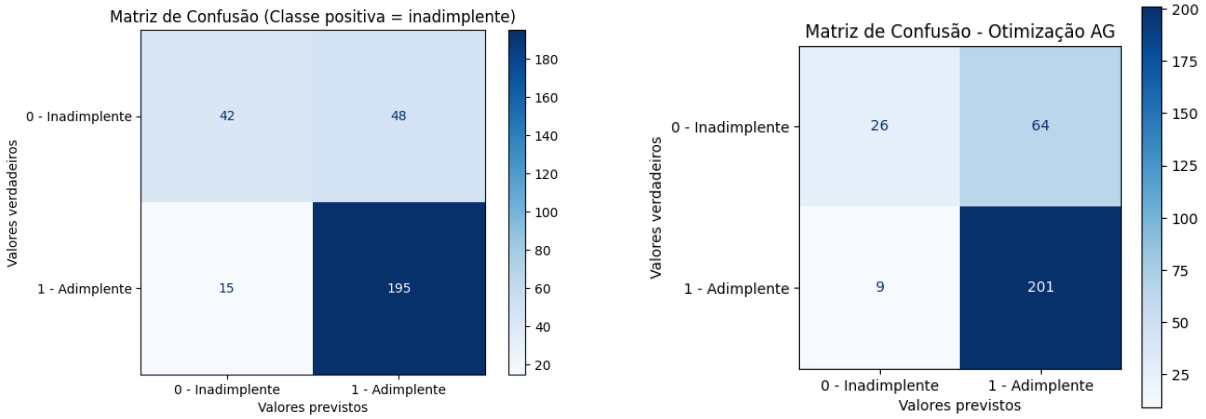

(a) Sem otimização (b) Bayesiana

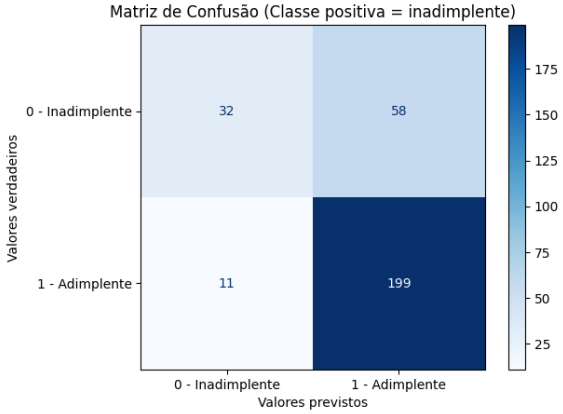

(c) Algotimo Genético

Figura 20 – Matrizes de confusão - Base alemã

Dessa forma, ao serem avaliados os valores apresentados, o efeito decorrente do desbalanceamento das classes na base alemã mostrou-se um fator significativo. Observou-se, a partir das primeiras métricas geradas, um comportamento incomum: a métrica de *recall*, definida como padrão de ancoragem para avaliar o sucesso dos modelos em relação à classe positiva (inadimplentes), foi comprometida pelo fato de essa classe ser rara. Além disso, ao ser submetida ao processo de validação cruzada, sua representatividade tornou-se ainda mais reduzida.

Diante desse cenário, uma das medidas adotadas especificamente para a base alemã foi a substituição da métrica de avaliação, tanto na função *fitness* quanto na função objetivo, de *recall* para *f1-score*. Essa decisão foi guiada pelo objetivo de evitar modelos excessivamente conservadores, uma vez que, dada a escassez da classe positiva, os modelos não conseguiam identificar seus padrões de forma significativa, passando a priorizar altos valores de *recall* para a classe negativa. A métrica *f1-score*, por ser a média harmônica entre Precisão e *Recall*, penaliza cenários em que uma das métricas apresenta desempenho inferior, tornando essa limitação mais evidente e promovendo um melhor *trade-off* entre ambas. Sob a ótica de uma instituição financeira, essa abordagem permite manter boas previsões para adimplentes, sem que o modelo sacrifique previsões de inadimplenes e se concentre exclusivamente na classe negativa.

Em conjunto com essa estratégia, para mitigar e melhorar os resultados referentes à classe positiva, foi ajustado o argumento *pos_label*, anteriormente mencionado. Tal

ajuste possibilitou corrigir os percentuais das métricas, uma vez que, por padrão, esse argumento é definido como 1, enquanto o *dataset* utilizado considera 1 como bom pagador. Adicionalmente, adotaram-se 5 *folds* internos para aprimorar a amostragem das classes, bem como a divisão estratificada desses *folds* e das porções de treino e teste utilizadas na validação cruzada aninhada.

Ao comparar os percentuais obtidos pelos modelos otimizados com os resultados apresentados no artigo de Lopes, Colombi e Mutz (2023), que registrou 42% de *recall* em seu modelo *Random Forest* para a base alemã, faz-se necessário destacar o impacto do espaço de busca anteriormente mencionado, o qual contribuiu para valores inferiores aos observados no trabalho relacionado. Em contrapartida, o modelo sem otimização apresentou desempenho ligeiramente superior, com um ganho aproximado de 5%, atingindo 47% de *recall* para a classe positiva. Em relação à base australiana, o artigo reporta 86,64% de *recall*, superando os 83% alcançados neste trabalho, valor máximo obtido entre as duas otimizações. Assim, considerando os aspectos discutidos e os resultados referentes à classe positiva, a diferença entre os modelos deste estudo e os apresentados no artigo pode ser considerada pouco expressiva.

5 Conclusão

Esta monografia teve como objetivo treinar e avaliar o desempenho de diferentes configurações de um mesmo modelo de *Machine Learning*, o *Random Forest*, utilizando algoritmos de otimização de hiperparâmetros, com o intuito de potencializar sua capacidade de previsão de inadimplência em duas bases públicas referentes à concessão de crédito. Devido ao bom desempenho reportado nos trabalhos pesquisados, as técnicas de otimização de hiperparâmetros escolhidas foram a Otimização Bayesiana e o Algoritmo Genético.

As etapas do trabalho foram divididas entre o tratamento inicial das informações disponíveis para cada *dataset* e, posteriormente, a aplicação da validação cruzada aninhada nos modelos submetidos às otimizações, a fim de evitar possíveis problemas de *data leakage*, enquanto a validação cruzada comum foi aplicada ao modelo sem otimização. Dessa forma, três modelos foram gerados para cada base, com o Algoritmo Genético apresentando melhor desempenho na base australiana e, entre os modelos otimizados, também na base alemã. No entanto, para esta última, os resultados não se mostraram muito expressivos quando comparados ao modelo sem otimização.

Embora as otimizações tenham contribuído de forma relevante para o desempenho dos modelos, ao comparar as métricas da classe inadimplente com o estado da arte, observa-se que, para a base australiana, o Algoritmo Genético também se destaca, apresentando melhores valores de Precisão e resultados próximos em termos de *f1-score*. Entretanto, em relação à métrica priorizada no estudo, o *recall*, os valores obtidos mostraram-se semelhantes aos reportados na literatura. Já para a base alemã, principalmente devido ao desbalanceamento das classes, o *recall* dos modelos otimizados não conseguiu se equiparar aos resultados obtidos por Lopes, Colombi e Mutz (2023), sendo necessário considerar o impacto da validação cruzada adotada, que interferiu diretamente no espaço amostral da classe inadimplente. Em relação às demais métricas, os três modelos gerados apresentaram melhor desempenho em Precisão e valores próximos de *f1-score*.

Dessa maneira, considerando o contexto geral, é possível inferir que há indicativos de eficiência no poder preditivo dos modelos para auxiliar nas etapas pré-processuais de concessão de crédito por parte de instituições financeiras. Ressalta-se que tal efetividade foi obtida a partir de dados públicos, não refletindo eventuais particularidades dos processos internos de cada instituição para deliberação de crédito. Ainda assim, foi notável a capacidade apresentada para a previsão de *defaults*, mesmo sem o refinamento das informações por meio de outras técnicas adicionais.

5.1 Trabalhos Futuros

- Dado as incongruências com relação ao balanceamento das classes na base alemã e a outros fatores que compõem a engenharia de atributos, é válido a utilização de outras técnicas relevantes e que consolidem ainda mais o poder preditivo do modelo, como técnicas de *oversampling* ou *undersampling* e técnicas de *enconding* para melhor discriminar atributos que sejam separados por classes;
- Explorar outras configurações possíveis para os algoritmos de otimização de hiperparâmetros, assim como, outras abordagens para refinamento das soluções a partir das funções objetivo e *fitness*;
- Experimentar o desempenho das otimizações em outros tipos de modelos de *Machine Learning* para prever eventos de *default*, especialmente modelos de gradiente, como *XGBoosting*, que também apresentaram bons resultados nos trabalhos pesquisados, além, é claro de utlizar outras otimizações existentes.

Referências

AGGARWAL, C. C. *Outlier Analysis*. [S.l.]: Springer, 2017. Citado na página 33.

AGHAABBASI, M. et al. On hyperparameter optimization of machine learning methods using a bayesian optimization algorithm to predict work travel mode choice. *IEEE*, p. 19762 – 19774, 2024. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10049559>. Citado na página 37.

ALGARNI, A.; ALGARNI, A.; ALOUANE, M. T.-H. Imbalanced data problem in machine learning: A review. *IEEE*, p. 13686–13699, 2025. Vol. 12, No2. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10845793>. Citado 2 vezes nas páginas 34 e 35.

AMAZON WEB SERVICE. *O que é aprendizado por reforço?* 2024. Redação AWS. Acesso em: 28 abr. 2025. Disponível em: <https://aws.amazon.com/pt/what-is/reinforcement-learning/>. Citado na página 24.

BANCO CENTRAL DO BRASIL. *Pesquisa Trimestral de Condições de Crédito*. Brasília, 2025. Acesso em: 5 abr. 2025. Disponível em: <https://www.bcb.gov.br/publicacoes/ptc/202503>. Citado na página 12.

BARBOSA, L. M.; PORTES, L. A. F. A inteligência artificial. *Revista Tecnologia Educacional*, p. 16–27, 2019. Rio de Janeiro, RJ, nº 236. Disponível em: <https://abt-br.org.br/wp-content/uploads/2023/03/RTE_236.pdf>. Citado na página 21.

BLANCAS, E. *Model selection done right: A gentle introduction to nested cross-validation*. 2022. Disponível em: <https://ploomber.io/blog/nested-cv>. Acesso em: 18 set. 2025. Citado na página 52.

BLOCKEEL, H.; STRUYF, J. Efficient algorithms for decision tree cross-validation. *IEEE*, 2001. Disponível em: <https://arxiv.org/pdf/cs/0110036>. Citado na página 40.

BREIMAN, L. Bagging predictors. *Department of Statistics University of California Berkeley, California*, 1994. Disponível em: <https://www.stat.berkeley.edu/~breiman/bagging.pdf>. Citado na página 30.

BREIMAN, L. Bagging predictors. *Department of Statistics University of California Berkeley, California*, 2001. Disponível em: <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>. Citado na página 31.

BRITO, G. A. S.; NETO, A. A. Modelo de classificação de risco de crédito de empresas. *SCIELO*, 2008. Citado 3 vezes nas páginas 15, 16 e 18.

BRITO, G. A. S.; NETO, A. A.; CORRAR, L. J. Sistema de classificação de risco de crédito: uma aplicação a companhias abertas no brasil. *Revista Contabilidade amp; Finanças*, v. 20, n. 51, p. 28–43, dez. 2009. Disponível em: <https://revistas.usp.br/rcf/article/view/34299>. Citado na página 17.

CAMARGO, M. A. de. Fatores condicionantes de inadimplência em processos de concessão de crédito a micro e pequenas empresas do estado de minas gerais. *SCIELO*, 2010. Citado na página 15.

CONSELHO MONETÁRIO NACIONAL. *Resolução nº 4.557, de 23 de fevereiro de 2017*. 2017. Diário Oficial da União. Disponível em: <https://normativos.bcb.gov.br/Lists/Normativos/Attachments/50344/Res_4557_v12_P.pdf>. Citado na página 12.

CORDEIRO, T. V. B. *PREDIÇÃO DE DEFAULT DE EMPRESAS: TÉCNICAS DE MACHINE LEARNING EM DADOS DESBALANCEADOS*. Programa de Mestrado — Engenharia Financeira, São Paulo, 2020. Disponível em: <https://hdl.handle.net/10438/29873>. Citado 2 vezes nas páginas 32 e 43.

CUNHA, J. P. Z. *Um estudo comparativo das técnicas de validação cruzada aplicadas a modelos mistos*. Dissertação (Mestrado em Estatística) — Instituto de Matemática e Estatística, São Paulo, 2019. Disponível em: <https://www.teses.usp.br/teses/disponiveis/45/45133/tde-26082019-220647/pt-br.php>. Citado na página 41.

DELGADO, R. C. et al. ClassificaÇÃo espectral de Área plantada com a cultura da cana-de-aÇÚcar por meio da Árvore de decisÃo. *Eng. Agríc., Jaboticabal, v.32, n.2, p.369-380, mar./abr. 2012*, 2012. Disponível em: <https://www.scielo.br/j/eagri/a/Zc9mSJwVk5XkH4SykB7XPng/?format=html&lang=pt>. Citado na página 28.

FERREIRA, L. D. *Técnicas de aprendizado de máquina aplicadas à classificação de estudantes a partir de estilos de aprendizagem*. Dissertação (Mestrado em Ciências de Computação e Matemática Computacional) — Instituto de Ciências Matemáticas e de Computação, São Paulo, 2018. Acesso em: 2025-11-23. Disponível em: <https://teses.usp.br/teses/disponiveis/55/55134/tde-24102018-151910/pt-br.php>. Citado 2 vezes nas páginas 26 e 27.

GAD, A. Pygad: An intuitive genetic algorithm python library. *arXiv preprint arXiv:2106.06158*, 2021. Disponível em: <https://arxiv.org/abs/2106.06158>. Citado na página 48.

GUINDANI, B. et al. Integrating bayesian optimization and machine learning for the optimal configuration of cloud systems. *IEEE*, p. 277 – 294, 2024. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=10418550>. Citado na página 36.

GéRON. *Mãos à Obra: Aprendizado de Máquina com Scikit-Learn TensorFlow*. [S.l.]: ALTA BOOKS, 2019. Citado 14 vezes nas páginas 22, 23, 25, 26, 27, 28, 29, 30, 31, 40, 41, 42, 43 e 44.

HARRIS, C. R. et al. Array programming with numpy. *Nature*, v. 585, p. 357–362, 2020. Citado na página 48.

HE, S. et al. An effective cost-sensitive xgboost method for malicious urls detection in imbalanced dataset. *IEEE*, p. 93089 – 93096, 2021. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=9466844>. Citado na página 35.

HO, T. K. Random decision forests. In: *Proceedings of 3rd International Conference on Document Analysis and Recognition*. [S.l.: s.n.], 1995. v. 1, p. 278–282 vol.1. Citado na página 31.

HUNTER, J. D. Matplotlib: A 2d graphics environment. *Computing in Science & Engineering*, IEEE COMPUTER SOC, v. 9, n. 3, p. 90–95, 2007. Citado na página 48.

JERONIMO, M. T.; PRAZERES, F. S. dos. A inadimplÊncia e a liberalidade das linhas de crÉdito: Um estudo de caso em uma instituiÇÃo financeira. *Revista Eletrônica "Diálogos Acadêmicos"*, 2015. Citado na página 15.

JúNIOR, G. de M. et al. Missing data analysis using machine learning methods topredict the performance of technical students. *Revista Brasileira de Computação*, p. 134–143, 2020. Vol. 12, No2. Disponível em: <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>. Citado na página 32.

KALEYBAR, H. J. et al. Applications of genetic algorithm and its variants in rail vehicle systems: A bibliometric analysis and comprehensive review. *IEEE*, p. 68972 – 68993, 2023. Disponível em: <https://re.public.polimi.it/retrieve/05d652bf-678b-4d3b-9022-e2c5267d1bfd/Applications_of_Genetic_Algorithm_and_Its_Variants_in_Rail_Vehicle_Systems_A_Bibliometric_Analysis_and_Comprehensive_Review.pdf>. Citado 2 vezes nas páginas 38 e 39.

LEMOS, E. P.; STEINER, M. T. A.; NIEVOLA, J. C. Análise de crédito bancário por meio de redes neurais e árvores de decisão: uma aplicação simples de data mining. *R.Adm., São Paulo, v.40, n.3, p.225-234, jul./ago./set. 2005*, 2005. Disponível em: <https://rausp.usp.br/wp-content/uploads/files/V4003225.pdf>. Citado na página 28.

LOPES, R. D. S.; COLOMBI, L. R.; MUTZ, F. Comparação de algoritmos de aprendizado de máquina para predição de pontuação de crédito. *XIV Computer on the Beach*, 2023. Disponível em: <https://www.researchgate.net/publication/370565154_Comparacao_de_Algoritmos_de_Aprendizado_de_Maquina_para_Predicao_de_Pontuacao_de_Credito>. Citado 3 vezes nas páginas 46, 59 e 60.

MACHADO, W. A. M.; OLIVEIRA, E. C.; LEITE, L. da S. Gestão de riscos no processo de modelagem do risco de crédito em instituições financeiras / risk management in the process of modeling credit risk in financial institutions. *Brazilian Journal of Development*, 2021. Disponível em: <https://doi.org/10.34117/bjdv7n2-468>. Citado na página 17.

MAIA, A. do S. R. S. *Inadimplência e recuperação de créditos*. Programa de Pós-Graduação em Administração — Faculdade de Administração, Londrina, 2007. Orientador: Prof. Gilberto Kloeckner. Disponível em: <https://lume.ufrgs.br/bitstream/handle/10183/13938/000649712.pdf>. Citado na página 20.

MIENYE, I. D.; SUN, Y. A survey of ensemble learning: Concepts, algorithms, applications, and prospects. *IEEE*, p. 99129 – 99149, 2022. Disponível em: <https://ieeexplore.ieee.org/document/9893798>. Citado 2 vezes nas páginas 29 e 30.

NTI, I. K.; NYARKO-BOATENG, O.; ANINGZ, J. Performance of machine learning algorithms with different k values in k-fold cross-validation. *Modern Education and Computer Science*, 2021. Disponível em: <https://www.researchgate.net/publication/356914937_Performance_of_Machine_Learning_Algorithms_with_Different_K_Values_in_K-fold_Cross-Validation>. Citado na página 40.

NUBANK. *Nubank lança ferramenta que usa inteligência artificial para personalizar vida financeira dos clientes*. 2025. Redação Nubank. Acesso em: 27 abr. 2025. Disponível em: <https://blog.nubank.com.br/nubank-inteligencia-artificial-testes/>. Citado na página 21.

PAIVA, C. A. de C. *Administração do risco de crédito*. [S.l.]: Qualitymark, 1997. Citado 2 vezes nas páginas 17 e 18.

PANDAS, T. pandas development team. *pandas-dev/pandas: Pandas*. Zenodo, 2020. Disponível em: <https://doi.org/10.5281/zenodo.3509134>. Citado na página 48.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Citado na página 48.

PELLICER, L. F. A. O. *Otimização de hiperparâmetros de modelos machine learning com BarySearch*. Dissertação (Mestrado em Engenharia de Sistemas) — Escola Politécnica, São Paulo, 2020. Acesso em: 2025-11-23. Disponível em: <https://lume.ufrgs.br/bitstream/handle/10183/13938/000649712.pdf>. Citado na página 22.

PIRES, I. R. N. *Um modelo estratégico para a análise de crédito utilizando redes neurais artificiais*. Trabalho de Conclusão de Curso (TCC) — Faculdade de Engenharia Elétrica, Uberlândia, 2008. Orientador: Prof. Dr. Keiji Yamanaka. Disponível em: <https://repositorio.ufu.br/bitstream/123456789/14390/1/ModeloEstrategicoAnalise.pdf>. Citado na página 12.

REBOUçAS, L. da S.; ROCHA, E. M. da; COSTA, W. P. L. B. da. Fatores influenciadores da inadimplÊncia e seus impactos:um estudo nas instituições financeiras. s. d. Disponível em: <https://ojs.revistagc.com.br/ojs/index.php/rgc/article/view/94/98>. Citado na página 20.

RODRIGUES, A. L. M. *Um estudo comparativo entre algoritmos para otimização de hiperparâmetros*. TCC — Curso de graduação em Engenharia da Computação, Sobral, 2023. Disponível em: <http://repositorio.ufc.br/handle/riufc/76385>. Citado na página 41.

SANTANA, F. B. D. *FLORESTA ALEATÓRIA PARA DESENVOLVIMENTO DE MODELOS MULTIVARIADOS DE CLASSIFICAÇÃO E REGRESSÃO EM QUÍMICA ANALÍTICA*. Tese de Doutorado — Instituto de Química, São Paulo, 2020. Disponível em: <https://hdl.handle.net/20.500.12733/1639152>. Citado na página 31.

SANTOS, F. O.; NICOLETTI, M. do C. A família de algoritmos instance-based learning (ibl). *Departamento de Computação (DC) C.P. 676 13565-905 São Carlos - SP - Brasil*, 2018. Disponível em: <https://www.inf.ufsc.br/~aldo.vw/patrec/bibliografia/Ibl.pdf>. Citado na página 26.

SANTOS, J. O. dos. *Análise de Crédito: empresas, pessoas físicas, agronegócio e pecuária*. [S.l.]: Atlas, 2010. Citado 2 vezes nas páginas 18 e 19.

SANTOS, J. O. dos; FAMá, R. Avaliação de estratégias para a redução do risco de inadimplência em carteiras de crédito bancário rotativo de pessoas físicas. v. 17, p. 92–103, dez. 2006. Disponível em: <https://revistas.usp.br/rcf/article/view/34207>. Citado na página 20.

scikit-optimize developers. *Scikit-Optimize: Sequential model-based optimization in Python*. 2024. Disponível em: <https://scikit-optimize.github.io/>. Acesso em: 23 fev. 2025. Citado na página 48.

SECURATO, J. R.; FAMá, R. Um procedimento para a decisão de crédito pelos bancos. *SCIELO*, 1997. Citado 2 vezes nas páginas 12 e 16.

SEHN, C. F.; JUNIOR, R. J. C. InadimplÊncia no sistema financeiro de habitaÇÃo: Um estudo junto À caixa econÔmica federal (caixa). *RAM – revista de administração mackenzie Volume 8, n. 2*, p. 59–84, 2007. Disponível em: <https://www.scielo.br/j/ram/a/tW8TTtjhmNM8t4d959k6mbJ/?format=html&lang=pt>. Citado na página 20.

SELAU, L. P. R.; RIBEIRO, J. L. D. Uma sistemática para construção e escolha de modelos de previsão de risco de crédito. *Gest. Prod., São Carlos, v. 16, n. 3, p. 398-413*, 2009. Citado 2 vezes nas páginas 12 e 13.

SFEIR, E. *O crédito dentro e fora do sistema financeiro*. 2014. Disponível em: <https://anbc.org.br/o-credito-dentro-e-fora-do-sistema-financeiro/>. Acesso em: 13 abr. 2025. Citado na página 15.

SICHMAN, J. S. Inteligência artificial e sociedade: avanços e riscos. *ESTUDOS AVANÇADOS 35 (101), 2021*, 2021. Disponível em: <https://www.scielo.br/j/ea/a/c4sqqrthGMS3ngdBhGWtKhh/abstract/?lang=pt>. Citado na página 21.

SILVA, A. M. L. *Descoberta de Conhecimento através de Métodos de Aprendizagem de Máquina Simbólicos aplicados ao Ensino a Distância da Universidade Federal do Piauí*. Programa de Pós-Graduação em Ciência da Computação — Centro de Ciências da Natureza, Teresina, 2018. Acesso em: 2025-11-23. Disponível em: <http://hdl.handle.net/123456789/1506>. Citado 2 vezes nas páginas 22 e 27.

SILVA, D. de O. *Otimização de hiper-parâmetros de algoritmos de machine learning aplicados no contexto de análise de risco de crédito*. Monografia (Especialização em Ciências de Dados) — Curso de Especialização em Ciência de Dados, Dois Vizinhos, 2022. Disponível em: <http://repositorio.utfpr.edu.br/jspui/handle/1/31719>. Citado 5 vezes nas páginas 36, 38, 41, 42 e 46.

SILVA, F. G. de Araújo e. *Um modelo estratégico para a análise de crédito utilizando redes neurais artificiais*. Programa de Pós-Graduação em Economia — Faculdade de Ciências Econômicas, Porto Alegre, 2004. Orientador: Prof. Ronald Otto Hillbrecht. Disponível em: <http://hdl.handle.net/10183/4648>. Citado 3 vezes nas páginas 15, 17 e 18.

SILVA, J. P. da. *Gestão e análise de risco de crédito*. [S.l.]: Atlas, 2008. Citado na página 19.

SILVA, J. S. *Gerenciamento Integrado de Riscos: Modelos de Predição de Risco de Crédito em Machine Learning para a Identificação de Ativos Problemáticos em uma Instituição Financeira – Segmento Habitacional PF*. Programa de Pós-Graduação em Economia, Mestrado Profissional — Curso de Mestrado Profissional em Economia, Brasil, 2022. Disponível em: <https://repositorio.unb.br/bitstream/10482/44727/1/2022_JuellineShelciSilva.pdf>. Citado na página 45.

SOARES, S. G. *Ensemble Learning Methodologies for Soft Sensor Development in Industrial Processes*. Tese de Doutoramento em Engenharia Electrotécnica e de Computadores — Departamento de Engenharia Electrotécnica e de Computadores, Coimbra, feb 2015. Disponível em: <https://www.researchgate.net/publication/340165962_Ensemble_Learning_Methodologies_for_Soft_Sensor_Development_in_Industrial_Processes>. Citado 2 vezes nas páginas 32 e 33.

STANDARD & POOR'S. *Entendendo os ratings de crédito*. s.d. Acesso em: 5 mai. 2025. s.d. Disponível em: <https://www.spglobal.com/ratings/pt/credit-ratings/about/understanding-credit-ratings>. Citado na página 17.

TAVARES, R. A evidenciação do risco de crédito e das medidas de alocação de capital pelas instituições financeiras no brasil. *4º Congresso USP Contabilidade e Controladoria*, 2004. Citado 2 vezes nas páginas 16 e 17.

TROULLINOU, E. et al. A generative neighborhood-based deep autoencoder for robust imbalanced classification. *IEEE*, p. 80 – 91, 2024. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10054417>. Citado na página 34.

XIAOLONG, X.; WEN, C.; YANFEI, S. Over-sampling algorithm for imbalanced data classification. *IEEE*, p. 1182 – 1191, 2019. Disponível em: <https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=8945569>. Citado na página 35.

YANG, L.; SHAMI, A. On hyperparameter optimization of machine learning algorithms: Theory and practice. *Department of Electrical and Computer Engineering, University of Western Ontario, 1151 Richmond St, London, Ontario, Canada N6A 3K7*, 2020. Disponível em: <https://abt-br.org.br/wp-content/uploads/2023/03/RTE_236.pdf>. Citado 8 vezes nas páginas 22, 35, 36, 37, 38, 39, 45 e 46.

Apêndices

APÊNDICE A – Repositório público no github

Link para repositório