Erik Pires Zaina
Lucas Gonçalo de Morais
Murilo dos Santos Sena

Previsão de Resultados da NBA com CatBoost: Uma Análise Preditiva de Jogos

São Paulo - Brasil

2025

Erik Pires Zaina
Lucas Gonçalo de Morais
Murilo dos Santos Sena

Previsão de Resultados da NBA com CatBoost: Uma Análise Preditiva de Jogos

Monografia apresentada na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro
Bacharelado em Ciência da Computação

Orientador: Alessandro Ranulfo Nery

São Paulo - Brasil
2025

Resumo

A análise preditiva na NBA tem evoluído de abordagens subjetivas para modelagens quantitativas complexas. Entretanto, a maioria dos modelos existentes fundamenta-se em estatísticas agregadas de equipe, falhando em capturar a variância introduzida por rotações dinâmicas e pelo desempenho individual estocástico dos atletas. Para mitigar essa limitação, este trabalho propõe uma arquitetura preditiva baseada no algoritmo *Gradient Boosting* (CatBoost), enriquecida por uma engenharia de atributos que integra métricas granulares de jogadores e uma Janela Temporal Ótima (OTW). A metodologia empregou um protocolo de validação temporal *walk-forward* com embargo para eliminar o risco de vazamento de dados (*data leakage*), além da aplicação do SHAP (*Shapley Additive exPlanations*) para garantir a interpretabilidade das decisões do modelo. Os experimentos, conduzidos com dados das temporadas de 2021 a 2025, resultaram em uma acurácia de 68,05% e uma AUC-ROC de 0,7227 no conjunto de teste. O modelo proposto superou a linha de base em 15,51 pontos percentuais, validando estatisticamente a hipótese de que a incorporação da variabilidade individual dos jogadores é determinante para a maximização do poder preditivo em esportes coletivos.

Palavras-chave: Previsão Esportiva, NBA, Machine Learning, CatBoost, Engenharia de Atributos.

Abstract

Predictive analytics in the NBA has transitioned from subjective assessments to complex quantitative modeling. However, most existing models rely on aggregated team statistics, failing to capture the variance introduced by dynamic rotations and the stochastic individual performance of athletes. To address this limitation, this work proposes a predictive architecture based on the Gradient Boosting algorithm (CatBoost), enriched by feature engineering that integrates granular player metrics and an adaptive Optimal Time Window (OTW). The methodology employed a rigorous walk-forward temporal validation protocol with an embargo to eliminate data leakage risks, alongside SHAP (Shapley Additive exPlanations) to ensure model interpretability. Experiments conducted using data from the 2021 to 2025 seasons yielded an accuracy of 68.05% and an AUC-ROC of 0.7227 on the test set. The proposed model outperformed the baseline by 15.51 percentage points, statistically validating the hypothesis that incorporating individual player variability is decisive for maximizing predictive power in team sports.

Keywords: Sports forecasting, NBA, Machine learning, CatBoost. Feature engineering.

Lista de ilustrações

Figura 1 – Distribuição dos valores de BPM 2.0 entre 1974 e 2019. 13
Figura 2 – Funcionamento do boosting como técnica de aprendizado de máquina baseada em múltiplos classificadores sequenciais. 16
Figura 3 – Fluxo do algoritmo CatBoost baseado em Gradiente Boosting. O modelo é treinado com subconjuntos amostrados via bootstrap, com atualização sequencial de pesos e preditores. 19
Figura 4 – Framework do algoritmo SHAP (2025). 25
Figura 5 – Ilustração das Janelas Temporais Ótimas (OTWs, em verde) e sua relação com os intervalos de tempo dos conjuntos de dados de treinamento (em azul claro), para N jogos do time observado. 27
Figura 6 – Visão geral da metodologia em diagrama UML 29
Figura 7 – Buffer temporal na engenharia de atributos 31
Figura 8 – Embargo na validação cruzada temporal 32
Figura 9 – Regra de cálculo da janela OTW por time 34
Figura 10 – Pipeline de validação temporal: etapas e laço de dobras 38
Figura 11 – Validação temporal com embargo em esquema *walk-forward* 39
Figura 12 – Fluxo de previsão em cenário de uso com embargo de 24 horas 41
Figura 13 – Curvas ROC e Precision–Recall no conjunto de teste. 43
Figura 14 – Curvas de ganho e de *lift* no conjunto de teste. 43
Figura 15 – Desempenho do modelo por equipe comparando a acurácia quando o time atua como mandante (círculos) e como visitante (xis). 44
Figura 16 – Evolução da acurácia mensal na temporada regular (2024–2025). 46
Figura 17 – Análise de ablação no conjunto de teste. 47
Figura 18 – Top 20 variáveis mais importantes segundo a média de |SHAP| no conjunto de teste. 48
Figura 19 – Curva de confiabilidade do modelo no conjunto de teste. 50
Figura 20 – Explicação local por SHAP para uma predição individual de jogo da NBA 51

Lista de tabelas

Tabela 1 – Resumo das Métricas de Desempenho de Classificação 22
Tabela 2 – Variáveis categóricas utilizadas. 40
Tabela 3 – Melhores ensaios de otimização de hiperparâmetros (amostra) 42
Tabela 4 – Métricas globais no conjunto de teste 42
Tabela 5 – Resultados da análise de ablação incremental 47
Tabela 6 – Comparação de desempenho entre estratégias de Janela Temporal (OTW) 49
Tabela 7 – Métricas antes e depois da calibração no conjunto de teste 50
Tabela 8 – Comparação de desempenho entre o modelo proposto e algoritmos de referência no conjunto de teste 52
Tabela 9 – Comparação de desempenho entre estudos selecionados e o modelo proposto 53

Lista de abreviaturas e siglas

AI	Artificial Intelligence (Inteligência Artificial)
API	Application Programming Interface (Interface de Programação de Aplicações)
API-NBA	Interface de Programação de Aplicações da NBA
AUC	Área sob a curva
AUC-PR	Área sob a curva Precisão–Recall
AUC-ROC	Área sob a curva ROC
B2B	Back-to-back
BPM	Box Plus/Minus
CV	Coeficiente de variação
ECE	Erro de calibração esperado
EQM	Erro Quadrático Médio
F1	F1-Score
FN	Falso negativo
FP	Falso positivo
FPR	Taxa de falsos positivos
H2H	Head-to-head
IA	Inteligência Artificial
JSON	JavaScript Object Notation
LightGBM	Light Gradient Boosting Machine
Log loss	Perda logística
MDP	Markov Decision Process (Processo de Decisão de Markov)
ML	Machine Learning (Aprendizado de Máquina)
NBA	National Basketball Association
NR	Net rating
OTW	Optimal Time Window (Janela Temporal Ótima)
PER	Player Efficiency Rating

PPV	Valor preditivo positivo
PR	Precisão–Recall
p.p.	Pontos percentuais
ROC	Receiver Operating Characteristic
SHAP	Shapley Additive Explanations
SVM	Support Vector Machine (Máquina de Vetores de Suporte)
TN	Verdadeiro negativo
TP	Verdadeiro positivo
TPR	Taxa de verdadeiros positivos
VORP	Value Over Replacement Player
XGBoost	eXtreme Gradient Boosting

Sumário

1 INTRODUÇÃO . . . 10
1.1 Contexto . . . 10
1.2 Objetivos . . . 11
1.2.1 Objetivo Específico . . . 11

2 REVISÃO BIBLIOGRÁFICA . . . 12
2.1 National Basketball Association (NBA) . . . 12
2.1.1 Métricas Avançadas no Basquete . . . 12
2.2 Inteligência Artificial . . . 13
2.2.1 Aprendizado de Máquina . . . 13
2.2.2 Aprendizado Supervisionado . . . 14
2.2.3 Algoritmos de Boosting . . . 14
2.2.3.1 CatBoost . . . 16
2.2.4 Métricas de Avaliação . . . 19
2.2.4.1 Métricas de Desempenho de Classificação . . . 19
2.2.4.2 A Matriz de Confusão . . . 20
2.2.4.3 Acurácia . . . 20
2.2.4.4 Precisão e Recall . . . 21
2.2.4.5 F1-Score . . . 21
2.2.4.6 Métricas de Discriminação . . . 21
2.2.4.7 Curva ROC . . . 22
2.2.4.8 Área Sob a Curva (AUC) . . . 23
2.2.4.9 Métricas de Calibração . . . 23
2.3 SHAP (Shapley Additive exPlanations) . . . 24
2.4 OTW: Optimal Time Window . . . 25
2.5 Trabalhos Relacionados . . . 27

3 DESENVOLVIMENTO . . . 29
3.1 Fonte e Coleta de Dados . . . 30
3.2 Tratamento de Vazamento Temporal . . . 30
3.3 Dataset de Jogos . . . 32
3.4 Dataset de Estatísticas de Jogadores . . . 33
3.5 Engenharia de Features . . . 34
3.5.1 Atributos Baseados no Histórico de Jogos . . . 34
3.5.1.1 Janela Temporal Ótima (OTW) . . . 34
3.5.1.2 Ponderação Exponencial Dinâmica . . . 36
3.5.1.3 Atributos Derivados do Histórico . . . 36
3.6 Seleção e Configuração do Modelo . . . 36
3.6.1 Escolha do algoritmo . . . 36
3.6.2 Otimização de hiperparâmetros . . . 36
3.6.3 Configuração final . . . 37
3.7 Atributos Baseados em Estatísticas de Jogadores . . . 37
3.7.1 Agregação Ponderada . . . 37
3.7.2 Atributos Gerados dos Jogadores . . . 37

3.8 Atributos Contextuais e Derivados **38**
3.9 Validação Temporal com Embargo **38**
3.9.1 Justificativa da validação temporal 38
3.9.2 Estratégia implementada 39
3.10 Tratamento de Variáveis Categóricas **40**
3.10.1 Codificação ordenada 40
3.10.2 Quais categorias foram usadas 40
3.11 Análise de Ablação **40**
3.12 Explicabilidade das Predições **40**
3.13 Acurácia por Equipe e ao Longo do Tempo **41**
3.14 Aplicação em Cenário de Uso **41**

4 TESTES E RESULTADOS **42**
4.1 Configuração experimental **42**
4.2 Otimização de hiperparâmetros **42**
4.3 Desempenho geral **42**
4.4 Análises detalhadas **43**
4.4.1 Acurácia por equipe 43
4.4.2 Acurácia ao longo do tempo 45
4.5 Análise de ablação **46**
4.6 Explicabilidade das predições **47**
4.7 Validação da Janela Temporal Ótima (OTW) **48**
4.8 Calibração das Probabilidades **49**
4.9 Estudo de caso de predição individual **50**
4.10 Comparação de Desempenho com Outros Modelos **51**
4.11 Discussão dos resultados **52**

5 CONCLUSÃO **54**
5.1 Trabalhos Futuros **54**

REFERÊNCIAS **56**

1 Introdução

1.1 Contexto

O esporte profissional mudou muito na última década. A tomada de decisão deixou de depender quase só de intuição e avaliação subjetiva para adotar uma abordagem quantitativa baseada em dados. Esse movimento consolidou a análise esportiva como área que aplica técnicas de aprendizado de máquina para previsão de desempenho de atletas e equipes, com aplicações diretas no basquete profissional (PAPAGEORGIOU; SARLIS; TJORTJIS, 2024). A *National Basketball Association* (NBA) é historicamente rica em dados, e o recente avanço está na maior granularidade e acessibilidade das bases de estatísticas e rastreamento, que ampliaram o uso de métodos quantitativos (OBI et al., 2024).

A avaliação de desempenho também mudou. Em vez de métricas isoladas e regras fixas, ganham espaço modelos adaptativos que aprendem padrões a partir de grandes históricos de jogos, treinos e dados físicos. Essa mudança de abordagem levanta justamente a questão de quanto a adoção intensiva de dados e modelos preditivos se traduz em vantagem competitiva concreta (SARLIS; TJORTJIS, 2020).

Os efeitos são práticos. Um estudo com 12 temporadas da NBA encontrou correlação positiva e estatisticamente significativa entre o investimento em departamentos de análise e o número de vitórias. O resultado permaneceu consistente mesmo ao isolar a influência de fatores como folha salarial, experiência, química do elenco, estabilidade da comissão técnica e lesões. O tamanho e a qualificação da equipe de análise apareceram como preditores consistentes de sucesso em quadra (WANG; SARKER; HOSOI, 2025).

No entanto, muitos modelos preditivos ainda se baseiam em estatísticas agregadas por equipe. Essa abordagem, embora útil, apresenta uma limitação fundamental: a NBA é uma liga impulsionada por jogadores. O desempenho de uma equipe pode variar significativamente em função de trocas, lesões ou simplesmente da rotação de atletas em partidas específicas (KOVáCS, 2024). Modelos que consideram apenas dados coletivos são, portanto, mais frágeis diante dessa volatilidade e incapazes de capturar as interações e contribuições individuais que frequentemente determinam o resultado dos jogos. Diante dessa lacuna, este trabalho propõe investigar se a incorporação de *features* em nível de jogador, combinadas às métricas tradicionais de equipe, pode gerar um modelo mais preciso e mais resiliente à alta variabilidade característica da liga.

A escolha do algoritmo é de grande importância para lidar com a complexidade dos dados esportivos, que incluem uma mistura de variáveis numéricas e categóricas (como time da casa vs. visitante, conferência, etc.). Para este fim, foi selecionado o CatBoost *(Categorical Boosting)*, um algoritmo de gradient boosting desenvolvido pela Yandex (PROKHORENKOVA et al., 2018). Sua principal vantagem é o tratamento nativo de características categóricas, eliminando a necessidade de pré-processamentos manuais que podem levar à perda de informação (PROKHORENKOVA et al., 2018). Além disso, o CatBoost implementa uma técnica chamada Ordered Boosting, projetada para reduzir o sobreajuste *(overfitting)* e evitar um tipo de vazamento de dados *(target leakage)* comum em outras implementações de boosting, resultando em modelos mais generalizáveis.

Um dos maiores desafios na aplicação de aprendizado de máquina é o "dilema da caixa-preta" *(black box dilemma)*. Modelos complexos como os de gradient boosting, apesar de sua alta precisão, são frequentemente opacos, dificultando a interpretação de suas previsões por parte dos tomadores de decisões (ZENG et al., 2023). Para que um modelo seja verdadeiramente útil, ele não deve apenas prever, mas também explicar o "porquê" por trás de suas decisões.

1.2 Objetivos

O objetivo geral deste trabalho é avaliar a eficácia preditiva da integração de métricas granulares de jogadores e de Janelas Temporais Ótimas (OTW) na previsão de resultados de partidas da NBA. O estudo investiga a hipótese de que a incorporação da variabilidade individual dos atletas e da forma recente das equipes supera as limitações dos modelos tradicionais baseados apenas em médias agregadas.

A abordagem proposta busca definir de maneira mais fiel o momento (ou "forma") atual de uma equipe, utilizando pesos dinâmicos, permitindo assim descobrir com mais clareza os padrões que levam à vitória.

1.2.1 Objetivo Específico

- Criar um pipeline de engenharia de features para calcular métricas dinâmicas e adaptativas.
- Criar um módulo para integrar e agregar estatísticas de desempenho individual de jogadores.
- Treinar e validar o modelo usando um método de validação temporal cruzada com embargo.
- Implementar um algoritmo de explicabilidade (SHAP) para analisar o impacto de cada feature nas previsões individuais.
- Avaliar o desempenho e a calibração do modelo em dados de teste temporalmente isolados.

2 Revisão Bibliográfica

Este capítulo apresenta os principais conceitos, métodos e estudos anteriores relacionados à modelagem computacional aplicada à previsão de resultados na NBA. Serão abordados os algoritmos de *machine learning* utilizados em predições esportivas, a importância da interpretabilidade, o contexto específico da NBA enquanto domínio da aplicação, além de técnicas como CatBoost, SHAP e a Janela Temporal Ótima (OTW).

2.1 National Basketball Association (NBA)

A National Basketball Association (NBA) é uma das principais ligas de basquete profissional do mundo, sediada na América do Norte e composta por 30 equipes divididas entre as conferências Leste e Oeste (Encyclopædia Britannica, 2025). Fundada oficialmente em 1949, a National Basketball Association (NBA) surgiu da fusão entre duas organizações rivais: a Basketball Association of America (fundada em 1946) e a National Basketball League (fundada em 1937). A NBA é reconhecida por reunir atletas de destaque internacional e desempenhar papel central no cenário global do basquete profissional (Encyclopædia Britannica, 2025). Além de seu apelo esportivo e de entretenimento, a NBA distingue-se pela abundância de dados estatísticos coletados a cada partida e temporada. Cada jogo gera uma rica folha estatística (*box score*) com dezenas de indicadores (pontos, rebotes, assistências, etc.), além de estatísticas agregadas por temporada. Ao longo das últimas décadas, esse volume de dados impulsionou o surgimento de análises quantitativas e métricas avançadas no basquete, muitas das quais influenciaram tanto a comunidade acadêmica quanto as decisões gerenciais de times profissionais (OLIVER, 2004; KUBATKO et al., 2007).

2.1.1 Métricas Avançadas no Basquete

Métricas avançadas são medidas estatísticas elaboradas com o objetivo de avaliar de forma mais acurada o desempenho de jogadores e equipes, indo além dos números tradicionais. Diversos pesquisadores e analistas pioneiros desenvolveram tais métricas. John Hollinger, por exemplo, introduziu o Player Efficiency Rating (PER), que combina os principais dados de box score de um jogador como pontos, rebotes, assistências, roubos, tocos e desperdícios de posse em um único índice de eficiência por minuto em quadra (HOLLINGER, 2005). O PER é padronizado para que a média da liga seja sempre 15, valores acima ou abaixo dessa média indicam o quão acima ou abaixo da média é a performance estatística do atleta. Os detalhes do cálculo, incluindo ajustes por ritmo de jogo (pace), são disponibilizados por plataformas especializadas como o (Basketball Reference, 2025). Embora amplamente utilizado, o PER é criticado por não capturar aspectos defensivos mais sutis ou contribuições táticas intangíveis.

Outra classe importante são as métricas baseadas em *plus/minus*, que avaliam o impacto de um jogador no placar enquanto ele está em quadra. O chamado *plus/minus* bruto registra a diferença de pontos do placar com o jogador em ação já o *Box Plus/Minus* (BPM) é uma versão avançada que estima, a partir das estatísticas individuais de *box score*, quantos pontos por 100 posses de bola um jogador adiciona (ou subtrai) ao placar de seu

time em relação a um jogador médio (MYERS, 2020). O BPM leva em conta fatores como eficiência ofensiva e defensiva do time quando o jogador está em quadra, tentando isolar a contribuição individual do atleta (MYERS, 2020). Embora introdutoriamente descrito em trabalhos como o de Kubatko et al. (2007), que discutem métricas de *plus/minus* e suas limitações, o BPM em si foi refinado posteriormente dentro da comunidade de analistas de basquete(KUBATKO et al., 2007).

Figura 1 – Distribuição dos valores de BPM 2.0 entre 1974 e 2019.

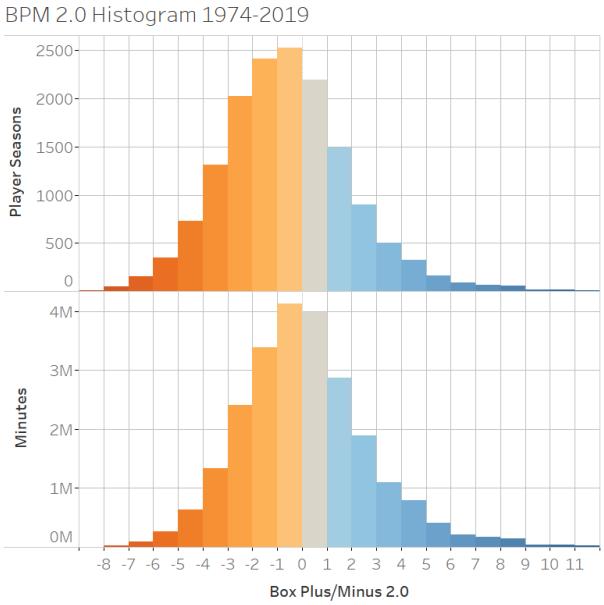

Fonte: <https://www.basketball-reference.com/about/bpm2.html>

2.2 Inteligência Artificial

A Inteligência Artificial (IA) é o campo da computação dedicado ao desenvolvimento de sistemas capazes de realizar tarefas que normalmente requereriam inteligência humana, como reconhecimento de padrões e tomada de decisão. Desde os primórdios, nos anos 1950, busca-se criar agentes artificiais que percebam o ambiente e ajam de forma autônoma para atingir objetivos estabelecidos(RUSSELL; NORVIG, 2010).

2.2.1 Aprendizado de Máquina

O Aprendizado de Máquina (ML), uma das principais subáreas da IA, desenvolve algoritmos que permitem ao computador aprender padrões ou comportamentos a partir de dados e melhorar seu desempenho em tarefas específicas. Uma definição clássica descreve que um algoritmo de ML explora dados de treinamento para induzir um modelo capaz de fazer predições ou decisões sem ser explicitamente programado para cada caso (MITCHELL, 1997).

Os métodos de ML costumam ser categorizados em aprendizado supervisionado, não supervisionado e por reforço, sendo este trabalho focado em técnicas supervisionadas de classificação. Nos últimos anos, redes neurais profundas (aprendizado profundo) alcançaram avanços notáveis em tarefas complexas como visão computacional e jogos

estratégicos(GOODFELLOW; BENGIO; COURVILLE, 2016), contudo, esses modelos tipicamente requerem grandes volumes de dados e alto poder computacional. Para dados estruturados tabulares, técnicas de *ensemble* baseadas em árvores de decisão, como o *boosting*, têm se destacado pela alta eficácia preditiva.

2.2.2 Aprendizado Supervisionado

No aprendizado supervisionado, o algoritmo recebe um conjunto de exemplos de treinamento compostos por pares de entrada e saída esperada (rótulo ou valor) (MITCHELL, 1997). O objetivo é aprender uma função ou modelo que mapeie as entradas para as saídas corretas, de forma geral para novos dados não vistos. Tipicamente, problemas supervisionados subdividem-se em classificação (quando a saída é uma classe ou categoria) e regressão (quando a saída é um valor numérico contínuo) (ALPAYDIN, 2010). Exemplos de algoritmos supervisionados incluem regressão logística, máquinas de vetores de suporte (SVM), árvores de decisão e redes neurais artificiais (MITCHELL, 1997; ALPAYDIN, 2010).

Esses algoritmos ajustam seus parâmetros internos para minimizar um erro de previsão em relação aos rótulos conhecidos do conjunto de treino. Quando bem-sucedido, o modelo resultante consegue generalizar o aprendizado para realizar previsões acuradas em novos dados (MITCHELL, 1997). Nos últimos anos, métodos de aprendizado profundo (*deep learning*, redes neurais com muitas camadas) tornaram-se proeminentes dentro do paradigma supervisionado, alcançando avanços significativos em tarefas como reconhecimento de imagens e jogos estratégicos (GOODFELLOW; BENGIO; COURVILLE, 2016). Embora redes profundas exijam grandes volumes de dados e poder computacional, elas demonstram o potencial do aprendizado supervisionado quando as condições de treinamento são favoráveis (GOODFELLOW; BENGIO; COURVILLE, 2016).

2.2.3 Algoritmos de Boosting

A técnica de *boosting*, introduzida por Freund e Schapire(FREUND; SCHAPIRE, 1995) e posteriormente generalzada por Friedman(FRIEDMAN, 2001), combina múltiplos modelos fracos de forma sequencial para formar um modelo final mais sólido. Implementações modernas, como o XGBoost(CHEN; GUESTRIN, 2016) e o CatBoost(PROKHORENKOVA et al., 2018), incorporam diversas otimizações e obtêm desempenho de ponta em muitos cenários de classificação e regressão.

Em cada iteração do processo de boosting, um novo modelo é treinado para corrigir os erros do conjunto de modelos anteriores, focando especialmente nas instâncias que foram preditas incorretamente nas etapas precedentes. Diferentemente do *bagging* (onde modelos são treinados em paralelo em subconjuntos aleatórios dos dados), no boosting os modelos são ajustados em sequência adaptativa, de modo que cada modelo adicional concentra-se nos erros do anterior. Essa estratégia iterativa tende a reduzir o viés do modelo e, quando bem regulamentada, produz modelos de alta acurácia em tarefas de classificação e regressão(Amazon Web Services, 2023). Um dos primeiros e mais influentes algoritmos dessa família é o AdaBoost (*Adaptive Boosting*), proposto por Freund e Schapire na década de 1990 (FREUND; SCHAPIRE, 1995).

O AdaBoost foi concebido para problemas de classificação binária e mostrou empiricamente como combinar múltiplos classificadores fracos (por exemplo, árvores de decisão

rasas ou *stumps*) pode gerar um classificador forte com desempenho significativamente melhor (FREUND; SCHAPIRE, 1995). Em cada iteração do AdaBoost, os pesos associados a cada instância de treinamento são ajustados: exemplos que foram classificados incorretamente pelo modelo anterior têm seus pesos aumentados, enquanto exemplos classificados corretamente têm seus pesos reduzidos. Em seguida, um novo classificador fraco é treinado com base nesses pesos ajustados, enfatizando os exemplos difíceis. Cada classificador recebe uma ponderação α_m proporcional à sua performance (tipicamente calculada como uma função do erro de classificação), e a predição final do ensemble é obtida por uma votação ponderada desses classificadores (FREUND; SCHAPIRE, 1995). Do ponto de vista teórico, demonstra-se que o AdaBoost minimiza aproximadamente uma função de perda exponencial, o que ajuda a explicar seu sucesso em reduzir erros de generalização em diversas aplicações (SCHAPIRE; FREUND, 2012). Aplicações típicas do AdaBoost incluem tarefas de classificação em visãocomputacional (por exemplo, detecção de faces) e outras áreas onde a interpretabilidade e a simplicidade dos classificadores fracos são vantajosas, embora hoje existam variantes mais adequadas para dados complexos.

Outro avanço fundamental foi a introdução do Gradient Boosting (boosting por gradiente), generalizado por Friedman (FRIEDMAN, 2001). Enquanto o AdaBoost ajusta iterativamente os modelos dando ênfase a erros de classificação, o Gradient Boosting reformula o problema de boosting como a otimização de uma função de perda arbitrária por meio de descida de gradiente em espaço de funções (FRIEDMAN, 2001). Nessa abordagem, em cada etapa m ajusta-se um novo modelo base $h_m(x)$ para aproximar o gradiente negativo da função de perda (os resíduos) do modelo atual em relação aos dados de treinamento. Em outras palavras, o modelo sequencialmente tenta corrigir os resíduos (erros) do modelo conjunto anterior. Esse framework é bastante flexível: permite usar diferentes funções de perda (ex.: erro quadrático para regressão, deviação binária para classificação) e diferentes modelos base (embora sejam comumente utilizadas árvores de decisão CART de média profundidade como aprendizes fracos).

O Gradient Boosting provou ser altamente eficaz em uma variedade de domínios, pois combina a capacidade preditiva de modelos de alta variância (como árvores de decisão) com a redução de viés proporcionada pelo esquema de boosting. Ele rapidamente se tornou uma das técnicas de referência para dados tabulares, exibindo desempenho superior em muitas tarefas de classificação e regressão onde modelos lineares ou até redes neurais não capturam tão bem interações complexas entre variáveis(MCELFRESH et al., 2024).

Com o crescente uso do boosting em aplicações do mundo real, surgiram melhorias práticas no algoritmo de Friedman. Uma das mais proeminentes é o XGBoost (*eXtreme Gradient Boosting*), proposto por Tianqi Chen (CHEN; GUESTRIN, 2016). O XGBoost é essencialmente uma implementação otimizada do Gradient Boosting que incorpora diversas inovações para torná-lo mais rápido, escalável e ainda mais preciso. Dentre as contribuições técnicas do XGBoost estão: (i) a utilização de uma formulação de segunda ordem para a otimização o algoritmo calcula não apenas os gradientes primeiro-ordem, mas também o Hessiano (gradientes de segunda ordem) da função de perda para orientar o crescimento das árvores, o que acelera a convergência e pode melhorar a qualidade dos *splits*(CHEN; GUESTRIN, 2016), (ii) a introdução de um termo de regularização explícito na função objetivo, penalizando a complexidade das árvores (por exemplo, número de folhas e magnitude dos pesos nas folhas) para evitar sobreajuste (CHEN; GUESTRIN, 2016); (iii) otimizações de computação, como processamento em paralelo dos nós da árvore, compressão de dados em memória e tratamento eficiente de valores ausentes e atributos

esparsos.

Figura 2 – Funcionamento do boosting como técnica de aprendizado de máquina baseada em múltiplos classificadores sequenciais.

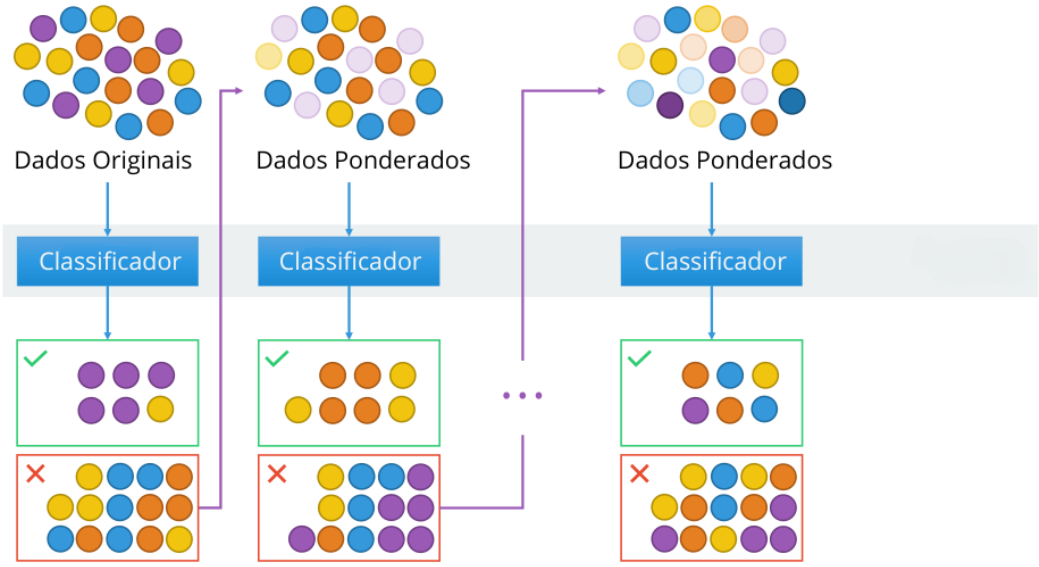

Fonte: <https://commons.wikimedia.org/wiki/File:Ensemble_Boosting.svg>

2.2.3.1 CatBoost

O CatBoost (do inglês *Category Boosting*) é um algoritmo mais recente de boosting por gradiente, desenvolvido pela equipe da Yandex, que se destaca por oferecer melhorias técnicas específicas em relação a implementações anteriores como o XGBoost e outros (PROKHORENKOVA et al., 2018).

Assim como estes, o CatBoost constrói um ensemble de árvores de decisão de forma sequencial para minimizar uma função de perda, porém, ele introduz técnicas que visam resolver problemas particulares do boosting tradicional, especialmente no tratamento de variáveis categóricas e na redução de vieses durante o treinamento. Essas inovações permitem ao CatBoost obter desempenho semelhante ou superior aos demais métodos de boosting em muitos cenários, além de facilitar seu uso em problemas com dados heterogêneos (PROKHORENKOVA et al., 2018).

Matematicamente, o CatBoost busca minimizar a função de perda esperada

$$L(F) = \mathbb{E}_{(x,y)} \left[\ell(y, F(x)) \right],$$

onde $F : \mathbb{R}^m \to \mathbb{R}$ é o modelo preditor, ℓ é uma função de perda convexa e suave, e (x, y) são os dados de entrada e alvo, respectivamente. Em cada iteração t, o modelo é atualizado adicionando uma árvore h_t que aproxima o gradiente negativo da perda:

$$F^t(x) = F^{t-1}(x) + \alpha h_t(x),$$

com α sendo a taxa de aprendizado. A árvore h_t é obtida ao resolver

$$h_t = \arg\min_{h \in \mathcal{H}} \mathbb{E}_{(x,y)} \left[\left(-g_t(x, y) - h(x) \right)^2 \right],$$

Onde:

$$g_t(x, y) = \left.\frac{\partial \ell(y, s)}{\partial s}\right|_{s=F^{t-1}(x)}$$

é o gradiente da função de perda em relação à predição atual.

Uma das principais vantagens do CatBoost é o tratamento nativo de variáveis categóricas. Diferentemente do XGBoost e da maioria dos algoritmos de árvore, que exigem converter variáveis categóricas em representações numéricas (por exemplo, via codificação one-hot, label encoding ou embeddings fornecidos pelo usuário), o CatBoost lida internamente com atributos categóricos de forma eficiente (PROKHORENKOVA et al., 2018). Ele emprega uma técnica de *target encoding* especial chamada de estatísticas ordenadas (*ordered target statistics*), na qual os valores categóricos são transformados com base nas estatísticas de resposta (média ou likelihood do alvo) calculadas a partir dos dados de treinamento sem introduzir vazamento de informação do alvo (target leakage) (PROKHORENKOVA et al., 2018).

Em termos práticos, para cada exemplo k, o valor codificado $\hat{x}_{ik}$ para a variável categórica i é calculado como

$$\hat{x}_{ik} = \frac{\sum_{j:\sigma(j)<\sigma(k)} \mathbf{1}\{x_{ij} = x_{ik}\} y_j + ap}{\sum_{j:\sigma(j)<\sigma(k)} \mathbf{1}\{x_{ij} = x_{ik}\} + a},$$

Onde: σ é uma permutação aleatória dos índices das amostras, usada para garantir que apenas exemplos "anteriores" sejam considerados e evitar o vazamento de informação futura, $a > 0$ é um parâmetro de suavização que evita divisão por zero e controla o peso da constante p, p é uma constante, tipicamente a média global do alvo, $\mathbf{1}\{\cdot\}$ é a função indicadora, que vale 1 se a condição é verdadeira e 0 caso contrário.

Essa abordagem se traduz no seguinte processo: o CatBoost percorre o conjunto de treinamento em diferentes permutações aleatórias e, para cada categoria, calcula gradualmente a média do alvo considerando apenas observações anteriores na ordem percorrida, junto com um termo de suavização bayesiana. Dessa forma, cada exemplo nunca contribui para a codificação de si mesmo, evitando viés. O resultado final é uma representação numérica de cada categoria que reflete a tendência de seu valor de acordo com os dados já vistos, minimizando overfitting e preservando a ordem temporal durante o treinamento (PROKHORENKOVA et al., 2018).

Em resumo, o CatBoost automatiza o manejo de dados categóricos, poupando trabalho de pré-processamento e frequentemente resultando em modelos mais acurados quando há muitas variáveis não numéricas. Outra inovação introduzida pelo CatBoost é o chamado *ordered boosting* (boosting ordenado). No *boosting* convencional (como Gradient Boosting e XGBoost), ao treinar o m-ésimo modelo do ensemble, utiliza-se todo o conjunto de treinamento atual (com as respostas reais) para calcular os resíduos ou gradientes inclusive para as próprias instâncias que esse modelo m irá ajustar. Isso pode levar a um leve vazamento de informação, pois a etapa m "vê" o valor real que deveria prever, ainda que como parte do cálculo do resíduo. O CatBoost resolve esse problema treinando cada nova árvore de decisão em um modo restrito: ele cria divisões ordenadas do *dataset* (novamente usando permutações aleatórias) e garante que, para calcular os resíduos e decidir os melhores *splits* de uma nova árvore, sejam utilizadas apenas estatísticas obtidas de instâncias que já foram predizidas em etapas anteriores (ou que estão em outras partições),

evitando que uma árvore em treinamento "se veja no espelho" (PROKHORENKOVA et al., 2018).

Além disso, o CatBoost adota árvores de decisão simétricas (também chamadas *oblivious trees*) em sua construção do ensemble (PROKHORENKOVA et al., 2018). Diferentemente das árvores de decisão tradicionais, em que cada nó pode dividir por um critério diferente gerando estruturas irregulares, as árvores simétricas impõem que, em cada nível da árvore, todas as divisões ocorram pela mesma variável. Em outras palavras, a estrutura da árvore é balanceada e predefinida: primeiro todos os nós dividem pela variável X, depois todos os nós resultantes dividem pela variável Y, e assim por diante, independentemente de qual caminho na árvore está sendo considerado. Assim, as árvores simétricas contribuem para que o CatBoost mantenha desempenho em termos de velocidade e também reduzam a complexidade do modelo, o que pode ser vantajoso em dados com alto ruído ou altamente desequilibrados. Graças a esse conjunto de aprimoramentos, o CatBoost apresenta um desempenho vantajoso em comparação a demais métodos de boosting. Os desenvolvedores do CatBoost reportaram que a combinação das técnicas de *ordered boosting* e codificação eficiente de variáveis categóricas levou o algoritmo a superar implementações públicas existentes (como XGBoost e LightGBM) em termos de qualidade preditiva em uma variedade de conjuntos de dados benchmark (PROKHORENKOVA et al., 2018). Em particular, em tarefas com muitas variáveis categóricas ou com classes desbalanceadas, o CatBoost tende a se destacar: a abordagem livre de vazamentos evita favorecer indevidamente a classe majoritária durante o treinamento, e o algoritmo permite ajustar facilmente pesos para classes minoritárias se necessário, resultando em melhor equilíbrio entre desempenho e generalização. Em cenários gerais, mesmo sem ajustes específicos, o CatBoost frequentemente alcança acurácia igual ou superior à de seus concorrentes, necessitando menos engenharia de atributos por parte do usuário (PROKHORENKOVA et al., 2018). Além disso, seu desempenho com dados ruidosos e heterogêneos o torna atrativo em aplicações do mundo real.

Figura 3 – Fluxo do algoritmo CatBoost baseado em Gradiente Boosting. O modelo é treinado com subconjuntos amostrados via bootstrap, com atualização sequencial de pesos e preditores.

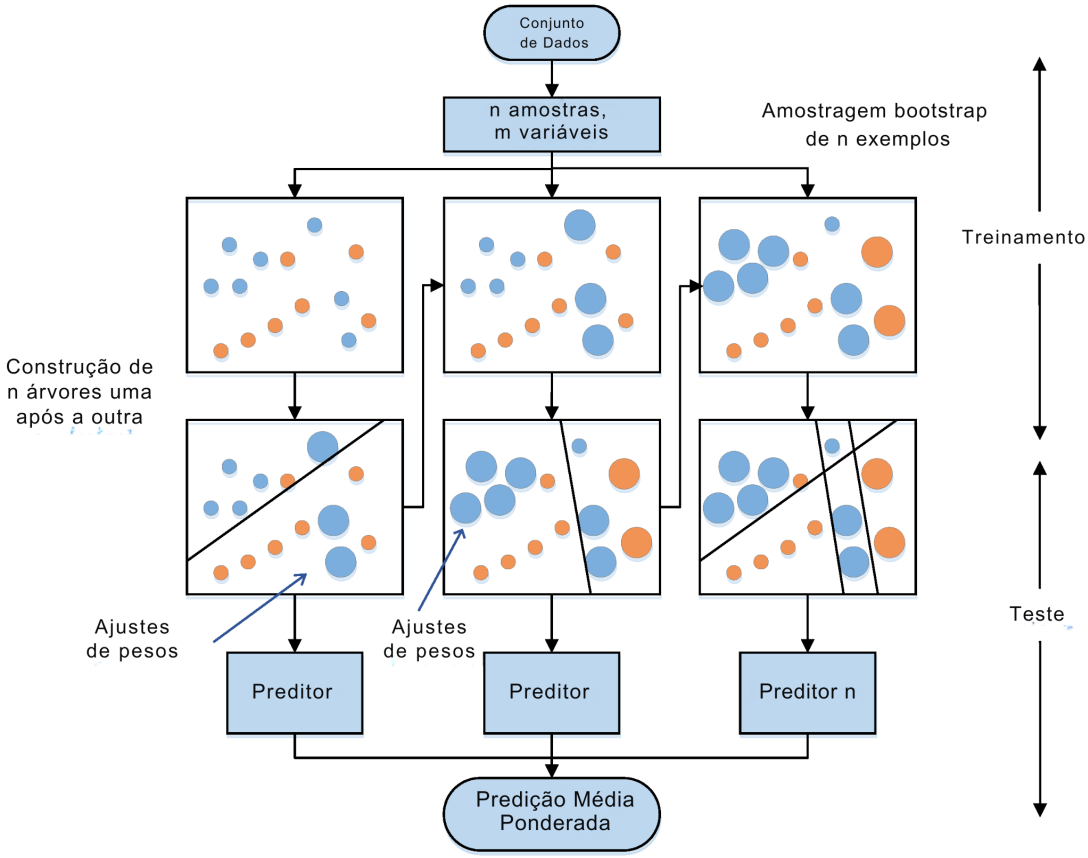

Fonte: Adaptado de Zeng et al. (2023).

2.2.4 Métricas de Avaliação

A avaliação de modelos preditivos não deve se resumir a um único indicador. Neste trabalho, consideram-se três dimensões complementares: desempenho, discriminação e calibração. Desempenho mede o quanto o modelo acerta as classes. Discriminação avalia se o modelo consegue ordenar corretamente vencedores e perdedores ao atribuir probabilidades. Calibração verifica se as probabilidades previstas estão próximas das frequências observadas (por exemplo, *Brier score* e curvas de calibração). Uma análise completa deve integrar essas três dimensões, ignorar qualquer uma delas pode levar a conclusões incompletas ou enganosas sobre a qualidade real do modelo (JIANG; GRADUS; ROSELLINI, 2020; Giskard AI, s.d.)

2.2.4.1 Métricas de Desempenho de Classificação

As métricas de desempenho de classificação são utilizadas para avaliar a eficácia do modelo em acertar a classe correta, medindo diretamente a frequência e o tipo de erros cometidos nas previsões finais.

2.2.4.2 A Matriz de Confusão

A Matriz de Confusão, também conhecida como matriz de erro, é uma tabela $N \times N$ que serve como base para a visualização e cálculo da performance de um classificador (BAHETI, s.d.). Para o problema binário de prever o resultado de um jogo da NBA (por exemplo, a equipe da casa vence), a matriz 2x2 compara os valores previstos pelo modelo com os valores reais *(ground truth)* (MUREL; KAVLAKOGLU; IBM Research, s.d.). A sua estrutura permite uma análise detalhada dos tipos de erros cometidos, fornecendo uma visão muito mais granular do que uma única métrica agregada pode oferecer. Os seus componentes fundamentais são:

- Verdadeiros Positivos *(TP - True Positives)*: O modelo prevê corretamente que a equipe da casa vence, e a equipe da casa de fato vence.
- Verdadeiros Negativos *(TN - True Negatives)*: O modelo prevê corretamente que a equipe da casa perde (ou seja, a equipe visitante vence), e a equipe da casa de fato perde.
- Falsos Positivos *(FP - False Positives)*: O modelo prevê que a equipe da casa vence, mas na realidade ela perde. Este erro é também conhecido como Erro Tipo I (BAHETI, s.d.).
- Falsos Negativos *(FN - False Negatives)*: O modelo prevê que a equipe da casa perde, mas na realidade ela vence. Este erro é também conhecido como Erro Tipo II (BAHETI, s.d.).

Ao decompor as previsões nestas quatro categorias, a matriz de confusão revela não apenas quantos erros o modelo comete, mas também de que forma ele erra, o que é fundamental para o diagnóstico e aprimoramento do modelo (MUREL; KAVLAKOGLU; IBM Research, s.d.).

2.2.4.3 Acurácia

A acurácia é a métrica mais comum e intuitiva para avaliar modelos de classificação. É calculada como a proporção de previsões corretas (TP e TN) sobre o número total de previsões realizadas(Coursera Staff, 2025). A sua fórmula é:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

Apesar de sua simplicidade, a acurácia pode ser enganosa em bases com classes desbalanceadas, algo comum no esporte. Na NBA, partidas entre um líder de conferência e o lanterna ilustram esse desequilíbrio. Métricas globais como a acurácia tendem a favorecer a classe majoritária e podem ocultar a incapacidade do modelo de reconhecer casos raros. Em um cenário em que o mandante tem 90% de probabilidade de vitória, um classificador que sempre prevê vitória do mandante atinge 90% de acerto sem, de fato, aprender padrões úteis.

Para a previsão de jogos da NBA, em que o objetivo é superar o conhecimento comum e as linhas de aposta, a acurácia isolada torna-se uma métrica de vaidade. Recomenda-se priorizar métricas mais avançadas ao desbalanceamento e a custos assimétricos de erro,

como AUC-ROC, AUC-PR, F1, *balanced accuracy*, além de medidas de calibração como *Brier score* e curvas de calibração (LóPEZ et al., 2013).

2.2.4.4 Precisão e Recall

Para superar as limitações da acurácia, a precisão e o recall oferecem uma avaliação mais focada na performance do modelo em relação à classe positiva.

Precisão *(Positive Predictive Value - PPV)* mede a proporção de previsões positivas que estavam de facto corretas. Responde à pergunta:"Das vezes que o modelo previu uma vitória da equipe da casa, quantas vezes acertou?" (FAWCETT, 2006). A sua fórmula é:

Precisão $= \frac{TP}{TP+FP}$

Recall (Sensibilidade ou Taxa de Verdadeiros Positivos - TPR) mede a proporção de positivos reais que foram corretamente identificados pelo modelo. Responde à pergunta: "De todas as vitórias reais da equipe da casa, quantas é que o modelo conseguiu prever?" (FAWCETT, 2006). A sua fórmula é:

Recall $= \frac{TP}{TP+FN}$

Entre estas duas métricas existe um trade-off fundamental: otimizar uma geralmente leva à degradação da outra (MUREL; KAVLAKOGLU; IBM Research, s.d.). Um modelo que prevê "upset" de forma muito liberal (com base em pouca evidência) terá um recall elevado (captura a maioria dos "upsets" reais), mas uma precisão baixa (muitos falsos alarmes). Por outro lado, um modelo conservador que só prevê um "upset" com evidência muito forte terá alta precisão, mas baixo recall (FAWCETT, 2006).

A decisão de priorizar precisão ou recall não é puramente técnica, mas sim uma decisão estratégica que depende do objetivo do utilizador final.

2.2.4.5 F1-Score

O F1-Score combina a precisão e o recall numa única métrica, calculada como a sua média harmônica (MUREL; KAVLAKOGLU; IBM Research, s.d.).

$$\text{F1-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Esta métrica foi concebida para fornecer uma medida de performance equilibrada, sendo particularmente útil quando as classes são desbalanceadas e quando a importância de FPs e FNs é semelhante. Ao contrário da média aritmética, a média harmónica penaliza fortemente valores extremos. Isto significa que um F1-Score elevado só é alcançado quando tanto a precisão como o recall são elevados, tornando-o um indicador mais sólido da performance geral do que a acurácia em cenários não ideais (MUREL; KAVLAKOGLU; IBM Research, s.d.).

2.2.4.6 Métricas de Discriminação

Enquanto as métricas de desempenho avaliam o resultado final da classificação, as métricas de discriminação avaliam a capacidade intrínseca do modelo de separar as duas classes (vitória vs. derrota), independentemente de um limiar de classificação específico.

Tabela 1 – Resumo das Métricas de Desempenho de Classificação

Métrica	Fórmula	Pergunta respondida	Vantagem	Limitações e contexto na NBA
Acurácia	$\frac{\text{TP}+\text{TN}}{\text{TP}+\text{TN}+\text{FP}+\text{FN}}$	Proporção de previsões corretas no total.	Simples e intuitiva.	Pode ser enganosa em jogos desiguais e mascarar a incapacidade de prever *upsets*.
Precisão	$\frac{\text{TP}}{\text{TP}+\text{FP}}$	Das previsões de vitória, quantas estavam corretas.	Mede a confiabilidade das previsões positivas.	Ignora falsos negativos, importante para manter credibilidade.
Recall	$\frac{\text{TP}}{\text{TP}+\text{FN}}$	De todas as vitórias reais, quantas foram previstas.	Mede a capacidade de detectar eventos positivos.	Ignora falsos positivos, pode levar à perda de oportunidades de valor.
F1-Score	$2 \times \frac{P \times R}{P+R}$	Equilíbrio entre precisão e recall.	Forte ao desbalanceamento de classes.	Menos interpretável do que precisão e recall isoladamente.

TP = verdadeiros positivos; TN = verdadeiros negativos; FP = falsos positivos; FN = falsos negativos; P = precisão; R = recall.
Fonte: elaboração própria (2025).

2.2.4.7 Curva ROC

As métricas da seção anterior dependem de um limiar de decisão para converter scores contínuos em classificações discretas. No entanto, este limiar é arbitrário e raramente é o ideal. A análise de discriminação avalia a qualidade dos scores do modelo em toda a gama de limiares possíveis (FAWCETT, 2006).

$$\text{FPR} = \frac{FP}{FP + TN}$$

A curva é gerada ao variar continuamente o limiar de decisão de 1 (mais restritivo) a 0 (mais permissivo). Para cada limiar, um novo par (FPR, TPR) é calculado e plotado, formando a curva (FAWCETT, 2006).

- Linha diagonal ($y = x$): representa um classificador aleatório, sem poder preditivo. Um modelo útil deve ter a curva acima dessa linha (FAWCETT, 2006).
- Canto superior esquerdo $(0, 1)$: representa o classificador perfeito, com TPR = 1 e FPR = 0 (FAWCETT, 2006).
- Posição na curva: pontos no canto inferior esquerdo indicam comportamento conservador (baixo FPR e também baixo TPR), enquanto pontos no canto superior direito indicam comportamento liberal (alto TPR e também alto FPR). O gráfico torna explícito o *trade-off* entre o benefício de detectar positivos e o custo de alarmes falsos (FAWCETT, 2006).

2.2.4.8 Área Sob a Curva (AUC)

A Área Sob a Curva (AUC) é uma métrica escalar que resume a curva ROC num único número, representando a área geométrica sob a curva. O seu valor varia entre 0.5 (para um classificador aleatório) e 1.0 (para um classificador perfeito) (FAWCETT, 2006).

A AUC possui uma interpretação estatística particularmente intuitiva e poderosa: é a probabilidade de que o modelo atribua uma pontuação de previsão mais alta a uma instância positiva (uma vitória real) escolhida aleatoriamente do que a uma instância negativa (uma derrota real) escolhida aleatoriamente.

Esta interpretação revela uma propriedade fundamental da AUC: ela mede a qualidade do "ranking" interno do modelo, independentemente dos valores absolutos das probabilidades. Um modelo que atribui uma probabilidade de 0.1 a todas as derrotas e 0.2 a todas as vitórias terá uma AUC perfeita de 1.0, pois consegue separar perfeitamente as classes, embora as probabilidades em si não sejam realistas. A AUC mede, portanto, a capacidade de discriminação ou separação do modelo. Um valor de AUC elevado indica que o modelo aprendeu padrões que distinguem fundamentalmente as vitórias das derrotas. É uma medida da qualidade do "motor" preditivo do modelo, independente de como as suas saídas são calibradas ou de qual limiar de decisão é escolhido, tornando-a uma das métricas mais importantes para comparar o poder preditivo fundamental de diferentes modelos (FAWCETT, 2006).

2.2.4.9 Métricas de Calibração

A calibração avalia se as probabilidades previstas por um modelo correspondem às frequências reais dos eventos (GUO et al., 2017). Um modelo bem calibrado é aquele cujas previsões podem ser interpretadas como probabilidades confiáveis: para todos os casos aos quais o modelo atribui, por exemplo, 80% de probabilidade de ocorrência, espera-se que o evento realmente ocorra em cerca de 80% das vezes. É importante ressaltar que um modelo pode apresentar excelente discriminação isto é, elevada capacidade de distinguir entre classes, refletida por uma alta área sob a curva ROC (AUC) e ainda assim ser mal calibrado (WANG, 2025).

A má calibração é um problema recorrente em redes neurais modernas e em outros modelos complexos, que tendem a produzir previsões excessivamente confiantes (*overconfident*) em relação à probabilidade real dos eventos (GUO et al., 2017).

Para uma avaliação quantitativa, o Brier Score é uma das métricas mais utilizadas (RENOOIJ, 2004). Proposto originalmente para a verificação de previsões meteorológicas, ele mede o erro quadrático médio entre as probabilidades previstas (p_i) e os resultados reais (o_i, codificados como 1 para ocorrência e 0 para não ocorrência). Para previsões binárias, a fórmula é:

$$\text{Brier Score} = \frac{1}{N}\sum_{i=1}^{N}(p_i - o_i)^2$$

O Brier Score é uma proper scoring rule, o que significa que o valor mínimo esperado da métrica é alcançado apenas quando o modelo prevê as verdadeiras probabilidades. Seus valores variam de 0 a 1, onde um score mais baixo indica melhor calibração e acurácia das probabilidades. Ele combina, em uma única medida, tanto a calibração quanto a resolução

(a capacidade do modelo de emitir previsões "afiadas", ou seja, próximas de 0 ou 1), tornando-se uma medida abrangente da qualidade da previsão probabilística (RENOOIJ, 2004).

2.3 SHAP (Shapley Additive exPlanations)

Conforme modelos de aprendizado de máquina tornaram-se mais complexos e opacos (como *ensembles* de árvores ou redes neurais profundas), surgiu a necessidade de técnicas de interpretabilidade que permitam entender as predições produzidas. Dentre essas técnicas, o método SHAP (*Shapley Additive exPlanations*) destacou-se pela fundamentação teórica e pela consistência das explicações geradas (LUNDBERG; LEE, 2017). O SHAP, proposto por Scott Lundberg e Su-In Lee, baseia-se no conceito de valor de Shapley da Teoria dos Jogos cooperativos. Em um jogo cooperativo, o valor de Shapley define como distribuir de forma justa a recompensa total obtida por uma coalizão de jogadores, atribuindo a cada jogador uma parcela da recompensa proporcional à sua contribuição marginal média. Analogamente, no contexto de modelos preditivos, cada "jogador" é uma *feature* (variável de entrada) e a "recompensa" é a diferença entre a predição do modelo para uma instância e a predição média do modelo (ou de um baseline) (LUNDBERG; LEE, 2017). O SHAP então calcula, para uma dada instância, quanto cada feature contribuiu positiva ou negativamente para que o modelo produzisse aquele resultado em comparação a uma predição base.

Matematicamente, o SHAP pertence à classe dos métodos aditivos de explicação, cuja predição é representada como:

$$\hat{y} = \phi_0 + \sum_{i=1}^{M} \phi_i,$$

onde ϕ_i é o valor SHAP da feature i (LUNDBERG; LEE, 2017). Esses valores ϕ_i são calculados considerando todas as coalizões possíveis de features sem a presença de i e avaliando o impacto médio da adição de i à predição (tomando a média sobre todas as ordens de inserção). Embora o cálculo exato seja computacionalmente custoso (exponencial no número de features), Scott Lundberg e Su-In Lee propuseram algoritmos de aproximação eficientes, especialmente para modelos de árvores de decisão, tornando viável a utilização do SHAP na prática.

As principais propriedades do SHAP incluem: (i) consistência, ou seja, se um modelo for alterado de forma que a contribuição marginal de uma feature aumente (mantidas as demais constantes), o valor SHAP dessa feature não diminui; (ii) localidade exata, significando que a soma dos valores SHAP de todas as features (mais o valor base ϕ_0) é igual à diferença entre a predição do modelo para aquela instância e a média global (LUNDBERG; LEE, 2017). Essas propriedades garantem que as explicações sejam sensíveis e coerentes com o comportamento do modelo.

Com o SHAP, pode-se, por exemplo, explicar por que um determinado jogo foi previsto como vitória do Time A: os valores SHAP poderiam revelar que a excelente média de aproveitamento de arremessos do Time A e um número superior de rebotes previstos contribuíram positivamente para a predição, enquanto o fato de o adversário jogar em casa contribuiu negativamente mas não o suficiente para reverter a tendência. Essa granularidade de explicação é valiosa, pois agrega confiabilidade ao modelo e permite insights acionáveis, por exemplo, destacar a importância de certos fundamentos do jogo.

Estudos recentes já começaram a aplicar o SHAP na área de análise esportiva: Zeng et al. (2023), por exemplo, utilizaram SHAP para interpretar quais estatísticas de desempenho tinham maior peso nas vitórias de equipes da liga chinesa de basquete, demonstrando o potencial da ferramenta em extrair conhecimento mesmo de modelos complexos. Diante disso, o uso do SHAP neste projeto alinha-se com a busca por um modelo não apenas preciso, mas também transparente e explicável.

Figura 4 – Framework do algoritmo SHAP (2025).

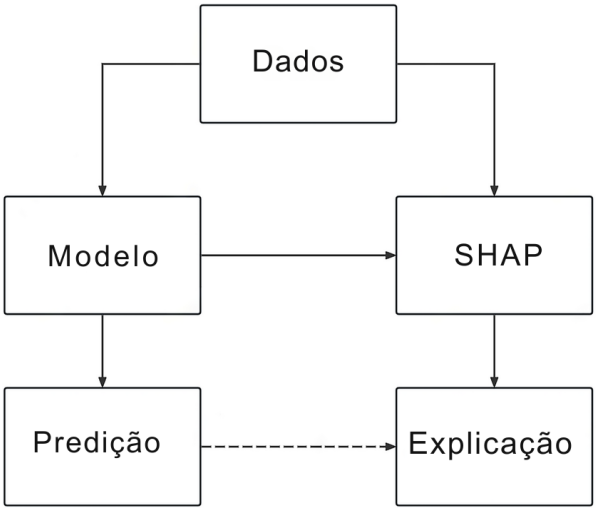

Fonte: Adaptado de <https://www.researchgate.net/figure/Framework-of-the-SHAP-algorithm_fig1_390988996>

2.4 OTW: Optimal Time Window

A *Optimal Time Window* (OTW) é uma abordagem proposta para otimizar a seleção de dados históricos utilizados no treinamento de modelos preditivos esportivos, determinando qual intervalo temporal de partidas passadas deve ser considerado para melhor refletir o estado atual das equipes (HORVAT, 2020). A ideia central é que nem todos os jogos passados possuem a mesma relevância preditiva, jogos muito antigos podem não refletir mais a força atual de um time (devido a mudanças de elenco, técnico, estratégias), enquanto considerar apenas jogos muito recentes pode resultar em pouco volume de dados e maior volatilidade estatística (HORVAT, 2020). Assim, haveria uma "janela de tempo ótima" por exemplo, os N jogos ou X temporadas mais recentes que oferece o melhor balanço entre frescor dos dados e tamanho de amostra para treinar o modelo.

Horvat (2020) introduziu um método sistemático para identificar essa janela temporal ideal, integrado a um modelo de previsão de resultados de jogos de basquete. Em sua tese de doutorado, Horvat propôs um modelo adaptativo baseado em um índice de eficiência das equipes, no qual a OTW é definida de maneira a maximizar a correlação entre o índice de eficiência calculado e os resultados dos jogos (HORVAT, 2020). Em termos práticos, isso significa determinar quantos jogos ou até que ponto da temporada passada (ou temporadas passadas) devem ser utilizados no cálculo das variáveis preditivas para que estas tenham maior poder explicativo sobre o próximo jogo. Por exemplo, pode-se descobrir que usar estatísticas acumuladas das últimas 20 partidas de cada equipe produz

um modelo preditivo mais acurado do que usar toda a temporada anterior ou apenas as últimas cinco partidas.

No trabalho recente de Horvat et al. (2023), o conceito de OTW foi incorporado em experimentos de previsão de jogos da NBA, e os resultados corroboram em parte sua utilidade. Ao testar diferentes comprimentos de janela, os autores observaram que a escolha de uma janela de tempo ótima trouxe um pequeno ganho de acurácia em relação ao uso irrestrito de todos os dados históricos disponíveis (HORVAT et al., 2023). Em particular, o melhor resultado (acurácia em torno de 78 %) foi obtido treinando o modelo com dados de apenas uma temporada anterior (como janela de treino) e testando na temporada seguinte, sugerindo que dados de mais de duas temporadas atrás adicionavam mais ruído do que sinal (HORVAT et al., 2023). Esse achado está alinhado com a intuição de que a NBA está em constante evolução jogadores transferem-se, novos talentos surgem, times mudam de estratégia e, portanto, limitar a abrangência temporal do treinamento pode ajudar o modelo a se concentrar em padrões mais pertinentes ao momento atual.

Cabe ressaltar, que determinar a OTW ideal não é trivial e demanda testes experimentais para sua definição adequada. Horvat et al. (2023) reconhecem que sua implementação da OTW trouxe ganhos modestos e sugerem que há espaço para aprimorar o cálculo dessa janela (HORVAT et al., 2023). Questões em aberto incluem como adaptar dinamicamente a janela à medida que novas partidas ocorrem (por exemplo, dar mais peso aos jogos mais recentes dentro da janela) e como proceder quando existem poucos confrontos diretos recentes entre dois times (caso em que poderia ser relevante ampliar a janela especificamente para incluir mais partidas entre eles) (HORVAT et al., 2023). Apesar desses detalhes em evolução, o conceito de OTW traz para a modelagem preditiva uma preocupação importante: a de que a pertinência dos dados de treino não é uniforme ao longo do tempo, e que estratégias que priorizam informações mais atualizadas tendem a melhorar a capacidade de previsão em domínios dinâmicos como o esporte.

No contexto deste projeto, a utilização de uma OTW visa garantir que o modelo de previsão esteja sempre treinado com dados suficientemente recentes para refletir a performance atual das equipes, sem entretanto descartar tantos dados a ponto de perder significância estatística. Com base na literatura (HORVAT, 2020; HORVAT et al., 2023), espera-se que essa abordagem contribua para um modelo mais adaptado às condições vigentes em cada período da liga, complementando as demais técnicas empregadas.

Figura 5 – Ilustração das Janelas Temporais Ótimas (OTWs, em verde) e sua relação com os intervalos de tempo dos conjuntos de dados de treinamento (em azul claro), para N jogos do time observado.

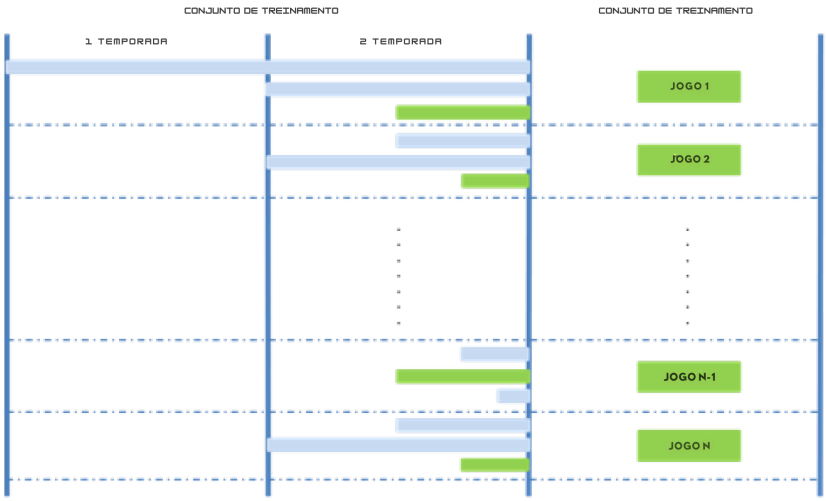

Fonte: Adaptado (HORVAT et al., 2023)

2.5 Trabalhos Relacionados

Uma linha de pesquisa envolve *ensembles* heterogêneos, combinando diferentes tipos de modelos preditivos. ALBERT et al. integraram algoritmos de *boosting* com redes neurais para prever a seleção de jogadores no All-Star Game da NBA, obtendo melhora de acurácia nas predições e acrescentando certa interpretabilidade por meio da análise das importâncias de atributos (ALBERT et al., 2021).

Outra vertente destacada na literatura diz respeito ao horizonte temporal dos dados utilizados para treino de modelos. HORVAT et al. propuseram restringir o conjunto de treinamento a uma "janela" temporal dinâmica, de modo a refletir apenas a forma recente das equipes e atenuar a influência de dados históricos possivelmente defasados (HORVAT et al., 2023). Esse conceito de Janela Temporal Ótima (OTW) resultou em ganhos modestos de desempenho, por exemplo, ao considerar somente os jogos da temporada imediatamente anterior para treinar um modelo preditivo, obteve-se acurácia em torno de 78% superior ao treinamento com múltiplas temporadas, que pode introduzir ruído (HORVAT et al., 2023).

Também vêm ganhando espaço abordagens que integram predição e explicação. Métodos de interpretabilidade como o SHAP (LUNDBERG; LEE, 2017) têm sido aplicados para tornar modelos de *gradient boosting* menos opacos, embora seu uso específico em predição de partidas de basquete ainda seja incipiente. OUYANG et al., por exemplo, combinaram um modelo XGBoost com a análise SHAP para identificar os fatores mais determinantes nos resultados de jogos da NBA, e relataram que métricas como aproveitamento de arremessos de quadra, rebotes defensivos e número de desperdícios de posse estão consistentemente entre as mais influentes para definir o vencedor de uma partida (OUYANG et al., 2024).

Contudo, uma crítica recorrente a muitos modelos preditivos é sua dependência excessiva de estatísticas agregadas por equipe, que podem mascarar a dinâmica interna

do elenco. Como apontam (WANG; JI; DAI, 2025), modelos baseados apenas na força histórica da equipe possuem poder explicativo limitado, e a inclusão de dados sobre lesões melhora significativamente a acurácia. Essa vulnerabilidade é reforçada por (WU, 2020), que descreve a lesão de um jogador-chave como uma "influência vital" capaz de reverter o resultado esperado mesmo entre equipes com grande disparidade de força. Além das lesões, modelos que utilizam dados agregados de time "não conseguem levar em conta rapidamente as mudanças no elenco", como trocas e contratações, o que representa uma falha estrutural, especialmente no início de novas temporadas.

Por fim, estudos recentes sugerem que a combinação de métricas individuais de jogadores com estatísticas coletivas de equipes eleva o poder preditivo dos modelos. O modelo híbrido *MambaNet*, apresentado por KHANMOHAMMADI et al., exemplifica essa estratégia ao processar simultaneamente séries históricas de desempenho de times e de jogadores para estimar probabilidades de vitória e classificação aos playoffs (KHANMOHAMMADI et al., 2024). Essa incorporação de dados em nível de jogador permitiu ao MambaNet superar abordagens baseadas apenas em estatísticas agregadas por equipe (KHANMOHAMMADI et al., 2024).

3 Desenvolvimento

Este capítulo apresenta a estratégia metodológica adotada para construir e avaliar o modelo de previsão de resultados da NBA. A Figura 6 resume, em um diagrama UML de alto nível, o fluxo completo da solução desde a coleta de dados até a utilização do modelo em um cenário de uso. Em seguida, o texto detalha a fonte e o processo de coleta dos dados, os procedimentos para evitar vazamento temporal, a estrutura dos conjuntos em nível de jogo e de jogador e a etapa de engenharia de atributos, incluindo a Janela Temporal Ótima e a ponderação exponencial. Depois são descritas a seleção e a configuração do CatBoost, a validação temporal com embargo, o tratamento das variáveis categóricas e a análise de ablação. Por fim, apresentam-se os procedimentos de explicabilidade com SHAP, a análise de acurácia por equipe e ao longo do tempo e o fluxo de aplicação do modelo em um cenário de uso.

Figura 6 – Visão geral da metodologia em diagrama UML

Diagrama UML de alto nível que sintetiza a metodologia adotada.

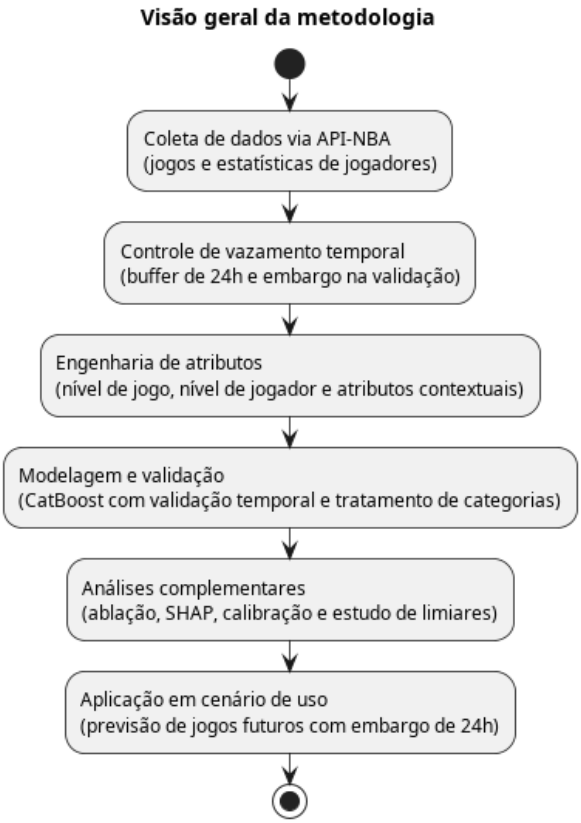

Fonte: Elaboração própria (2025)

3.1 Fonte e Coleta de Dados

Os dados primários foram extraídos por meio de consultas à *API-NBA*, uma interface de programação de aplicações (API) comercialmente disponível. A escolha desta fonte justifica-se pela sua capacidade de fornecer dados estruturados, consistentes e de alta granularidade, atendendo às necessidades específicas do modelo em dois níveis: dados em nível de jogo e dados em nível de jogador. O primeiro consiste em um conjunto contendo o registro de cada partida, detalhando as equipes mandante e visitante, a data do confronto e os placares finais. O segundo consiste em um conjunto granular que contém as estatísticas individuais (*box score*) de cada atleta para cada partida disputada.

O escopo temporal dos dados abrange as temporadas regulares da *National Basketball Association* a partir de 2021–2022 até a data de execução do processo de coleta (junho de 2025), garantindo uma base de dados confiável para a análise.

3.2 Tratamento de Vazamento Temporal

Uma preocupação central na modelagem de séries temporais é o vazamento de dados (*data leakage*), onde o modelo, durante o treinamento ou validação, inadvertidamente tem acesso a informações que não estariam disponíveis no momento da previsão real. No contexto de previsão de jogos, usar dados do próprio dia do jogo ou de dias futuros para calcular atributos preditivos comprometeria a validade da avaliação do modelo.

Para mitigar esse risco e garantir a causalidade estrita, foram implementadas duas salvaguardas principais:

- Buffer Temporal na Engenharia de Atributos: Foi utilizada uma função que aplica um *buffer* temporal, de 1 dia (24 horas). Ao calcular os atributos para um jogo ocorrendo na data T, essa função assegura que apenas dados de jogos ocorridos estritamente antes de T (ou seja, até $T - 1$) sejam consultados. Isso simula realisticamente a informação disponível no momento da previsão, como ilustrado na Figura 7.

- Embargo na Validação Cruzada: Durante a validação cruzada temporal, um período de "embargo" de 1 dia foi introduzido entre o final do conjunto de treinamento e o início do conjunto de validação. Isso evita que a performance na validação seja influenciada por dados muito próximos (ou do mesmo dia) aos últimos dados usados no treino, como ilustrado na Figura 8.

Essas medidas asseguram que a avaliação do modelo reflita de forma mais fidedigna seu desempenho esperado em um cenário de previsão operacional.

Figura 7 – Buffer temporal na engenharia de atributos

Representação do procedimento de buffer temporal para evitar vazamento temporal. A partir do jogo-alvo na data T, define-se a data segura em $T - 24$ h. Filtram-se nas bases de partidas e de estatísticas de jogadores apenas registros anteriores a essa data. Os atributos do jogo-alvo são construídos somente com informações disponíveis até $T - 1$ dia. Nenhum dado de T ou do futuro é utilizado.

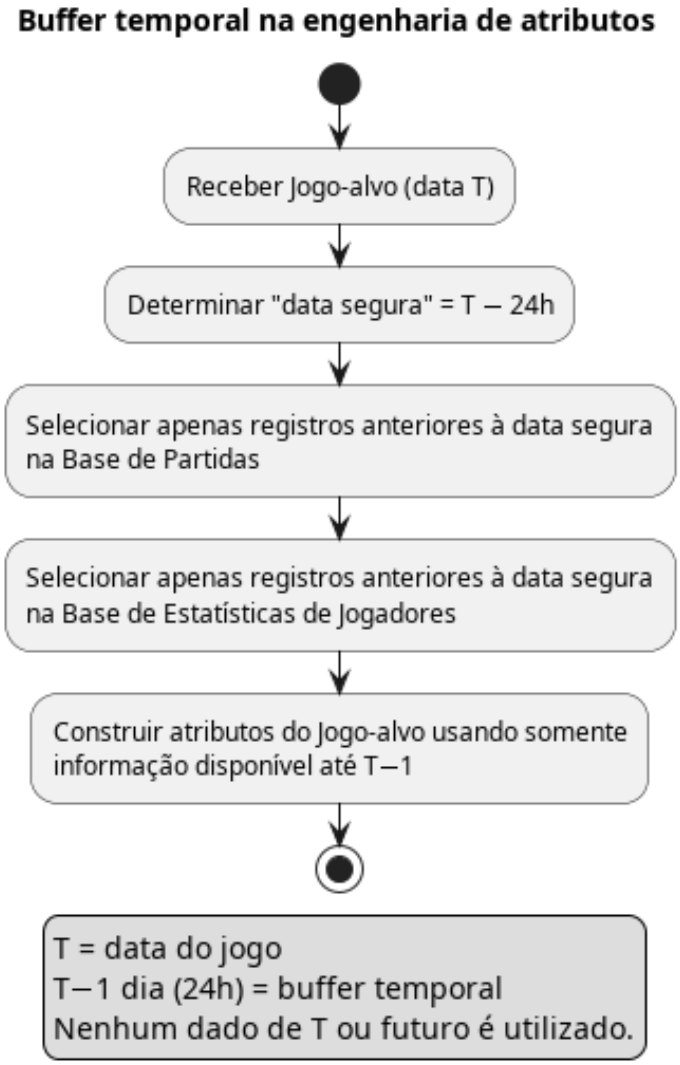

Fonte: Elaboração própria (2025)

Figura 8 – Embargo na validação cruzada temporal

Esquema do embargo para evitar vazamento temporal. Em cada dobra define-se a janela de teste $[T \,..\, T{+}k]$ e aplica-se um embargo de 24 horas imediatamente anterior a T. O treino usa apenas registros com data $< T - 24$ h. A validação usa registros em $[T \,..\, T{+}k]$. O processo se repete para todas as dobras.

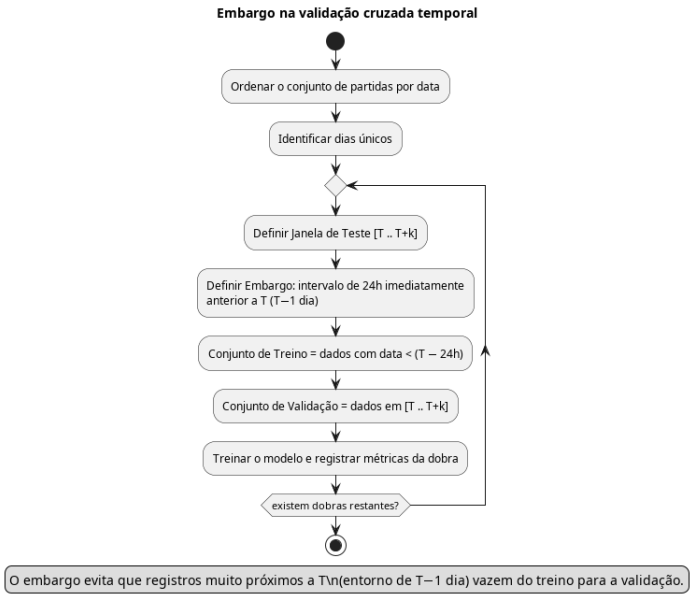

Fonte: Elaboração própria (2025)

3.3 Dataset de Jogos

O primeiro conjunto de dados contém informações agregadas para cada partida disputada no período analisado. Cada linha representa um único jogo e inclui as seguintes colunas:

- *game_id*: Identificador numérico único para cada partida. Serve como chave primária para relacionar com os dados de jogadores.
- *date*: Data e hora de início da partida, em formato UTC. Utilizada para ordenação cronológica e cálculos temporais.
- *home_team_code* / *away_team_code*: Códigos de três letras identificando as equipes mandante e visitante (por exemplo,“LAL” para Los Angeles Lakers).
- *home_team_name* / *away_team_name*: Nomes completos das equipes mandante e visitante.
- *home_score* / *away_score*: Pontuação final das equipes mandante e visitante.
- *arena*: Nome da arena onde o jogo foi disputado.
- *city*: Cidade onde a arena está localizada.

- *season*: Ano da temporada correspondente (por exemplo, 2021 para a temporada 2021-2022).
- *status*: Status final do jogo (por exemplo, "Finished").

Este *dataset* fornece o contexto geral de cada confronto, incluindo o resultado final, que é fundamental para a definição da variável alvo (*home_win*).

3.4 Dataset de Estatísticas de Jogadores

O segundo conjunto de dados oferece uma visão granular do desempenho individual dos atletas em cada partida. Cada linha representa as estatísticas de um jogador específico em um determinado jogo, vinculada ao jogo correspondente através do *game_id*. As colunas mais relevantes incluem:

- *game_id*: Chave estrangeira que referencia o jogo no *dataset* de partidas.
- *date*: Data e hora da partida.
- *team_code*: Código da equipe pela qual o jogador atuou na partida.
- *player_id*: Identificador numérico único para cada jogador.
- *player_name*: Nome completo do jogador.
- *pos*: Posição primária do jogador (por exemplo, "G" para *Guard*, "F" para *Forward*, "C" para *Center*).
- *min*: Minutos jogados na partida (formato texto, por exemplo, "30:15" ou vazio).
- *points*: Total de pontos marcados.
- *fgm*, *fga*, *fgp*: Cestas de campo convertidas (*made*), tentadas (*attempted*) e percentual de acerto (*percentage*).
- *ftm*, *fta*, *ftp*: Lances livres convertidos, tentados e percentual.
- *tpm*, *tpa*, *tpp*: Arremessos de três pontos convertidos, tentados e percentual.
- *offReb*, *defReb*, *totReb*: Rebotes ofensivos, defensivos e totais.
- *assists*: Número de assistências.
- *steals*: Número de roubos de bola.
- *blocks*: Número de tocos.
- *turnovers*: Número de perdas de bola.
- *pFouls*: Número de faltas pessoais.
- *plusMinus*: Saldo de pontos da equipe enquanto o jogador esteve em quadra.

Este *dataset* é a fonte primária para a engenharia de atributos relacionados ao desempenho recente dos jogadores e das equipes, permitindo calcular médias ponderadas, consistência e outras métricas que alimentam o modelo.

Combinados, esses dois datasets fornecem uma base detalhada para a modelagem. O *dataset* de jogos estabelece o resultado e o contexto de cada evento, enquanto o *dataset* de jogadores permite a análise do desempenho que levou a esse resultado. A estrutura relacional, unida pelo id da partida, possibilita a criação de atributos que consideram tanto o histórico das equipes quanto a performance individual recente dos atletas.

3.5 Engenharia de Features

A etapa de engenharia de atributos (*feature engineering*) é importante para transformar os dados brutos coletados e tratados em variáveis preditivas informativas que possam ser efetivamente utilizadas pelo modelo. O objetivo principal foi criar atributos que capturassem não apenas o desempenho médio histórico das equipes e jogadores, mas também a dinâmica temporal, a forma recente, a consistência, o contexto do calendário e as interações específicas de cada confronto.

3.5.1 Atributos Baseados no Histórico de Jogos

Para refletir o desempenho recente das equipes de forma mais precisa do que médias móveis simples, foram implementadas duas técnicas principais: a Janela Temporal Ótima (OTW) e a Ponderação Exponencial Dinâmica.

3.5.1.1 Janela Temporal Ótima (OTW)

A OTW determina dinamicamente o número de jogos passados (N) a serem considerados para cada equipe antes de uma partida específica. A janela base é de 10 jogos, com limites mínimo de 5 e máximo de 20. Esse tamanho é ajustado heuristicamente com base em:

Para cada confronto, adota-se como janela efetiva a menor OTW entre a equipe mandante e a visitante. Essa escolha garante que ambas sejam avaliadas com históricos recentes de tamanho comparável, evitando distorções por janelas desbalanceadas.

Figura 9 – Regra de cálculo da janela OTW por time

Parâmetros: MIN = 5, BASE = 10, MAX = 20 jogos.
Fase da temporada: início (< 30 dias) usa janela menor; final (> 150 dias) levemente maior.
Volatilidade (CV): coeficiente de variação do *net rating* nos últimos 10 jogos; CV $> 1{,}5$ reduz a janela; CV $< 0{,}5$ aumenta.
Mudança de rotação: sobreposição $< 70\%$ entre os 8 jogadores com mais minutos nas últimas 2 semanas implica janela mínima.
Densidade de jogos (7 dias): ≥ 4 jogos reduz a janela; ≤ 1 jogo aumenta.
Mudança de performance: $|\overline{NR}_{\text{recente}} - \overline{NR}_{\text{anterior}}| > 10$ pontos reduz a janela.
Saída: *window* inteiro após ajustes.

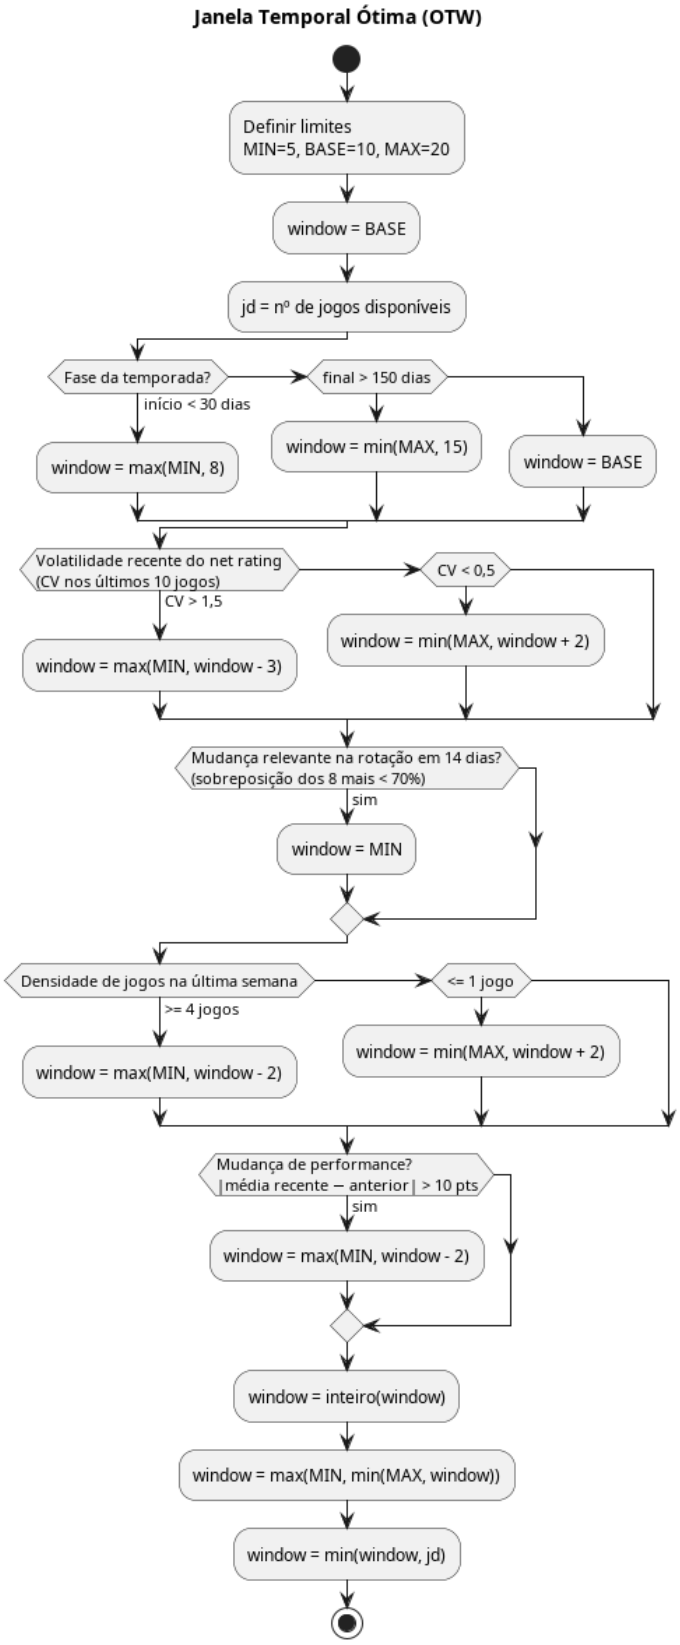

Fonte: Elaboração própria (2025)

3.5.1.2 Ponderação Exponencial Dinâmica

Dentro da OTW selecionada, nem todos os jogos têm a mesma relevância: partidas mais recentes e equipes mais estáveis tendem a ser mais preditivas. Adota-se um esquema de ponderação por decaimento exponencial, em que o peso w_i de um jogo i, ocorrido d_i dias antes da data de referência, é dado por

$$w_i \propto \exp(-\lambda d_i).$$

A taxa de decaimento λ é adaptativa e modulada pela volatilidade recente (σ) do *net rating* da equipe:

$$\lambda = 0{,}05\left(1 + \frac{\sigma}{10}\right).$$

Times mais instáveis (maior σ) recebem um λ maior, de modo que os jogos antigos perdem influência mais rapidamente. Os pesos são normalizados para somar 1. Todas as métricas baseadas no histórico (por exemplo, médias e desvios padrão) são calculadas de forma ponderada por esses pesos dinâmicos.

3.5.1.3 Atributos Derivados do Histórico

Com a OTW e a ponderação dinâmica, foram calculados, para mandante e visitante, os seguintes atributos:

- desempenho geral: taxa de vitórias, média de pontos marcados, média de pontos sofridos e saldo de pontos (*net rating*);
- sequências recentes: comprimento da sequência atual de vitórias ou derrotas consecutivas;
- *momentum* de curto prazo: saldo de vitórias nos três jogos mais recentes;
- volatilidade ofensiva: desvio padrão ponderado dos pontos marcados na janela;
- eficácia casa/fora: nos últimos 15 jogos em casa (mandante) ou fora (visitante), taxa de vitória e médias de pontos marcados e sofridos.

3.6 Seleção e Configuração do Modelo

3.6.1 Escolha do algoritmo

Utilizou-se o CatBoost, um método de *gradient boosting* em árvores, adequado para dados tabulares com muitos atributos categóricos (como equipes, mês e fase da temporada), sem exigir codificação manual extensa. Seu mecanismo de treinamento evita vazamento do alvo durante a construção das estatísticas categóricas, e o uso de árvores simétricas favorece previsões rápidas e controle de sobreajuste.

3.6.2 Otimização de hiperparâmetros

A calibração dos hiperparâmetros foi feita por otimização Bayesiana (via Optuna), sempre avaliando cada proposta com a mesma validação temporal já descrita. O espaço de busca incluiu número de iterações, profundidade das árvores, taxa de aprendizado, regularização L2 e amostragem de linhas e colunas.

3.6.3 Configuração final

O modelo final foi treinado no bloco de treino (80% mais antigo) com os hiperparâmetros selecionados:

- iterações: 764 (com parada antecipada);
- profundidade das árvores: 5;
- taxa de aprendizado: $\approx 0{,}027$;
- regularização L2: $\approx 8{,}17$;
- amostragem de linhas: $\approx 0{,}96$;
- amostragem de colunas: $\approx 0{,}998$;
- função de perda: *logloss*;
- métrica de avaliação: AUC.

As variáveis categóricas (equipes, mês, dia da semana, fim de semana e fase da temporada) foram informadas explicitamente para tratamento nativo.

3.7 Atributos Baseados em Estatísticas de Jogadores

Para capturar o impacto do desempenho individual e da composição do elenco, adotou-se um procedimento que, antes de cada jogo, analisa as estatísticas dos atletas em um período recente (30 dias por padrão, ajustado quando há poucos dados). Assim como no histórico de jogos, aplica-se ponderação por recência via decaimento exponencial, de modo que partidas mais novas pesem mais do que antigas.

3.7.1 Agregação Ponderada

As estatísticas de cada jogador (pontos, rebotes, assistências, *plus-minus*, percentuais de arremesso, entre outras) são resumidas por médias ponderadas com base na recência dos jogos daquele atleta. Em seguida, essas médias por jogador são combinadas no nível do time utilizando um peso adicional proporcional à importância do atleta na rotação, aproximada pelo produto entre os minutos médios em quadra e o número de partidas disputadas no período recente. Com isso, jogadores mais utilizados influenciam mais os atributos agregados da equipe.

3.7.2 Atributos Gerados dos Jogadores

A partir dessa consolidação, foram construídos, para cada equipe:

- médias agregadas das estatísticas básicas de *box score* no nível do time (pontos, rebotes, assistências, *plus-minus*, acurácias de arremesso, etc.);
- indicadores dos cinco atletas com maior média de minutos, reportando suas médias de pontos, rebotes, assistências e *plus-minus* (retrato do núcleo da rotação);
- medidas de consistência e profundidade do elenco: consistência ofensiva obtida por $1 - \mathrm{CV}$ das médias de pontos entre jogadores, e contagem de atletas com média ponderada superior a 8 pontos (profundidade);
- escores heurísticos de ataque e defesa do elenco: o ofensivo combina produção de pontos, eficiência de arremessos e criação de jogadas; o defensivo combina roubos e tocos, com penalização para perdas de bola.

3.8 Atributos Contextuais e Derivados

Além das métricas de desempenho baseadas no histórico, outros atributos foram criados para fornecer contexto adicional:

- Descanso e agenda: dias desde a última partida, indicador de jogos em dias consecutivos (*back-to-back*) e quantidade de partidas nos sete dias anteriores.
- Confronto direto (H2H): taxa de vitórias do mandante nos cinco encontros mais recentes contra o visitante, desconsiderando partidas da mesma semana para evitar dependências imediatas.
- Temporais: mês, dia da semana, marcador de fim de semana, dias decorridos desde o início da temporada e fase da temporada (início, meio, fim).
- Diferenças mandante–visitante: para a maior parte das métricas de ambos os lados (taxa de vitória, saldo de pontos, descanso, momento, sequência, médias de jogadores), calcula-se a diferença direta (mandante menos visitante). Exemplos: vantagem de taxa de vitória, vantagem de saldo de pontos, vantagem de descanso e diferença nas médias agregadas de jogadores. Essas diferenças capturam a vantagem relativa em múltiplas dimensões.
- Matchups ataque–defesa: comparação direta entre a produção ofensiva de um time e a solidez defensiva do adversário, como a diferença entre a média de pontos marcados por uma equipe e a média de pontos sofridos pela oponente.

Esse conjunto de atributos combinando histórico ponderado, estatísticas de jogadores, contexto de calendário e comparações diretas forma a base de entrada do modelo apresentado no capítulo seguinte.

3.9 Validação Temporal com Embargo

3.9.1 Justificativa da validação temporal

Dados esportivos são sequenciais: o futuro não pode "vazar" para o passado. Métodos aleatórios de validação cruzada superestimariam o desempenho por misturar jogos posteriores aos que estão sendo previstos. Para refletir o uso real do sistema, adotou-se validação estritamente cronológica.

Figura 10 – Pipeline de validação temporal: etapas e laço de dobras

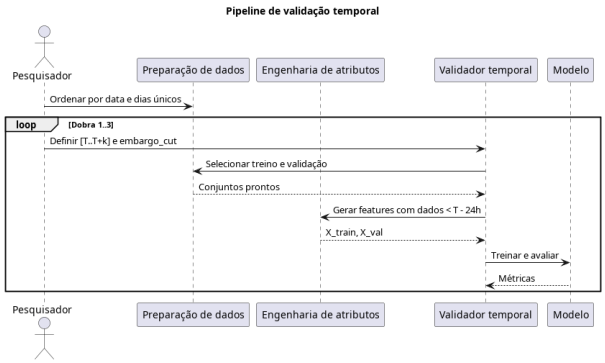

Fonte: elaboração própria (2025).

3.9.2 Estratégia implementada

Aplicou-se o esquema *walk-forward* com três dobras. Entre o fim de cada conjunto de treino e o início do conjunto de validação impôs-se um embargo de um dia, eliminando sobreposições. Cada dobra respeitou tamanhos mínimos de 50 jogos para treino e 10 para teste, garantindo consistência estatística. A figura 11 correspondente, a composição dessas dobras.

Figura 11 – Validação temporal com embargo em esquema *walk-forward*

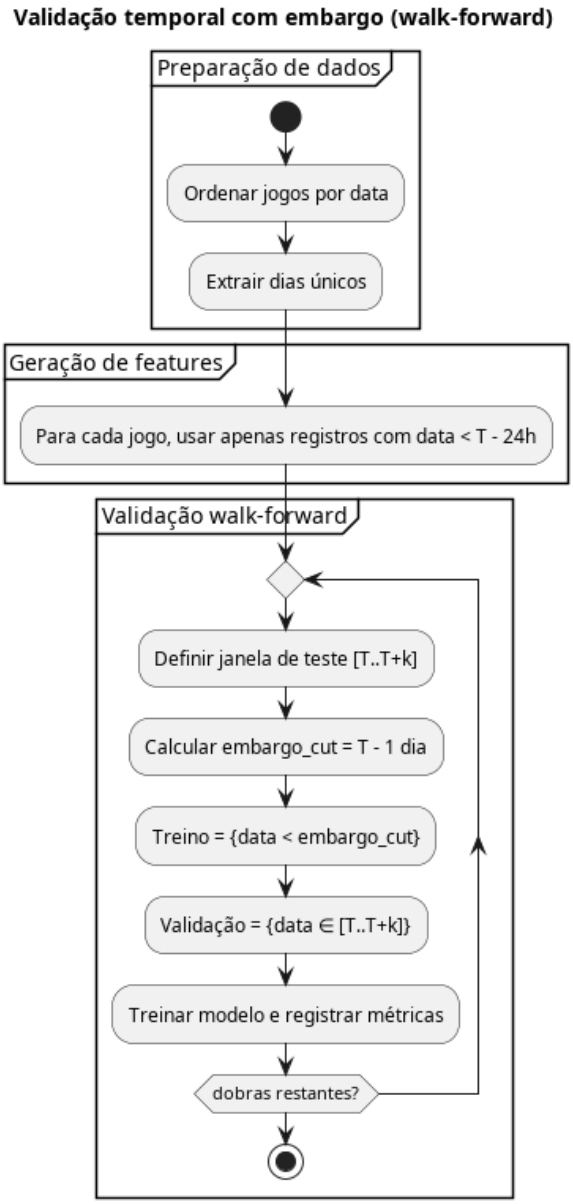

Elaboração própria (2025)

3.10 Tratamento de Variáveis Categóricas

3.10.1 Codificação ordenada

As categorias foram transformadas em valores numéricos por estatísticas do alvo calculadas de forma ordenada, isto é, cada exemplo vê apenas informação de exemplos "anteriores" em uma permutação dos dados. Esse procedimento reduz vazamento e estabiliza categorias raras por meio de um *prior*. Em termos gerais, o valor numérico atribuído a uma categoria combina a média histórica do alvo para aquela categoria (considerando apenas observações anteriores) e uma ancoragem na média global, regularizada para não supervalorizar categorias com poucos exemplos.

3.10.2 Quais categorias foram usadas

A Tabela 2 lista os atributos categóricos usados pelo modelo.

Tabela 2 – Variáveis categóricas utilizadas.

Categoria	Valores únicos (aprox.)	Tipo
Time mandante	30	Identificador
Time visitante	30	Identificador
Mês	12	Cíclico/ordinal
Dia da semana	7	Cíclico/ordinal
Fim de semana	2	Binário
Fase da temporada (início/meio/fim)	3	Nominal

3.11 Análise de Ablação

Para quantificar a contribuição marginal de cada grupo de variáveis na performance preditiva, adotou-se uma estratégia de análise incremental (ablação aditiva). Ao contrário da abordagem tradicional de remoção de componentes, este método constrói a complexidade do modelo passo a passo, permitindo isolar o ganho de desempenho associado a cada nova dimensão de dados introduzida.

Essa abordagem visa testar a hipótese de que a inclusão de dados granulares de jogadores oferece um ganho de discriminação superior ao obtido apenas com o refinamento de métricas de equipe.

3.12 Explicabilidade das Predições

Para entender como o modelo chega às previsões, aplicou-se o método SHAP no conjunto de teste temporal. Foram calculados valores contribucionais por jogo e consolidações por grupos de variáveis. As visualizações permitem observar, caso a caso, quais fatores empurraram a probabilidade para cima ou para baixo.

Essa leitura oferece dois ganhos. Aumenta a transparência do sistema, pois torna explícitas as razões das previsões. E orienta aprimoramentos, indicando quais variáveis acrescentam valor e quais podem ser simplificadas.

3.13 Acurácia por Equipe e ao Longo do Tempo

A avaliação também foi detalhada por equipe e por período. A acurácia por equipe revelou variação associada à estabilidade do elenco e à constância tática. Conjuntos com menos mudanças apresentaram desempenho mais alto. Séries mensais mostraram oscilações compatíveis com fases de temporada, sequência de jogos em curto intervalo e ausências de atletas. Essa análise contextualiza limites e fortalezas do modelo e aponta frentes específicas de melhoria.

3.14 Aplicação em Cenário de Uso

Para demonstrar a aplicação prática, executou-se um procedimento de previsão para um jogo futuro com dados verossímeis disponíveis antes da partida. O fluxo seguiu as mesmas salvaguardas temporais adotadas no treinamento. Primeiro, reuniram-se as informações recentes de equipes e jogadores até a véspera do confronto. Em seguida, calcularam-se os atributos exatamente no mesmo formato utilizado pelo modelo. Por fim, obteve-se a probabilidade de vitória e a classe prevista.

Essa demonstração ilustra como o método pode ser operado em ambiente real. O mesmo fluxo serve para integrar o modelo a um processo periódico de geração de probabilidades, desde que respeitados os cuidados de atualização de dados e de avaliação contínua de calibração.

Figura 12 – Fluxo de previsão em cenário de uso com embargo de 24 horas

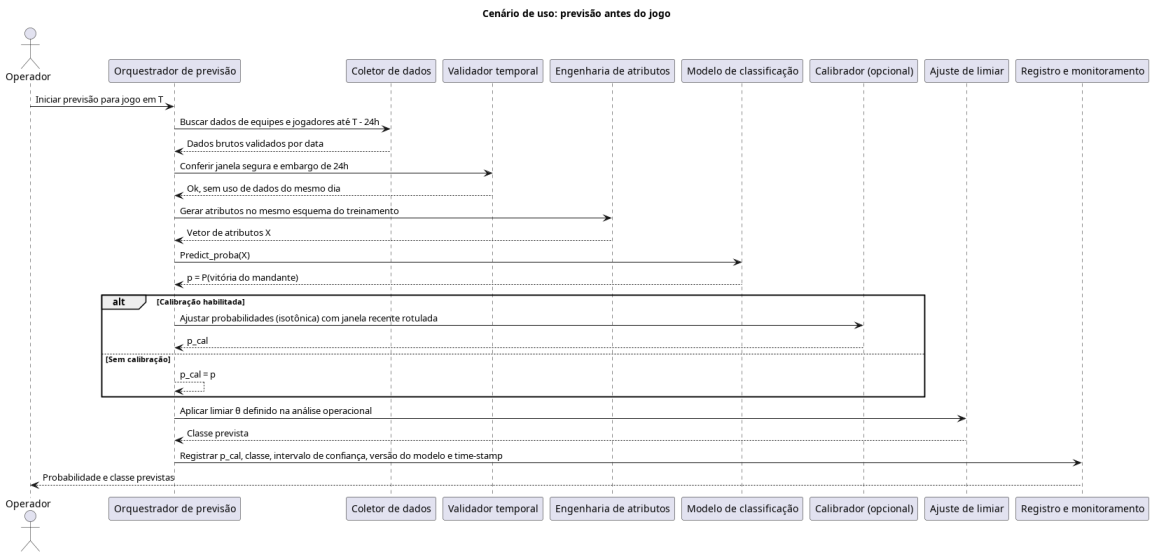

Fonte: elaboração própria (2025).

4 Testes e Resultados

Este capítulo apresenta e discute os resultados obtidos com o modelo proposto, conectando diretamente a estratégia metodológica descrita no Capítulo 3 com o desempenho empírico em dados históricos da NBA. O objetivo é verificar em que medida a combinação de CatBoost, engenharia de atributos em nível de equipe e de jogadores e validação temporal com embargo se traduz em ganhos concretos de predição frente a linhas de base e modelos de referência.

4.1 Configuração experimental

Os experimentos foram executados em ambiente Python 3.10 com as bibliotecas CatBoost, Optuna, Scikit-learn, Pandas e SHAP. A base histórica compreende jogos e estatísticas individuais de jogadores da NBA a partir de 2021 até 27 de dezembro de 2024 para treino. O conjunto de teste é composto por 783 jogos ocorridos entre 28 de dezembro de 2024 e 23 de junho de 2025. Todas as rotinas respeitam a cronologia e aplicam embargo temporal de 24 horas, tanto na engenharia de atributos quanto na validação, conforme descrito no Capítulo 3.

4.2 Otimização de hiperparâmetros

A busca por hiperparâmetros foi realizada com validação temporal e métrica AUC como função-objetivo. Observou-se melhor desempenho com profundidades intermediárias, taxa de aprendizado baixa e regularização L2 moderada. A Tabela 3 ilustra uma amostra dos melhores ensaios.

Tabela 3 – Melhores ensaios de otimização de hiperparâmetros (amostra)

Ensaio	Iterações	Profundidade	Taxa de aprend.	L2	AUC (val.)
1	250	5	0,030	5,0	0,664
2	764	5	0,027	8,2	0,7227
3	500	7	0,040	3,0	0,673
Melhor	764	5	0,027	8,2	0,7227

4.3 Desempenho geral

O classificador final atingiu desempenho superior à linha de base. Os valores a seguir foram obtidos no conjunto de teste cronológico.

Tabela 4 – Métricas globais no conjunto de teste

Métrica	Valor
Acurácia	68,05%
AUC-ROC	0,7227
F1-Score	0,6908
Brier Score	0,217
Linha de base (acurácia)	52,54%

O modelo ficou 15,51 p.p. mais preciso que a linha de base. A AUC-ROC de 0,7227 confirma boa discriminação entre vitórias e derrotas. Após calibração, observou-se redução do desvio médio entre probabilidade prevista e frequência observada.

Figura 13 – Curvas ROC e Precision–Recall no conjunto de teste.

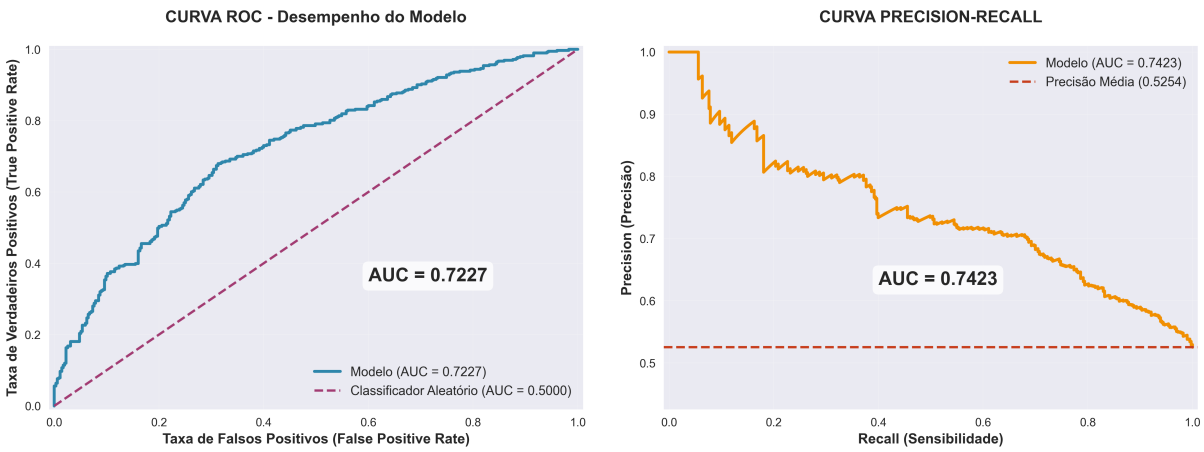

Fonte: elaboração própria (2025).

Figura 14 – Curvas de ganho e de *lift* no conjunto de teste.

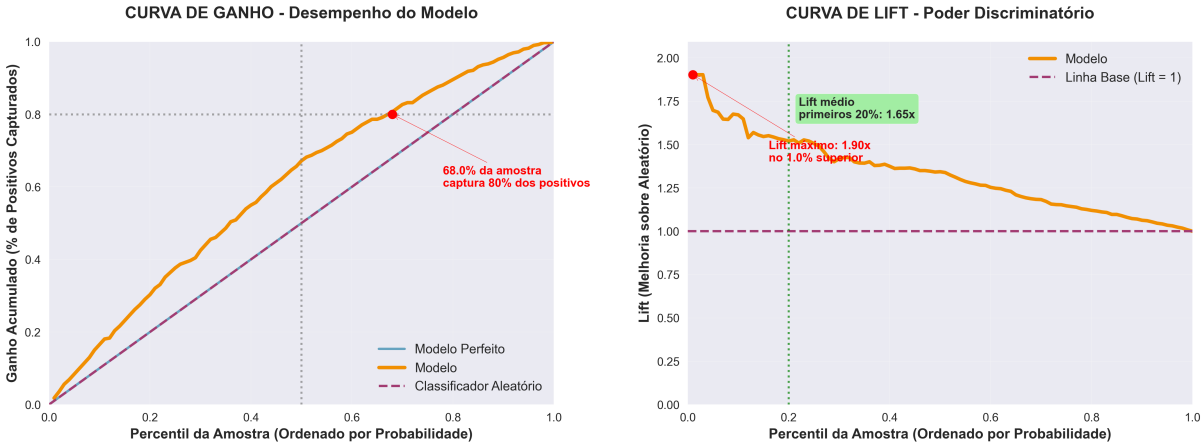

Fonte: elaboração própria (2025).

4.4 Análises detalhadas

4.4.1 Acurácia por equipe

A análise estratificada por equipe permite identificar como o modelo lida com a heterogeneidade das trinta franquias da liga. A Imagem 15 de resultados por equipe evidencia que a assertividade do algoritmo varia consideravelmente, oscilando entre 55,88% e 81,25%.

O Oklahoma City Thunder apresentou a maior acurácia global do conjunto de teste, com 81,25% de acerto em 64 jogos. Esse desempenho foi sustentado por uma consistência

notável em seus domínios, onde o modelo alcançou 84,85% de precisão. O resultado corrobora a premissa de que equipes com rotações estáveis e desempenho técnico superior tendem a apresentar padrões de vitória mais detectáveis pelo algoritmo, reduzindo o ruído aleatório típico de partidas equilibradas.

O Indiana Pacers ilustra um caso particular de assimetria relacionada ao fator local. Embora sua acurácia geral de 66,10% esteja próxima da média do modelo, a decomposição dos resultados revela dois comportamentos distintos: 81,25% de acerto quando a equipe joga em casa e apenas 48,15% quando atua como visitante. Essa discrepância sugere que as variáveis de contexto local exercem peso determinante nas predições envolvendo a franquia, capturando a dificuldade do time em replicar seu desempenho ofensivo fora de casa.

Outras franquias também apresentaram alta previsibilidade, como o Charlotte Hornets (77,14%) e o Cleveland Cavaliers (76,67%), indicando que o modelo consegue generalizar bem tanto para equipes em reconstrução quanto para candidatos ao título, desde que apresentem regularidade estatística.

Na extremidade inferior, o San Antonio Spurs registrou a menor acurácia global (55,88%), seguido pelo Milwaukee Bucks (58,54%). No caso do Spurs, a dificuldade de previsão pode ser atribuída à natureza de um elenco em desenvolvimento, sujeito a oscilações de desempenho que não seguem tendências lineares observadas nos dados históricos de treinamento.

Figura 15 – Desempenho do modelo por equipe comparando a acurácia quando o time atua como mandante (círculos) e como visitante (xis).

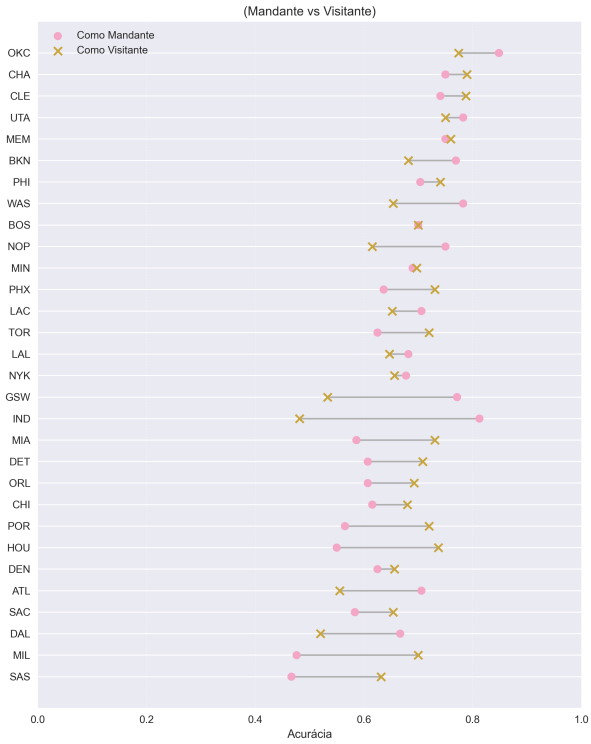

Fonte: elaboração própria (2025).

4.4.2 Acurácia ao longo do tempo

A análise temporal da temporada regular 2024–2025 demonstra uma evolução consistente na capacidade preditiva do classificador, com uma acurácia global de 67,62%. A trajetória de desempenho, ilustrada na Figura 16, não é linear, mas reflete as diferentes dinâmicas competitivas que ocorrem ao longo de uma temporada regular da NBA. O modelo partiu de 64,08% em outubro e atingiu seu ápice de 70,83% em fevereiro, indicando que a acumulação de dados históricos da temporada vigente beneficia diretamente a assertividade das previsões.

O comportamento temporal pode ser segmentado em três momentos analíticos:

- Fase de Adaptação (Outubro – Novembro): O desempenho inicial, oscilando entre 64,08% e 64,77%, reflete o fenômeno de *cold start*. Nesse estágio, as janelas temporais ainda não possuem volume suficiente de jogos recentes, e as métricas das equipes carregam ruído estatístico ou dependem excessivamente de *priors* da temporada anterior, limitando a precisão do algoritmo.
- Consolidação e Volatilidade (Dezembro – Janeiro): Dezembro apresenta um salto expressivo de qualidade, atingindo 69,27% de acerto, o que sugere uma rápida adaptação do modelo às táticas e rotações estabelecidas. Contudo, janeiro registra uma retração para 66,47%. Essa queda é coerente com a literatura esportiva, coincidindo com o período de maior desgaste físico pré-*All-Star* e com a incerteza gerada por rumores de trocas (*trade deadline*), fatores que aumentam a variância dos resultados.
- Maturação e Estabilidade (Fevereiro – Abril): O último terço da temporada exibe os melhores indicadores. Fevereiro marca o pico de desempenho com 70,83% de acerto, seguido por uma estabilidade elevada em março (68,64%) e abril (68,87%). A consistência desses meses finais demonstra que, quando alimentado por um histórico denso e atualizado, o modelo consegue capturar com eficácia a hierarquia de forças da liga e as motivações de classificação (*seeding*) ou reconstrução (*tanking*).

Os dados refutam a hipótese de insensibilidade temporal. A variação de quase 7 pontos percentuais entre o início da temporada e o pico em fevereiro evidencia que a densidade de informação contextual é um fator determinante. O desempenho sustentado próximo a 69% nos meses finais valida a estratégia de janelas temporais, confirmando que o classificador se torna progressivamente mais confiável conforme a temporada avança e os padrões de jogo se consolidam.

É necessário estabelecer uma distinção de escopo entre as métricas apresentadas: a acurácia global de 68,05% refere-se ao desempenho consolidado em todo o conjunto de teste. Por outro lado, a média de 67,62% discutida nesta seção reflete especificamente o recorte mensal da temporada regular (outubro a abril).

Figura 16 – Evolução da acurácia mensal na temporada regular (2024–2025).

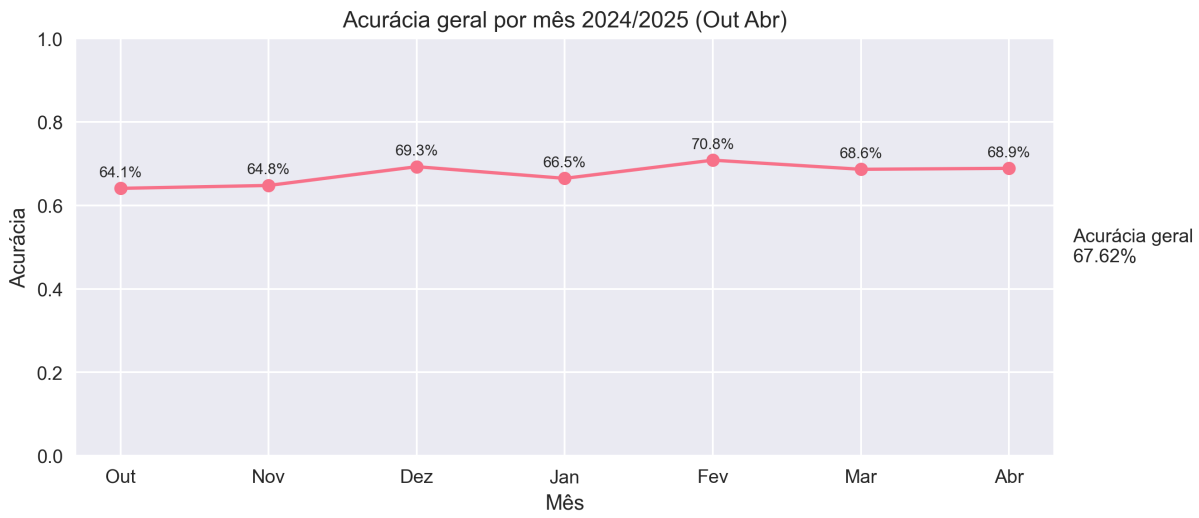

Fonte: elaboração própria (2025).

4.5 Análise de ablação

Para mensurar a contribuição marginal de cada categoria de atributos na performance preditiva, adotou-se uma abordagem aditiva. O experimento iniciou-se com um modelo base minimalista, ao qual foram progressivamente incorporados novos grupos de variáveis, permitindo isolar o ganho de desempenho associado a cada dimensão dos dados. A Tabela 5 detalha a evolução das métricas conforme a complexidade do modelo aumenta.

O ponto de partida (01 Estatísticas básicas agregadas) utilizou apenas 6 variáveis fundamentais. Essa configuração alcançou uma AUC de 0,7073 e acurácia de 65,78%, estabelecendo um patamar de referência elevado. Esse resultado indica que métricas simples de eficiência já capturam parcela relevante da variância explicável de uma partida.

Ao longo das iterações intermediárias observou-se um comportamento não linear. A inclusão do momento recente da equipe (Configuração 04) elevou a acurácia para 67,11%, evidenciando a relevância das sequências de vitórias e derrotas. Por outro lado, a adição isolada de variáveis de descanso e volatilidade (Configurações 03, 05 e 06) resultou em estagnação ou leve oscilação das métricas, sugerindo que esses fatores, sem o contexto detalhado dos elencos, podem introduzir ruído em conjuntos de dados menores.

O salto qualitativo definitivo ocorre na transição para o Modelo Final Completo (07). Ao integrar as estatísticas granulares dos jogadores e totalizar 107 variáveis, o algoritmo atingiu seus melhores resultados: AUC de 0,7227 e acurácia de 68,05%.

A comparação entre o modelo base e o completo evidencia um ganho de aproximadamente 2,27 pontos percentuais na acurácia e uma melhoria consistente na separação de classes (AUC). Esses dados reforçam a hipótese central do trabalho: embora modelos simplificados apresentem bom desempenho, é a alta dimensionalidade proporcionada pelos atributos individuais dos atletas que permite superar a barreira dos 67% de acerto, refinando a capacidade de previsão em jogos equilibrados.

Tabela 5 – Resultados da análise de ablação incremental

Configuração do Modelo	N. Features	AUC	Acurácia
01 Estatísticas básicas agregadas	6	0,7073	65,78%
02 + Ratings avançados	11	0,7143	66,31%
03 + Descanso e fadiga	15	0,7134	66,18%
04 + Momento recente	19	0,7163	67,11%
05 + Desempenho casa/fora	23	0,7109	66,31%
06 + Volatilidade e confrontos	26	0,7129	65,91%
07 Modelo Final Completo	107	0,7227	68,05%

Fonte: elaboração própria (2025).

Figura 17 – Análise de ablação no conjunto de teste.

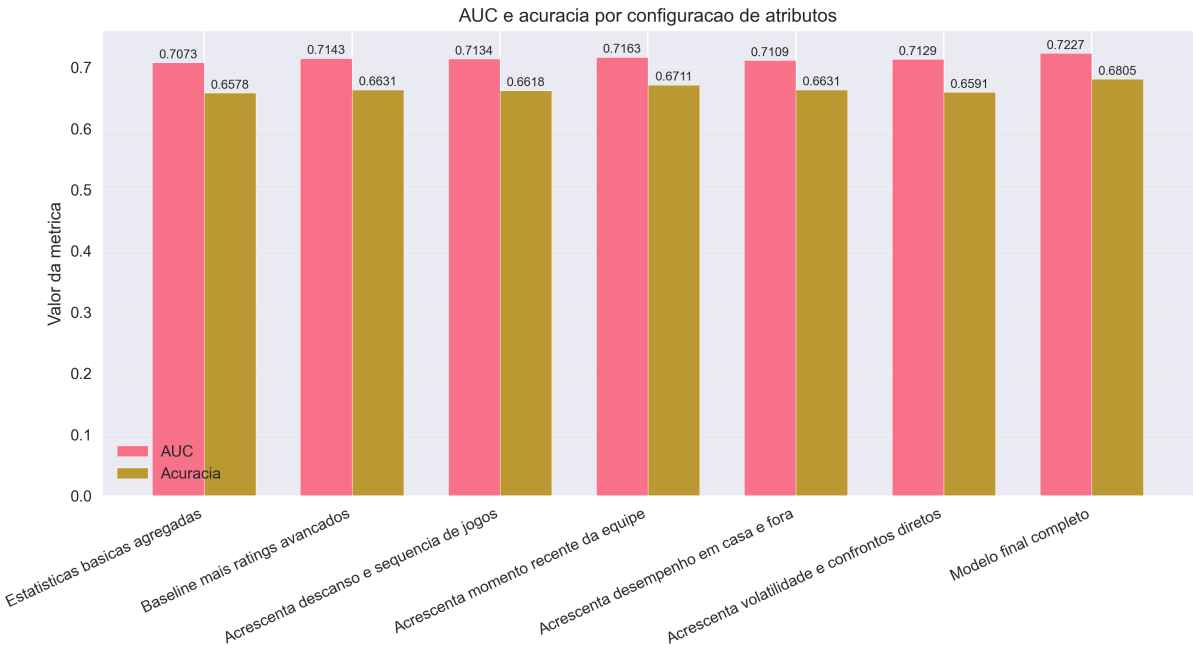

Fonte: elaboração própria (2025).

4.6 Explicabilidade das predições

A análise de importância de atributos via SHAP (*SHapley Additive exPlanations*) no conjunto de teste revela uma hierarquia de decisão sofisticada, que integra indicadores macroscópicos de desempenho com métricas granulares de elenco. A Figura 18 apresenta as 20 variáveis com maior impacto médio absoluto nas decisões do classificador.

A interpretação dos fatores determinantes pode ser sintetizada em três eixos principais:

- Disparidade de desempenho consolidado: A variável de maior influência isolada é a diferença de taxa de vitórias entre as equipes (*win_rate_diff*), ocupando a primeira posição com valor SHAP médio de 0,0678. Isso indica que, antes de analisar nuances

táticas ou escalações, o modelo utiliza o histórico recente de sucesso como âncora principal para estimar o favoritismo. Essa métrica atua como uma *baseline* de força relativa, capturando o desequilíbrio óbvio entre equipes de topo e fundo de tabela.

- Identidade e fator casa: As variáveis categóricas que identificam as franquias mandante (*home_team*) e visitante (*visitor_team*) aparecem, respectivamente, na 2ª e 3ª posições. A alta relevância desses identificadores sugere que o algoritmo capturou fatores latentes intrínsecos a cada organização, como cultura, qualidade técnica mais estável e peso histórico, que extrapolam as estatísticas imediatas. Adicionalmente, a taxa de vitórias específica do mandante em casa (Rank 4) reforça a capacidade do modelo de ponderar a vantagem do mando de quadra de forma dinâmica, valorizando equipes que historicamente defendem bem seu território.

- Refinamento via métricas de jogadores: Embora os indicadores macro liderem o topo, a engenharia de atributos focada em jogadores domina o restante da lista, provendo o ajuste fino da predição. O *Plus-Minus* médio dos jogadores do time da casa (Rank 5) e a diferença direta dessa métrica entre os elencos (Rank 7) mostram que a qualidade individual dos atletas escalados é importante para corrigir a expectativa baseada apenas no histórico do time. Observa-se ainda uma atenção específica às estrelas: a diferença de desempenho do principal jogador (*Top 1*, Rank 8) e da dupla principal (*Top 2*, Rank 9) confirma que o modelo considera o impacto desproporcional dos *superstars* no resultado final.

Figura 18 – Top 20 variáveis mais importantes segundo a média de |SHAP| no conjunto de teste.

Fonte: elaboração própria (2025).

4.7 Validação da Janela Temporal Ótima (OTW)

Para definir a extensão ideal do histórico de dados utilizado no treinamento, foi conduzido um experimento comparativo isolando esta variável. Foram avaliadas janelas fixas de curto (4 jogos), médio (12 jogos) e longo prazo (20 jogos), confrontando-as com a abordagem de janela adaptativa (heurística) proposta na metodologia, a configuração de janela fixa com 20 jogos obteve a maior AUC (0,7227), superando significativamente janelas mais curtas, como 12 jogos (0,7159) e 4 jogos (0,6836) e também a janela ajustada heuristicamente (0,7024).

Esse resultado permite uma interpretação importante sobre a natureza dos dados da NBA: o ruído estatístico de curto prazo (partidas atípicas, variações aleatórias de arremesso) é alto. Uma janela de 20 partidas correspondente a aproximadamente 25% da temporada regular atua como um filtro passa-baixa eficiente, permitindo que as métricas de eficiência convirjam para o valor real da equipe e diluindo o impacto de *outliers*, algo que janelas curtas não conseguem realizar.

Um achado fundamental deste estudo foi a comparação entre a abordagem fixa e a heurística de janela adaptativa. Contrariando a hipótese inicial de que a variação dinâmica

do histórico capturaria melhor as mudanças de tendência (como trocas ou lesões), a janela fixa de 20 jogos demonstrou maior valor preditivo. A análise sugere que a complexidade adicional da heurística tornou o modelo excessivamente sensível à volatilidade de curto prazo, reagindo a ruídos como se fossem mudanças de sinal. Assim, a simplicidade e a estabilidade estatística do recorte de 20 jogos provaram-se superiores.

Diante dessas evidências, o modelo final foi consolidado utilizando a janela estendida de 20 jogos, configuração com a qual foi submetido à validação longitudinal e alcançou os resultados definitivos de 68,05% de acurácia e 0,7227 de AUC no conjunto de teste independente.

Tabela 6 – Comparação de desempenho entre estratégias de Janela Temporal (OTW)

Estratégia	Configuração	AUC
Fixa (Selecionada)	20 jogos	0,7227
Janela Fixa	12 jogos	0,7159
Janela Fixa	4 jogos	0,6836
Janela Adaptativa	Heurística	0,7024

Fonte: elaboração própria (2025).

4.8 Calibração das Probabilidades

Após o treinamento do classificador, avaliou-se a qualidade das probabilidades prevendo a confiabilidade por faixas, o *Brier score* e a curva de calibração. Um modelo pode discriminar bem vitórias e derrotas e, ainda assim, apresentar probabilidades desajustadas, por exemplo, atribuir 70% de chance e observar frequências reais afastadas desse valor.

O procedimento adotado seguiu três passos: (i) medição da confiabilidade por faixas de probabilidade e cálculo do *Brier score*; (ii) verificação de viés sistemático de confiança, tanto para favoritos quanto para azarões; (iii) aplicação de calibração pós-treino quando o viés excedeu um limiar pré-definido. As partições respeitaram a cronologia para evitar uso indevido de informações futuras.

Nos resultados deste trabalho, a calibração melhorou levemente o *Brier score* no conjunto de teste (0,2178 para 0,2167), porém reduziu discretamente a AUC (0,7227 para 0,7123) e piorou o *log loss* (0,6395 para 0,6530). Assim, as probabilidades calibradas são mais fiéis em termos de frequência observada, mas, para decisões sensíveis a *log loss* e ordenação, o modelo não calibrado apresentou desempenho superior.

Figura 19 – Curva de confiabilidade do modelo no conjunto de teste.

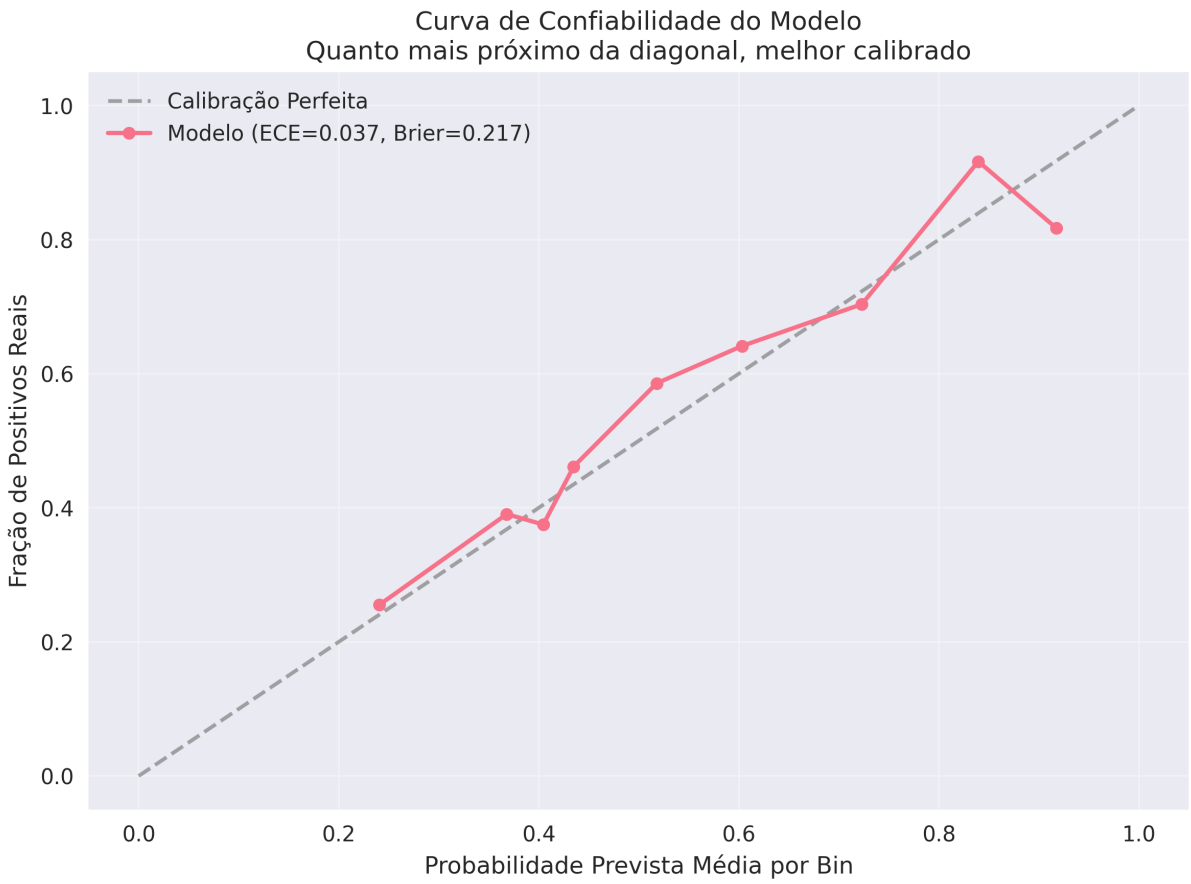

Fonte: Elaboração própria (2025).

Tabela 7 – Métricas antes e depois da calibração no conjunto de teste

Métrica	Antes	Depois
Acurácia	0,6805	0,6626
AUC-ROC	0,7227	0,7123
Log loss	0,6395	0,6530
Brier score	0,2178	0,2167

Fonte: Elaboração própria (2025)

4.9 Estudo de caso de predição individual

Para ilustrar a aplicação prática do modelo em um cenário de uso real, foi selecionado um confronto específico do conjunto de teste. Assim como no restante do pipeline, os atributos desse jogo foram gerados apenas com base nas informações disponíveis até a véspera da partida, respeitando o buffer temporal de 24 horas e as mesmas regras de engenharia de atributos descritas no Capítulo 3. A partir desses atributos, o modelo produziu a probabilidade de vitória do mandante.

A Figura 20 apresenta a decomposição contribucional dessa probabilidade por meio dos valores SHAP. Cada atributo recebe um valor que indica o quanto empurrou a predição em direção a maior ou menor chance de vitória do mandante, em relação a um valor base do modelo. Valores positivos aumentam a probabilidade prevista, enquanto valores negativos reduzem essa probabilidade. Dessa forma, é possível identificar de forma transparente quais fatores relacionados ao histórico recente das equipes, ao elenco e ao contexto do jogo foram mais determinantes para a previsão daquela partida.

Figura 20 – Explicação local por SHAP para uma predição individual de jogo da NBA

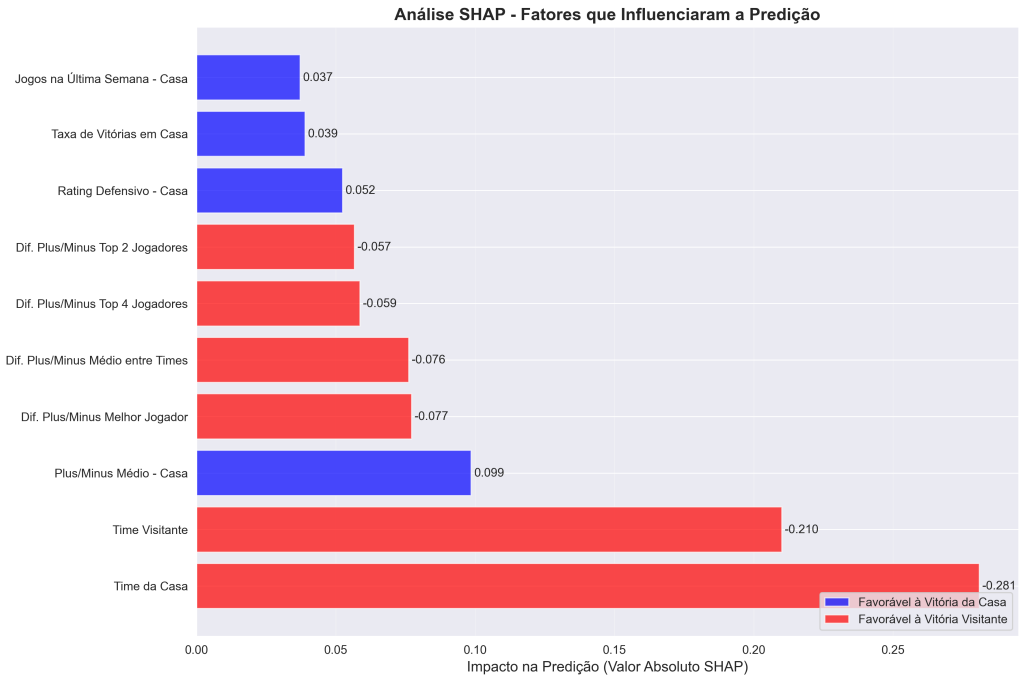

Fonte: elaboração própria (2025).

4.10 Comparação de Desempenho com Outros Modelos

Para validar a eficácia da arquitetura proposta baseada no CatBoost, o desempenho final foi comparado com um conjunto de algoritmos de referência (*benchmarks*) amplamente utilizados na literatura de previsão esportiva e aprendizado de máquina.

Os modelos comparativos foram submetidos ao mesmo pipeline de validação temporal descrito na Seção 4, utilizando o mesmo conjunto de dados de teste. É importante ressaltar que, para garantir a isonomia na comparação, os modelos de referência baseados em árvores (XGBoost, LightGBM e Random Forest), foram instanciados utilizando os mesmos hiperparâmetros otimizados obtidos para o CatBoost (como profundidade das árvores, taxa de aprendizado e regularização). Essa abordagem visou isolar a eficiência intrínseca do algoritmo CatBoost e da engenharia de atributos proposta, removendo a variação que poderia advir de buscas de hiperparâmetros distintas.

A Tabela 8 apresenta os resultados consolidados. O "Modelo Proposto" refere-se à configuração final do CatBoost integrada com a engenharia de atributos de jogadores e Janelas Temporais Ótimas (OTW).

Tabela 8 – Comparação de desempenho entre o modelo proposto e algoritmos de referência no conjunto de teste

Modelo	Acurácia	AUC-ROC
Modelo proposto (CatBoost + OTW)	68,05%	0,7227
Regressão logística	65,34%	0,6990
Random Forest	64,47%	0,7020
LightGBM	63,04%	0,6674
XGBoost	62,64%	0,6562
Baseline: sempre mandante (home)	52,54%	0,5000

Fonte: elaboração própria (2025).

O modelo proposto superou todas as linhas de base ingênuas por uma margem significativa (melhoria de aproximadamente 15,5 p.p. sobre a estratégia "Sempre Mandante"), confirmando a capacidade do sistema de extrair sinal preditivo dos dados.

Na comparação direta com outros algoritmos de aprendizado de máquina:

- Modelos de Árvore (XGBoost e LightGBM): O CatBoost apresentou desempenho superior aos seus concorrentes diretos de *gradient boosting*. Enquanto o XGBoost e o LightGBM obtiveram acurácias na faixa de 62% a 63%, o modelo proposto atingiu 68,05%. Essa diferença pode ser atribuída ao tratamento nativo de variáveis categóricas do CatBoost (como times e fase da temporada) e à eficácia das *Ordered Target Statistics* em evitar vazamento de dados durante o treinamento, algo crítico em séries temporais esportivas.
- Random Forest e Regressão Logística: A Regressão Logística mostrou-se um bom competidor (65,34%), o que é consistente com a literatura de *sports analytics*, onde modelos lineares frequentemente performam bem devido à natureza ruidosa dos dados, que pode levar modelos mais complexos ao sobreajuste. No entanto, o Modelo Proposto obteve uma vantagem marginal na acurácia e, mais importante, uma AUC superior (0,7227 contra 0,6990). Isso indica que o CatBoost não apenas classifica melhor o vencedor final, mas também ordena melhor as probabilidades, discriminando com mais precisão entre vitórias confiáveis e jogos incertos.

A superioridade do modelo final não advém apenas da escolha do algoritmo, mas da sinergia entre o CatBoost e a engenharia de atributos específica (estatísticas de jogadores agregadas e janelas dinâmicas).

4.11 Discussão dos resultados

Os resultados obtidos superaram a linha de base e corroboraram as hipóteses centrais do estudo. O ganho de 15,51 pontos percentuais em acurácia sobre a referência (conforme detalhado na Tabela 4) confirma a relevância da engenharia de atributos focada nos jogadores e a adequação da estratégia de validação temporal.

Ao contrastar o classificador final com outros algoritmos, nota-se que a escolha do CatBoost foi justificada. A superioridade frente a métodos de *ensemble* tradicionais, como

XGBoost (62,64%) e LightGBM (63,04%), sugere que o tratamento nativo de variáveis categóricas e a redução de vazamento de dados (*target leakage*) são diferenciais importantes em séries temporais esportivas. Embora modelos lineares como a Regressão Logística tenham apresentado bom desempenho (65,34%), a arquitetura proposta obteve maior discriminação (AUC de 0,7227), o que indica maior capacidade de separar vitórias confiáveis de resultados incertos.

A comparação com a literatura reforça a consistência dos achados. Horvat et al. (2023) reportam acurácia média próxima de 78%, enquanto Khanmohammadi et al. (2024) apresentam AUC entre 0,72 e 0,82. O valor de AUC de 0,7227 alcançado neste trabalho situa-se próximo a esses intervalos, sendo que diferenças metodológicas na composição do conjunto de dados e no horizonte temporal explicam parte da variação.

O desempenho heterogêneo entre as franquias também é coerente com a teoria esportiva: elencos estáveis, como o do Oklahoma City Thunder, apresentaram maior previsibilidade, ao passo que equipes com alta rotatividade ou variância tática, como o Indiana Pacers, sofreram queda de precisão. Tais oscilações reforçam que a estabilidade da rotação afeta diretamente a capacidade preditiva de modelos fundamentados em desempenho recente.

A análise de ablação ratificou a importância da inclusão progressiva de atributos. A comparação entre o modelo base e a configuração completa revela um ganho na capacidade de ordenação das probabilidades, evidenciado pelo aumento da AUC de 0,7073 para 0,7227. Esse incremento demonstra que, embora a acurácia bruta tenda a estabilizar em torno de 66% em configurações intermediárias, a adição de estatísticas granulares dos jogadores é fundamental para refinar a margem de confiança das previsões.

Em síntese, os experimentos validam a premissa de que a integração de estatísticas de jogadores e validação rigorosa eleva o desempenho preditivo em relação às abordagens simplificadas baseadas apenas em médias de equipe.

Tabela 9 – Comparação de desempenho entre estudos selecionados e o modelo proposto

	Acurácia	AUC	Fonte
Horvat et al. (2023)	$\approx 78\%$	n.d.	(HORVAT et al., 2023)
MambaNet (2024)	n.d.	0,72−0,82	(KHANMOHAMMADI et al., 2024)
Albert et al. (2022)	0,85−0,89	n.d.	(ALBERT et al., 2021)
Modelo proposto (CatBoost)	68,05%	0,7227	autores

5 Conclusão

Este trabalho desenvolveu um modelo de *machine learning* para previsão de resultados de jogos da NBA, com uso do classificador CatBoost e uma arquitetura de engenharia de atributos que combina informações contextuais de equipes e estatísticas agregadas de jogadores. O processo de validação adotou partições temporais com embargo de 24 horas, garantindo a integridade causal dos experimentos.

O modelo alcançou acurácia de 68,05% e AUC-ROC de 0,7227, superando a linha de base de 52,54%. Esses resultados demonstram ganho estatisticamente consistente e indicam que a modelagem proposta é capaz de ordenar corretamente a maioria dos confrontos, atribuindo maior probabilidade às equipes vencedoras na maior parte dos casos.

Entre as principais contribuições estão:

- a demonstração da relevância de *features* derivadas de jogadores para aprimorar modelos preditivos de desempenho coletivo;
- a aplicação rigorosa de validação temporal e calibração, que reduzem viés e aumentam a confiabilidade probabilística;
- e a introdução da heurística de janela temporal adaptativa, ajustando dinamicamente o histórico considerado para cada equipe.

Como limitações, destacam-se a dependência de dados públicos sujeitos a inconsistências e a ausência de variáveis exógenas, como viagens, clima ou indicadores de fadiga fisiológica. Também não foram explorados modelos híbridos com redes neurais temporais ou arquiteturas de atenção, que podem capturar interações mais complexas entre jogadores e partidas.

5.1 Trabalhos Futuros

Por conta de limitações impostas no projeto para poder ser desenvolvido no tempo proposto, e comportamentos da solução durante testes, há algumas sugestões de melhorias e adições que podem ser úteis em trabalhos futuros:

- Enriquecimento de dados com indicadores de disponibilidade e carga de trabalho de jogadores, bem como métricas de força do elenco.
- Avaliação do uso controlado de *odds* das casas de apostas como variável explicativa, com testes de sensibilidade para evitar vazamento de dados.
- Investigação de funções de perda personalizadas (*custom loss functions*) que penalizem erros de calibração diretamente durante o treinamento, visando otimizar métricas como o *Brier Score* de forma nativa.
- Estratégias de *ensembling* e modelos hierárquicos que acomodem heterogeneidade entre equipes.
- Análise de subgrupos por margem de vitória e contexto.

- Incorporação de dados de *matchups* históricos: Expandir a engenharia de atributos para considerar o histórico de desempenho direto entre pares de jogadores (atacante vs. defensor). Isso permitiria ao modelo ajustar as expectativas de pontuação baseando-se em "duelos" específicos, capturando nuances táticas como defensores de elite anulando estrelas adversárias, algo que médias agregadas não conseguem detectar.

Referências

ALBERT, A. et al. A hybrid machine learning model for predicting usa nba all-stars. *Electronics*, v. 11, n. 1, p. 97, 2021. Disponível em: <https://www.mdpi.com/2079-9292/11/1/97>. Citado 2 vezes nas páginas 27 e 53.

ALPAYDIN, E. *Introduction to Machine Learning*. 2. ed. Cambridge, MA: MIT Press, 2010. Citado na página 14.

Amazon Web Services. *O que é Boosting? - Amazon Web Services (AWS)*. 2023. Acesso em: 24 maio 2025. Disponível em: <https://aws.amazon.com/pt/what-is/boosting/>. Citado na página 14.

BAHETI, N. *Classification Evaluation Metrics*. s.d. ML Guide Book. Disponível em: <https://mlguidebook.com/en/latest/Evaluation/classification.html>. Acesso em: 26 out. 2025. Citado na página 20.

Basketball Reference. *Player Efficiency Rating (PER)*. 2025. Accessed: 24 maio 2025. Disponível em: <https://www.basketball-reference.com/about/per.html>. Citado na página 12.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: . [S.l.: s.n.], 2016. p. 785–794. Citado 2 vezes nas páginas 14 e 15.

Coursera Staff. *What Is a Confusion Matrix?* 2025. Updated on May 5, 2025. Disponível em: <https://www.coursera.org/articles/what-is-a-confusion-matrix>. Acesso em: 26 out. 2025. Citado na página 20.

Encyclopædia Britannica. *National Basketball Association (NBA) – History & Facts*. 2025. Disponível em: <https://www.britannica.com/topic/National-Basketball-Association>. Citado na página 12.

FAWCETT, T. An introduction to roc analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006. Citado 3 vezes nas páginas 21, 22 e 23.

FREUND, Y.; SCHAPIRE, R. E. A desicion-theoretic generalization of on-line learning and an application to boosting. In: VITÁNYI, P. (Ed.). *Computational Learning Theory*. Berlin, Heidelberg: Springer Berlin Heidelberg, 1995. p. 23–37. ISBN 978-3-540-49195-8. Citado 2 vezes nas páginas 14 e 15.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. Citado 2 vezes nas páginas 14 e 15.

Giskard AI. *Model Calibration*. s.d. Glossary. Disponível em: <https://www.giskard.ai/glossary/model-calibration>. Acesso em: 26 out. 2025. Citado na página 19.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016. <http://www.deeplearningbook.org>. Citado na página 14.

GUO, C. et al. On calibration of modern neural networks. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. PMLR, 2017. (Proceedings of Machine Learning Research, v. 70), p. 1321–1330. Disponível em: <https://arxiv.org/abs/1706.04599>. Citado na página 23.

HOLLINGER, J. *Pro Basketball Forecast: 2005–06 Edition*. Washington, DC: Brassey's, 2005. ISBN 9781574888812. Citado na página 12.

HORVAT, T. *An Adaptive Method for Predicting Sport Outcomes Based on the Efficiency Index and Optimal Time Window*. Tese (Doutorado) — University of Osijek, Osijek, Croatia, 2020. Citado 2 vezes nas páginas 25 e 26.

HORVAT, T. et al. A data-driven machine learning algorithm for predicting the outcomes of nba games. *Symmetry*, v. 15, p. 798, 03 2023. Citado 3 vezes nas páginas 26, 27 e 53.

JIANG, T.; GRADUS, J. L.; ROSELLINI, A. J. Supervised machine learning: A brief primer. *Behavior Therapy*, v. 51, n. 5, p. 675–687, 2020. Disponível em: <https://doi.org/10.1016/j.beth.2020.05.002>. Citado na página 19.

KHANMOHAMMADI, R. et al. Mambanet: A hybrid neural network for predicting the nba playoffs. *SN Computer Science*, 2024. Disponível em: <https://link.springer.com/article/10.1007/s42979-024-02977-0>. Citado 2 vezes nas páginas 28 e 53.

KOVáCS, H. Injury trends and performance implications in the nba using sports analytics. *Journal of Sports Medicine & Doping Studies*, v. 14, n. 2, p. 357, 2024. Disponível em: <https://doi.org/10.37421/2161-0673.2024.14.357>. Acesso em: 26 out. 2025. Disponível em: <https://www.longdom.org/abstract/injury-trends-and-performance-implications-in-the-nba-using-sports-analytics-130912.html>. Citado na página 10.

KUBATKO, J. et al. A starting point for analyzing basketball statistics. *Journal of Quantitative Analysis in Sports*, v. 3, n. 3, p. 1–22, 2007. Disponível em: <https://doi.org/10.2202/1559-0410.1070>. Citado 2 vezes nas páginas 12 e 13.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems 30*. [S.l.: s.n.], 2017. p. 4765–4774. Citado 2 vezes nas páginas 24 e 27.

LóPEZ, V. et al. An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. *Information Sciences*, v. 250, p. 113–141, 11 2013. Citado na página 21.

MCELFRESH, D. et al. When do neural nets outperform boosted trees on tabular data? *arXiv preprint arXiv:2305.02997*, 2024. 37th Conference on Neural Information Processing Systems (NeurIPS 2023), Datasets and Benchmarks Track. Disponível em: <https://arxiv.org/pdf/2305.02997>. Citado na página 15.

MITCHELL, T. M. *Machine Learning*. New York, NY: McGraw-Hill, 1997. Disponível em: <https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf>. Citado 2 vezes nas páginas 13 e 14.

MUREL, J.; KAVLAKOGLU, E.; IBM Research. *O que é uma matriz de confusão?* s.d. IBM Think. Disponível em: <https://www.ibm.com/br-pt/think/topics/confusion-matrix>. Acesso em: 26 out. 2025. Citado 2 vezes nas páginas 20 e 21.

MYERS, D. *About Box Plus/Minus (BPM)*. 2020. <https://www.basketball-reference.com/about/bpm2.html>. Acesso em: 24 maio 2025. Citado na página 13.

OBI, O. C. et al. Data science in sports analytics: A review of performance optimization and fan engagement. *World Journal of Advanced Research and Reviews*, v. 21, n. 1, p. 2663–2670, 2024. Disponível em: <https://doi.org/10.30574/wjarr.2024.21.1.0370>. Acesso em: 26 out. 2025. Disponível em: <https://wjarr.com/>. Citado na página 10.

OLIVER, D. *Basketball on Paper: Rules and Tools for Performance Analysis*. Dulles, VA: Potomac Books, 2004. ISBN 9781574886887. Citado na página 12.

OUYANG, Y. et al. Integration of machine learning xgboost and shap models for nba game outcome prediction and quantitative analysis methodology. *PLOS ONE*, v. 19, n. 7, p. e0307478, 2024. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0307478>. Citado na página 27.

PAPAGEORGIOU, G.; SARLIS, V.; TJORTJIS, C. Evaluating the effectiveness of machine learning models for performance forecasting in basketball: a comparative study. *Knowledge and Information Systems*, v. 66, n. 7, p. 4333–4375, 2024. ISSN 0219-3116. Disponível em: <https://doi.org/10.1007/s10115-024-02092-9>. Citado na página 10.

PROKHORENKOVA, L. et al. Catboost: Unbiased boosting with categorical features. In: *Advances in Neural Information Processing Systems 31*. [S.l.: s.n.], 2018. p. 6638–6648. Citado 5 vezes nas páginas 10, 14, 16, 17 e 18.

RENOOIJ, S. Forecast verification and the uncertain truth. *Institute of Information and Computing Sciences, Utrecht University*, Utrecht, Netherlands, 2004. Disponível em: <https://dspace.library.uu.nl/handle/1874/1008>. Citado 2 vezes nas páginas 23 e 24.

RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 3. ed. Upper Saddle River, NJ: Prentice Hall, 2010. Citado na página 13.

SARLIS, V.; TJORTJIS, C. Sports analytics – evaluation of basketball players and team performance. *Information Systems*, v. 93, p. 101562, 05 2020. Citado na página 10.

SCHAPIRE, R. E.; FREUND, Y. *Boosting: Foundations and Algorithms*. [S.l.]: MIT Press, 2012. Citado na página 15.

WANG, C. Calibration in deep learning: A survey of the state-of-the-art. *arXiv preprint arXiv:2308.01222*, 2025. Disponível em: <https://arxiv.org/abs/2308.01222>. Citado na página 23.

WANG, H.; SARKER, A.; HOSOI, A. The effect of basketball analytics investment on national basketball association (nba) team performance. *Journal of Sports Economics*, v. 26, n. 6, p. 668–688, 2025. Disponível em: <https://doi.org/10.1177/15270025251328264>. Citado na página 10.

WANG, Y.; JI, H.; DAI, D. From sidelines to scoreboards: Regression modelling for predicting nba game outcomes. *Applied and Computational Engineering*, v. 131, p. 60–71, 2025. Citado na página 28.

WU, W. Injury analysis based on machine learning in nba data. *Journal of Data Analysis and Information Processing*, v. 08, p. 295–308, 01 2020. Citado na página 28.

ZENG, Y. et al. Explaining basketball game performance with shap: Insights from chinese basketball association. *Applied Sciences*, MDPI, v. 13, n. 9, p. 5418, 2023. Disponível em: <https://www.mdpi.com/2076-3417/13/9/5418>. Citado 3 vezes nas páginas 11, 19 e 25.