Caio de Lazari Rosa e Felipe Nicolau Moreti

Fazendo uso de Hidden Markov Model para prever ações

São Paulo - Brasil

2019

Caio de Lazari Rosa e Felipe Nicolau Moreti

Fazendo uso de Hidden Markov Model para prever ações

Projeto apresentado na disciplina Trabalho de Conclusão de Curso, como parte dos requisitos para obtenção do título de Bacharel em Ciência da Computação.

Centro Universitário Senac - Santo Amaro

Bacharelado em Ciência da Computação

Orientador: Prof. Ms. Luiz Augusto Zazeri

São Paulo - Brasil

2019

Resumo

Para uma pessoa com pouco conhecimento de mercado investir seu dinheiro na Bolsa de Valores é uma tarefa que envolve incertezas, seja por não entender a volatilidade do mercado ou não compreender os aspectos que definem o valor de uma ação. Quando falamos de investimentos na Bolsa de Valores devemos pensar que os grandes investidores que ali estão utilizam ferramentas de análises técnicas e/ou fundamentalistas para determinar o momento ideal de comprar e vender seus ativos. A proposta deste trabalho é fornecer para os investidores, sejam eles os mais experientes ou aqueles com menos conhecimentos no mercado de capitais a possibilidade de obter uma possível resposta sobre a valorização de seus ativos, ou daqueles que pretende investir, ajudando-o através de modelos matemáticos e Modelo Oculto de Markov se uma determinada ação irá valorizar ou desvalorizar em determinado tempo.

Palavras-Chave: Mercado de capitais, bolsa de valores, ações, predição, inteligência artificial, Modelo Oculto de Markov, HMM

Abstract

For a person with a little market knowledge apply their money on Stock Exchange is a task that involves risks, per not understanding the volatility of the market or not understanding the aspects that define the price of a stock. When we talk about investments in the Stock Exchange we must think that the big investors who are there use technical analysis and/or fundamentalists tools to determine the ideal time to buy and sell their assets. The purpose of this paper is to provide investors, whether they are the most experienced or those with less knowledge in the stock market, the possibility of obtaining a possible response on the valuation of their stocks, or of those who intend to buy, by helping them through mathematical models and Hidden Markov Model to determine if a particular action will value or devalue at a given time.

Key-words: stocks, stock exchange, prediction, artificial intelligence, finance market, capital market, Hidden Markov Model, HMM

Lista de ilustrações

Figura 1 - Evolução do índice nos últimos 5 anos. (GOOGLE, 2019) 16
Figura 2 - Gráfico de Barras. (B3. 2019) 19
Figura 3 - Gráfico de Candlestick. (B3 2019) 20
Figura 4 - Gráfico de Linhas. (B3 2019) 21
Figura 5 - Gráfico de Colunas. (B3 2019) 21
Figura 6 - Componentes da análise fundamentalista. WINGER; FRASCA (1995) 22
Figura 7 - Exemplo de um Gráfico de regressão linear. SHIMAKURA (2005) 25
Figura 8 - Metodologia do KNN. DATACAMP (2018) 26
Figura 9 - Rede Neural LVQ. CAPARRINI (2017) 28
Figura 10 - Pesos entre conexão de neurônios. EGELI; OZTURAN; BADUR (2019) 29
Figura 11 - Camadas de Rede Neural. DORMEHL (2019) 29
Figura 12 - Representação de uma SVM linear. RAY (2017) 31
Figura 13 - Representação de uma SVM não linear. MOREIRA (2011) 32
Figura 14 - Exemplo de cadeias de markov. JURAFSKY; MARTIN (2007) 33
Figura 15 - Matriz de transição de 4 estados. KUINCHTNER; MADALOZZO (2018) 34
Figura 16 - Representação de um HMM. KANG (2017) 35
Figura 17 - Algoritmo Forward. Fonte: JURAFSKY; MARTIN (2018) 37
Figura 18 - Algoritmo Viterbi. Fonte: JURAFSKY; MARTIN (2018) 38
Figura 19 - Dados coletados em JSON. World Trading Data (2019) 42
Figura 20 - Dados da ação MGLU3 importados por CSV. AUTORES 42
Figura 21 - Exemplo de dados idênticos para um mesmo dia, ABEV3. AUTORES 43
Figura 22 - Dados do CSV convertidos para JSON. AUTORES 44
Figura 23 - Exemplo de seleção dos dados para 5 dias. AUTORES 45

Figura 24 - Exemplo de página para previsão da ação MGLU3. AUTORES 46
Figura 25 - Tabela RMSE das ações testadas. AUTORES 48
Figura 26 - Tabela MAPE das ações testadas. AUTORES 48
Figura 27 - Gráfico de 14 dias para a ação ABEV3. AUTORES 49
Figura 28 - Gráfico de 14 dias para a ação AZUL4. AUTORES 50
Figura 29 - Gráfico de 14 dias para a ação B3SA3. AUTORES 50
Figura 30 - Gráfico de 14 dias para a ação BRFS3. AUTORES 51
Figura 31 - Gráfico de 14 dias para a ação ITUB4. AUTORES 52
Figura 32 - Gráfico de 14 dias para a ação MGLU3. AUTORES 52
Figura 33 - Gráfico de 14 dias para a ação PETR4. AUTORES 53
Figura 34 - Gráfico de 14 dias para a ação RENT3. AUTORES 53
Figura 35 - Gráfico de 14 dias para a ação VALE3. AUTORES 54
Figura 36 - Gráfico de 14 dias para a ação B3SA3 utilizando 60 dias de observação. AUTORES 54
Figura 37 - Gráfico de 14 dias para a ação VALE3 utilizando 100 dias de observação. AUTORES 55

Lista de abreviaturas e siglas

ANN	Artificial Neural Network (Redes Neurais Artificiais)
API	Application Programming Interface
B3	Brasil, Bolsa, Balcão
BM&F	Bolsa de Mercadorias e Futuros
Bovespa	Bolsa de valores do Estado de São Paulo
CVM	Comissão de valores Mobiliários
FIP	Fundo de Inovação Paulista
GFF	Generalized Feed-Forward Networks
HMM	Hidden Markov Model
IPO	Initial Public Offer (Oferta Pública Inicial)
KNN	K Nearest Neighbors
LVQ	Learning Vector Quantization
MAPE	Mean Average Percentage Error
RMSE	Root Mean Square Error
SVM	Support Vector Machines

Sumário

Fazendo uso de Hidden Markov Model para prever ações **1**

Resumo 2

Abstract 3

Lista de ilustrações 4

Lista de abreviaturas e siglas 6

Sumário 7

1 Introdução **10**

2 Revisão **12**

2.1 Mercado financeiro 12

2.1.1 Ações 13

2.2 Mercado de capitais 13

2.3 Bolsa de Valores e Mercado de ações 13

2.4 A Bolsa de Valores no Brasil 15

2.5 Bovespa 15

2.6 Índice Bovespa 16

2.7 Ações 17

2.8 Análise de Ações 18

2.9 Análise Técnica 18

2.9.1 Análise técnica empírica 18

2.9.2 Análise técnica estatística 18

Gráfico de barras 19

Gráfico candlestick 19

Gráfico de linhas 20

Gráfico de colunas 21

2.10 Análise Fundamentalista 22

2.11 Fintech 23
2.12 Algoritmos de aprendizado de máquina 24
2.12.1 Aprendizado supervisionado e não supervisionado 24
2.12.2 Árvore de decisão 24
2.12.3 KNN 25
2.12.4 LVQ 27
2.12.5 Redes Neurais 28
Coleta de dados 30
Pré processamento dos dados 30
Desenvolvimento do modelo 30
Teste do modelo 30
2.12.6 SVM 31
2.13 HMM (Modelo Oculto de Markov) 32
2.13.1 Cadeias de Markov 33
2.13.2 Definição do HMM 34
2.13.3 Algoritmo Forward 36
2.13.4 Viterbi 37
2.13.5 Baum-Welch 38
2.14 Avaliação de Resultados 38
3 Desenvolvimento 40
3.1 Proposta de solução 40
3.2 Ferramentas 40
3.3 Metodologia 41
3.3.1 Coleta de dados históricos 41
3.3.2 Pré-processamento dos dados 42
3.3.3 Implementação 44
3.4 Resultados 47

4 Conclusão **56**

4.1 Trabalhos Futuros 56

Referências **58**

1 Introdução

Em um mundo cada vez mais tecnológico as melhorias na parte de automação e inteligência artificial, visando melhorar e reduzir possíveis erros humanos que possam passar despercebidos, seja por falta de atenção ou simplesmente algo fora dos padrões que não foi previsto.

Com o auxílio da computação, é possível reduzir a frequência dos erros. É possível observar hoje robôs sendo utilizados na medicina para aumentar a precisão em uma cirurgia, ou robôs sendo utilizado em fábricas para aumentar a produção.

O setor financeiro também começa a se desenvolver na área de inteligência artificial, seja para aplicações automatizadas ou modelos de previsão. Uma pessoa com pouco conhecimento da área financeira acaba não vendo uma possibilidade real de investimento com chances de um retorno maior. Geralmente por medo de entrar em um mercado onde se ouve falar muito de risco, essa pessoa com pouco conhecimento acaba optando por não investir seu dinheiro no mercado de capitais, escolhendo obter uma renda menor de forma mais segura.

Quando falamos de segurança em investimento nós falamos sobre os riscos que envolvem o mercado. Ninguém quer perder dinheiro, todos querem ganhar, mas onde o risco é maior os retornos financeiros são maiores também, por isso queremos demonstrar que é possível reduzir um pouco os riscos através de análises automatizadas e modelos de previsão do que pode acontecer com um determinado papel na bolsa de valores.

Segundo Ares (2016), historicamente o ativo mais rentável a longo prazo, tem vindo a ser o mercado de ações. Com esta pesquisa iremos buscar facilitar a entrada de pessoas que não entendem nada do assunto a poder investir melhor seu dinheiro e faremos isso ensinando a máquina a aprender a utilizar os dados relevantes para esta finalidade.

O objetivo deste projeto é mostrar através de Hidden Markov Model (Modelo Oculto de Markov) que é possível identificar a variação ou tendência de um ativo em um

determinado período de tempo, e com isso saber se o momento desse ativo é propício ou não para investimentos. Para atingir este objetivo utilizaremos técnicas de análise do mercado de capitais aliadas à um aprendizado de máquina para prever o comportamento do papel e então fornecer uma previsão da variação desse ativo para auxiliar a decisão final do investidor.

O trabalho proposto visa auxiliar o investidor a investir seu dinheiro com menor risco no mercado de renda variável, de forma que os dados entregues pelo modelo sejam um facilitador no estudo e avaliação de um ativo, dessa forma o investidor pode se basear no histórico de dados que uma ação possui e ter uma idéia de como esta estará se comportando nos próximos dias.

2 Revisão

2.1 Mercado financeiro

O mercado financeiro é um meio do mercado de investimentos que possibilita a compra e venda de valores mobiliários, câmbio e mercadorias. Essas negociações envolvem diversas instituições que regulam e fiscalizam as transações. Nesse mercado os investidores são aqueles que dispõe de dinheiro e que buscam uma valorização de seu patrimônio de uma maneira mais rentável.

De acordo com Spritzer & Spritzer (2013 p.20), a grande importância do mercado financeiro é a capacidade que ele têm de mobilizar os recursos da poupança popular, transferindo-os para investimentos que aumentam a capacidade produtiva do país.

A valorização do dinheiro investido pode vir de diversas diretrizes que são pré acordadas na hora da aplicação financeira. Na renda fixa por exemplo é possível projetar o ganho no momento da aplicação, já na renda variável não há uma garantia de retorno ao investidor, o ativo pode se valorizar ou desvalorizar dependendo de diversos fatores externos como o interesse do mercado.

No mercado brasileiro são comercializados diversos títulos, os principais e mais conhecidos são, Letras de Câmbio (LC), Letra de Crédito Agronegócio (LCA), Letra de Crédito Imobiliário (LCI), Certificados de Depósito Bancário (CDB), Certificado de Depósito Interbancário (CDI), que também é usado como um indexador para o rendimento de outros títulos, e Debêntures. Além destes temos o principal título e foco deste projeto que são as Ações.

2.1.1 Ações

Ações são títulos de renda variável, elas são emitidas por sociedades anônimas privadas ou públicas e representam uma parcela do capital da empresa que a emitiu. São comercializadas na bolsa de valores, e podem ser compradas durante o pregão.

Na compra de uma ação o investidor se torna sócio da empresa que a emitiu, e assim passa a poder receber dividendos dos lucros oriundos dessa empresa.

2.2 Mercado de capitais

Quando pensamos em mercado de capital, a primeira coisa que vêm a nossa mente é a Bolsa de valores, mas não é apenas ela que compõe o mercado de capitais, também temos corretoras de valores e outras instituições financeiras. Antes de falarmos sobre a bolsa de valores precisamos primeiro entender o que é o mercado.

O mercado de capitais nada mais é do que um sistema de distribuição dos títulos financeiros, que são emitidos por um instituição pública ou privada. Estes títulos podem ser comprados ou vendidos por empresas, investidores e intermediários.

Cada empresa pode decidir por abrir ou fechar seu capital, e tudo isso passa por diversos detalhes jurídicos e administrativos, uma vez finalizado a empresa começa a negociar seus ativos na bolsa de valores e os investidores decidem por comprar ou vender seus papéis, dessa maneira o mercado permite a circulação de capital e custeia o desenvolvimento econômico dessa empresa.

Spritzer & Spritzer (2013 p.35) disseram que os participantes dos mercados de capitais podem ser divididos em dois grupos: os que regulam e supervisionam, como a CVM e as bolsas de valores; e os que operam, como os investidores e as instituições financeiras, além de empresas de capital aberto.

2.3 Bolsa de Valores e Mercado de ações

De acordo com Silva (2016), ninguém tem certeza absoluta de onde nasceu o conceito de bolsa de valores. Durante a transição da Idade Antiga para a Idade Média onde

eventos marcantes na história em geral, oriundos da queda do Império Romano do Ocidente, do movimento da nobreza e do clero para a manutenção do poder e da intensificação das trocas comerciais entre as nações, surgiu a necessidade dos empresários e demais representantes comerciais da época realizarem encontros com foco nas trocas comerciais. Registros apontam que essa necessidade se intensificou no século XII, na Europa.

Segundo Ruiz (2003), citado por Silva (2016, p. 176), a bolsa de valores teve seu início na Roma Antiga. Para outros historiadores, ela teve início na Grécia Antiga, em civilizações mais remotas onde os comerciantes se reuniam nas grandes praças para negociar suas mercadorias. O certo é que as bolsas de valores surgiram há muito tempo com atribuições bem diferentes das bolsas de hoje.

É possível notar que a finalidade da bolsa de valores de hoje tem sua origem em um contexto de trocas comerciais, assim podemos dizer que a bolsa de valores está relacionada a uma idéia de negociação e troca de mercadorias entre seus usuários.

A bolsa de valores, possui a finalidade de fazer crescer o mercado de capitais, focando na compra ou venda de ações e títulos que representam o capital da empresa que os emitiu. Dessa forma, o comprador que optar por investir seu capital em ações de determinada empresa ou organização possuirá uma participação no lucro ou no prejuízo da empresa, são os chamados acionistas, que compram ou vendem essas ações em um salão de negociações, que é chamado de pregão.

Podemos observar atualmente com a evolução da tecnologia que essa negociação e troca de mercadorias pode ser realizada online, durante os chamados pregões eletrônicos.

> Hoje, essa negociação de compra e venda pode ser feita de duas maneiras: no pregão físico ou no eletrônico. O pregão físico é o tradicional, o da gritaria no saguão da bolsa. Mas esse sistema "viva-voz" vem perdendo espaço para o pregão eletrônico, que em 2004 foi responsável por 90% dos negócios da Bovespa - a bolsa paulista. "A tendência é que o pregão físico seja extinto. A formação de blocos econômicos dificulta os negócios em um só lugar. Prova disso é a Bovespa, que já teve quase mil operadores e hoje não chega a ter cem", diz o ex-operador José Budeu (COELHO, 2013, s.p.).

2.4 A Bolsa de Valores no Brasil

Durante o período em que o Brasil ainda era colônia, as relações comerciais foram se acentuando devido ao grande fluxo de mercadorias entre o Brasil e a Europa. Com a chegada da família Real no Brasil, o mercado nacional se valorizou, e durante o século XIX foi inaugurada no Rio de Janeiro a primeira bolsa de valores do País.

Segundo Reis (2019), a Bolsa de Valores do Rio de Janeiro foi a primeira bolsa de grande importância a ser fundada no Brasil, Nessa época os pregões eram realizados ao ar livre e os corretores ficaram conhecidos como "Zangões".

Alguns anos depois foi fundada outra Bolsa de Valores conhecida no Brasil, a Bolsa de Valores de São Paulo, conhecida na época como a Bolsa Livre. De acordo com Cultura Mix (2013), Foi apenas no ano de 1895 que começaram a ser realizadas as atividades de negociação da Bolsa de Fundos Públicos de São Paulo. Após aproximadamente quatro décadas de atuação essa bolsa passou a ser chamada de Bolsa Oficial de Valores de São Paulo. Já no ano de 1967, o nome mudou para Bolsa de Valores do Estado de São Paulo (Bovespa), se mantendo até hoje.

2.5 Bovespa

A BM&F (Bolsa de Mercadorias e Futuros) foi criada no ano de 1986, e foi o resultado da junção de duas bolsas que já existiam e atuavam no Brasil, a Bolsa Mercantil de Futuros e a Bolsa de Mercadorias de São Paulo. Na BM&F são negociados contratos de commodities dentre os quais alguns se destacam, como o café, o gado e o algodão. Depois de alguns anos de atuação essa bolsa foi unida a Bovespa e se tornou a BM&FBovespa.

Após a fusão da BM&F com a Bovespa foi fundada a B3 (iniciais de Brasil, Bolsa, Balcão), a bolsa de valores oficial do Brasil. A B3 está ligada a todas as bolsas de valores do Brasil, seu indicador de referência é o Ibovespa. Além de ser responsável por todas as bolsas, a B3 também está listada no mercado, ou seja, é possível comprar papéis da B3 durante o pregão.

2.6 Índice Bovespa

O Índice Bovespa (Ibovespa) é um indicador de desempenho médio que avalia a cotação das ações negociadas na B3. Ele é formado pelas ações que possuem o maior volume de papéis negociados nos últimos meses.

Na B3, os investidores podem negociar ações de empresas variadas, atualmente a B3 possui aproximadamente de 400 empresas diferentes com capital aberto. E para se ter um indicador que represente de uma maneira eficiente e fiel como o mercado está se comportando, foi criado o Ibovespa.

O índice é uma formação de uma suposta carteira de investimentos composta por 66 ações, retratando a movimentação dos principais papéis que são negociados ao dia na B3, dessa maneira é possível representar não apenas o como se comportam os preços das ações, mas também o perfil das negociações observadas durante o pregão.

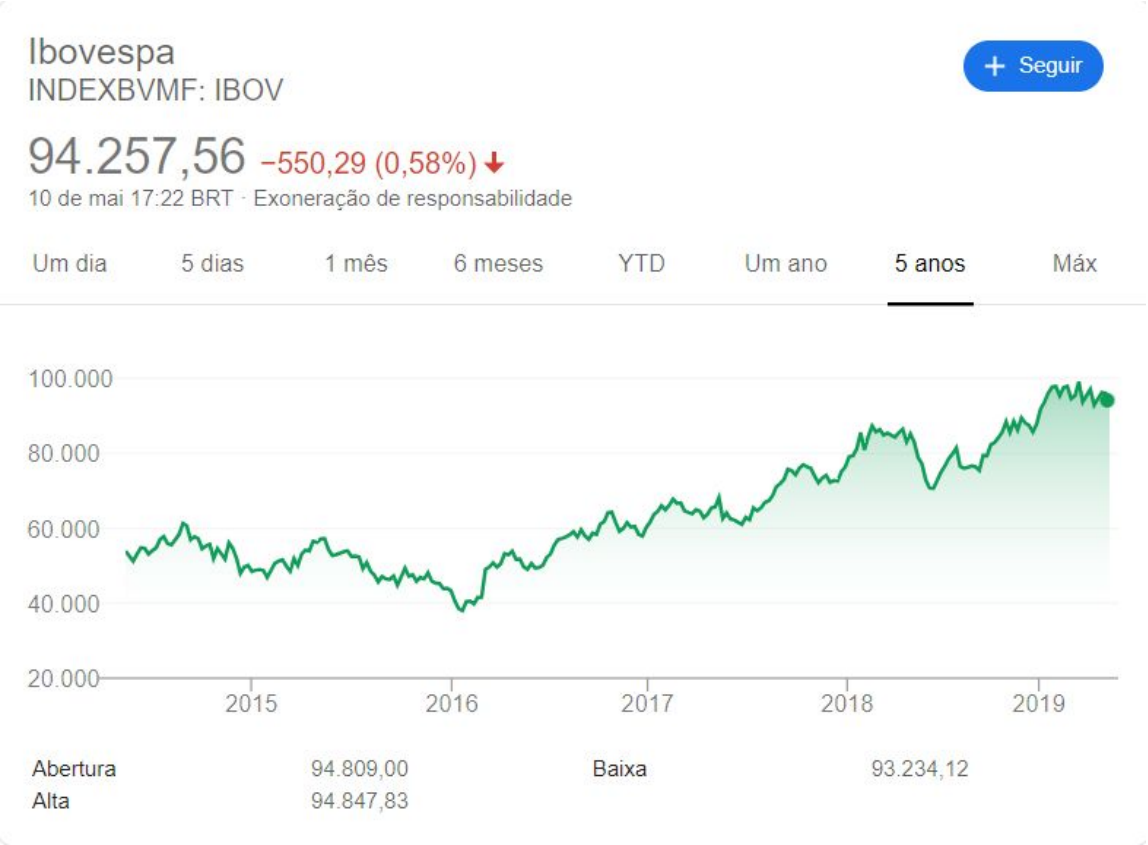

Figura 1: Evolução do índice nos últimos 5 anos. Fonte: Google (mai. 2019)

2.7 Ações

De acordo com o site XPinvestimentos (2019) as ações representam uma fração do capital social de uma empresa. Quando o investidor compra uma ação, ele se torna sócio dessa empresa, ou seja, sócio do negócio. Dito isso este investidor corre os mesmos riscos desse negócio, assim como participa dos eventuais lucros e prejuízos que essa empresa possa ter.

A pessoa que compra uma ação na Bolsa de Valores está obtendo uma pequena parte de uma empresa, e assim passa a ser chamado de acionista minoritário.

Investir em ações é classificado como um tipo de renda variável, pois não há como saber com 100% de certeza qual será o ganho que o investidor irá obter ao final do período investido. Como o mercado é dinâmico, os compradores e vendedores ajustam o preço durante o pregão.

Quando o investidor busca obter lucro a curto prazo ele está mais sujeito aos ruídos do mercado, ou seja, a uma maior variação do valor das ações, porque o mercado está sofrendo constantes oscilações.

Para obter lucro na bolsa de valores o investidor pode aplicar para receber dividendos ou rendimentos, ou praticar a compra e venda dos ativos após a valorização deles.

Dividendos ou Rendimentos são valores que as empresas pagam para seus acionistas, em FIIs (Fundos Imobiliários) o investidor ao comprar um papel ele recebe os rendimentos relativos ao empreendimento no qual ele está investindo, ou seja, mensalmente ele recebe os valores relativos àquele Fundo.

Já os dividendos, são valores a serem recebidos de empresas, por exemplo, se o investidor comprar papéis do Itaú (ITUB4) ele receberá parte dos lucros que o banco pagará aos seus acionistas. Para os dois tipos de recebíveis o investidor receberá um valor relativo ao capital investido nesses papéis.

2.8 Análise de Ações

Analisar ações é um meio de tentar prever variações e obter bons resultados. Através da observação e estudo o investidor poderá tentar medir flutuações nos valores das ações e assim tentar obter lucro acreditando que aquele papel possa desvalorizar, ou decidir vender algum papel que possua sabendo que o mesmo irá desvalorizar.

Para realizar esses estudos o investidor pode optar por duas técnicas mais utilizadas atualmente, as análises Técnica e a Fundamentalista.

2.9 Análise Técnica

Debastiani (2008 p.26) diz que a análise Técnica é um conjunto de métodos e ferramentas que busca por meio de observações do comportamento passado do mercado, identificar tendências para o futuro.

Com esses indicadores de probabilidade o investidor pode decidir o que fazer com seus negócios, e tomar uma decisão de quais papéis tendem a valorizar ou desvalorizar. Assim o investidor consegue lucrar comprando e vendendo os papéis.

Para realizar a essa observação existem duas ferramentas de análise que podem ser utilizadas, as análises técnicas, empírica e estatística.

2.9.1 Análise técnica empírica

Este é o meio mais antigo de análise, se baseia na observação de fatos repetitivos que existam no mercado. Possui um certo grau de confiabilidade devido a sua presença constante e repetida no mercado.

2.9.2 Análise técnica estatística

Método mais recente, se baseia em modelos matemáticos e estatísticos com informações vindas da evolução do mercado ao longo dos anos, como por exemplo o preço dos papéis e o volume de negócios.

Alguns meios de se realizar uma análise técnica é se baseando em informações obtidas através de gráficos. Dentre estes podemos citar os quatro a seguir:

Gráfico de barras

- Utilizado para representar um período temporal, é representado através de uma barra formada por um traço vertical, a ponta superior indica o preço máximo que a ação obteve durante o período e a inferior o preço mínimo. O valor de inicial do período é representado por um traço horizontal no lado esquerdo da barra, e o valor de fechamento do período é representado como um traço direito a barra.

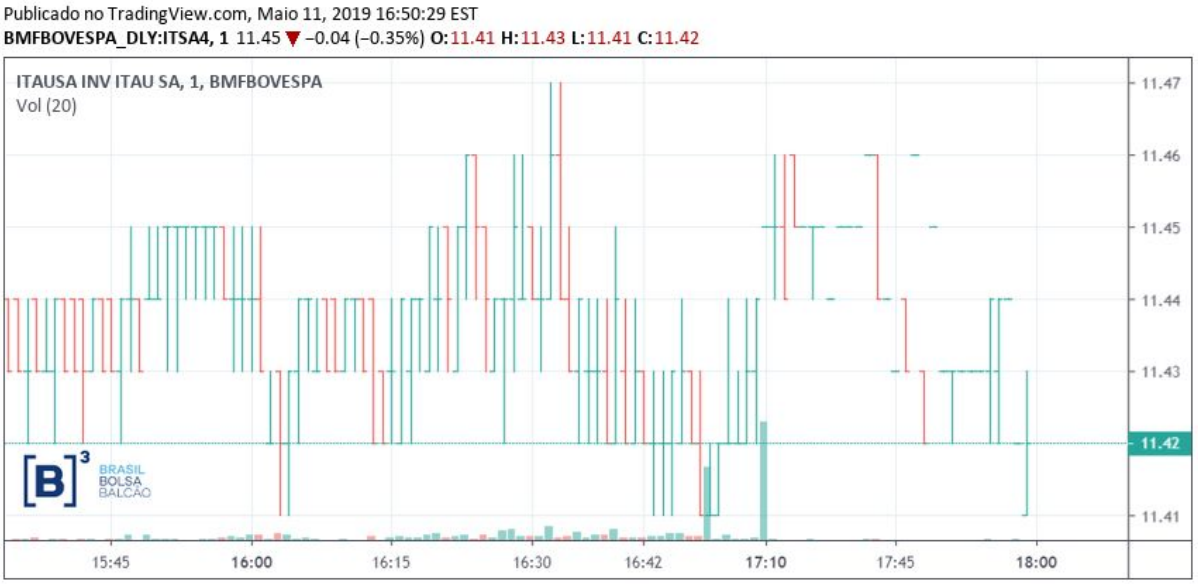

Figura 2: Gráfico de Barras. Fonte: B3 (mai. 2019)

Gráfico candlestick

- De origem japonesa, o gráfico de candlestick (em português, gráfico de velas) também representa os preços na forma de barras verticais, porém diferentemente do gráfico de barras ele possui um corpo mais largo para representar a variação do preço, e também representa a distância entre os preços de máxima e mínima com um traço mais fino.

Figura 3: Gráfico de Candlestick. Fonte: B3 (mai. 2019)

Gráfico de linhas

- O gráfico de linhas consiste apenas na marcação dos valores para o período selecionado. Cada ponto do gráfico de linha representa o valor do momento escolhido, e é ligado ao valor anterior formando ao longo da escala horizontal uma linha de forma irregular, subindo e descendo de acordo com as oscilações de valores que o papel sofreu.

Figura 4: Gráfico de Linhas. Fonte: B3 (mai. 2019)

Gráfico de colunas

- Representado na parte inferior dos outros gráficos apresentados, o gráfico de colunas representa o volume de operações negociadas durante o pregão, respondendo ao volume de vendas e compras do papel selecionado.

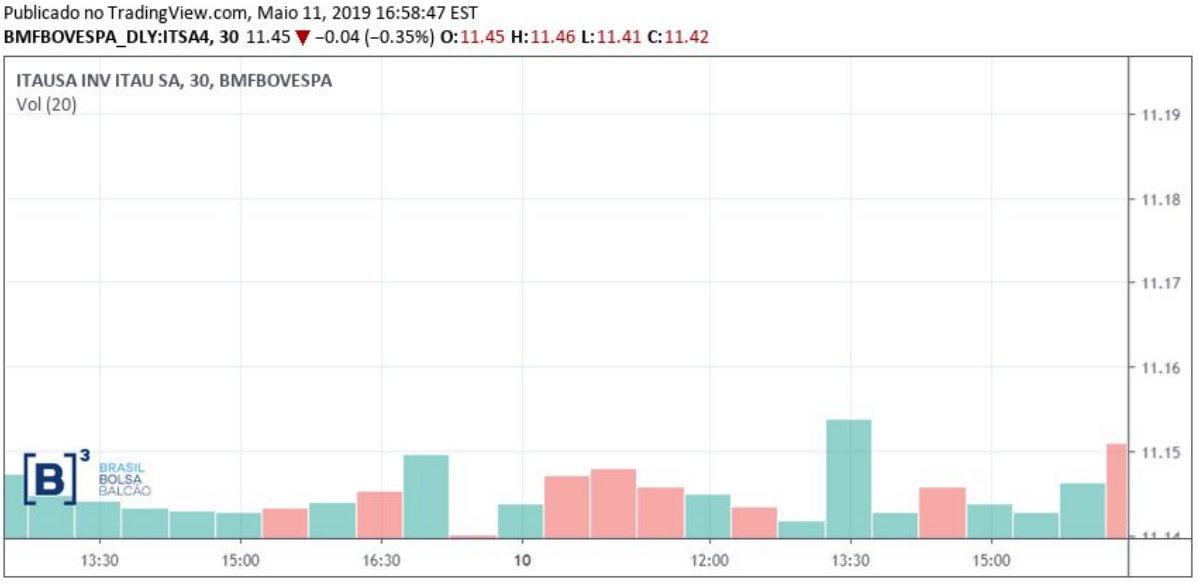

Figura 5: Gráfico de Colunas. Fonte: B3 (mai. 2019)

2.10 Análise Fundamentalista

A análise Fundamentalista é um estudo dos fatores que podem afetar as situações de uma empresa no mercado com o objetivo de determinar o valor de uma ação. Com esse estudo o acionista é capaz de fazer um levantamento do preço que o ativo deveria ter com seu preço real no mercado, classificando-o como opção de compra ou venda.

Com esse estudo pode-se dizer que a análise determina qual ativo o investidor deve comprar ou vender, essa análise não indica quando é o tempo certo para entrar ou sair do mercado.

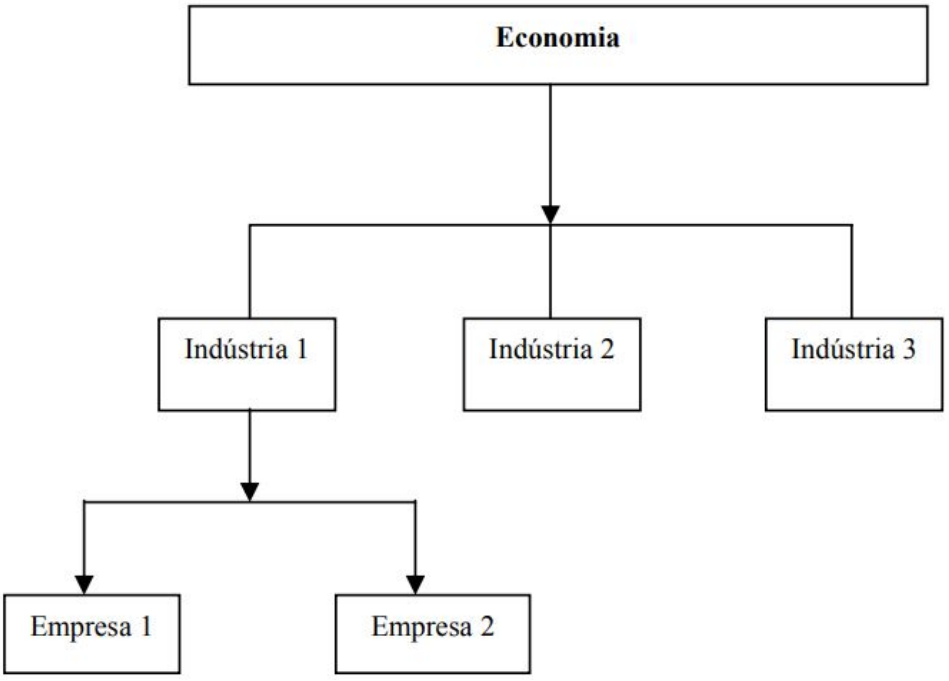

Figura 6: Componentes da análise fundamentalista. Fonte: Winger e Frasca (1995) citado por Chaves (2004, p. 17)

Spritzer e Spritzer (2013, pg.51) indicam que em uma análise fundamentalista os indicadores a serem estudados podem ser divididos em dois grupos: de balanço e de mercado.

Os indicadores de balanço são aqueles que indicam apenas as informações contidas em demonstrações financeiras consolidadas: balanço patrimonial e demonstração de resultado, esses resultados são publicados periodicamente e refletem diretamente no valor das ações.

Já os indicadores de mercado utilizam as informações de balanço mais os dados do mercado, portanto seu valor se altera diariamente.

2.11 Fintechs

Quando se fala em novas tecnologias para investimentos temos de citar a recente explosão de startups financeiras no Brasil, nos últimos anos nasceram diversas empresas como Nubank, GuiaBolso, Creditas, XP, entre outras.

A popularização das startups despertou interesse no mercado em geral trazendo inclusive novos investidores. Em São Paulo temos a FIP (Fundo de Inovação Paulista) que investe capital de risco em empresas nascentes no estado, de acordo com MARQUES (2018) o fundo investiu R$105 milhões e pretende encerrar as operações em Dezembro de 2021 devolvendo R$420 milhões aos investidores, quadruplicando o capital investido. É interessante correlacionar o grande investimento da FIP com o fato de que a capital de São Paulo hoje é, atualmente, o maior polo tecnológico no Brasil contando com 52% das empresas avaliadas pela FIP, seguido por Campinas e Ribeirão Preto-Jaboticabal com 8% e 4% respectivamente.

O grande crescimento das fintechs se deu, em grande parte, pelo atraso na evolução do mercado financeiro, que durante muito tempo ficou preso no passado. Tais fintechs trazem como grande aliado o mundo digital e o grande foco nos jovens, que desejam praticidade e velocidade nas suas interações, tais interações que ainda hoje são arcaicas nas empresas tradicionais do ramo.

> Considerada como uma ameaça aos bancos, as Fintechs surgiram com o intuito de revolucionar o mercado financeiro. Isso não significa o fim do setor bancário e demais instituições financeiras, porém é uma

> concorrência de alta qualidade que promove mudanças variadas e foco no cliente (FERREIRA; SILVA; JUNIOR; PORTUGAL, 2017).

Hoje, com a grande expansão das Fintechs no mercado, o investidor consegue operar na bolsa de valores fora dos grandes bancos, obtendo assim taxas menores de custódia, transação, entre outras. Isso acaba por atrair investidores mais inexperientes para o mundo das ações, pessoas que estão dispostas a correr riscos maiores em busca de uma diversificação de sua carteira de investimentos e que com o auxílio das Fintechs obtém um acesso simplificado de como investir nesse mercado novo.

2.12 Algoritmos de aprendizado de máquina

Existem diversas técnicas para se aplicar em aprendizado de máquina, dentre os estudados para entender melhor o HMM estão os algoritmos que serão mostrados nessa seção. Falaremos sobre aprendizado de máquina, árvores de decisão, algoritmos de predição, rede neural e SVM.

2.12.1 Aprendizado supervisionado e não supervisionado

É possível treinar um modelo de inteligência artificial de duas formas, supervisionada e não supervisionada. A diferença entre os dois tipos está no fato de que aprendizado supervisionado se baseia no conhecimento do resultado esperado.

Dessa forma podemos entender que o aprendizado supervisionado busca aprender uma função que com base em um conjunto de dados de entrada fornece a saída esperada.

Por outro lado o aprendizado não supervisionado não possui nenhuma identificação que nos permita saber o resultado esperado, assim, o intuito desse tipo de aprendizado é inferir com base na estrutura dos dados presentes.

2.12.2 Árvore de decisão

Uma árvore de decisão é um modelo de classificação estruturado em forma de árvore, que é fácil de entender, e pode ser eficientemente induzido a partir de dados. A indução de árvores de decisão é uma das técnicas mais antigas e populares para aprender modelos discriminatórias, que tem sido desenvolvido de forma independente nas

comunidades de estatística e de aprendizagem de máquina. (SAMMUT e WEBB, 2011) citado por RAMOS (2016, p. 124).

Os nós da árvore representam condições e as arestas possíveis saídas da condicional, dessa forma a navegação na árvore de decisão passa por nós e arestas até que se chegue em uma das folhas.

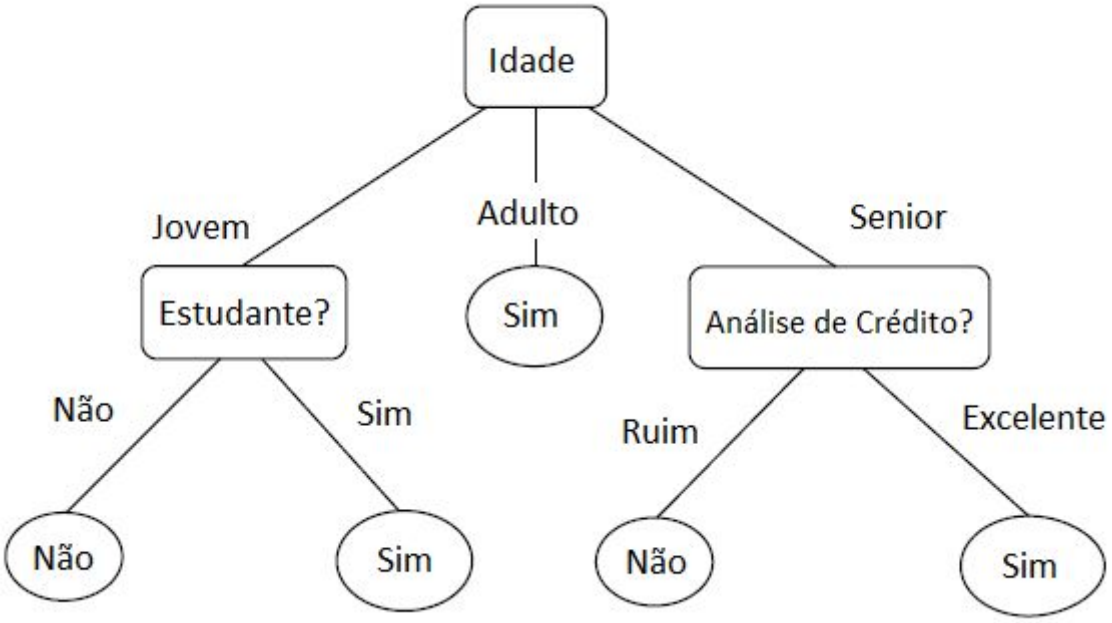

Figura 7: Representação de uma árvore de decisão. Fonte: Ramos (2016)

O ponto final da árvore de decisão representa a resposta final, essa estrutura é útil sempre que se tem resultados conhecidos após todas as etapas condicionais.

2.12.3 KNN

K Nearest Neighbors é um dos algoritmos mais simples de classificação, sua premissa se baseia em classificar uma entrada com base na menor distância entre a entrada e seus vizinhos, de tal forma que os vizinhos de menor distância e que possuam em sua maioria o mesmo tipo definem a classificação da entrada.

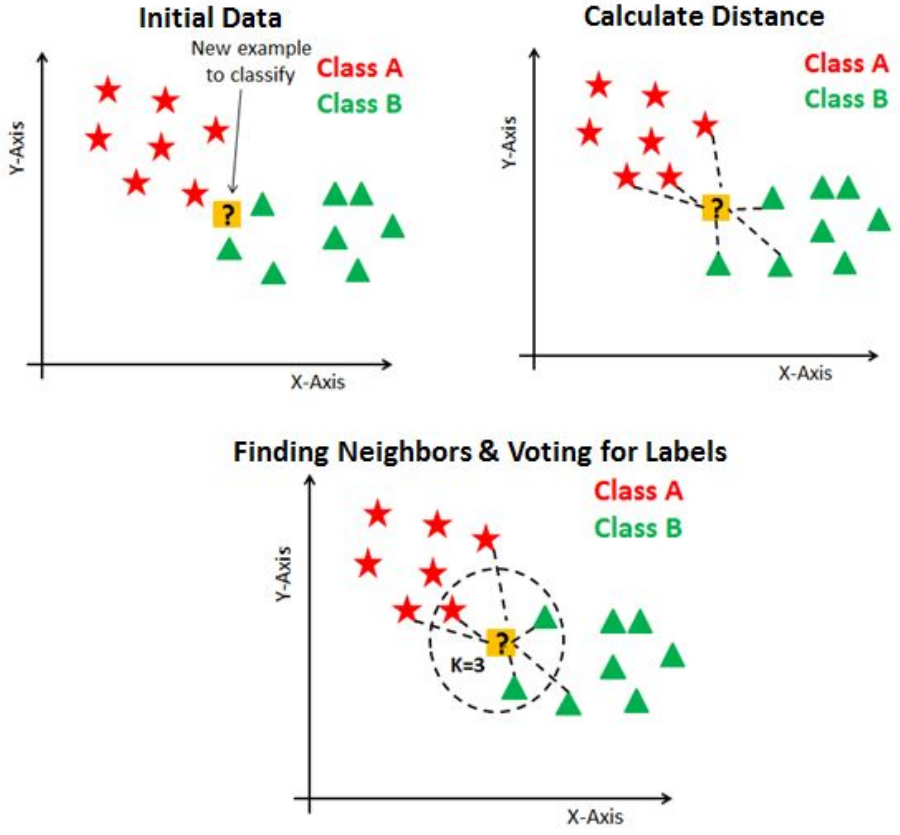

Figura 8: Metodologia do KNN. Fonte: Datacamp (2018)

A letra K em K Nearest Neighbors define o total de K vizinhos que o algoritmo irá considerar para a classificação. É importante realizar alguns testes com diferentes valores de K e analisar a curva de erro do conjunto de validação para determinar o valor que pode ser considerado como ótimo para a variável K para evitar um sobreajuste, ou seja, evitar que o modelo se ajuste muito bem ao conjunto observado, pois isso torna ineficiente o método para prever novos resultados. Um valor muito alto de K pode acabar invalidando todo o modelo por realizar um sobreajuste.

Quando se possui uma grande quantidade de recursos o KNN pode não funcionar muito bem, isso se deve a *Maldição da Dimensionalidade*, que faz com que quanto mais recursos forem utilizados, maior a quantidade de dados que deverá ser utilizados, segundo NAVLANI (2018) para lidar com esse problema, é necessário executar a análise dos componentes principais antes de aplicar qualquer algoritmo de aprendizado de máquina ou utilizar a abordagem de seleção de recursos.

2.12.4 LVQ

O algoritmo KNN pode ser considerado pouco otimizado para processos grandes, pois cada vez que uma predição vai ser realizada todos os dados precisam ser recalculados pela máquina para obter uma aproximação e resposta. O LVQ utiliza uma proposta semelhante porém mais otimizada que o KNN.

Segundo BROWNLEE (2016), o Learning Vector Quantization (LVQ) é um algoritmo de rede neural artificial que permite que se decida quantas instâncias de treinamento irão ser executadas e nos permite visualizar como essas instâncias se parecem.

Na primeira etapa de sua execução, o LVQ realiza um treinamento em cima dos dados pré-determinados que o sistema possui, durante esse treinamento cada resultado é separado dentro de um vetor de neurônios, de tamanho NxN, onde N é a quantidade de classes distintas no banco de datas.

Através do treinamento, que pode ser executado diversas vezes para aumentar a precisão, cada neurônio é ajustado com um valor relativo a classe a qual ele pertence. Esta matriz de neurônios pode ser salva para ser utilizada novamente quando necessário, não precisando assim realizar um novo processamento a cada previsão.

Após estar concluída sua matriz de neurônios deve-se entrar com os dados do que se planeja prever, que através dos cálculos de distância euclidiana entre os neurônios e um raio pré determinado no programa, ver em qual destes os dados novos se enquadram melhor.

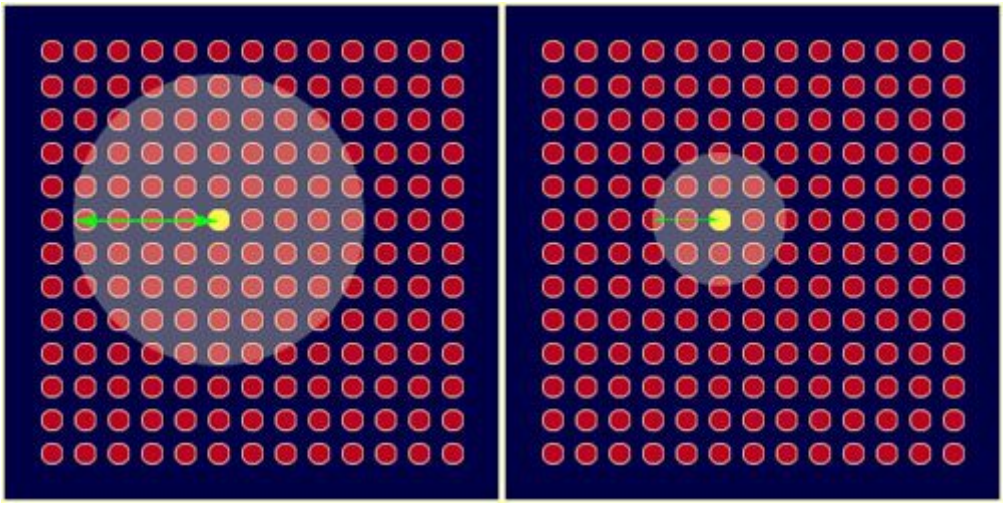

Figura 9: Rede Neural LVQ. Fonte: Caparrini (2017)

A figura 9 mostra exatamente onde os dados novos se localizam na matriz de neurônios, e como o raio é determinante na escolha de sua possível classe, quanto maior o raio maior o número de neurônios a ser comparado em determinada região.

Após determinar quais são os neurônios vizinhos, é contada a quantidade de classes pertencentes a cada vizinho, e o programa sugere que o dado de entrada provavelmente pertence a esta classe.

2.12.5 Redes Neurais

Redes neurais são um modelo computacional no qual sua arquitetura visa imitar a capacidade de aprendizado do cérebro humano. Os nós de processamento de uma ANN e suas interconexões lembram as operações internas e a estrutura de neurônios do cérebro humano.

Cada conexão na ANN contém um peso que demonstra a força de sua conexão com a próxima camada, quanto maior o peso, maior será a influência do nó atual em seu nó subsequente.

Os pesos de um nó podem ser positivos ou negativos, indicando um reforço do dado contido ali ou a inibição do mesmo respectivamente, e serão alterados conforme necessário

durante o período de treinamento com o intuito de aproximar a taxa de erro ao limite desejado. Normalmente os pesos da rede neural são inicializados com valores aleatórios.

Figura 10: Pesos entre conexão de neurônios. Fonte: Egeli, Birgul; Ozturan, Meltem; Badur, Bertan (2019)

Um modelo bastante comum de rede neural são as redes feed-forward (DORMEHL, 2019), neste modelo temos uma série de elementos de entrada que serão propagados para uma ou mais camadas intermediárias chamadas de Hidden Layers (em português, Camadas Escondidas) e ao final do processo temos a camada de saída.

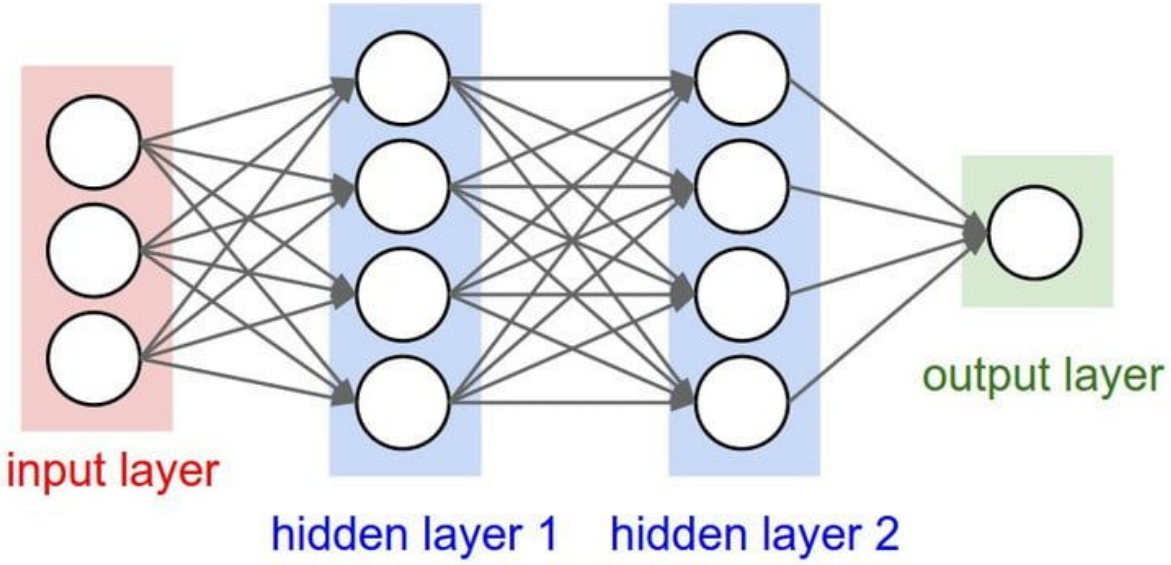

Figura 11: Camadas de Rede Neural. Fonte: Dormehl, Luke (2019)

De maneira geral deve-se seguir as seguintes etapas para utilizar uma ANN:

- *Coleta de dados*

  Parte fundamental do processo, por servir de base para que seja possível treinar o modelo criado, uma vez que uma grande massa de dados é necessária, tal volume de dados pode ser extraído utilizando crawlers ou APIs web que retornem os valores necessários.

- *Pré processamento dos dados*

  Nessa etapa é feito o tratamento dos dados que foram coletados na etapa anterior a fim de deixá-los no formato necessário para os próximos processamentos, podemos, por exemplo, retirar informações extras que não serão utilizadas nos próximos passos, assim como identificar possíveis Outliers (valores que fogem dos padrões) contidos no conjunto.

- *Desenvolvimento do modelo*

  Essa etapa é a de maior experimentação, o objetivo é criar um modelo capaz de inferir o resultado final, para tanto é necessário um tratamento empírico para a combinação de parâmetros de entrada a fim de gerar a maior porcentagem de acerto.

- *Teste do modelo*

  O modelo desenvolvido na etapa anterior é treinado com a massa de dados coletada na primeira etapa, testado e validado de acordo com os resultados esperados.

As etapas de desenvolvimento e teste do modelo e geral são repetidas ciclicamente até que se alcance a porcentagem de acerto desejada, caso não tenha alcançado as expectativas o modelo volta para o estado de desenvolvimento para alterações nos parâmetros de entrada e será validado novamente.

2.12.6 SVM

Support Vector Machines (SVM) é um algoritmo de aprendizado de máquina onde na maioria das vezes é utilizado para resolver problemas de classificação. Esse algoritmo separa cada dado de entrada como um ponto de espaço n-dimensional (onde N é o número de características do modelo) onde o valor de cada característica é o valor de uma coordenada única. (RAY, 2017). Para o SVM detectar padrões e fazer a separação da entrada em diferentes grupos o algoritmo utiliza um hiperplano afim de maximizar a margem entre os conjuntos de dados. O SVM pode ser dividido em dois grupos, lineares e não lineares.

As SVMs lineares com margens rígidas definem fronteiras lineares a partir de dados linearmente separáveis (LORENA; CARVALHO, 2007, p. 53), ou seja, são capazes de separar diferentes grupos linearmente traçando uma reta de tal forma que os N grupos fiquem separados com a maior margem entre o hiperplano e os grupos. Somente é possível utilizar essa técnica quando o conjunto de dados é linearmente separável, como mostra a figura abaixo.

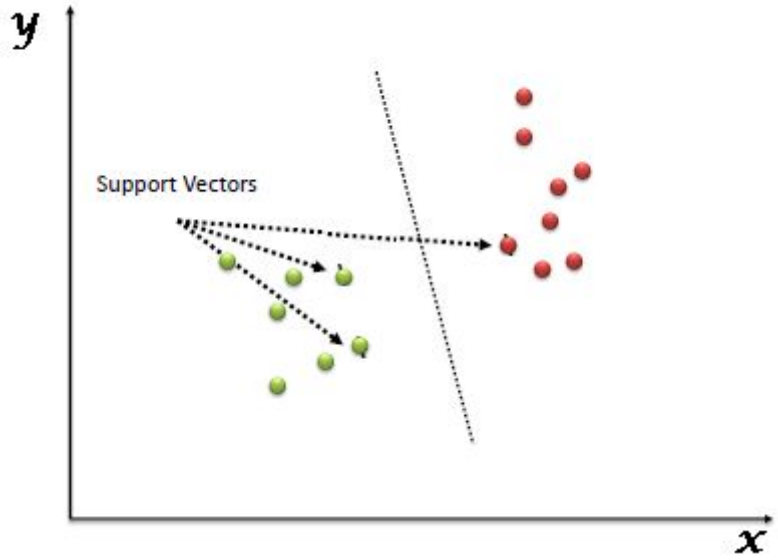

Figura 12: Representação de uma SVM linear. Fonte: Ray (2017)

SVM não lineares podem ser utilizadas quando os grupos não podem ser separados linearmente, para que seja possível fazer a separação é necessário mapear o conjunto de

dados de entrada para um espaço de maior dimensão do que o espaço original, podem assim traçar um hiperplano separador na dimensão superior. Essa separação pode ser feita através das funções de núcleo, que estão diretamente relacionadas com o conceito de transformação linear. (CASTRO, 2018. p. 19).

Segundo RAY (2017), As SVM utilizam Kernel Functions (Funções de kernel) para mapear o conjunto de dados de entrada para o plano de maior dimensão. É possível utilizar a biblioteca em python Scikit Learn, que dentre outras funcionalidades nos permite trabalhar com SVM e fornece as seguintes funções de kernel: Linear, polinomial, função de base radial e senoide.

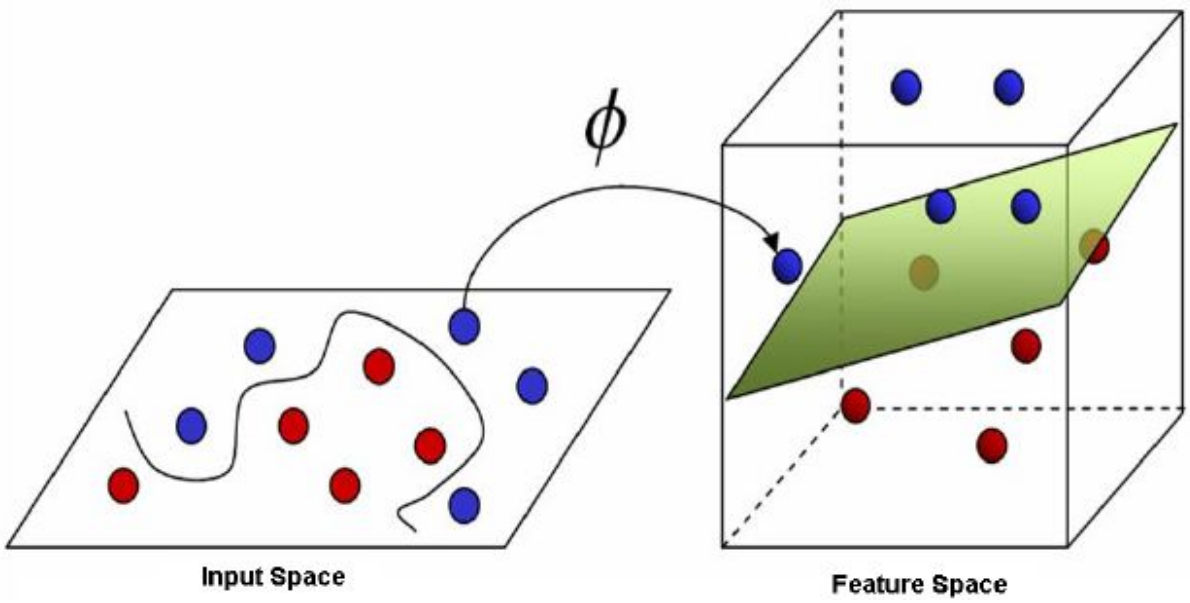

Figura 13: Representação de uma SVM não linear. Fonte: Moreira (2011)

2.13 HMM (Modelo Oculto de Markov)

GHAHRAMANI (2001) disse que o Modelo Oculto de Markov (HMM) é uma ferramenta utilizada para representar distribuições de probabilidades em uma dada sequência de observações.

O HMM deriva da utilização de duas outras técnicas, o modelo estatístico de cadeias de Markov e a utilização de Hidden Layers. Dessa forma o sistema a ser modelado

deve poder ser compreendido por cadeias de Markov e possuir estados ocultos que auxilia a direcionar as probabilidades aos estados finais.

Segundo ESPINDOLA (2009), Modelos Ocultos de Markov são usados na modelagem de processos Markovianos que geram observáveis de forma indireta, em função das transições entre os estados da cadeia de Markov que governa o processo, mas que não pode ser diretamente observada.

2.13.1 Cadeias de Markov

Para compreender melhor a maneira que o HMM funciona necessitamos de uma breve explicação sobre cadeia de Markov. O HMM é baseado no aumento da cadeia de Markov, a cadeia de Markov é um modelo que nos diz algo sobre as probabilidades de uma sequência aleatória de variáveis e estados, cada qual pode nos levar a valores de um determinado conjunto. Esses conjuntos podem ser palavras, tags ou símbolos que representem o que aquele conjunto quer nos mostrar. JURAFSKY & MARTIN (2007) dizem que a cadeia de Markov faz uma suposição em que se quisermos prever o futuro na sequência, tudo que importa é o estado atual. É como se fosse para predizer o clima de amanhã, podemos examinar o estado do clima hoje, mas não poderíamos olhar como estava o tempo ontem.

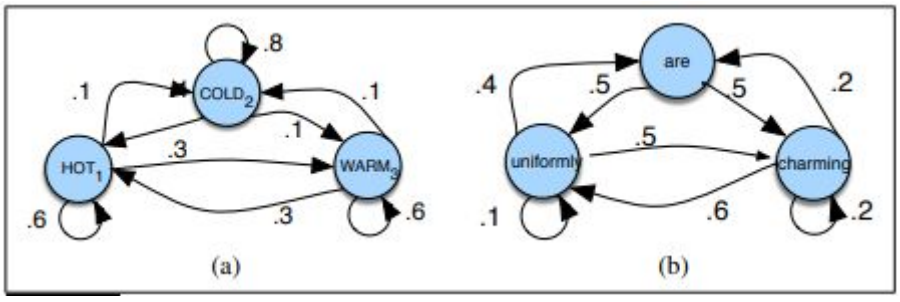

Figura 14: Exemplo de cadeias de markov, (a) representa o clima. (b) representa conjunto de palavras. Fonte: JURAFSKY; MARTIN (2007).

2.13.2 Definição do HMM

Modelos Ocultos de Markov são usados na modelagem de processos Markovianos que geram observáveis de forma indireta, em função das transições entre os estados da cadeia de Markov que governa o processo, mas que não pode ser diretamente observada. (ESPINDOLA, 2009).

Isso quer dizer que existem no HMM estados ocultos. Sendo assim podemos dizer que a grande diferença entre modelos Markovianos e HMM está na observação dos estados, enquanto em modelos de Markov a observação é feita de forma direta, no HMM ela é feita de maneira indireta, por inferência, onde o que o observador têm são apenas funções de probabilidades ou transições entre os estados conhecidos.

Existem alguns conceitos básicos que fazem parte do HMM, são eles (KUINCHTNER; MADALOZZO, 2018):

A. Um conjunto de N estados S = {s1, s2, s3, · · · , sN }
B. Um número N de observáveis M = {m1, m2, m3, … , mN}, onde estes são as variáveis visíveis que dependem dos estados. Cada uma dessas observações terão probabilidades distintas para cada estado.
C. Uma distribuição A, da probabilidade das transições de um estado para o outro, estes resultados podem ser mostrados através de uma matriz de transição como a da figura abaixo.

	1	2	3	4
1	a_{11}	a_{12}	a_{13}	a_{14}
2	a_{21}	a_{22}	a_{23}	a_{24}
3	a_{31}	a_{32}	a_{33}	a_{34}
4	a_{41}	a_{42}	a_{43}	a_{44}

Figura 15: Matriz de transição de 4 estados. Fonte: KUINCHTNER; MADALOZZO (2018).

D. A distribuição da probabilidade de emissão de estado, são as probabilidades que interligam os estados ocultos com as observações conhecidas.

E. A distribuição de probabilidade inicial π de cada estado. Essa probabilidade vai ser calculada utilizando os algoritmos Forward e Backward que será tratado mais a frente.

F. λ, o modelo em si.

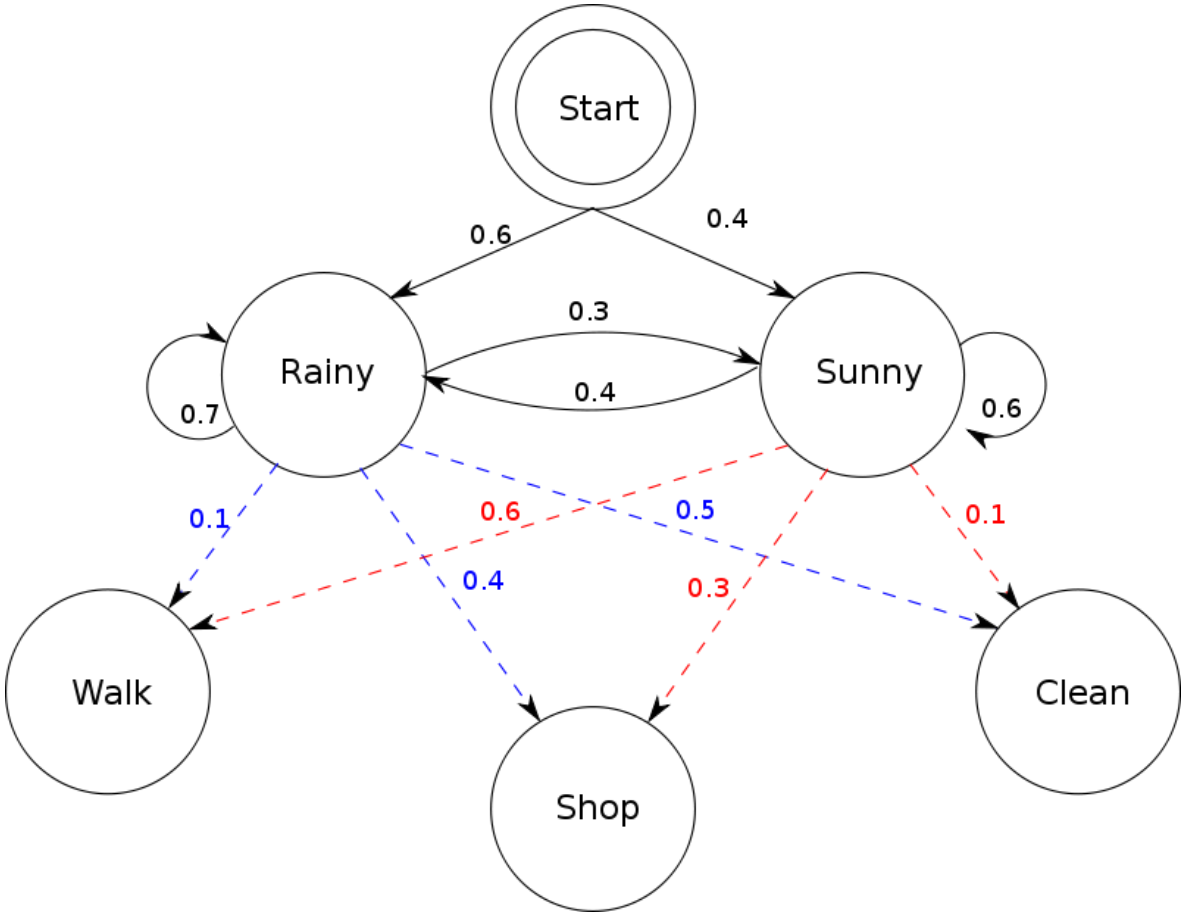

Figura 16: Representação de um HMM. Fonte: Kang (2017)

A figura 16 pode ser usada para explicar um pouco melhor o algoritmo HMM, o exemplo da figura é determinar o que uma pessoa faria durante o dia dela dependendo do clima. Para começar é determinar se está fazendo sol (Sunny) ou se está chovendo (Rainy), para isso temos as probabilidades para cada estado. Também há a probabilidade do dia se manter chovendo, ou o tempo abrir e fazer sol.

Com esses resultados basta calcular qual chance se aproxima mais dos estados finais para determinar o que a pessoa irá fazer, se está chovendo a probabilidade dessa pessoa sair para caminhar é 0.1, para fazer compras a probabilidade é 0.4, e para fazer faxina a probabilidade é 0.5. É importante ressaltar que as probabilidades somadas das transições em cada camada de estados não devem passar de 1.

Segundo Rabiner (1989), citado por Kuinchtner e Madalozzo (2018), O papel do HMM é apenas modelar a situação do que queremos obter, e para poder aplicá-lo necessitamos resolver três problemas fundamentais, são eles:

I. Problema de avaliação, nele procura-se calcular a probabilidade de uma determinada sequência de observação (O = O1, O2, … On) dado o modelo λ. Para se resolver esse problema é utilizado o algoritmo Forward e/ou Backward.
II. Problema de decodificação, nesse problema descobre-se a parte oculta do modelo para se determinar qual sequência que melhor explica as observações. Nele é utilizado o algoritmo Viterbi para encontrar a sequência mais provável de estados ocultos que irá resultar em uma sequência de eventos observados.
III. Problema de treinamento, Nesse problema é onde irá ocorrer o ajuste dos parâmetros do modelo para otimizar a probabilidade da sequência de observação. Esse ajuste é o que irá treinar o HMM, nele é utilizado o algoritmo Baum-Welch.

2.13.3 Algoritmo Forward

O algoritmo Forward é utilizado para resolver possíveis problemas de avaliação do HMM, eles utilizam uma técnica de programação dinâmica, ou seja, o algoritmo utiliza uma tabela para armazenar valores intermediários conforme ele calcula as probabilidades observadas na sequência. O algoritmo irá calcular as probabilidades observadas ao somar todas as probabilidades possíveis dos estados ocultos que podem gerar sequências de observação, mas o faz de maneira eficiente dobrando implicitamente cada um desses caminhos em uma única treliça para frente (JURAFSKY; MARTIN, 2018).

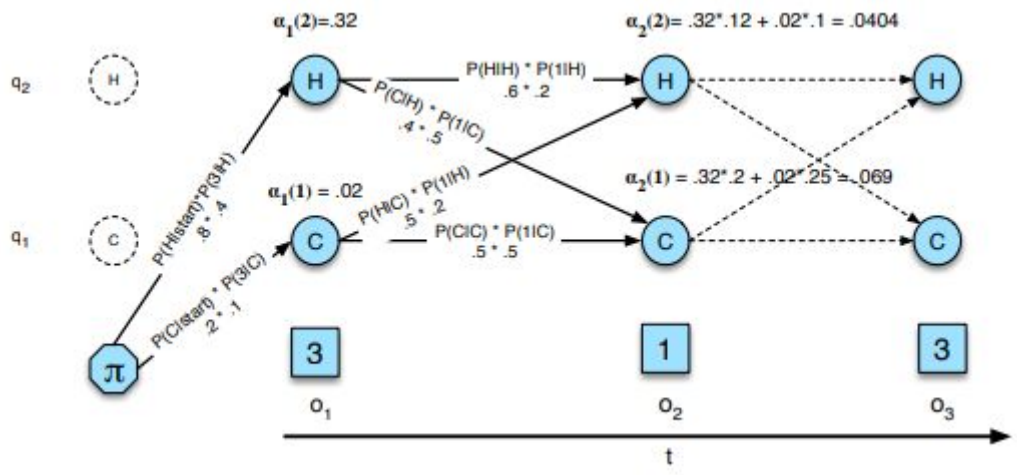

Figura 17: Algoritmo Forward. Fonte: JURAFSKY; MARTIN (2018)

Um pseudo-código para exemplificar este algoritmo pode ser representado como:

TEMPO $t = 0$

TRANSIÇÃO DE PROBABILIDADES $p(X_t|X_t - 1)$

EMISSÃO DE PROBABILIDADES $p(Y_j|X_i)$

SEQUÊNCIA OBSERVADA $y(1:t)$

PARA $t = t + 1$

$$\alpha(X_t) = p(Y_t \mid X_t) \sum_{i=1} p(X_t \mid X_{t-1}) \alpha_{t-1}(X_t - 1)$$

ATÉ $t = T$

RETORNA $p(y(1:T)) = \alpha_T$

2.13.4 Viterbi

Assim como o algoritmo Forward, o algoritmo Viterbi também utiliza programação dinâmica, ele é responsável por resolver a parte oculta do HMM, e irá obter como resultado a sequência de estados mais prováveis. A principal diferença entre o algoritmo Viterbi e o algoritmo Forward está na maneira de se determinar o estado mais provável, enquanto no Forward somamos as probabilidades que levam a um estado oculto, no Viterbi se realiza a comparação entre o maior valor obtido entre as probabilidades que levam a esses estados e se assume que o estado com maior probabilidade é o mais provável de ter ocorrido.

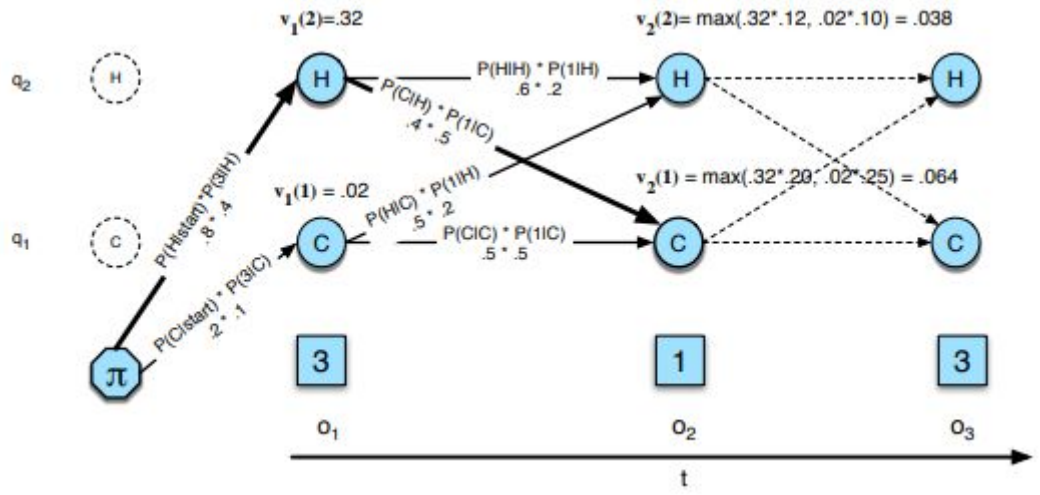

Figura 18: Algoritmo Viterbi. Fonte: JURAFSKY; MARTIN (2018)

Segundo Rabiner, citado por Espíndola (2009), o critério para resolver o problema II é o de achar a melhor, ou mais provável, sequência de estados, e o algoritmo Viterbi é a técnica formal usada nesse critério.

2.13.5 Baum-Welch

Também conhecido como Forward-backward, o algoritmo de Baum-Welch irá utilizar os parâmetros obtidos após executar os algoritmos acima de modo iterativo, e realizará um treinamento do modelo de dados, através da técnica de forward-backward que se baseia na técnica de Maximização de Expectativa, ou seja, ele obtém os parâmetros desconhecidos do modelo sobre cada iteração, realizando uma fase de estimação e outra de maximização (KUINCHTNER; MADALOZZO, 2018). Há algumas variáveis que precisam ser calculadas através das variáveis conhecidas e observáveis, e então, a fase de estimação irá determinar um valor para um parâmetro para o qual não se conhece um valor absoluto, e a etapa de maximização irá calcular os parâmetros maximizando o resultado.

2.14 Avaliação de Resultados

Para que se possa medir os resultados obtidos pelo modelo, podemos utilizar o MAPE (*Mean Average Percentage Error*), que avalia o erro percentual absoluto médio, assim ele se utiliza do preço real e atual da ação que está sendo avaliada (A), o seu preço

previsto (F) e o total de dias que se deve levar em conta (n), como exibido na fórmula a seguir.

$$M = \frac{1}{n} \sum_{t=1}^{n} \left| \frac{At - Ft}{At} \right|$$

Segundo Lewis (1997), citado por BARBOSA (2010), o MAPE é considerado como uma das medidas de erro mais usadas para se avaliar os métodos de previsão.

Também podemos utilizar para medir os resultados o *Root Mean Square Error* (RMSE), Segundo ARMSTRONG; COLLOPY (1992), ele tem sido usado frequentemente para tirar conclusões sobre os métodos de previsão. Sua fórmula utiliza as mesmas variáveis que o MAPE, ela pode ser escrita como mostrada a seguir.

$$\sqrt{\frac{1}{n} \sum_{t=1}^{n} (At - Ft)^2}$$

O RMSE calcula a média de desvio da previsão com relação ao valor real, este erro é importante já que valores maiores resultam em maior peso para a média, portanto quanto mais próximo de zero menor o erro obtido.

3 Desenvolvimento

Este capítulo apresenta uma descrição do modelo desenvolvido para realizar uma previsão do preço de ações e sua tendência, aqui será mencionado todas as tecnologias, ferramentas e metodologias utilizadas detalhadamente e também o resultado obtido com esta pesquisa.

3.1 Proposta de solução

Para resolver o problema proposto utilizamos o algoritmo HMM para prever o preço de fechamento das ações, bem como sua tendência futura. Para isso iremos *alimentar* o robô com alguns dados coletados sobre o histórico de preços de determinadas ações, e realizar uma previsão para quatro prazos, chamaremos de "Diário" a previsão para o dia seguinte, de "Curto" a previsão 3 dias seguintes, de "Médio" a previsão de preço para até 14 dias, e por fim chamaremos de "Longo" as previsões de preço para no máximo 22 dias à frente da última data obtida no histórico da ação.

Para o desenvolvimento do robô até a apresentação dos resultados, este projeto é dividido em 4 etapas: coleta de dados históricos, pré-processamento dos dados, integração com o algoritmo de aprendizado de máquina (HMM) e por fim a obtenção e análise dos resultados.

3.2 Ferramentas

Para o desenvolvimento deste projeto foi utilizado a linguagem de programação *Python 3.7.4*, python hoje é muito utilizado para desenvolver aplicações de aprendizado de máquina, principalmente pelo fato de que existem muitas bibliotecas disponíveis para auxiliar a implementação, desde a coleta dos dados até o treinamento do modelo e análise dos resultados, além disso Python é uma linguagem de fácil acesso, possibilitando que pessoas com pouco conhecimento de programação consigam desenvolver modelos.

As principais bibliotecas utilizadas para desenvolver este projeto foram, *NumPy*[1], *Pandas*[2], *HmmLearn* [3]e *MatPlotLib*[4].

NumPy fornece uma série de funções matemáticas e utilidades que facilitam e aumentam a produtividade durante o desenvolvimento, sendo considerada uma biblioteca fundamental para o desenvolvimento de projetos científicos.

Pandas fornece estrutura de dados (DataFrame) e utilidades para análise de dados, estamos utilizando-a para a leitura e conversão do conjunto de dados de cada ação.

HmmLearn é uma biblioteca de código aberto que implementa e executa a inferência de dados utilizando as técnicas do HMM apresentadas no capítulo 2.14.

E por fim a *MatPlotLib* é uma biblioteca que permite a criação de gráficos 2D.

3.3 Metodologia

Nesta etapa será descrita as principais etapas de desenvolvimento deste projeto, desde sua coleta de dados até a execução do algoritmo.

3.3.1 Coleta de dados históricos

O conjunto de dados são obtidos de duas APIs, o site *World Trading Data*[5] e o *Yahoo Finance*[6], os dois sites entregam a mesma quantidade de informações, a única diferença é o *Yahoo Finance* entregar os dados de ações brasileiras que o *World Trading Data* não possui, além disso estas APIs possibilitam que sejam obtidos dados de forma diária, semanal ou mensal.

Os dados são baixados nos formatos JSON pela API do *World Trading Data,* exibido na figura 19, e CSV pela API do *Yahoo Finance*, exibido na figura 20.

[1] https://numpy.org/
[2] https://pandas.pydata.org/
[3] https://hmmlearn.readthedocs.io/
[4] https://matplotlib.org/
[5] https://www.worldtradingdata.com/
[6] https://finance.yahoo.com/

```
1   GET /api/v1/history?symbol=SNAP&api_token=demo
2   "name": "SNAP",
3   "history": [
4     "2019-11-19": {
5         "open": "14.58",
6         "close": "15.16",
7         "high": "15.26",
8         "low": "14.39",
9         "volume": "24174179"
10    },
11    "2019-11-18": {
12        "open": "14.08",
13        "close": "14.69",
14        "high": "14.74",
15    ...
```

Figura 19. Dados coletados em JSON. Fonte: World Trading Data (2019).

Date	Open	High	Low	Close	Adj Close	Volume
2011-05-02	2,0125	2,075	2,0125	2,05625	0,79109	70000800
2011-05-03	2,0625	2,08625	2,025	2,0375	0,783877	8417600
2011-05-04	2,04	2,06	2,04	2,06	0,792533	9800800
2011-05-05	2,05125	2,05125	2,04	2,0475	0,787724	8774400
2011-05-06	2,04375	2,0475	2	2,0325	0,781953	9668000
2011-05-09	2,02625	2,03125	2,005	2,0125	0,774259	166920
2011-05-10	null	null	null	null	null	null
2011-05-11	2,03125	2,0625	2,03125	2,05	0,788686	1560000
2011-05-12	2,0275	2,0525	2,025	2,0525	0,789648	1840000
2011-05-13	2,05	2,05	2,03	2,04375	0,786281	1761600
2011-05-16	null	null	null	null	null	null
2011-05-17	2,0125	2,01875	2,0025	2,0125	0,774259	1383200
2011-05-18	2,00625	2,01625	1,97125	1,975	0,759831	5565600
2011-05-19	1,975	1,9975	1,97	1,97875	0,761274	3540800
2011-05-20	1,97625	1,99875	1,93875	1,9925	0,766564	2629600
2011-05-23	1,97	1,985	1,94375	1,985	0,763679	2188000

Figura 20. Dados da ação MGLU3 importados por CSV. Fonte: Autor.

3.3.2 Pré-processamento dos dados

O pré-processamento dos dados é importante para eliminar informações que não consideramos relevantes, na figura 20 é possível observar que em alguns dias os dados obtidos possuem valor *null*, isto acaba se tornando um problema para o algoritmo, então devemos eliminar estas informações de forma que todas as entradas nulas ou brancas sejam removidas do conjunto de dados.

A coluna Adj-Close, relacionada ao CSV obtido do *Yahoo Finance,* também é removida durante a limpeza dos dados porque não utilizamos essa informação para *alimentar* o modelo, e por último são removidos valores idênticos de abertura, fechamento, máxima e mínima para um mesmo dia, a figura 21 mostra detalhadamente um dia de um modelo o qual esses valores acontecem.

```
[ ⊖
    "2007-07-25",
    5.57334,
    5.57334,
    5.57334,
    5.57334,
    59191.0
],
```

Figura 21. Exemplo de dados idênticos para um mesmo dia, ABEV3. Fonte: Autor.

Os dados obtidos utilizando a *World Trading Data* também passam pelo mesmo processo de limpeza que os dados obtidos via *Yahoo Finance,* no entanto são convertidos para o formato de vetor seguindo a ordem, data, preço de abertura, preço de alta, preço de baixa, preço de fechamento e volume.

Por fim, o algoritmo responsável pela limpeza dos dados foi desenvolvido também em *Python* e funciona fazendo a leitura e carregamento dos dados em um *DataFrame*, após isso os dados nulos e brancos são removidos, a coluna adj close é removida caso exista e os dados são reordenados partindo do último dia conhecido, com isso feito o algoritmo converte os dados em um JSON para utilizar facilitar a leitura e carregamento para usar como entrada para o HMM. A imagem a seguir mostra os dados já limpos e convertidos em JSON.

```
[
    ["2019-11-14", 42.700001, 44.459999, 42.57, 44.25, 18068100.0],
    ["2019-11-13", 42.860001, 42.880001, 41.700001, 42.5, 22822800.0],
    ["2019-11-12", 45.200001, 45.459999, 43.07, 43.400002, 16359300.0],
    ["2019-11-11", 43.5, 45.48, 43.240002, 45.02, 11163900.0],
    ["2019-11-08", 43.509998, 44.790001, 42.950001, 43.810001, 10639700.0],
    ["2019-11-07", 45.610001, 45.900002, 44.16, 44.200001, 9778700.0],
    ["2019-11-06", 44.5, 45.299999, 43.490002, 45.200001, 11794000.0],
    ["2019-11-05", 45.32, 46.279999, 43.52, 44.040001, 18187200.0]
    ...,
    ["2011-05-03", 2.0625, 2.08625, 2.025, 2.0375, 8417600.0],
    ["2011-05-02", 2.0125, 2.075, 2.0125, 2.05625, 70000800.0]
]
```


Figura 22. Dados do CSV convertidos para JSON. Fonte: Autor.

Os dados são salvos na seguinte ordem, data, preço de abertura, preço de alta, preço de baixa, preço de fechamento e volume.

3.3.3 Implementação

Para a implementação do código foi utilizado como base o algoritmo *open source* desenvolvido por DARBHA; JAIN & MEHTA (2018), e disponível no *GitHub*[7], esse algoritmo prevê os preços do dia seguinte utilizando como base o último dia conhecido, então em um modelo de testes de 100 dias, ele subtrai do conjunto o total de dias que irá ser testado e realiza a previsão com base nesses dias subtraídos para poder comparar os resultados, basicamente ele irá prever cada um dos próximos dias com base no dia anterior já conhecido, dessa forma o valor que ele quer prever irá olhar para o valor de 50 dias atrás, D_{-50}, até o dia anterior, D_{-1}, para prever o primeiro dia após o último dado conhecido do conjunto, D_0.

A partir desse modelo base foram realizadas mudanças no algoritmo de forma que ele fosse capaz de prever N dias à frente, utilizando como antecedente as últimas previsões geradas nas iterações anteriores, dessa forma, realizando a primeira iteração para a primeira previsão, D_0, o algoritmo irá utilizar o valor existente de 50 dias atrás, D_{-50}, até o último valor conhecido, D_{-1}, e para prever o "amanhã", D_{+1}, o algoritmo irá utilizar os dados de

[7] https://github.com/ayushjain1594/Stock-Forecasting

50 dias atrás até o valor previsto anteriormente, D_{-49}, …, D_0, e repetirá essa iteração por N vezes, ou seja, por N dias. Com esses valores calculados, o algoritmo encontra o dia mais semelhante ao estado atual dentre os últimos 50 dias e a partir daí ele passa a considerar que seu próximo evento deve ocorrer de forma parecida a esse dia.

A figura 23 a seguir mostra como esses dados são obtidos para um N de 5 dias, e como são realizadas as seleções dos dados utilizando como dados passados 50 dias.

Para N = 5	50 dias						
D+0	D-50	D-49	D-48	...	D-3	D-2	D-1
D+1	D-49	D-48	D-47	...	D-2	D-1	D0
D+2	D-48	D-47	D-46	...	D-1	D0	D+1
D+3	D-47	D-46	D-45	...	D0	D+1	D+2
D+4	D-46	D-45	D-44	...	D+1	D+2	D+3

Figura 23. Exemplo de seleção dos dados para 5 dias. Fonte: Autor.

Vale mencionar que esses 50 dias ditos anteriormentes podem ser alterados para valores maiores ou menores, porém o algoritmo utilizando 50 dias têm sido o padrão que utilizamos durante o desenvolvimento.

Para a execução do algoritmo mencionado anteriormente foi utilizada a biblioteca *open-source* chamada *HmmLearn* desenvolvida em Python para realizar o treinamento do modelo e calcular a semelhança encontrada entre as observações (conjunto de dados). Para nosso problema foi utilizado o método HMM Gaussiano, utilizado para HMMs com observações contínuas, essa biblioteca implementa os algoritmos apresentados no capítulo 2.14.

Para que fosse possível interagir com o algoritmo de forma prática, foi desenvolvido em *JavaScript* uma página HTML onde podemos alterar os valores de entrada do modelo, como o total de dias que serão previstos, a quantidade de observações anteriores que serão calculadas, o total de iterações que a biblioteca irá realizar, o total de estados ocultos que desejamos informar para o *HmmLearn* e o nome da ação a qual desejamos prever. A figura 24 a seguir exibe essa página criada com algumas configurações.

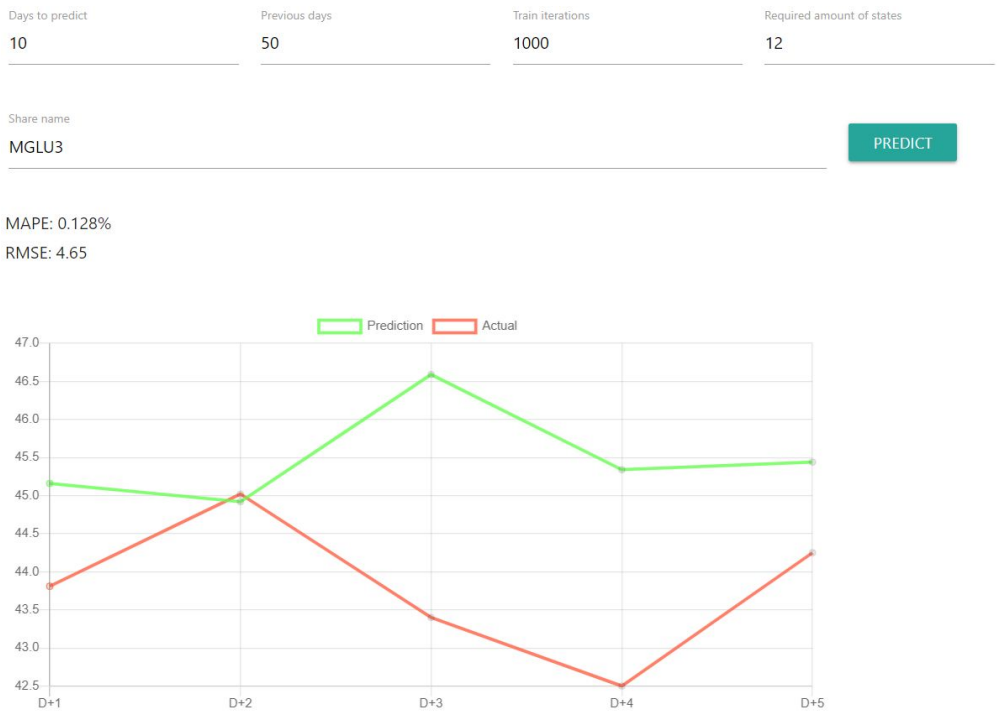

Figura 24. Exemplo de página para previsão da ação MGLU3. Fonte: Autor.

A fim de validar o modelo e saber se as mudanças sendo feitas nos parâmetros de entrada estavam sendo efetivas precisamos calcular o erro médio do modelo, para isso utilizamos dois algoritmos bastante comuns para essa finalidade.

Como dito no capítulo 2.14, o MAPE calcula a porcentagem média absoluta de erro do modelo, utilizando segue a seguinte fórmula:

$$M = \frac{1}{n} \sum_{t=1}^{n} \left| \frac{At - Ft}{At} \right|$$

Sendo n o tamanho do vetor de entrada, A_t o valor real no tempo t e F_t o valor previsto no tempo t.

Também utilizamos o seguinte método RMSE, apresentado no capítulo 2.14, o qual calcula a média de desvio da previsão com relação ao valor real. A seguinte fórmula representa o RMSE, Suas variáveis são as mesmas do algoritmo MAPE.

$$\sqrt{\frac{1}{n}\sum_{t=1}^{n}(At - Ft)^2}$$

Além dos métodos citados, podemos fazer algumas observações gráficas quanto aos resultados do modelo, estas observações indicam a tendência de alta ou de baixa da ação prevista, no capítulo 3.4 será mostrado mais sobre isso.

3.4 Resultados

Para realizar os testes foram escolhidas as principais ações negociadas na B3, cada uma das ações escolhidas representam um segmento do mercado, foram evitadas ações voltadas ao mesmo segmento para que não existam padrões de notícias que afetem um mesmo ramo. As ações escolhidas e seus segmentos são:

1. ABEV3 - Ambev, ramo de cervejaria.
2. AZUL4 - Azul, ramo de aviação.
3. B3SA3 - B3, ação da própria bolsa, com base no índice.
4. BRFS3 - BRF, ramo alimentício.
5. ITUB4 - Itaú, ramo bancário.
6. MGLU3 - Magazine Luiza, ramo de varejo.
7. PETR4 - Petrobrás, ramo de petróleo.
8. RENT3 - Localiza Hertz, ramo de aluguel de automóveis.
9. VALE3 - Vale, ramo de mineração.

Os dados históricos foram coletados no dia 24 de novembro de 2019 do site *Yahoo Finance*, portanto o conjunto de dados possui como última entrada os preços das ações até o dia 22 de novembro de 2019. Para que os resultados possam ser demonstrados aqui, os dados de teste serão extraídos do conjunto baixado e comparados com os valores previstos pelo algoritmo, portanto não haverá previsão para datas acima do dia 22 de novembro.

As imagens a seguir apresentam o RSME e MAPE gerados para os testes nos períodos *Diário*, *Curto*, *Médio* e *Longo.*

Ações	RMSE - Diario - 1 dia	RMSE - Curto - 3 dias	RMSE - Médio - 14 dias	RMSE - Longo - 22 dias
ABEV3	0,22	0,444	0,998	1,99
AZUL4	0,01	2,67	2,23	3,14
B3SA3	1,36	1,32	1,88	2,24
BRFS3	0,78	0,514	4,13	1,46
ITUB4	0,31	0,466	0,507	1,66
MGLU3	0,5	2,9	2,37	6,99
PETR4	0,17	0,573	1,19	1,91
RENT3	1,94	0,881	1,55	2,36
VALE3	0,81	1,1	3,26	2,4

Figura 25. Tabela RMSE das ações testadas. Fonte: Autor.

É interessante notar para o RMSE, que quanto mais para o futuro se deseja prever, maior o erro calculado, lembrando que no RMSE quanto mais próximo for de 0, melhor. Esse aumento do valor para períodos mais longos pode ser interpretado por fatores externos que possam ter ocorrido e influenciado no preço de algumas ações em algum momento dentro do intervalo calculado, ou o fato do HMM começar a considerar, no último caso, quase 50% dos dados utilizados para encontrar o dia mais semelhante foram dados gerados por ele mesmo, o qual pode fazer o modelo entrar em ascensão ou declínio constante.

Ações	MAPE - Diario - 1 dia	MAPE - Curto - 3 dias	MAPE - Médio - 14 dias	MAPE - Longo - 22 dias
ABEV3	0,498%	0,917%	9,140%	3,640%
AZUL4	3,280%	2,430%	4,960%	8,330%
B3SA3	2,030%	0,864%	6,950%	12,200%
BRFS3	1,280%	0,861%	4,810%	8,870%
ITUB4	1,000%	0,835%	4,210%	3,840%
MGLU3	1,490%	8,910%	8,280%	28,000%
PETR4	0,436%	0,838%	7,990%	3,270%
RENT3	5,310%	1,740%	5,120%	4,480%
VALE3	0,723%	5,210%	6,160%	7,360%

Figura 26. Tabela MAPE das ações testadas. Fonte: Autor.

Notamos no MAPE algo similar ao que acontece com o RMSE, ao longo do tempo previsto o HMM começa a se afastar do preço real e isso aumenta a sua taxa de erro, no caso do MAPE essa taxa é mostrada em porcentagem, o interessante aqui é notar que para um MAPE curto de 3 dias a taxa de erro é menor do que para o valor diário, são 5 as taxas de MAPE menores do que para 1 dia. Um fato que vale mencionar se deve a MGLU3 que aconteceu uma diferença grande nos períodos testados, isso pode ter sofrido influência da

divulgação dos resultados trimestrais que ocorreram no início do mês[8], pelo fato da grande alta ocorrida nos últimos dias dos dados de treino a tendência prevista foi de manter a alta, vide figura 32.

MAPE e RMSE podem variar conforme a projeção da ação utilizando os próprios valores gerados, dito isso as próximas figuras irão mostrar os gráficos de valores previstos comparados ao valor real da ação, podemos com base na análise técnica dos gráficos indicar ou não a tendência das ações.

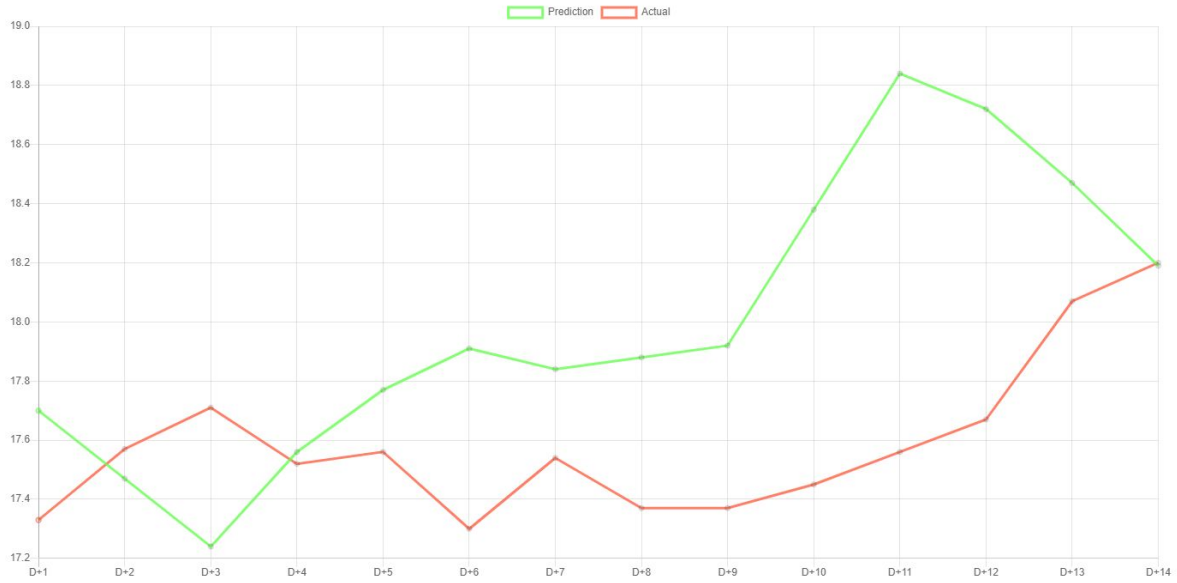

Figura 27. Gráfico de 14 dias para a ação ABEV3. Fonte: Autor.

As linhas representam o valor de uma ação dentro do período previsto, a verde representa a previsão e a vermelha o valor real da ação. É possível observar na Figura 27 uma leve tendência de alta que com o passar dos dias acaba acontecendo com as ações da Ambev.

8 https://www.infomoney.com.br/mercados/magazine-luiza-mglu3-lucra-r-136-mi-no-3o-trimestre-e-supera-a-melhor-das-projecoes/

Figura 28. Gráfico de 14 dias para a ação AZUL4. Fonte: Autor.

Observando o gráfico da figura 28 observamos dois momentos interessantes, no começo o HMM previu uma tendência de baixa nas ações seguidos de uma alta que ultrapassa o valor do primeiro dia, observando os valores reais observamos uma queda nos preços seguidos de uma forte alta que ultrapassa o valor do primeiro dia.

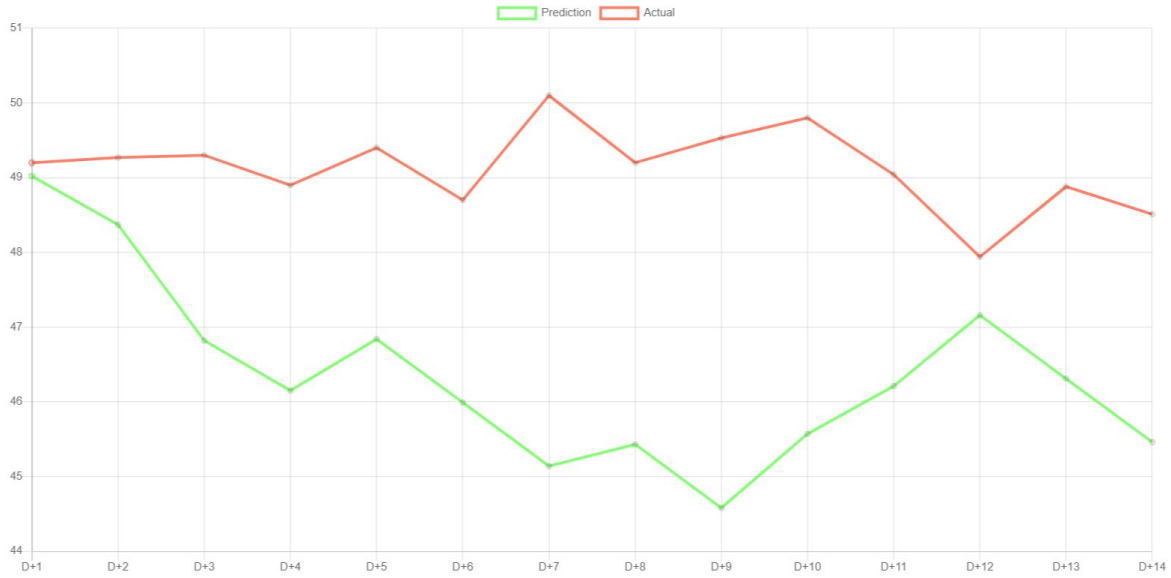

Figura 29. Gráfico de 14 dias para a ação B3SA3. Fonte: Autor

A ação da B3 mostrada na figura 29 acaba falhando na previsão e na tendência. Isso pode ter ocorrido devido ao fato dessa ação estar atrelada ao Índice Bovespa e sofrer influência de eventos externos de diversas ações.

Acima foram mostrados os três casos possíveis de ocorrer com a previsão do HMM, um acerto de tendência de alta e de baixa, e um caso de erro de previsão, a seguir as imagens apresentam o que ocorreu com as outras ações analisadas para o mesmo período de tempo (14 dias). É importante ressaltar que a maior taxa de acerto é para um período menor, mesmo para a tendência, porém por questões visuais e para que se possa ver mais informações sobre o que ocorre com a ação ao longo do tempo foi optado por mostrar um período maior, além de que para cada ação o número ideal de estados ocultos deve ser testado através da ferramenta, isso pode otimizar a previsão.

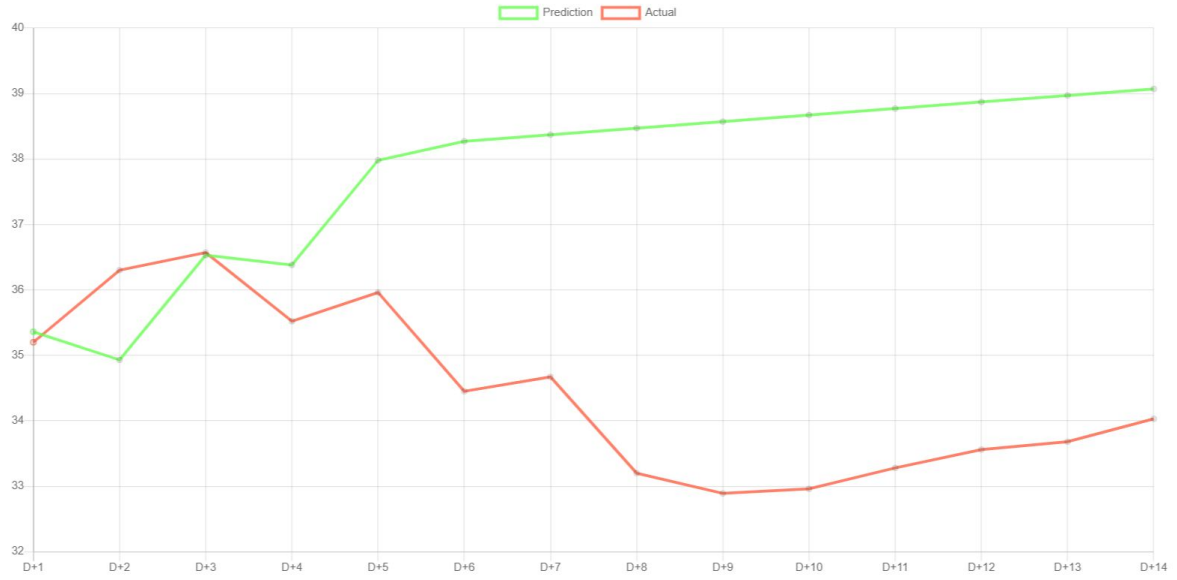

Figura 30. Gráfico de 14 dias para a ação BRFS3. Fonte: Autor.

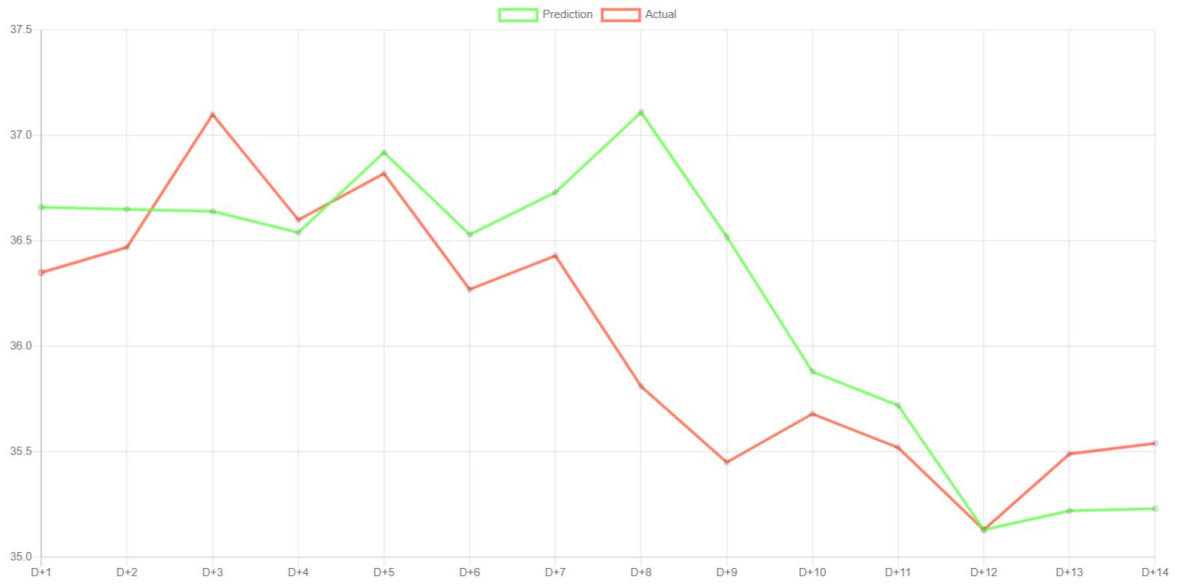

Figura 31. Gráfico de 14 dias para a ação ITUB4. Fonte: Autor.

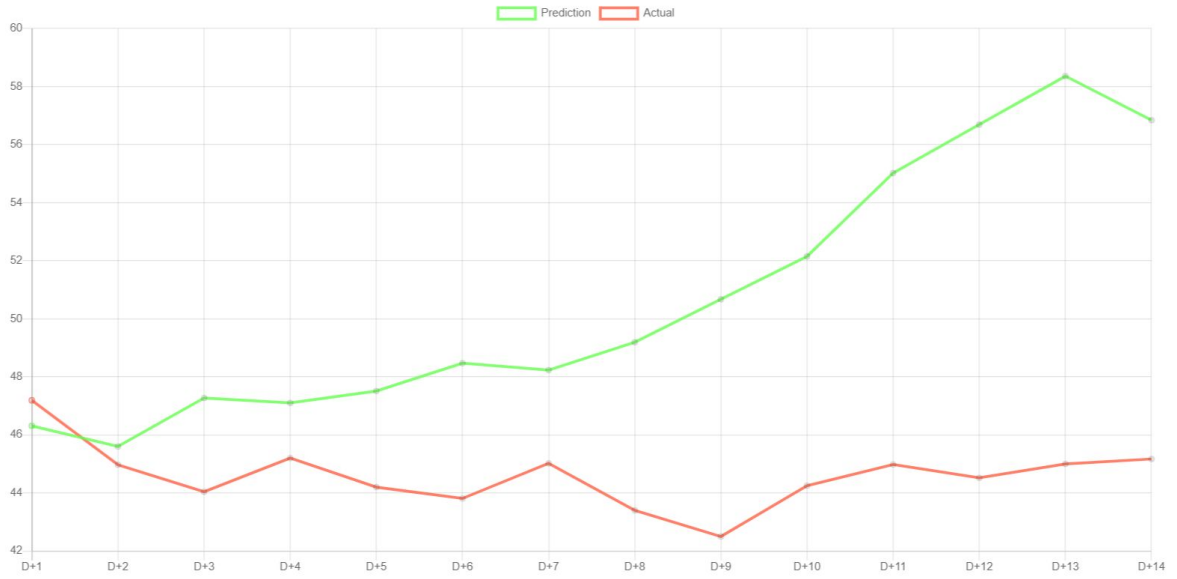

Figura 32. Gráfico de 14 dias para a ação MGLU3. Fonte: Autor.

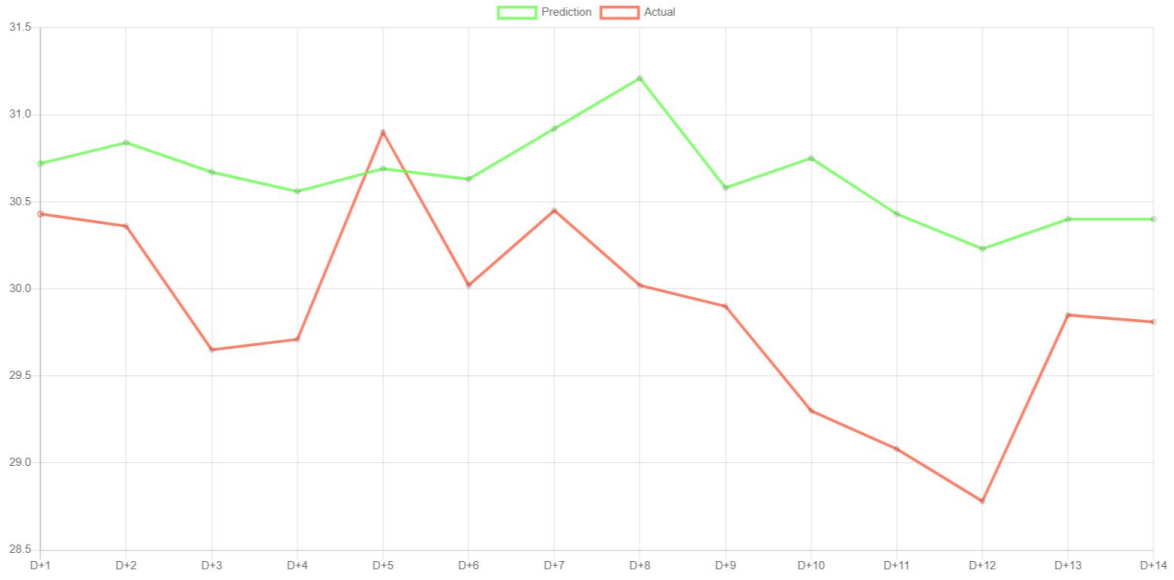

Figura 33. Gráfico de 14 dias para a ação PETR4. Fonte: Autor.

Figura 34. Gráfico de 14 dias para a ação RENT3. Fonte: Autor.

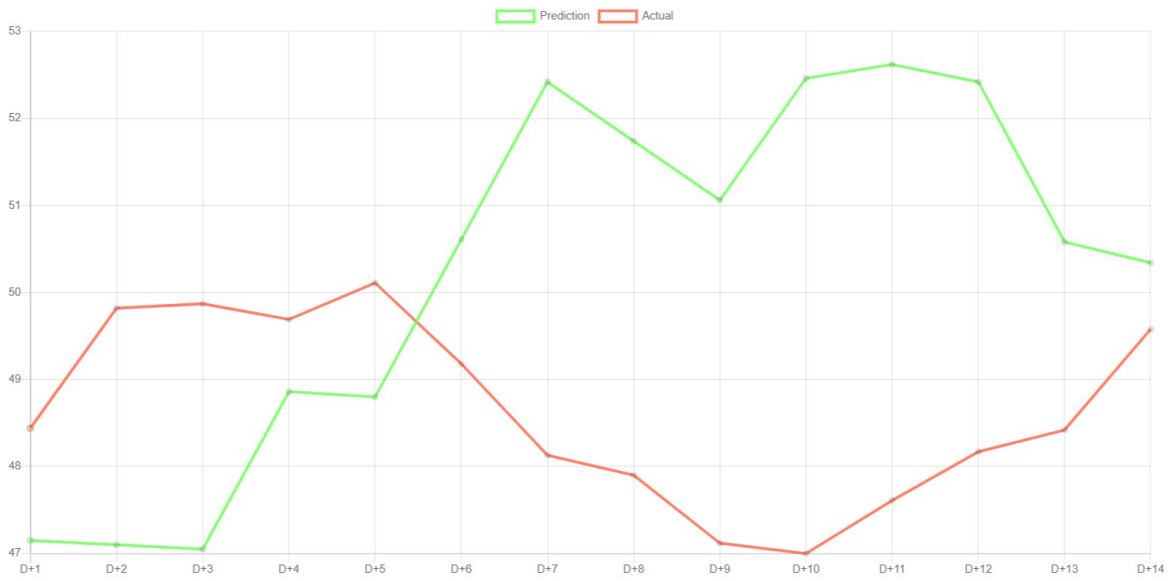

Figura 35. Gráfico de 14 dias para a ação VALE3. Fonte: Autor.

Para uma melhor otimização do algoritmo, o número de estados ocultos utilizados podem variar de ação para ação, assim como a quantidade de observações anteriores, as figuras de número 27 a 35 utilizaram 12 camadas ocultas e 50 dias anteriores de observações, a figura 36 e 37 mostram dois casos de previsão que foram otimizados trocando o total de estados ocultos, e/ou, o total de observações que o HMM utilizará.

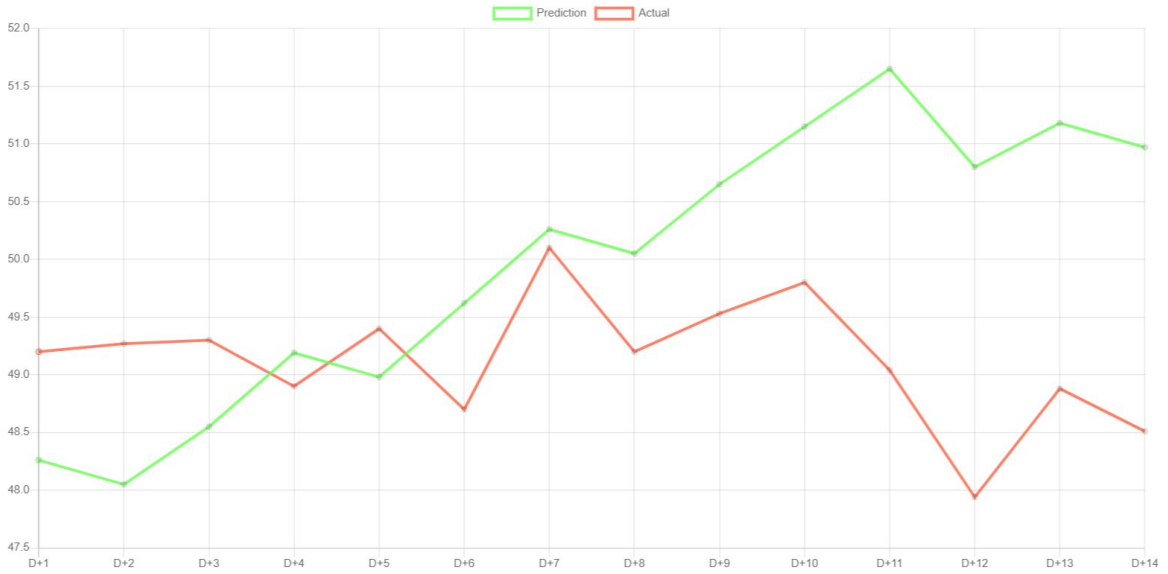

Figura 36. Gráfico de 14 dias para a ação B3SA3 utilizando 60 dias de observação. Fonte: Autor.

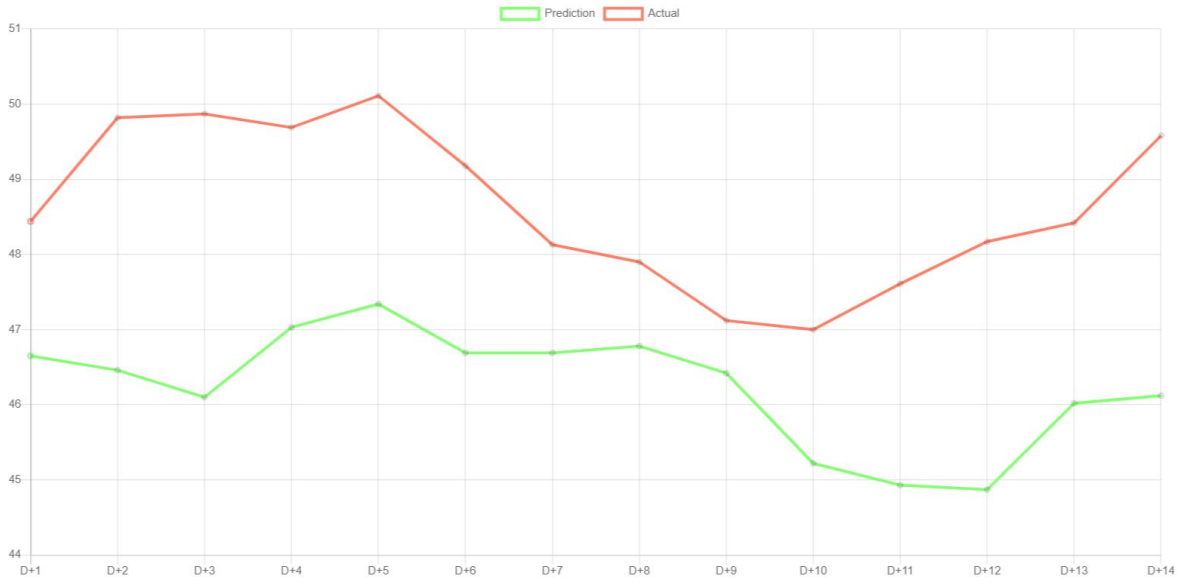

Figura 37. Gráfico de 14 dias para a ação VALE3 utilizando 100 dias de observação.

Fonte: Autor.

Como podemos observar nas figuras 36 e 37, após alguns ajustes feitos nos valores passados ao algoritmo a previsão passa a acompanhar com mais precisão o movimento realizado pelas ações VALE3 e B3SA3, comparando o movimento realizado por elas após o ajuste, e antes do ajuste, há de se notar uma melhora visto que a linha de previsão segue um movimento parecido ao da linha do valor real.

4 Conclusão

Esse trabalho mostra que é possível realizar uma redução nos riscos para um investidor sem muito conhecimento de mercado auxiliando-o por meio de algoritmos para a tomada de decisão.

O HMM se mostra uma ferramenta interessante para realizar previsão de preços das ações, porém sua eficácia é maior para previsões de curto prazo. No momento que se tenta prever muitos dias à frente algumas variáveis externas ou mesmo o próprio modelo podem fazer com que a previsão indique uma tendência que não se concretiza, porém com prazos mais curtos o algoritmo se mostra assertivo na tendência de variação do preço das ações desde que não haja grandes interferências de fatores externos ao mercado.

É possível também realizar ajustes por ação que se deseja prever já que seu conjunto de dados varia de ação para ação, principalmente pelo fato de algumas ações possuírem um histórico mais antigo devido a sua data de IPO. Com os ajustes certos e realizando por ativo é possível afirmar que o algoritmo de Modelo Oculto de Markov obtém um resultado satisfatório e possível de ser aplicado no investimento de mercado de capitais.

Por fim, podemos dizer que os resultados aqui mostrados tornam o HMM relevante para as pessoas que desejam colocar seu dinheiro em aplicações que oferecem um certo risco e que é possível sim minimizá-los ao aportar seu patrimônio no mercado financeiro de capitais.

4.1 Trabalhos Futuros

Durante o desenvolvimento do trabalho diversas idéias surgiram, porém no momento nem todas foram possíveis de serem abordadas já que teríamos aumento no escopo da pesquisa. Entre as principais estão:

- Realizar uma comparação entre os algoritmos HMM e SVM de forma que possa ser comparados os resultados para observar qual possui a maior eficácia na previsão do preço das ações.
- Buscar maneiras de melhorar a acurácia no preço dos dias seguintes caso haja fatores externos, utilizando algoritmos de avaliação de notícias.
- Poder avaliar dados das empresas de forma fundamentalista e combinar a tendência com o previsto pelo HMM.

Referências

ADHIKARI, Ratnadip; AGRAWAL, R. K. **An Introductory Study on Time Series Modeling and Forecasting**. Cornell University, 2013. Disponível em: https://arxiv.org/ftp/arxiv/papers/1302/1302.6613.pdf. Acesso em: 27 abr. 2019.

ARES, Iago Roi Pérez. **Influência das novas tecnologias na gestão das finanças pessoais: Desenho de um Robo-advisor**. 2016. Dissertação (Mestre em Informática Aplicada à Sociedade da Informação e do Conhecimento) - Instituto Universitário de Lisboa, [S. l.], 2016. Disponível em: https://repositorio.iscte-iul.pt/bitstream/10071/12744/1/2016-11-02%20Iago%20PerezDisserta%C3%A7%C3%A3o_MIASIC%20n%C2%BA69870.pdf. Acesso em: 24 abr. 2019.

ARMSTRONG, J. Scott; COLLOPY, Fred. **Error Measures For Generalizing About Forecasting Methods: Empirical Comparisons**. 1992. Disponível em: http://faculty.weatherhead.case.edu/Fred-Collopy/researchArticles/ErrorMeasures.pdf. Acesso em 24 Nov. 2019.

BARBOSA, Dimas Daniel da Silva. **Previsão de demanda em um comércio de móveis e eletrodomésticos**. 2010. Dissertação (Trabalho de conclusão de curso) - Universidade Federal de Juiz de Fora. Disponível em: http://www.ufjf.br/engenhariadeproducao/files/2014/09/2010_3_Dimas.pdf. Acesso em 21 Nov. 2019.

BROWNLEE, Jason. **Learning Vector Quantization for Machine Learning**. [S. l.], 18 abr. 2018. Disponível em: https://machinelearningmastery.com/learning-vector-quantization-for-machine-learning/. Acesso em: 2 abr. 2019.

CAPARRINI, Fernando Sancho. **Self Organizing Maps (SOM) in NetLogo**. [S. l.], 16 dez. 2017. Disponível em: http://www.cs.us.es/~fsancho/?e=136. Acesso em: 19 mai. 2019.

CASTRO, Humberto Vieira de. **Predição de preços de ações através de técnicas de pré-processamento de dados aplicadas a Máquina de Vetores de Suporte**. In: TRABALHO DE CONCLUSÃO DE CURSO, 2018, Centro Universitário SENAC. **Monografia** [...]. São Paulo: [s. n.], 2018

CHAVES , Daniel Augusto Tucci. **Análise Técnica E Fundamentalista: Divergências, Similaridades E Complementariedades**. 2004. Monografia (Bacharel em Administração) - Universidade De São Paulo, São Paulo, 2004. Disponível em: http://bit.do/eRTZZ. Acesso em: 8 mai. 2019.

COELHO, Endrigo. **Como funciona a bolsa de valores?**. [S. l.], 4 jul. 2018. Disponível em: http://mundoestranho.abril.com.br/materia/como-funciona-a-bolsa-de-valores. Acesso em: 18 mai. 2019.

CULTURA MIX. **História Da Bolsa De Valores Do Brasil**. [S. l.], 2013. Disponível em: http://www.culturamix.com/dinheiro/historia-da-bolsa-de-valores-do-brasil/. Acesso em: 12 abr. 2019.

DEBASTIANI, Carlos Alberto. **Análise Técnica de Ações: Identificando oportunidades de compra e venda**. São Paulo: Novatec, 2008. Disponível em: http://bit.do/eRZA8. Acesso em: 14 mai. 2019.

DORMEHL, Luke. **What is an artificial neural network?**. [S. l.], 2019. Disponível em: https://www.digitaltrends.com/cool-tech/what-is-an-artificial-neural-network/. Acesso em 05 mai. 2019.

Entendendo o Mercado de Valores Mobiliários. Disponível em: http://www.investidor.gov.br/menu/primeiros_passos/Entendendo_mercado_valores.html. Acesso em 08 mai. 2019.

ESPINDOLA, Luciana da Silveira. **Um Estudo sobre Modelos Ocultos de Markov HMM - Hidden Markov Model**. Porto Alegre, p. 1-33, 2009. Disponível em: https://www.inf.pucrs.br/peg/pub/tr/TI1_Luciana.pdf. Acesso em: 10 set. 2019.

FERREIRA, Caroline Agostinho; JUNIOR, Pedro Dos Santos Portugal; SILVA, Sheldon William; PORTUGAL, Nilton Dos Santos. Novas evoluções do mercado de crédito: Uma análise sobre as Fintechs. **VI SINGEP**: Simpósio internacional de Gestão de Projetos, Inovação e Sustentabilidade, São Paulo, 14 nov. 2017. Disponível em: https://singep.org.br/6singep/resultado/102.pdf. Acesso em: 25 ago. 2019.

GHAHRAMANI, Zoubin. **A Introduction to Hidden Markov Model and Bayesian Networks**. International Journal of Pattern Recognition and Artificial Intelligence, Londres, Inglaterra, p. 9-42, 2001.

IPO - **O que é e como funciona?** [S. l]. Disponível em: https://www.tororadar.com.br/investimento/bovespa/ipo-o-que-e-como-funciona. Acesso em 08 mai. 2019.

JURAFSKY, Daniel; MARTIN, James H. **Speech and Language Processing: An introduction to natural language processing**. 2007. Disponível em: http://santini.se/teaching/ml/2014/JurafskyMartinSpeechAndLanguageProcessing2ed_draft%202007.pdf. Acesso em 10 set. 2019.

KANG, Eugine. **Hidden Markov Model**. 31 ago. 2017. Disponível em: https://medium.com/@kangeugine/hidden-markov-model-7681c22f5b9. Acesso em: 14 mai. 2019

KUINCHTNER, Daniela; MADALOZZO, Guilherme Afonso. **Predição do Mercado de Ações Usando Hidden Markov Model**. 2018. Dissertação (Bacharelado de Ciência da Computação) - Universidade de Passo Fundo, Passo Fundo, RS, 2018.

KUTLU, Birgul & Prof, Asst; ÖZTURAN, Meltem; Prof, Assoc & BADUR, Bertan. 2019. **Stock Market Prediction Using Artificial Neural Networks**.

LORENA, Ana Carolina; CARVALHO, André C. P. L. F. **Uma Introdução às Support Vector Machines**. 2007. Disponível em: https://www.seer.ufrgs.br/rita/article/view/rita_v14_n2_p43-67/3543. Acesso em 19 mai. 2019.

MARQUES, Fabricio. **Tempo de Colher**. Pesquisa FAPESP, São Paulo, 273, p. 32-37, nov. 2018.

MIZUNO, Hirotaka; Kosaka, Michitaka; Yajima, Hiroshi; Komoda, Norihisa. (1998). **Application Of Neural Network To Technical Analysis Of Stock Market Prediction**. 7.

MOREIRA, Catarina; CALADO, Pável; MARTINS, Bruno. **Learning to Rank Academic Experts in the DBLP Dataset**. 2013. Artigo (Superior) - Instituto de Engenharia de Sistemas e Computadores - Investigação e Desenvolvimento, Porto Salvo, Portugal, 2013.

NAVLANI, Avnash. **KNN Classification using Scikit-learn**. [S. l.], 2 ago. 2018. Disponível em: https://www.datacamp.com/community/tutorials/k-nearest-neighbor-classification-scikit-learn. Acesso em 12 mai. 2019.

PHUA, P.K.H. & Ming, DH & Lin, WD. (2001). **Neural network with genetically evolved algorithms for stocks prediction.** Asia Pacific Journal of Operational Research. 18. 103-107.

RAMOS, JORGE LUIS CAVALCANTI. **Uma abordagem preditiva da evasão na educação a distância a partir dos construtos da distância transacional.** 2016. Artigo (Superior) - Universidade Federal de Pernambuco, Recife, Pernambuco, 2016.

RAY, Sunil. **Understanding Support Vector Machine algorithm from examples**. 2017. Disponível em:

https://www.analyticsvidhya.com/blog/2017/09/understaing-support-vector-machine-example-code/. Acesso em: 19 mai. 2019.

REIS, Tiago. **Conheça a história da Bolsa de Valores do Rio de Janeiro**. [S. l.], 17 jan. 2019. Disponível em: https://www.sunoresearch.com.br/artigos/bolsa-valores-rio-de-janeiro/. Acesso em: 17 abr. 2019.

SILVA, Rodrigo Borsatto Sommer. **Abordagem histórica da bolsa de valores.** 2016. Artigo (Superior) - Centro Universitário Leonardo Da Vinci, Indaial, Santa Catarina, 2016. Disponível em: https://publicacao.uniasselvi.com.br/index.php/GESTAO_EaD/article/view/1590/719. Acesso em: 23 abr. 2019.

SHIMAKURA, Silvia. **Regressão Linear**. 2005. UFPR. Disponível em: http://www.leg.ufpr.br/~silvia/CE701/node81.html. Acesso em: 01 mai. 2019.

SPRITZER, M.; SPRITZER, I. **A Bolsa No Bolso** - Fundamentos Para Investimentos Em Ações. 1. ed. [S.l.]: FGV, 2013.

STAMP, Mark. **A Revealing Introduction to Hidden Markov Models.** 2018. Artigo (Superior) - San Jose State University, San Jose, California, 2018.

TEJA DARBHA, Ravi.; JAIN, Ayush. & MEHTA, Prateek. **Stock Forecasting using Hidden Markov Models**. Boston Univesity, 2018. Disponível em: https://github.com/ayushjain1594/Stock-Forecasting. Acesso em 11 set. 2019.

XPINVESTIMENTOS. **O que são Ações**. Disponível em: https://www.xpi.com.br/investimentos/acoes/o-que-sao-acoes/. Acesso em 02 mai. 2019.